

机器学习与数据挖掘—作业二

evaluation metrics

学　　号: 23336179

姓　　名: 马福泉

专　　业: 计算机科学与技术

课 程 教 师: 梁上松

起 始 日 期: 2025年9月28日

结 束 日 期: 2025年9月28日

实 验 地 点: c206

目录

1 练习1: 基于排名的评估指标，MAP@K，MRR@K **2**
1.1 计算过程和结果 4

2 练习2: 基于排名的评估指标，Precision@K，Recall@K，NDCG@K **5**

3 练习3: 精度-召回率曲线 **8**

4 练习4: 其他评估指标 **8**
4.1 分类任务评估指标 8
4.1.1 AUC-ROC (Area Under ROC Curve) 8
4.1.2 AUC-PR (Area Under PR Curve) 9
4.1.3 F-beta Score 9
4.2 回归任务评估指标 9
4.2.1 RMSE (Root Mean Square Error) 9
4.2.2 MAE (Mean Absolute Error) 9
4.2.3 MAPE (Mean Absolute Percentage Error) 9
4.3 聚类任务评估指标 10
4.3.1 Silhouette Score 10
4.3.2 Adjusted Rand Index (ARI) 10
4.3.3 Davies-Bouldin Index 10
4.4 推荐系统评估指标 10
4.4.1 Hit Rate@K 10
4.4.2 Coverage 10
4.4.3 Novelty 11
4.5 信息检索特定指标 11
4.5.1 ERR (Expected Reciprocal Rank) 11
4.5.2 bpref 11
4.6 总结 11

1 练习1: 基于排名的评估指标，MAP@K，MRR@K

假设您有三个查询，系统针对这三个查询的排名结果如下：

排名1（响应查询#1）：d1, d2, d3, d4, d5, d6, d7, d8, d9, d10。这里只有d1, d3, d4, d6, d7和d10是相关的（相关性是二元的，即相关为1，不相关为0）。

排名2（响应查询#2）：d3, d8, d7, d1, d2, d4, d5, d9, d10, d6。这里只有d8和d9是相关的。

排名3（响应查询#3）：d7, d6, d5, d3, d2, d1, d9, d10, d4, d8。这里只有d5, d9和d8是相关的。

请回答以下问题：

(a) 计算这些指标的分数：每个查询的AP@5（平均精度@5）、AP@10；每个查询的RR@5（倒数排名分数@5）、RR@10。

(b) 计算这些指标的分数：该系统的MAP@5（平均精度均值@5）、MAP@10、MRR@5（平均倒数排名分数@5）、MRR@10。

1.1 计算过程和结果

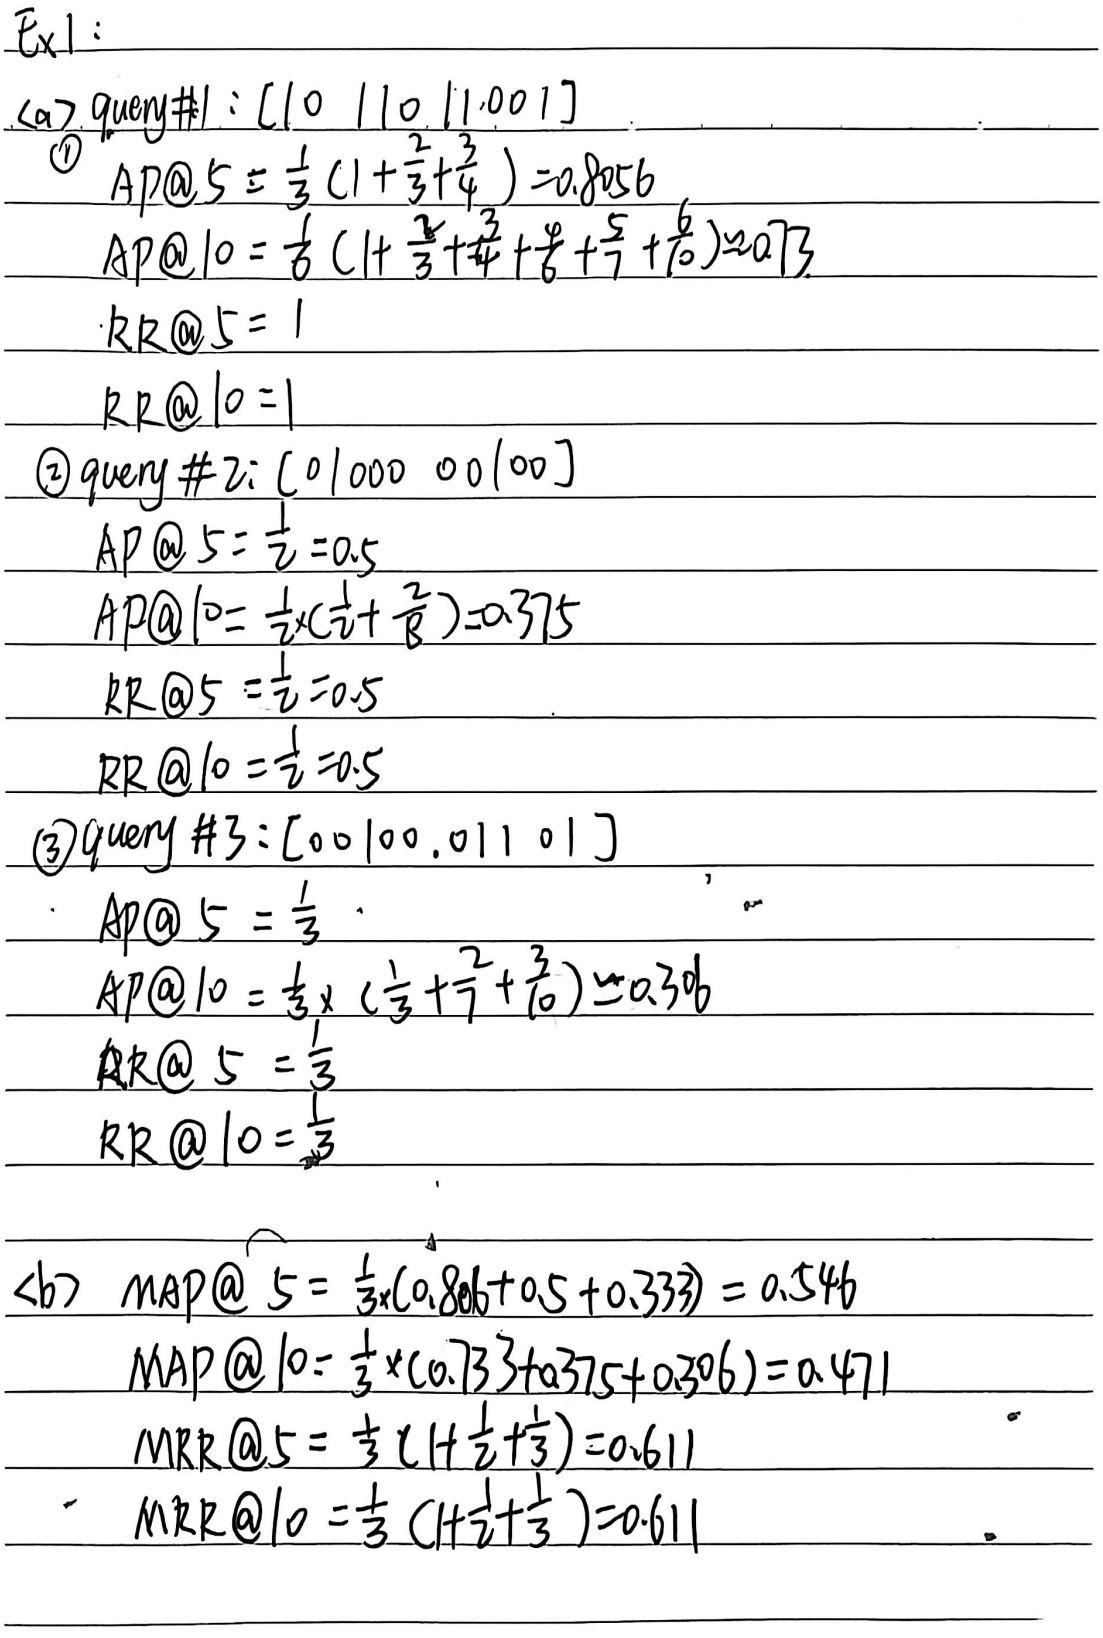


图 1: 练习1计算过程

2 练习2: 基于排名的评估指标，Precision@K，Recall@K，NDCG@K

假设给定查询的以下排名（仅显示结果1-10）；见表1。”rank”列给出了文档的排名。”docID”列给出了与该排名关联的文档ID。”graded relevance”列给出了与文档相关的相关性等级（4=完美，3=优秀，2=良好，1=一般，0=差）。”binary relevance”列提供了两个相关性值（1=相关，0=不相关）。假设相关性等级为”一般”或更好的任何内容都是相关的，相关性等级为”差”的任何内容都是不相关的。

同时，假设此查询只有7个相关性等级为一般或更好的文档。这些文档都在给定排名的前10名中。

请回答以下问题。P@K（精度@K）、R@K（召回率@K）和平均精度（AP）假设二元相关性。对于这些指标，请使用”binary relevance”列。DCG和NDCG假设分级相关性。对于这些指标，请使用”graded relevance”列。

rank	docID	graded relevance	binary relevance
1	51	4	1
2	501	1	1
3	21	0	0
4	75	3	1
5	321	4	1
6	38	1	1
7	521	0	0
8	412	1	1
9	331	0	0
10	101	2	1

图 2: 表1 系统响应查询的前10名排名结果。

(a) 计算P@5和P@10。

(b) 计算R@5和R@10。

(c) 提供一个使P@5最大化的此查询排名示例。

(d) 提供一个使P@10最大化的此查询排名示例。

(e) 提供一个使R@5最大化的此查询排名示例。

(f) 提供一个使R@10最大化的此查询排名示例。

(g) 您有理由相信此系统的用户将希望检查给定查询的每个相关文档。换句话说，您有理由相信用户希望完美的召回率。您希望基于P@K进行评估。在这种情况下，是否有设置K值的查询特定方法特别合适？是什么？（提示：有一个叫做R-Precision的评估指标，我们在讲座中没有讨论。您的答案应该与R-Precision相关。Wikipedia/Google可能会有帮助。）

(h) 计算平均精度（AP）。AP和MAP（平均精度均值）之间有什么区别？

(i) 提供一个使平均精度（AP）最大化的此查询排名示例。

(j) 计算DCG5（即第5位的折扣累计增益）。

(k) NDCG5由以下公式给出：

$$NDCG5 = \frac{DCG5}{IDCG5}$$

其中IDCG5是与此查询相关的理想前5名排名的DCG5。计算NDCG5需要三个步骤：

(i) 与此查询相关的理想前5名排名是什么（注意查询有2个完美文档，1个优秀文档，1个良好文档，3个一般文档，其余文档都是差的）？

(ii) IDCG5是与理想排名相关的DCG5。计算IDCG5。（提示：为您在部分(i)中提出的排名计算DCG5。）

(iii) 使用上面的公式计算NDCG5。

(l) 是否还有其他评估指标可用于评估表中排名的性能？这些指标获得的评估分数是多少？

Ex2：

(a) P@5 = $\frac{4}{5}$ = 0.8　　P@10 = $\frac{7}{10}$ = 0.7

(b) R@5 = $\frac{4}{7}$ ≈ 0.571　　R@10 = $\frac{7}{7}$ = 1

(c) 最大化P@5：51, 501, 75, 321, 38, 21, 521, 101, 412, 331

(d) 最大化P@10：51, 501, 75, 321, 38, 412, 101, 21, 521, 331

(e) 最大化R@5：51, 501, 75, 321, 38, 412 101, 21, 521, 331

(f) 最大化R@10：51, 501, 75 321, 38, 412, 101, 21, 521, 331

(g) R-Precision：设置k=7

此时R-Precision = P@k = P@7

此时可以考虑所有相关文档的同时，也可避免过多检索，降低准确度。

(h) AP = $\frac{1}{7}$ × (1 + $\frac{2}{3}$ + $\frac{3}{5}$ + $\frac{4}{8}$ + $\frac{5}{10}$)

= 0.843

AP是单个查询的平均精度

MAP是多个查询的AP的平均值.

(i) 最大化AP：将相关文档排前面：AP(1+1+1+1+1+1+1) × $\frac{1}{7}$ = 1

51, 501, 75, 321, 38, 412, 101, 21, 521, 331.

(j) DCG5 = 4 + $\frac{1}{\log_2 2}$ + $\frac{0}{\log_2 3}$ + $\frac{3}{\log_2 4}$ + $\frac{4}{\log_2 5}$ = 4 + 1 + 0 + 1.5 + 1.79 = 8.29

(k) (i) 5查询相关的理想前5名排名为

51(4), 501(4), 75(3), 101(2), 501(1)

(ii) IDCG5 = 4 + $\frac{4}{\log_2 2}$ + $\frac{3}{\log_2 3}$ + $\frac{2}{\log_2 4}$ + $\frac{1}{\log_2 5}$ = 4 + 4 + 1.58 + 1 + 0.68 = 11.

(iii) NDCG5 = $\frac{DCG5}{IDCG5}$ = $\frac{8.29}{11.26}$ = 0.74

(l) 其他评估指标：F1-score, MRR, ERR等.

图 3: 练习2计算过程

3 练习3: 精度-召回率曲线

精度-召回率（PR）曲线将精度表示为召回率的函数。通常，为评估集中的每个查询计算PR曲线，然后求平均。为简单起见，此问题的目标是为单个查询绘制PR曲线。绘制与练习2中排名相关的PR曲线（相同查询，相同结果）。（提示：您的PR曲线应该随着召回率水平的增加而始终下降。）

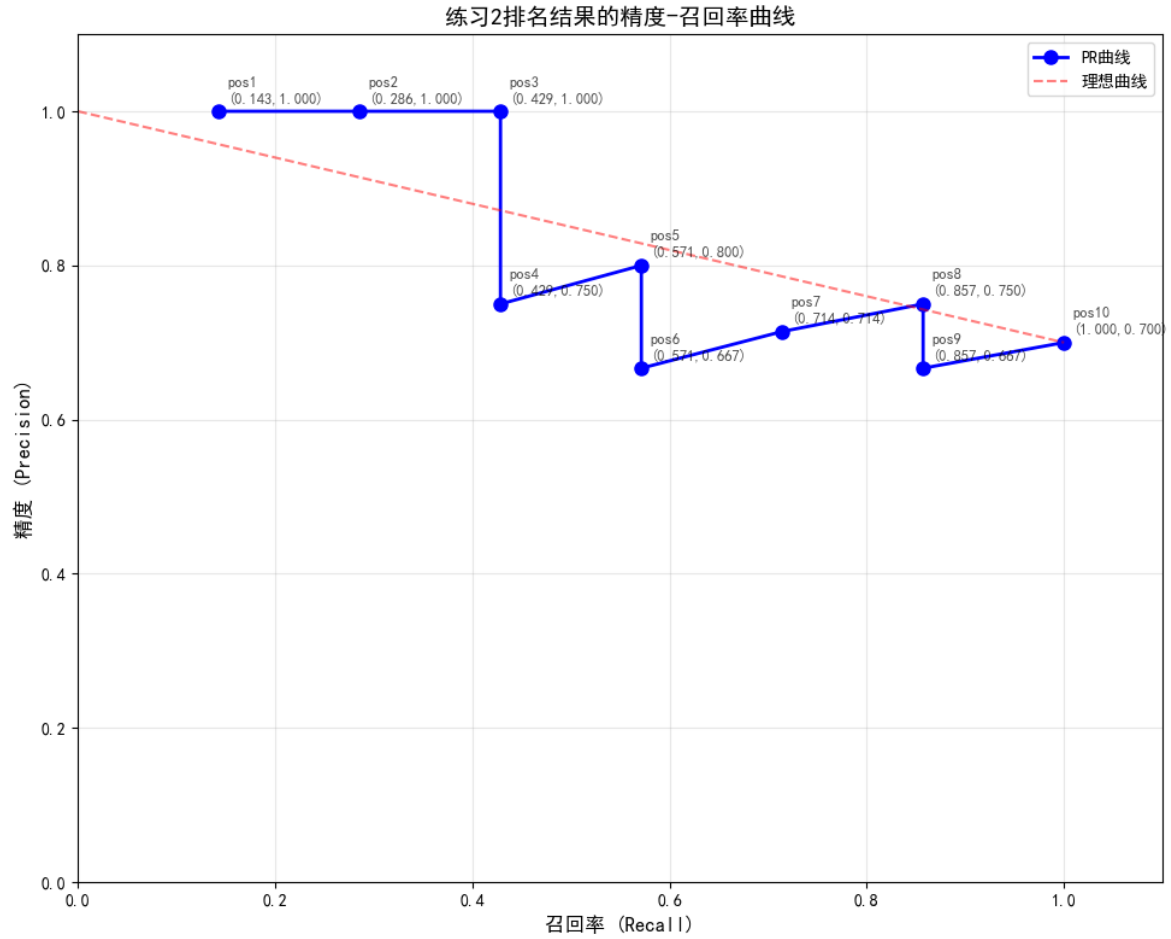


图 4: 练习3结果

4 练习4: 其他评估指标

除了我们在讲座幻灯片中提到的指标外，是否还有其他评估指标可用于评估数据挖掘中特定任务的性能？这些任务是什么？如何计算这些评估指标？（提示：使用互联网查找您的答案。）

4.1 分类任务评估指标

4.1.1 AUC-ROC (Area Under ROC Curve)

任务： 二分类问题的性能评估

计算方法： ROC曲线下的面积。ROC曲线以假正例率(False Positive Rate)为x轴，真正例

率(True Positive Rate)为y轴绘制。

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}} \tag{1}$$

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}} \tag{2}$$

AUC-ROC值越接近1，分类器性能越好。

4.1.2 AUC-PR (Area Under PR Curve)

任务： 不平衡数据集的分类问题评估

计算方法： 精度-召回率曲线下的面积。相比AUC-ROC，AUC-PR在数据不平衡时更能反映模型的真实性能。

4.1.3 F-beta Score

任务： 需要在精度和召回率间进行加权的分类任务

计算方法：

$$F_\beta = (1 + \beta^2) \times \frac{\text{precision} \times \text{recall}}{\beta^2 \times \text{precision} + \text{recall}}$$

其中$\beta > 1$更重视召回率，$\beta < 1$更重视精度。F_1是$\beta = 1$的特殊情况。

4.2 回归任务评估指标

4.2.1 RMSE (Root Mean Square Error)

任务： 回归预测任务

计算方法：

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_{\text{true},i} - y_{\text{pred},i})^2}$$

RMSE对大误差更敏感，适用于希望严格控制大误差的场景。

4.2.2 MAE (Mean Absolute Error)

任务： 回归预测任务

计算方法：

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_{\text{true},i} - y_{\text{pred},i}|$$

MAE对异常值不敏感，提供误差的平均大小。

4.2.3 MAPE (Mean Absolute Percentage Error)

任务： 需要相对误差评估的回归任务

计算方法：

$$\text{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_{\text{true},i} - y_{\text{pred},i}}{y_{\text{true},i}}\right| \times 100\%$$

4.3 聚类任务评估指标

4.3.1 Silhouette Score

任务： 无监督聚类质量评估

计算方法： 对于每个样本i，计算：

$$a(i) = \text{样本i与同簇其他样本的平均距离} \tag{3}$$

$$b(i) = \text{样本i与最近邻簇样本的平均距离} \tag{4}$$

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \tag{5}$$

轮廓系数为所有样本$s(i)$的平均值，取值范围[-1,1]，越接近1表示聚类效果越好。

4.3.2 Adjusted Rand Index (ARI)

任务： 有真实标签时的聚类结果评估

计算方法： 基于混淆矩阵，调整了随机分类的影响：

$$\text{ARI} = \frac{\text{RI} - \text{Expected RI}}{\max(\text{RI}) - \text{Expected RI}}$$

取值范围[-1,1]，1表示完全匹配，0表示随机分类水平。

4.3.3 Davies-Bouldin Index

任务： 聚类紧密性和分离性评估

计算方法：

$$\text{DBI} = \frac{1}{k}\sum_{i=1}^{k}\max_{j\neq i}\left(\frac{\sigma_i + \sigma_j}{d(c_i, c_j)}\right)$$

其中σ_i是簇i的平均内部距离，$d(c_i, c_j)$是簇中心距离。值越小表示聚类效果越好。

4.4 推荐系统评估指标

4.4.1 Hit Rate@K

任务： 推荐系统命中率评估

计算方法：

$$\text{Hit Rate@K} = \frac{\text{前K个推荐中包含相关物品的用户数}}{\text{总用户数}}$$

4.4.2 Coverage

任务： 推荐系统多样性评估

计算方法：

$$\text{Coverage} = \frac{\text{被推荐的不同物品数量}}{\text{总物品数量}}$$

高覆盖率表示推荐系统能够推荐更多样化的物品。

4.4.3 Novelty

任务： 推荐新颖性评估

计算方法：

$$\text{Novelty} = -\frac{1}{|R|}\sum_{i\in R}\log_2 P(i)$$

其中$P(i)$是物品i在全体用户中的流行度，新颖性越高表示推荐了越多小众物品。

4.5 信息检索特定指标

4.5.1 ERR (Expected Reciprocal Rank)

任务： 考虑用户满意度的排序评估

计算方法：

$$\text{ERR} = \sum_{r=1}^{n}\frac{1}{r}\prod_{i=1}^{r-1}(1-R_i)\times R_r$$

其中R_i是位置i处文档的相关性概率。

4.5.2 bpref

任务： 不完整相关性判断的检索评估

计算方法：

$$\text{bpref} = \frac{1}{R}\sum_{r}\left(1-\frac{|\text{不相关文档排在相关文档r前}|}{R}\right)$$

适用于相关性判断不完整的情况。

4.6 总结

这些评估指标针对不同的数据挖掘任务和应用场景，能够更准确地评估模型在特定条件下的性能表现。选择合适的评估指标需要考虑任务类型、数据特征、业务需求等多个因素。在实际应用中，通常需要结合多个指标来全面评估模型性能。