以下是针对“基础与评估的学习”部分的详细讲解。我将基于您提供的课件内容（文档1: Introduction.ppt、文档2: data.pptx、文档3: Cross Validation.ppt、文档4: retrieval-evaluation.ppt）进行翻译和整理，重点讲解基础概念和评估方法。讲解会覆盖定义、重难点、举例说明，并避免插入图片，只描述图片的大致位置和内容。结构分为四个部分：机器学习与数据挖掘基础、数据预处理与特征工程、模型评估方法、检索系统评估指标。每个部分都会详细展开，确保内容基础且易于理解。

一、机器学习与数据挖掘基础（基于文档1: Introduction.ppt）

这部分是课程介绍，定义了机器学习（ML）和数据挖掘（DM）的基本概念、重要性及应用场景。作为选修课，考察重点在于理解概念而非复杂计算。

1. 数据挖掘与机器学习的定义

- **数据挖掘（Data Mining）**：从大型数据集中发现未知或新模式的流程，涉及统计学和人工智能方法。例如，从销售数据中找出频繁购买的商品组合。
- **机器学习（Machine Learning）**：计算机算法通过经验自动改进的学科，是人工智能的子集。算法基于训练数据构建模型，用于预测或决策，而无需显式编程。例如，垃圾邮件过滤器通过历史邮件学习分类规则。

重难点：

- 区别：数据挖掘更注重从数据中“发现”模式（如关联规则），而机器学习更注重“学习”模型以进行预测（如分类）。但两者常重叠，例如聚类既属于数据挖掘也属于无监督学习。
- 何时使用机器学习？当人类专家不存在（如火星导航）、人类无法解释专业知识（如语音识别）、需定制模型（如个性化医疗）或数据量巨大（如基因组学）时。

举例：

- 手写数字识别（如识别数字“2”）：人类难以明确描述所有特征，但ML算法可以通过大量样本学习模式。
- 课件中有一张图片展示了手写数字的例子（位于文档1第15页附近），用来说明ML任务的复杂性。

2. 数据挖掘的任务

- **预测性任务**：用变量预测未知或未来值，如分类（预测类别）和回归（预测连续值）。
- **描述性任务**：发现可解释的模式，如聚类（分组相似对象）和关联规则（如购物篮分析）。
- **常见任务列表**：分类、聚类、关联规则发现、异常检测等。

重难点：

- 分类与聚类的区别：分类有标签（监督学习），聚类无标签（无监督学习）。例如，信用评分是分类（预测“是否可信”），而客户细分是聚类（自动分组）。
- 课件中有一张表格展示了分类任务的例子（位于文档1第27-28页），用信用数据说明如何构建预测模型。

3. 为什么数据挖掘重要？

- **商业视角**：大数据时代，数据挖掘能提供定制化服务（如亚马逊推荐系统）。
- **科学视角**：帮助科学家分析海量数据（如卫星图像分析），形成假设。
- **社会价值**：改善医疗、气候变化预测等。

举例：

- 社区问答、交通模式、传感器网络等应用图片（位于文档1第5-6页），展示了数据挖掘的广泛应用。

二、数据预处理与特征工程（基于文档2: data.pptx）

数据预处理是机器学习的前提，涉及数据清洗、转换和特征处理，确保数据质量。这部分概念多，需理解属性类型和相似性度量。

1. 数据属性与类型

- **属性（Attribute）**：对象的特性，如身高、温度。也称为变量、特征或维度。
- **属性类型**：
- **标称型（Nominal）**：仅区分类别，如邮政编码、性别。运算：相等与否（=, ≠）。
- **序数型（Ordinal）**：有顺序，如评级（好、更好、最佳）。运算：比较（<, >）。
- **区间型（Interval）**：差值有意义，如日期、温度（摄氏度）。运算：加减。
- **比率型（Ratio）**：比值有意义，如长度、温度（开尔文）。运算：乘除。

重难点：

- 区分类型的关键是支持的运算：标称型只支持相等，比率型支持所有运算。错误处理类型会导致分析无效，如对邮政编码计算平均值无意义。
- 课件中有一张表格总结了属性类型（位于文档2第8页），列出了运算和例子。

举例：

- 身高测量：如果用英尺和米，单位不同但属比率型；而ID号码是标称型，不能排序。

2. 数据质量问题

- **噪声（Noise）**：数据中的随机误差，如传感器读数偏差。课件中有一张正弦波加噪声的图片（位于文档2第29页），显示了噪声的影响。
- **缺失值（Missing Values）**：处理方式包括删除对象、估计值或忽略。类型包括：
- 完全随机缺失（MCAR）：缺失与数据无关。
- 随机缺失（MAR）：缺失与其他变量相关。
- 非随机缺失（MNAR）：缺失与未观测值相关。
- **重复数据**：合并数据源时需去重，但有时需保留（如时间序列）。

重难点：

- 缺失值处理：MCAR可简单填充，MNAR可能导致偏差。例如，调查中高收入者可能拒绝回答收入问题，导致MNAR。
- 课件中有一张关于数据质量的图表（位于文档2第27页），强调了低质量数据的成本。

3. 相似性与距离度量

- **欧氏距离（Euclidean Distance）**：常用距离公式，适用于数值型数据。公式：$\mathbf{d}(\mathbf{x},\mathbf{y})=\sum\mathbf{k}=\mathbf{1}\mathrm{n}(\mathbf{x}\mathrm{k}-\mathbf{y}\mathrm{k})\mathbf{2}$。
- **明可夫斯基距离（Minkowski Distance）**：通用公式，当参数r=1时为曼哈顿距离，r=2时为欧氏距离，r→∞时为切比雪夫距离。
- **余弦相似度（Cosine Similarity）**：用于文档向量，计算夹角余弦值，忽略大小重方向。公式：$\mathbf{cos}(\mathbf{d}1^{**},^{**}d^{**}2^{**})^{**}=^{**}\|^{**}d^{**}1\|\|^{**}d^{**}2\|^{**}\langle^{**}d^{**}1^{**},^{**}d^{**}2^{**}\rangle^{**}$。
- **其他**：Jaccard系数（用于二元数据）、马哈拉诺比斯距离（考虑数据分布）。

重难点：

- 距离度量选择：欧氏距离对尺度敏感，需标准化；余弦相似度适用于高维稀疏数据（如文本）。
- 课件中有一个文档向量的例子（位于文档2第21页），展示了词频向量和余弦计算。

举例：

- 文档相似性：两文档词频向量为d1=[3,2,0,5,0,0,0,2,0,0]和d2=[1,0,0,0,0,0,0,1,0,2]，计算余弦相似度为0.315。

4. 数据预处理技术

- **聚合（Aggregation）**：合并数据以减少规模，如将日数据聚合成月数据。
- **采样（Sampling）**：简单随机采样、分层采样（确保代表性子集）。
- **降维（Dimensionality Reduction）**：如主成分分析（PCA），避免维度灾难。
- **离散化（Discretization）**：将连续值转换为分类值，如年龄分组。

重难点：

- 维度灾难：高维数据中距离度量失效，因为数据过于稀疏。课件中有一张示意图（位于文档2第85页），显示随着维度增加，数据点距离变得相似。
- 预处理顺序：先处理缺失值，再标准化，最后降维。

三、模型评估方法（基于文档3: Cross Validation.ppt）

模型评估是确保模型泛化能力的关键，重点避免过拟合。核心方法是交叉验证。

1. 过拟合（Overfitting）

- **定义**：模型在训练数据上表现好，但在新数据上表现差。原因通常是模型过于复杂（如参数过多）。
- **识别**：训练误差低但测试误差高。
- **解决**：增加数据、简化模型、正则化、早停等。

举例：

- 课件中有一个回归例子（位于文档3第3-4页）：一个模型R^2=0.72但过拟合，另一个R^2=0.66更稳健。图片显示了拟合曲线与真实数据的偏差。

2. 评估方法

- **留出法（Hold-out Method）**：将数据分为训练集（如2/3）和测试集（如1/3）。简单但可能因划分不同而结果波动。
- **k折交叉验证（k-Fold Cross-Validation）**：
- 步骤：数据分k个子集，轮流用k-1个子集训练，1个子集测试，重复k次，取平均误差。
- 常用k=10，因实验表明估计准确。
- 分层k折：确保每个子集中类别比例一致。
- **留一法（Leave-One-Out）**：k等于样本数，每个样本单独测试。计算昂贵但充分利用数据。
- **Bootstrap方法**：有放回采样，训练集占63.2%，测试集占36.8%。估计误差为：**err**=**0.632**×**e**test+ **0.368**×**e**train。

重难点：

- 交叉验证选择：小数据用留一法，大数据用留出法，中等数据用k折。课件中有一张k折示意图（位于文档3第16页），展示了数据划分。
- 避免用测试集调参：需用单独验证集，否则会导致乐观偏差。

举例：

- 医学数据评估：用1985年数据训练，1986年数据测试，模拟真实应用场景。

3. 评估指标

- **分类**：准确率、精确度、召回率、F1分数（精确度和召回率的调和平均）。
- **回归**：均方误差（MSE）、R^2统计量。
- **聚类**：轮廓系数等。

重难点：

- F1分数：**F**1**=**P**1+**R**12=**2**P**+**R**P**×**R****，平衡精确度和召回率。例如，垃圾邮件检测中，高精确度（少误判）和高召回率（少漏判）都重要。

四、检索系统评估指标（基于文档4: retrieval-evaluation.ppt）

这部分专注信息检索（IR）系统的评估，如搜索引擎。指标包括精确度、召回率等，需理解其计算和应用。

1. 精确度（Precision）与召回率（Recall）

- **精确度** ：检索出的相关文档占所有检索文档的比例。公式：**P=检索出的文档总数**相关且检索出的文档数。
- **召回率** ：检索出的相关文档占所有相关文档的比例。公式：**R=相关文档总数**相关且检索出的文档数。
- **权衡** ：高精确度意味着少垃圾结果，高召回率意味着少遗漏。通常需平衡。

举例 ：

- 课件中有一个例子（位于文档4第15-16页）：10个文档中5个相关，检索出6个文档（其中3个相关）。则精确度=3/6=0.5，召回率=3/5=0.6。
- 精确度-召回率曲线：课件中有一张曲线图（位于文档4第32页），显示随着检索文档增加，精确度下降、召回率上升。

2. F-Measure 和 E-Measure

- **F-Measure** ：精确度和召回率的调和平均，常用F1分数。公式：**F**1**=**2**P**+**R**P**×**R****。
- **E-Measure** ：变体，引入参数b调整精确度和召回率的权重。公式：**E=1−α**P**1****+**(**1**−**α**)**R**1****1****，其中α=1/(b²+1)。

重难点 ：

- F1适用于二元相关判断，E-Measure允许自定义权重（如b=0.5表示更重精确度）。
- 课件中有一个计算例子（位于文档4第44页），展示了不同b值的影响。

3. 排名基础指标

- **精确度@K（P@K）** ：前K个结果中的精确度。例如P@10表示前10个结果的精确度。
- **平均精确度（Average Precision, AP）** ：对每个相关文档计算P@K，取平均。公式：**AP**=**R**1∑**k**=**1**R****P**@**k**。
- **均值平均精确度（Mean Average Precision, MAP）** ：多个查询的AP平均值。用于评估排名质量。
- **均值倒数排名（Mean Reciprocal Rank, MRR）** ：针对第一个相关文档的排名，计算倒数排名平均值。

举例 ：

- 课件中有一个MAP计算例子（位于文档4第51-52页）：两个查询的AP分别为0.62和0.44，则MAP=0.53。

4. 高级指标：NDCG

- **归一化折损累积增益（NDCG）** ：用于多级相关性（如评分0-3）。考虑排名位置，折扣低排名结果。公式基于累积增益和理想排名。
- **应用** ：在网页搜索中，NDCG评估结果列表的质量。

举例 ：

- 课件中有一个详细计算（位于文档4第62-65页）：文档相关性评分[3,2,3,0,0,1,2,2,3,0]，计算DCG和理想DCG，然后归一化。

5. 实践问题

- **测试集** ：如TREC（文本检索会议）提供标准数据集和查询。
- **用户点击数据** ：实际评估中，用点击率模拟用户偏好，但需避免位置偏差。

重难点 ：

- 指标选择：二元相关用F1，排名用MAP，多级相关用NDCG。课件中强调了这些指标在TREC中的应用（位于文档4第75-80页）。

总结

- **基础概念** ：数据挖掘和机器学习定义、任务区分、数据属性类型是基础，需理解而非死记。

- **评估核心**：交叉验证是模型评估的金标准，避免过拟合；检索指标如精确度、召回率、F1和MAP需会计算。
- **复习建议**：多举例强化理解，例如用信用评分案例理解分类，用搜索引擎案例理解评估指标。考试可能侧重概念解释和简单计算。

如果您需要某个部分更详细的推导或更多例子，我可以继续展开。祝您复习顺利！