无监督学习模型复习指南

无监督学习是机器学习的重要分支，主要处理无标签数据，目标是发现数据中的隐藏结构，如聚类、降维、主题发现等。本次复习基于你提供的课件，涵盖K-means聚类、聚类分析总论、EM算法、PCA降维、隐马尔可夫模型（HMM）和主题模型（LDA）。我会将英文课件内容翻译成中文，并详细讲解每个模型的概念、步骤、重难点和实际举例。由于是选修课，重点放在概念理解上，数学推导会简化。回复结构按模型分节，每节包括概述、详细讲解、举例和重难点分析。

---

1. K-means聚类（来自课件9 kmeans.ppt）

概述 ：K-means是一种基于质心的聚类算法，通过迭代将数据点分配到最近的簇中心，并更新中心位置，以最小化簇内距离。

详细讲解 ：

- **步骤** ：

1. **初始化** ：随机选择K个数据点作为初始簇中心（质心）。
2. **分配阶段** ：将每个数据点分配到最近的质心（通常使用欧氏距离）。
3. **更新阶段** ：重新计算每个簇的质心（取簇内点的平均值）。
4. **迭代** ：重复分配和更新，直到质心不再变化或达到最大迭代次数。

- **目标** ：最小化簇内平方误差（SSE），即所有数据点到其质心的距离平方和。
- **关键参数** ：K（簇数），需预先指定；常用肘部法或轮廓系数选择K。
- **优缺点** ：
- 优点：简单、高效，适用于大规模数据。
- 缺点：对初始质心敏感，可能陷入局部最优；假设簇为球形，对非球形簇效果差。

举例 ：

- 假设有一组二维数据点：[(1,2), (1,4), (2,2), (5,5), (6,5), (6,6)]，K=2。
  - 步骤1：随机选两个质心，如(1,2)和(5,5)。
  - 步骤2：计算每个点到质心的距离，分配点到最近簇。点(1,2)、(1,4)、(2,2)分配到簇1；(5,5)、(6,5)、(6,6)分配到簇2。
  - 步骤3：更新质心。簇1新质心为((1+1+2)/3, (2+4+2)/3) = (1.33, 2.67)；簇2新质心为((5+6+6)/3, (5+5+6)/3) = (5.67, 5.33)。
  - 步骤4：重复分配和更新，直到质心稳定。最终簇1中心约(1.33, 2.67)，簇2中心约(5.67, 5.33)。

- **重难点** ：

- **难点1：K值选择** ：K太小会导致欠拟合（如K=1，所有点归为一簇），K太大会过拟合（如K=点数，每点一簇）。解决方法：使用肘部法（SSE随K变化的拐点）或领域知识。

- **难点2：初始质心敏感** ：随机初始化可能导致不同结果。解决方法：多次运行取最优，或使用K-means++（优先选择远离已选质心的点）。

在课件中，有一个图表展示了K-means的迭代过程，显示了数据点如何被分配到簇并更新质心，这有助于可视化收敛过程。

---

2. 聚类分析总论（来自课件10 cluster_analysis.ppt）

概述 ：聚类分析包括多种方法，如层级聚类、密度聚类（如DBSCAN）和模型聚类（如GMM），旨在根据相似性将数据分组。

详细讲解 ：

- **主要类型** ：

- **层级聚类** ：通过合并或分裂簇构建树状图（ dendrogram ）。分为凝聚式（自底向上合并）和分裂式（自顶向下分裂）。距离度量常用欧氏距离，链接方法包括单链接（最近邻）、全链接（最远邻）和平均链接。
- **密度聚类** ：如DBSCAN，基于数据点密度形成簇，能处理任意形状的簇和噪声。关键参数：邻域半径ε和最小点数minPts。
- **模型聚类** ：如高斯混合模型（GMM），假设数据来自多个高斯分布，用EM算法拟合。
- **评估指标** ：轮廓系数（衡量簇内紧密度和簇间分离度）、Calinski-Harabasz指数等。

举例 ：

- **层级聚类举例** ：有一组点[A(1,1), B(1,2), C(5,5), D(6,5)]。
- 步骤1：计算距离矩阵，如A和B距离1，A和C距离5.66。
- 步骤2：单链接法：先合并最近的点A和B，形成簇AB；然后合并C和D，形成簇CD；最后合并AB和CD（基于AB中B与CD中C的距离）。
- 结果：树状图显示合并顺序，可切割树状图得到不同K的簇。
- **DBSCAN举例** ：同上数据，设ε=2，minPts=2。
- 步骤：A的邻域内有B（距离1<ε），故A和B为核心点，形成簇；C和D同理形成另一簇；孤立点会被标记为噪声。
- **重难点** ：
- **难点：参数选择** ：如DBSCAN的ε和minPts影响簇形状。解决方法：使用k距离图（点与其第k近邻的距离）确定ε。
- **难点：聚类有效性** ：不同方法适用于不同数据（如层级聚类对噪声敏感）。解决方法：结合多个指标评估。

课件中有一个对比图，显示了K-means、层级聚类和DBSCAN在不同形状数据上的效果，突出了密度聚类的优势。

---

3. EM算法（来自课件11 EM Algorithm.pptx）

概述 ：EM（期望最大化）算法是一种迭代优化方法，用于含有隐变量（未观测变量）的概率模型参数估计，如高斯混合模型（GMM）。

详细讲解 ：

- **步骤** ：

1. **E步（期望步）** ：基于当前参数，计算隐变量的后验概率（即每个数据点属于每个簇的概率）。
2. **M步（最大化步）** ：基于E步的结果，更新模型参数以最大化似然函数。
3. **迭代** ：重复E步和M步，直到参数收敛（似然函数变化很小）。

- **应用** ：常用于GMM聚类，其中隐变量是簇标签；也用于HMM和主题模型。
- **数学基础** ：通过Jensen不等式保证每次迭代增加似然值，但可能收敛到局部最优。

举例 ：

- **GMM聚类举例** ：假设有一维数据[1, 2, 5, 6]，假设有两个高斯分布（簇）。
- 初始化：随机设置两个高斯的均值和方差，如μ1=1, σ1=1; μ2=5, σ2=1。
- E步：计算每个点属于每个高斯的概率。例如点2，计算P(簇1|2)和P(簇2|2)（使用贝叶斯公式）。
- M步：更新参数。例如，μ1更新为所有点的加权平均，权重为E步中属于簇1的概率。
- 迭代：重复直到均值和方差稳定。
- **重难点** ：
- **难点：局部最优** ：EM对初始值敏感，可能陷入局部最优。解决方法：多次随机初始化，或使用K-means初始化。
- **难点：收敛慢** ：在高维数据上迭代次数多。解决方法：设置收敛阈值或最大迭代次数。

课件中有一个EM算法的流程图，展示了E步和M步的循环过程，并附有GMM的概率分布图，帮助理解隐变量更新。

---

4. 主成分分析PCA（来自课件12 Linear Dimensionality Reduction-PCA.ppt）

概述 ：PCA是一种线性降维方法，通过正交变换将数据投影到低维空间，保留最大方差，用于去噪、压缩和可视化。

详细讲解 ：

- **步骤** ：

1. **标准化** ：将数据减去均值，使中心为0（可选缩放方差为1）。
2. **计算协方差矩阵** ：衡量特征间的相关性。
3. **特征分解** ：计算协方差矩阵的特征值和特征向量。
4. **选择主成分** ：按特征值降序排序，选择前k个特征向量（主成分方向）。
5. **投影** ：将数据投影到主成分上，得到降维后的数据。

- **数学原理** ：最大化投影方差，等价于最小化重建误差。
- **关键概念** ：特征值表示主成分的方差贡献率；累计贡献率用于选择k（如>85%）。

举例 ：

- 假设二维数据：[(1,1), (2,2), (3,3), (4,4)]，这些点近似在直线y=x上。
  - 步骤1：中心化：减去均值(2.5,2.5)，得[(-1.5,-1.5), (-0.5,-0.5), (0.5,0.5), (1.5,1.5)]。
  - 步骤2：协方差矩阵为[[1.25,1.25],[1.25,1.25]]。
  - 步骤3：特征值λ1=2.5（对应特征向量[1/√2, 1/√2]），λ2=0。
  - 步骤4：选择k=1，主成分方向为[1/√2, 1/√2]（即45度线）。
  - 步骤5：投影：点(1,1)投影到主成分上，值为(1 * 1/√2 + 1 * 1/√2) = √2 ≈1.41。降维后数据为一维[1.41, 2.83, 4.24, 5.66]。

- **重难点** ：

- **难点：线性假设** ：PCA只能捕捉线性关系，对非线性数据效果差。解决方法：使用核PCA或流形学习（如t-SNE）。

- **难点：特征解释** ：主成分是原始特征的线性组合，可能缺乏物理意义。解决方法：分析载荷（特征向量权重）来解读。

课件中有一个散点图展示原始数据和主成分方向，以及降维后的分布，强调了方差最大化。

---

5. 隐马尔可夫模型HMM（来自课件13 hidden markov models.ppt）

概述 ：HMM是一种概率模型，用于序列数据（如语音、文本），假设系统是马尔可夫过程（当前状态只依赖前一个状态），但状态不可观测（隐藏），只能通过观测值推断。

详细讲解 ：

- **组成** ：
- 隐藏状态集：如词性标注中的名词、动词等。
- 观测值集：如单词。
- 参数：初始状态概率、状态转移概率（状态间转移）、观测概率（状态生成观测的概率）。
- **三大问题** ：

1. **评估问题** ：给定模型，计算观测序列的概率（使用前向算法）。
2. **解码问题** ：给定观测序列，找最可能的状态序列（使用维特比算法）。
3. **学习问题** ：给定观测序列，估计模型参数（使用EM算法，即Baum-Welch算法）。

- **应用** ：语音识别、基因序列分析、词性标注。

举例 ：

- **词性标注举例** ：句子“I like coding”，隐藏状态是词性（如PRP代词、VB动词、NN名词），观测值是单词。

- 假设初始概率：P(PRP)=0.5, P(VB)=0.3等。
- 转移概率：P(VB|PRP)=0.6（代词后接动词的概率）。
- 观测概率：P("I"|PRP)=0.1（代词生成“I”的概率）。
- 解码：用维特比算法找最可能状态序列，如[PRP, VB, NN]。
- **重难点** ：
- **难点：参数估计** ：当训练数据少时，概率估计不准确。解决方法：使用平滑技术（如加一平滑）。
- **难点：计算复杂度** ：序列长时，维特比算法需$O(N^2T)$时间。解决方法：使用近似算法或优化数据结构。

课件中有一个HMM的状态转移图，显示了隐藏状态和观测值的关系，并附有维特比算法的trellis图，演示了动态规划过程。

---

6. 主题模型LDA（来自课件14 topic_model.pptx 和 LDA推导.pdf）

概述 ：LDA（潜在狄利克雷分配）是一种主题模型，将文档表示为主题的混合，每个主题是单词的概率分布，用于发现文档集中的隐藏主题。

详细讲解 ：

- **生成过程** ：

1. 对每个文档，从狄利克雷分布采样一个主题分布（多项式分布）。
2. 对文档中每个单词：先从主题分布采样一个主题，再从该主题的单词分布采样一个单词。

- **参数** ：α控制文档-主题分布的稀疏性，β控制主题-单词分布的稀疏性。
- **推断** ：通常用吉布斯采样或变分推断估计参数，找到最可能主题分配。
- **应用** ：文本分类、推荐系统、可视化。

举例 ：

- 假设文档集包含文档1“machine learning”和文档2“data mining”。
    - 主题可能为“计算机”（单词：machine, data, learning）和“统计”（单词：learning, mining, data）。
    - LDA会分配主题比例：文档1可能60%计算机主题、40%统计主题；文档2可能50%计算机、50%统计。
    - 每个主题的单词分布：计算机主题P(machine)=0.3, P(data)=0.3等。

- **重难点** ：

- **难点：主题数选择** ：主题数K影响结果，太大过拟合，太小欠拟合。解决方法：使用困惑度（perplexity）或领域知识。

- **难点：推导复杂** ：LDA涉及贝叶斯推断和采样。简化理解：吉布斯采样通过迭代更新每个单词的主题分配，基于当前其他单词的主题。

从LDA推导.pdf中，关键公式是主题分配的后验概率，涉及单词-主题共现计数和狄利克雷先验。课件中有一个板块图展示了文档生成过程，帮助理解主题混合。

总结与复习建议

- **重难点汇总** ：
- **聚类** ：K值选择、初始值敏感；解决方法是肘部法和多次运行。
- **降维** ：PCA的线性限制；可探索非线性方法。
- **概率模型** ：EM的局部最优、HMM的参数估计、LDA的主题数选择，都需注意初始化和评估指标。
- **复习技巧** ：
- 重点理解每个模型的核心思想和应用场景。
- 通过举例加深记忆，如用简单数据手动模拟算法步骤。
- 对比模型：如K-means与GMM（硬聚类 vs 软聚类）、PCA与LDA（降维 vs 主题发现）。
- **考试提示** ：选修课可能考察概念题、简答题或简单计算（如PCA投影），多练习举例和步骤描述。

如果有特定部分需要更详细的解释或更多举例，请告诉我，我可以进一步展开！祝你复习顺利，考试高分！