机器学习与数据挖掘期末复习：集成学习与半监督学习详解

针对你的期末复习需求，我将基于你提供的文档（文档2和文档3），重点讲解集成学习和半监督学习。作为选修课，考察偏重基础概念，我会详细解释每个算法的核心思想、步骤、优缺点，并辅以具体举例来帮助理解重难点。文档中的英文内容我会翻译成中文并加以讲解。由于你要求不要插入图片，我会在必要时描述图片的大致位置（例如，“在PPT的第X页有一个图展示了...”），但不会使用图片标签。

一、集成学习（Ensemble Learning）

集成学习通过组合多个弱学习器来提升模型性能，核心思想是“三个臭皮匠，顶个诸葛亮”。它能减少方差、提高鲁棒性，适用于分类、聚类等任务。

1. Bagging（Bootstrap Aggregating）

- **核心思想**：通过自助采样（Bootstrap）生成多个训练子集，分别训练基学习器，然后通过投票或平均方式组合预测结果。
- **步骤**：

1. 从原始数据集中有放回地随机抽取多个子集（每个子集包含约63.2%的原始数据）。
2. 在每个子集上训练一个基学习器（如决策树）。
3. 对测试样本，所有学习器投票决定最终分类（分类问题）或取平均（回归问题）。

- **例子**：假设有一个数据集包含10个样本，我们进行Bagging：
- 原始数据：样本1-10，标签为[1,1,1,-1,-1,-1,-1,1,1,1]（1代表正类，-1代表负类）。
- 自助采样可能生成子集1：样本1,3,5,7,9（有重复），训练决策树1；子集2：样本2,4,6,8,10，训练决策树2。
- 对新样本，如果树1预测为1，树2预测为-1，则通过多数投票（假设2棵树）决定最终结果。
- **优缺点**：
- 优点：减少过拟合，尤其适用于高方差模型（如决策树）。
- 缺点：基学习器如果高度相关，效果提升有限；计算成本较高。
- **重难点**：自助采样时，子集可能遗漏部分数据，需确保多样性。Bagging的核心是降低方差，因此基学习器应尽量独立。

2. Boosting（如AdaBoost）

- **核心思想**：逐步调整样本权重，让后续学习器聚焦于之前分错的样本，最终加权组合所有学习器。
- **步骤（以AdaBoost为例）**：

1. 初始化样本权重为均匀分布。

2. 每一轮：

    - 训练一个弱学习器（如决策树桩），计算错误率。
    - 根据错误率计算该学习器的权重（错误率越低，权重越大）。
    - 增加错分样本的权重，减少正确分类样本的权重。

3. 最终分类器为所有弱学习器的加权和。

- **例子**：二分类问题，初始样本权重相同。第一轮学习器可能将样本4错分（样本4难分类），则增加样本4的权重；第二轮学习器会更多关注样本4，逐步改进。
- **公式**：学习器权重 **α**m=**2**1ln**(**e**m1**−**e**m**)**，其中 **e**m****是错误率。
- **优缺点**：
- 优点：常比Bagging更准确，能处理复杂边界。
- 缺点：对噪声敏感，可能过拟合；需要仔细调参。
- **重难点**：样本权重的调整可能导致后续学习器过于关注噪声点。Adaboost的损失函数是指数损失，需理解权重更新的推导。

3. Random Forests（随机森林）

- **核心思想**：Bagging的扩展，在决策树训练中引入随机特征选择，进一步增加多样性。
- **步骤**：

1. 从原始数据中自助采样生成多个子集。
2. 对每个子集训练决策树，但在每个节点分裂时，随机选择部分特征（如总特征数的平方根）而非全部特征。
3. 最终通过多数投票组合所有树。

- **例子** ：图像分类任务，总特征为100个（如像素值）。每棵树在节点分裂时，只随机选择10个特征计算最佳分裂点，从而减少树之间的相关性。
- **优缺点** ：
- 优点：高准确率，能处理高维数据；不易过拟合。
- 缺点：模型解释性差；计算资源消耗大。
- **重难点** ：随机特征选择是关键，需平衡特征数（太多则树相关，太少则信息不足）。在PPT中，随机森林部分有图展示多棵树投票的过程（大约在文档3的第40页附近）。

4. 无监督集成（聚类集成）

- **简要说明** ：将多个聚类结果组合成共识聚类，解决无监督学习中的不确定性。例如，使用不同参数运行K-means生成多个聚类，然后通过共识函数（如超图分割）合并。
- **例子** ：对同一数据集，聚类算法A将数据分为2类，算法B分为3类，共识方法（如MCLA）可能得出2个更稳定的类。
- **难点** ：聚类标签对应问题（不同聚类的类标签可能不一致）。

二、半监督学习（Semi-Supervised Learning, SSL）

SSL利用少量标记数据和大量未标记数据提升学习效果，核心假设是“相似样本有相似标签”（如平滑性假设）。

1. 基于分类器的方法

- **EM算法** ：

- **核心思想** ：通过期望最大化（EM）算法最大化标记和未标记数据的联合似然。E步估计未标记数据的隐藏标签，M步更新模型参数。

- **步骤** ：

    1. 初始化模型参数（如高斯混合模型的均值和方差）。
    2. E步：基于当前参数，计算未标记数据属于每个类的概率。
    3. M步：用所有数据（标记和未标记）重新估计参数。
    4. 迭代直到收敛。

- **例子** ：垃圾邮件分类，标记数据少，未标记数据多。假设数据服从高斯混合分布，EM算法能利用未标记数据改进分类边界。

- **重难点** ：EM可能陷入局部最优；对初始值敏感。需理解似然函数的形式（文档2第21页有公式）。

- **Co-Training（协同训练）** ：

- **核心思想** ：假设数据有两个独立视图（如网页的文本和链接），分别训练两个分类器，并互相提供高置信度的未标记样本作为新训练数据。

- **步骤** ：

    1. 用标记数据训练视图1的分类器f1和视图2的分类器f2。
    2. f1对未标记数据预测，选择置信度高的样本加入f2的训练集；反之亦然。
    3. 重新训练f1和f2，迭代进行。

- **例子** ：网页分类任务：视图1是页面文本，视图2是超链接文本。初始用少量标记数据训练f1（基于文本）和f2（基于链接）。如果f1高置信度地将某个未标记网页判为正类，则将该网页及其预测标签加入f2的训练集。

- **重难点** ：视图独立性假设可能不成立；需谨慎选择置信度阈值。文档2第27-29页有示意图展示迭代过程。

- **Yarowsky算法** ：类似Co-Training，但使用单一视图，通过高置信度样本自举增强。

2. 基于数据的方法

- **流形正则化（Manifold Regularization）** ：

- **核心思想** ：假设数据分布在低维流形上，要求分类函数在流形上平滑（即相似样本的预测值相近）。

- **步骤** ：在标准正则化损失中加入平滑项，惩罚函数在未标记数据上的变化。公式：

  $$f_{opt}=\arg\min_{f\in H}\lambda_I\|f\|_I^2+\lambda_k\|f\|_k^2+\frac{1}{l}\sum_{i=1}^{l}(f(x_i)-y_i)^2$$

  其中$\|f\|_I^2$是平滑项，基于未标记数据的图拉普拉斯矩阵。

- **例子** ：图像识别任务，未标记图像可能帮助估计数据流形（如人脸图像的姿态变化）。平滑项确保相似姿态的图像有相似标签。

- **重难点** ：流形假设的合理性；计算图拉普拉斯矩阵的成本高。文档2第39-40页有数学推导。

- **信息正则化** ：基于互信息，鼓励条件概率在密集区域平滑变化。例子：在文档2第45页，有一个二分类问题的图展示决策边界应置于低密度区域。

3. SSL的应用与难点

- **结构化预测的SSL** ：处理复杂输出（如序列标注），利用未标记数据约束结构一致性。
- **通用难点** ：
- 假设依赖性：SSL效果依赖于假设（如聚类假设、流形假设）是否成立。
- 计算复杂性：EM、图构建等计算量大。
- **复习提示** ：重点理解假设背后的直觉（如PPT中“数据流形”图在文档2第35页附近，展示了数据在低维空间的分布）。

三、总结与复习建议

- **集成学习** ：核心是通过多样性减少误差。Bagging、Boosting和Random Forests是重点，需掌握区别（Bagging降方差，Boosting降偏差）。
- **半监督学习** ：关键是如何利用未标记数据。Co-Training和流形正则化是典型方法，要理解其假设和适用场景。
- **举例的重要性** ：例如，Co-Training在网页分类中的应用，或Random Forests在图像分类中的实现，能帮助记忆概念。
- **考试重点** ：概念性题目可能涉及算法比较（如Bagging vs. Boosting）、假设解释（如SSL的平滑性假设），计算题少但需了解基本公式（如AdaBoost的权重更新）。

祝你复习顺利，考试高分！如果有特定概念需要进一步展开，请随时告诉我。