深度学习与表征学习期末复习指南

以下内容基于您提供的课件文档，我将详细讲解每个主题的重点、难点和关键概念，并辅以具体例子。讲解顺序按照您列出的PPT文件组织，确保结构丰富、易于理解。由于您要求不插入图片，我会描述图片的大致位置和内容，以便您参考。

---

1. 深度学习引言（对应文档3：Introduction to Deep Learning）

概念：深度学习是机器学习的一个分支，使用多层神经网络来学习数据的层次化表示。与传统方法相比，它能自动从原始数据中提取特征，无需手动设计。

重点与难点：

- **核心思想**：通过多层非线性变换学习复杂模式。难点在于理解"深度"的含义——每层逐渐抽象特征，例如从像素到边缘、再到物体部分。
- **与浅层网络的区别**：深度学习模型参数量大，需要大量数据和计算资源，但能处理高维数据（如图像、语音）。
- **关键突破**：2012年Hinton等人的工作显示深度学习在图像分类和语音识别上超越传统方法。例如，AlexNet在ImageNet竞赛中将错误率从26%降至15%。

举例说明：

- **图像分类**：输入一张猫的图片，第一层神经元可能检测边缘，第二层组合成纹理，第三层识别眼睛或鼻子，最终输出"猫"的概率。

  在PPT中，大约在第3-5页，有一个图展示了神经网络从像素到分类的层次化过程，类似多层滤波器叠加。

---

2. 反向传播算法（对应文档4：Back-Propagation Algorithm）

概念：反向传播是训练神经网络的核心算法，通过链式法则计算损失函数对权重的梯度，从而用梯度下降法更新权重。

重点与难点：

- **前向传播与反向传播**：前向传播计算输出，反向传播从输出层向输入层传递误差梯度。难点是链式法则的递归应用，容易在计算中混淆偏导数。
- **梯度消失/爆炸问题**：深层网络中梯度可能变得极小或极大，导致训练失败。解决方案包括使用ReLU激活函数或梯度裁剪。
- **算法步骤**：1) 前向计算输出；2) 计算损失（如均方误差）；3) 反向计算梯度；4) 更新权重（学习率控制步长）。

举例说明：

- **简单网络训练**：假设网络用于预测房价，输入是房屋面积和卧室数量，输出是价格。如果预测误差大，反向传播会调整权重，比如增加面积对价格的影响权重。

  在PPT中，第10-15页用数学公式和流程图展示了梯度计算过程，例如通过计算$\partial E/\partial w$来更新权重w。

---

3. 词嵌入（Word Embeddings）（对应文档5和6：Word Embeddings 1 & 2）

概念：将单词映射到低维向量空间，使得语义相似的词在空间中靠近。Word2Vec是经典方法，包括CBOW（用上下文预测中心词）和Skip-Gram（用中心词预测上下文）。

重点与难点：

- **CBOW vs. Skip-Gram**：CBOW适合频繁词，Skip-Gram适合稀有词。难点是理解负采样（Negative Sampling）——通过采样负例来简化计算，避免在全词典上求softmax。

- **向量语义** ：词向量可捕获类比关系，如“king - man + woman ≈ queen”。难点是向量空间的可解释性，需通过聚类可视化。
- **优化方法** ：使用随机梯度下降，目标函数是最大化上下文概率。

举例说明 ：

- **Skip-Gram示例** ：对于句子“I like deep learning”，以“like”为中心词，窗口大小为1，则尝试预测“I”和“deep”。训练后，“like”和“enjoy”的向量会接近。

在PPT中，文档5第13-15页展示了Skip-Gram的架构图，文档6第12-14页有负采样的数学推导。

---

4. 自编码器（Autoencoders）（对应文档7：AUTOENCODERS）

概念 ：自编码器是一种无监督学习模型，包含编码器（压缩输入为低维表示）和解码器（重构输入），用于降维或去噪。

重点与难点 ：

- **欠完备 vs. 过完备** ：欠完备自编码器（隐藏层维度小于输入）强制学习关键特征，过完备的需加正则化避免过拟合。难点是平衡重构误差和表示大小。
- **变种** ：包括去噪自编码器（DAE，加噪声训练以增强鲁棒性）和稀疏自编码器（加入稀疏约束）。难点是正则项的选择。
- **应用** ：用于图像压缩，如将28x28的MNIST图像压缩为10维向量再重构。

举例说明 ：

- **MNIST数字去噪** ：输入带噪声的手写数字图片，编码器提取特征，解码器输出清晰图片。训练目标是最小化原始图片与重构图片的差异。

在PPT中，第5-10页有自编码器结构图，第15-20页展示了去噪自编码器的效果对比。

---

5. 卷积神经网络（CNNs）（对应文档8：Convolutional Neural Networks）

概念 ：CNN专用于网格状数据（如图像），通过卷积层提取局部特征，池化层降维，全连接层分类。

重点与难点 ：

- **卷积操作** ：滤波器在输入上滑动计算点积，捕获局部模式。难点是理解参数共享——同一滤波器用于整个图像，减少参数量。
- **池化层** ：最大池化保留显著特征，减少计算量。难点是选择池化大小和步长。
- **经典架构** ：AlexNet（8层）、VGGNet（19层）、ResNet（残差连接解决梯度消失）。ResNet的“跳跃连接”允许训练极深网络。

举例说明 ：

- **猫狗分类** ：输入图片，第一层卷积检测边缘，第二层检测眼睛或耳朵，全连接层输出类别概率。使用ImageNet预训练模型可迁移学习。

在PPT中，第10-15页有卷积可视化图，展示滤波器如何响应边缘；第25-30页比较了不同网络的准确率。

---

6. 变分自编码器（VAE）（对应文档9：Variational Autoencoders）

概念 ：VAE是生成模型，在自编码器基础上引入概率编码，学习数据的潜在分布，可生成新样本。

重点与难点 ：

- **重参数化技巧** ：从编码器输出的均值方差采样潜在变量，使梯度可回溯。难点是理解KL散度项——约束潜在分布接近标准正态分布。

- **与GAN的区别** ：VAE更稳定但生成样本较模糊，GAN更清晰但难训练。难点是平衡重构误差和分布匹配。
- **应用** ：生成人脸图片，如CelebA数据集上 interpolate 潜在向量得到渐变人脸。

举例说明 ：

- **数字生成** ：在MNIST上训练VAE，编码器将图片映射为均值和方差，采样后解码器生成新数字。潜在空间插值可实现“0”到“1”的平滑过渡。

  在PPT中，第5-10页有VAE结构图，第20-25页展示了潜在空间插值效果。

---

7. 注意力机制与Transformer（对应文档10：Attention and Transformers）

概念 ：注意力机制让模型聚焦于输入的相关部分，Transformer基于自注意力处理序列数据，无需RNN，支持并行计算。

重点与难点 ：

- **自注意力** ：计算查询（Query）、键（Key）、值（Value）的相似度权重，加权求和。难点是理解多头注意力——多个头捕获不同关系。
- **Transformer架构** ：编码器-解码器结构，位置编码注入顺序信息。难点是掩码注意力（解码时避免看到未来词）。
- **应用** ：机器翻译，如英译法时，注意力聚焦于对应单词。

举例说明 ：

- **翻译任务** ：输入“I love deep learning”，编码器计算每个词的表示，解码器生成“我热爱深度学习”时，注意力机制让“love”对“热爱”有高权重。

  在PPT中，第15-20页有注意力权重热力图，展示单词对齐；第25-30页详细说明了Transformer的数学公式。

---

8. 表征学习（Representation Learning）（对应文档11：Representation Learning）

概念 ：学习数据的低维表示，保留语义信息，用于下游任务（如分类、聚类）。对比学习是主流方法，如SimCLR和MoCo。

重点与难点 ：

- **对比学习** ：拉近正样本（同一图片的不同增强），推离负样本。难点是InfoNCE损失函数——最大化正样本相似度，最小化负样本相似度。
- **SimCLR** ：使用数据增强（裁剪、变色）生成正对，大批量训练。难点是投影头设计——MLP将表示映射到对比空间。
- **MoCo** ：维护动态队列存储负样本，动量编码器稳定训练。难点是队列更新策略。

举例说明 ：

- **图像检索** ：在无标签图片上训练SimCLR，学习到的表示可用于查找相似图片。例如，查询狗图片，返回其他狗的图片。

  在PPT中，第10-15页有SimCLR流程图，第20-25页对比了MoCo和SimCLR的性能表。

---

9. 强化学习（对应文档1：Reinforcement Learning）

概念 ：智能体通过与环境交互学习策略，以最大化累积奖励。适用于决策问题，如游戏或机器人控制。

重点与难点 ：

- **马尔可夫决策过程（MDP）**：定义状态、动作、奖励、转移概率。难点是值函数和Q函数的计算——贝尔曼方程迭代求解。
- **Q学习**：用Q表或神经网络估计动作值，离线策略学习。难点是探索-利用权衡（ε-greedy）。
- **策略梯度**：直接优化策略网络，适合连续动作空间。难点是高方差，需基线减小方差。

举例说明：

- **Cart-Pole游戏**：智能体移动小车保持杆平衡，状态是角度和位置，动作是左/右移，奖励是存活时间。Q学习会学习到“杆左倾时向右移动”的Q值高。

  在PPT中，第5-10页有MDP图示，第15-20页展示了Q学习在网格世界的路径。

复习建议

- **概念优先**：深度学习的核心是理解层次化表示和梯度优化，多画图辅助记忆。
- **重难点突破**：反向传播的链式法则、注意力机制权重计算、VAE的重参数化是易错点，建议用简单例子推导。
- **举例应用**：每个概念都联系实际应用，如CNN用于图像分类、Transformer用于翻译，加深理解。
- **实践结合**：如果可能，用代码实现简单模型（如用NumPy实现反向传播），巩固算法细节。

如果您有特定主题需要更深入讲解，或需要更多例子，请随时告知！