机器学习 期末复习总结

- 第5章 多变量线性回归与逻辑回归 (Multivariate Linear Regression & Logistic Regression)
  - 5.1 多变量线性回归 (Multivariate Linear Regression)
    - 理论核心
    - 作业真题解析：Exercise One (Linear Regression)
  - 5.2 逻辑回归与极大似然估计 (Logistic Regression & MLE)
    - 理论核心
    - 作业真题解析：Exercise Two (Part A & B)
  - 5.3 逻辑回归的训练与评估
    - 理论核心
    - 作业真题解析：Exercise Two (Part C - F)
- 第6章 决策树 (Decision Tree)
  - 6.1 机器学习任务分类与基本概念 (PPT P1-3)
    - (1) 学习任务分类
    - (2) 决策树模型概述
  - 6.2 决策树基本流程：Hunt 算法 (PPT P4-5)
    - (1) 算法核心机制
    - (2) 递归返回的三种情形 (⚠️ 逻辑考点)
    - (3) Exam Hacks: 潜在考题
  - 6.3 划分选择：纯度度量 (PPT P7-17)
    - (1) 信息增益 (Information Gain) —— ID3算法
    - (2) 增益率 (Gain Ratio) —— C4.5算法
    - (3) 基尼指数 (Gini Index) —— CART算法
    - (4) Exam Hacks: 计算题考点
  - 6.4 剪枝处理 (Pruning) (PPT P18-24)
    - (1) 预剪枝 (Pre-pruning)
    - (2) 后剪枝 (Post-pruning)
  - 6.5 连续值与缺失值处理 (PPT P26-31)
    - (1) 连续属性离散化 (C4.5 采用二分法)
  - 6.6 多变量决策树 (Multivariate Decision Tree) (PPT P32-34)
    - (1) 分类边界的几何解释
    - (2) 多变量决策树
  - 6.7 最终复习总结 (Exam Hacks)
- 第7章 支持向量机 (SVM) 深度解析
  - 7.1 SVM 概论与线性分类器 (PPT P1-11)
    - 7.1.1 核心概念 (PPT P1-10)
    - 7.1.2 线性分类器模型
  - 7.2 间隔 (Margin) 的计算与原始问题 (PPT P12-17)
    - 7.2.1 点到超平面的距离 (PPT P12-15)
    - 7.2.2 最大间隔分类器的原始问题 (Primal Problem) (PPT P16-17)
  - 7.3 优化理论与拉格朗日乘子法 (PPT P18-73)
    - 7.3.1 核心数学工具
    - 7.3.2 经典例题演示 (PPT P62-65)
  - 7.4 SVM 对偶问题完整推导 (PPT P74-93)
    - 7.4.1 Step 1: 构造拉格朗日函数 (The Lagrangian)
    - 7.4.2 Step 2: 求解极小值 (Minimize L w.r.t w, b)
    - 7.4.3 Step 3: 导出对偶问题 (The Dual Problem)
    - 7.4.4 Step 4: KKT 条件与稀疏性 (PPT P89)
  - 7.5 软间隔与正则化 & 作业真题解析 (PPT P94-95)
    - 7.5.1 理论基础：软间隔 (Soft Margin)
    - 7.5.2 🎯 作业真题解析 (对应 Homework 4)
  - 7.6 核技巧 (Kernel Trick) (PPT P96-102)
    - 7.6.1 为什么要用核？ (PPT P97)
    - 7.6.2 核技巧 (The Kernel Trick) (PPT P98-99)
    - 7.6.3 常见核函数 (PPT P101)
  - 7.7 教授的考前总结 (Final Remarks)
- 第8章 分类算法：K-最近邻 (KNN)

    - 8.1 基于实例的分类器 (Instance Based Classifiers) (PPT P1-P2)
        - (1) 核心概念与定义
        - (2) 两种典型方法的对比
    - 8.2 KNN 算法核心机制 (PPT P3-P5)
        - (1) 核心思想 (Duck Test)
        - (2) 算法的三大要素 (PPT P4) (⚠️ 考试必背)
        - (3) 算法流程 (Algorithm Steps)
        - (4) K值的定义示例 (PPT P5)
        - (5) 潜在考题预测 (Exam Hacks)
    - 8.3 几何解释：沃罗诺伊图 (Voronoi Diagram) (PPT P6)
        - (1) 1-NN 的决策边界
    - 8.4 数学细节：距离与加权 (PPT P7)
        - (1) 距离度量 (Distance Metric) (⚠️ 需掌握公式)
        - (2) 投票机制的改进
    - 8.5 超参数选择：K 值的影响 (PPT P8) (⚠️ 核心考点)
        - (1) K 值太小 (如 $k = 1$)
        - (2) K 值太大 (如 $k \to N$)
        - (3) 潜在考题预测 (Exam Hacks)
    - 8.6 数据预处理与缩放 (Scaling Issues) (PPT P9-P10)
        - (1) 为什么需要缩放 (Scaling)?
        - (2) 相似度度量的选择 (PPT P10)
    - 8.7 KNN 的优缺点总结 (PPT P11)
        - (1) 优点
        - (2) 缺点与挑战 (⚠️ 考试常考)
    - 8.8 提升 KNN 效率的方法 (PPT P12)
        - (1) 避免计算所有距离 (索引与近似)
        - (2) 减少样本数量 (数据集缩减)
    - 8.9 扩展知识：邻近图 (Proximity Graphs) (PPT P13)
    - 8.10 终极备考总结 (Next Steps)
- 第9章 K-Means 与层次聚类 (K-means and Hierarchical Clustering)
    - 9.1 K-Means 核心概览 (PPT P1-2)
        - (1) 核心问题
    - 9.2 直观理解：有损压缩视角 (PPT P3-6)
        - (1) 场景设定
        - (2) 两种思路对比
    - 9.3 K-Means 算法流程详解 (PPT P7-21)
        - (1) 算法步骤
        - (2) 潜在考题预测 (Exam Hacks)
    - 9.4 数学原理与优化目标 (PPT P22-31) [⚠️ 重点必考]
        - (1) 定义：畸变函数 (Distortion Function)
        - (2) 最小化畸变的推导
        - (3) 潜在考题预测 (Exam Hacks)
    - 9.5 收敛性与最优性 (PPT P32-36)
        - (1) 算法会终止吗？(Convergence)
        - (2) 会找到全局最优解吗？(Optimality)
    - 9.6 改进策略与参数选择 (PPT P37-39)
        - (1) 如何获得更好的结果?
        - (2) 如何选择 K 值？(Choosing k)
    - 9.7 常见应用 (PPT P40)
    - 9.8 层次聚类 (Hierarchical Clustering) (PPT P41-47)
        - (1) 算法流程 (Agglomerative / 自底向上)
        - (2) 簇间距离定义 (Similarity Measures)
        - (3) 评价
    - 9.9 总结：你应该掌握什么？(PPT P48)
- 第10章 聚类分析进阶 (Cluster Analysis)
    - 10.1 软聚类 (Soft/Fuzzy Clustering)
        - 10.1.1 硬聚类与软聚类的区别 (PPT P1-3)
        - 10.1.2 模糊C均值算法 (Fuzzy c-Means, FCM) (PPT P3-7)
    - 10.2 概率聚类与混合模型 (Probabilistic Clustering & Mixture Models)
        - 10.2.1 基本思想 (PPT P10-13)

        - 10.2.2 高斯混合模型 (GMM) 与 EM 算法 (PPT P14-20)
    - 10.3 自组织映射 (SOM: Self-Organizing Maps)
        - 10.3.1 基本概念与架构 (PPT P34-35)
        - 10.3.2 SOM 四大过程 (PPT P36-40) (⚠️ 流程重点)
        - 10.3.3 结果可视化 (PPT P42-45)
    - 10.4 基于网格与子空间的聚类 (Grid-based & Subspace)
        - 10.4.1 基本网格聚类 (PPT P52)
        - 10.4.2 子空间聚类：CLIQUE 算法 (PPT P53-61)
    - 10.5 基于密度的扩展算法 (DENCLUE & SNN)
        - 10.5.1 DENCLUE (基于核密度估计) (PPT P62-65)
        - 10.5.2 SNN (共享最近邻) 聚类 (PPT P92-101)
    - 10.6 基于图的聚类 (Graph-Based Clustering)
        - 10.6.1 基本概念 (PPT P66)
        - 10.6.2 CURE 算法 (Clustering Using REpresentatives) (PPT P67-73)
        - 10.6.3 CHAMELEON (变色龙) 算法 (PPT P74-91)
    - 10.7 算法综合对比 (Exam Summary) (PPT P105-114)
        - 10.7.1 K-Means vs. DBSCAN
        - 10.7.2 K-Means (MIN) vs. EM (GMM)
        - 10.7.3 CURE vs. CHAMELEON
    - 10.8 期末备考建议 (Final Tips)
- 第11章 EM算法与蒙特卡洛方法
    - 11.1 问题背景与核心难点 (PPT P3)
        - (1) 核心概念与定义
    - 11.2 EM算法通用框架 (PPT P4-P5)
        - (1) 算法核心思想
        - (2) 算法流程
        - (3) 潜在考题预测 (Exam Hacks)
    - 11.3 理论保证：为什么EM能增加似然？ (PPT P7-P13)
        - (1) 对数似然的分解 (Re-representing Log-likelihood)
        - (2) EM算法的几何解释 (PPT P8-P12)
        - (3) 收敛性证明 (Monotonicity)
    - 11.4 实例一：高斯混合模型 (GMM) (PPT P14-P22)
        - (1) 模型定义
        - (2) GMM的E步 (PPT P16-P18)
        - (3) GMM的M步 (PPT P19-P20)
        - (4) 与软K-Means的关系 (PPT P22)
    - 11.5 实例二：概率PCA (PPCA) (PPT P23-P30)
        - (1) 模型定义 (PPT P24)
        - (2) PPCA的E步 (PPT P26, P28)
        - (3) "配方法" (Completing the Square) (PPT P29)
        - (4) PPCA的M步 (PPT P27)
    - 11.6 总结与复习策略 (教授寄语)
    - 11.7 蒙特卡洛方法 (Homework 1 真题详解)
        - 11.7.1 蒙特卡洛求 π (Exercise 1) (PPT P409-420)
        - 11.7.2 蒙特卡洛定积分：简单函数 (Exercise 2) (PPT P421-429)
        - 11.7.3 蒙特卡洛定积分：复杂二重积分 (Exercise 3) (PPT P430-438)
        - 11.7.4 随机游走 (Random Walk) 路径规划 (Exercise 4) (PPT P439-447)
        - 11.7.5 系统可靠性仿真 (Exercise 5) (PPT P448-458)
- 第12章 线性降维：主成分分析 (PCA)
    - 12.1 动机与背景 (PPT P1-P5)
        - (1) 核心概念与定义
    - 12.2 视角一：最小化重构误差 (PPT P6-P17)
        - (1) 核心概念
        - (2) 核心公式与推导 (⚠️ 必考推导)
        - (3) 潜在考题预测 (Exam Hacks)
    - 12.3 视角二：最大化方差 (PPT P18-P21)
        - (1) 核心概念
        - (2) 核心公式
    - 12.4 视角三：奇异值分解 (SVD) (PPT P22-P25)
        - (1) SVD 定义与 PCA 的关系

        - (2) 潜在考题预测 (Exam Hacks)
    - 12.5 PCA 的应用与解释 (PPT P26-P30)
        - (1) 常见应用场景
    - 12.6 PCA 的局限性与扩展 (PPT P31-P35)
        - (1) PCA 的局限性
        - (2) 扩展算法（概念对比）
    - 12.7 考前复习总结 (Final Review Checklist)
- 第15章 集成学习 (Ensemble Learning)
    - 15.1 集成学习综述 (Ensemble Overview)
        - 15.1.1 核心概念与动机 (PPT P1-16)
    - 15.2 监督集成学习 (Supervised Ensemble)
        - 15.2.1 Bagging 与 随机森林 (PPT P28-30, P40-41)
        - 15.2.2 Boosting 与 AdaBoost (PPT P31-39) ⚠️ ⚠️ ⚠️
    - 15.3 无监督集成学习 (Clustering Ensemble)
        - 15.3.1 核心问题与挑战 (PPT P49-51)
        - 15.3.2 解决方法分类 (PPT P53)
    - 15.4 半监督与多视图集成 (Semi-supervised & Multi-view)
        - 15.4.1 多视图学习 (Multi-view Learning) (PPT P90-95)
        - 15.4.2 协同训练 (Co-Training) 算法 (PPT P95) ⚠️ 常考流程
        - 15.4.3 正则化框架 (Co-Regularization) (PPT P102-104)
    - 15.5 共识最大化 (Consensus Maximization) (PPT P107-118)
        - 15.5.1 问题定义
        - 15.5.2 目标函数 (PPT P114)
    - 15.6 期末考试预测 (Exam Hacks)
- 第16章 半监督学习 (Semi-Supervised Learning) 深度复习讲义
    - 16.1 半监督学习基础与动机 (PPT P1-18)
        - 1. 为什么需要半监督学习？ (Motivation)
        - 2. 定义与学习范式 (Definitions)
    - 16.2 基于分类器的方法 (Classifier-based Methods) (PPT P21-33)
        - 1. 生成式模型与 EM 算法 (EM Algorithm) (PPT P21-24)
        - 2. 自训练 (Self-Training / Yarowsky) (PPT P26)
        - 3. 协同训练 (Co-Training) (PPT P27-30)
        - 4. 转导支持向量机 (Transductive SVM / S3VM) (PPT P31-33)
    - 16.3 基于数据的方法 (Data-based Methods) (PPT P34-42)
        - 1. 流形假设 (Manifold Assumption) (PPT P35-37)
        - 2. 流形正则化 (Manifold Regularization) (⚠️ 必考推导 PPT P39-40)
        - 3. 调和混合 (Harmonic Mixtures) (PPT P42)
    - 16.4 信息正则化 (Information Regularization) (PPT P43-46)
        - 1. 核心思想
        - 2. 互信息 (Mutual Information)
        - 3. 优化目标 (Szummer & Jaakkola 2002)
    - 16.5 结构化预测的半监督学习 (SSL for Structured Prediction) (PPT P48-53)
        - 1. 结构分解 (Decomposition)
        - 2. 部件流形 (Parts Manifold)
        - 3. 修改后的优化目标 (PPT P52-53)
    - 16.6 Exam Hacks (考题预测与解题技巧)
- 第19章 反向传播算法 (Back-Propagation Algorithm)
    - 19.1 感知机与激活函数 (Perceptron & Activation Functions) (PPT P1-7, P36, P40)
        - (1) 核心概念与定义 (PPT P1-3, P8-9)
        - (2) 激活函数 (Activation Functions) (PPT P4-7, P36, P40)
    - 19.2 梯度下降算法基础 (Gradient Descent Basics) (PPT P8-14)
        - (1) 目标函数与优化
        - (2) 梯度推导 (重点：链式法则)
        - (3) 权重更新规则 (Update Rule)
        - (4) 潜在考题预测 (Exam Hacks)
    - 19.3 多层前馈网络结构与前向传播 (Multi-layer Networks & Forward Pass) (PPT P23-28)
        - (1) 符号定义 (对应 PPT P24 图示)
        - (2) 前向传播 (Forward Pass)
    - 19.4 反向传播算法推导 (Back-Propagation Derivation) (PPT P29-35, P38)
        - (1) 情况一：更新“隐层到输出层”的权重 W_{ij} (PPT P29)

        - (2) 情况二：更新“输入层到隐层”的权重 w_{jk} (PPT P30-31)
        - (3) 总结：通用的 BP 更新公式 (PPT P33)
        - (4) 算法完整流程 (PPT P38)
    - 19.5 BP 算法的收敛性与动量 (Convergence & Momentum) (PPT P39-44)
        - (1) 局部最小值 (Local Minima)
        - (2) 动量项 (Momentum) (PPT P40)
        - (3) 泛化能力 (Generalization) (PPT P41-42)
    - 19.6 神经网络的表达能力 (Expressive Capabilities) (PPT P45)
        - (1) 通用逼近定理 (Universal Approximation Theorem)
    - 19.7 经典案例分析 (Case Studies) (PPT P46-52)
        - (1) NETtalk (PPT P46-47)
        - (2) 其他案例 (PPT P48-52)
    - 19.8 终极复习建议 (Exam Hack Summary)
- 第20章 Word Embeddings (词嵌入)
    - 20.1 词的意义与表示 (Word Meaning & Representation)
        - 1. 传统词义表示及其局限性 (PPT P1-P7)
    - 20.2 离散符号 vs. 分布式表示 (Discrete vs. Distributed)
        - 1. 独热编码 (One-hot Representation) (PPT P8-P9)
        - 2. 分布式语义与词向量 (Word Vectors) (PPT P10-P12)
    - 20.3 Word2Vec 模型详解 (Word2Vec Overview)
        - 1. 算法框架 (PPT P13-P15)
    - 20.4 目标函数与梯度推导 (Objective Function & Gradients)
        - 1. 目标函数 (Objective Function) (PPT P16-P17)
        - 2. 预测概率计算：Softmax (PPT P17-P19)
        - 3. 参数与梯度推导 (PPT P20-P25)
    - 20.5 优化基础 (Optimization Basics)
        - 1. 梯度下降法 (Gradient Descent) (PPT P27-P28)
        - 2. 随机梯度下降 (SGD) (PPT P29)
    - 20.6 模型变体与后续 (More Details)
        - 1. 两种模型架构 (PPT P26)
        - 2. 训练效率优化
    - 全文总结与复习建议
- 第22章 自编码器 (Autoencoders)
    - 22.1 无监督学习与自编码器基础 (Introduction & Basics)
        - 22.1.1 监督学习 vs 无监督学习 (PPT P3-P10)
        - 22.1.2 传统自编码器架构 (Traditional Autoencoder) (PPT P12-P17)
        - 22.1.3 欠完备 vs 过完备 (Undercomplete vs Overcomplete) (PPT P18-P20)
    - 22.2 进阶架构：卷积与正则化 (Advanced Architectures)
        - 22.2.1 卷积自编码器 (Convolutional AE) (PPT P26-P29)
        - 22.2.2 稀疏自编码器 (Sparse Autoencoders) (PPT P30-P37) (⚠️ 必考重点)
        - 22.2.3 降噪自编码器 (Denoising Autoencoders, DAE) (PPT P38-P49) (⚠️ 核心考点)
        - 22.2.4 堆叠自编码器 (Stacked Autoencoders, SAE) (PPT P50-P55)
        - 22.2.5 收缩自编码器 (Contractive Autoencoders, CAE) (PPT P56-P61) (⚠️ 高难度数学考点)
    - 22.3 总结与对比 (Comparison) (PPT P62-P63)
        - 22.3.1 DAE vs CAE
    - 22.4 复习建议与解题策略
- 第23章 卷积神经网络
    - 23.1 神经网络基础回顾与CNN引入
        - 23.1.1 Mini-batch SGD 与 训练流程 (PPT P2-P3)
    - 23.2 卷积层 (Convolution Layer) —— 核心考点
        - 23.2.1 卷积层的运作机制 (PPT P9-P20)
        - 23.2.2 空间维度计算 (Spatial Dimensions) (PPT P22-P43) —— 必考计算题
    - 23.3 卷积层的神经元视角 (Brain View) (PPT P48-P51)
        - 23.3.1 局部连接与感受野
        - 23.3.2 参数共享 (Parameter Sharing)
    - 23.4 池化层 (Pooling Layer) (PPT P53-P56)
        - 23.4.1 核心概念
        - 23.4.2 最大池化 (Max Pooling)
    - 23.5 经典架构案例分析 (Case Studies) —— 综合大题重灾区
        - 23.5.1 LeNet-5 (PPT P59)

        - 23.5.2 AlexNet (PPT P60-P68) (⚠️ 必须掌握每一层的尺寸推导)
        - 23.5.3 VGGNet (PPT P70-P73)
        - 23.5.4 GoogLeNet (Inception) (PPT P74-P75)
        - 23.5.5 ResNet (深度残差网络) (PPT P76-P86)
    - 23.6 考题实战演练 (Exam Hacks)
        - 23.6.1 参数量计算 (计算题)
        - 23.6.2 感受野理解 (简答题)
        - 23.6.3 1x1 卷积的作用 (概念题)
- 第24章 变分自编码器 (Variational Autoencoders, VAE)
    - 24.1 背景与传统自编码器回顾 (PPT P1-P6)
        - 24.1.1 传统自编码器 (Autoencoders, AE) 的局限性
        - 24.1.2 VAE 的动机 (Motivation) (PPT P4, P11)
    - 24.2 信息论基础回顾 (Information Theory Recap) (PPT P8-P18)
        - 24.2.1 信息量与熵 (Entropy)
        - 24.2.2 KL 散度 (Kullback-Leibler Divergence) (PPT P16-18)
    - 24.3 VAE 的理论核心——从不可积到变分推断 (PPT P19-P26, P54-P60)
        - 24.3.1 隐变量模型的问题 (PPT P20-23)
        - 24.3.2 变分推断 (Variational Inference) (PPT P24-26)
        - 24.3.3 ELBO (证据下界) 的推导 (PPT P54-P60) ⚠️ 重点背诵
    - 24.4 VAE 的具体实现与训练 (PPT P61-P77)
        - 24.4.1 神经网络视角
        - 24.4.2 重参数化技巧 (Reparameterization Trick) (PPT P69-74) ⚠️ 必考
        - 24.4.3 高斯分布的 KL 散度计算 (PPT P75-77)
    - 24.5 VAE 的性质与应用 (PPT P39-P53, P78-P86)
        - 24.5.1 潜在空间的组织 (PPT P39-53)
        - 24.5.2 潜在空间操作 (Latent Space Arithmetic) (PPT P82-85)
    - 24.6 考试复习总结 (Exam Hacks)
        - 24.6.1 潜在考题预测
        - 24.6.2 必须掌握的数学符号
- 第25章 Attention Mechanism & Transformer
    - 25.1 基础回顾与序列模型演进 (PPT P1-P9)
        - 25.1.1 基础神经网络回顾 (PPT P3-P7)
        - 25.1.2 循环神经网络 (RNN) 与 LSTM (PPT P8-P9)
    - 25.2 Encoder-Decoder 与 Attention 的起源 (PPT P10-P16)
        - 25.2.1 Encoder-Decoder 模型 (PPT P10-P11)
        - 25.2.2 Attention 机制的引入 (PPT P12)
        - 25.2.3 图像描述生成 (Image Captioning) (PPT P13-P16)
    - 25.3 Transformer 核心架构 (PPT P17-P29)
        - 25.3.1 整体架构概览 (PPT P18-P20)
        - 25.3.2 Self-Attention 机制详解 (PPT P21-P23) —— ⚠️ 必考推导
        - 25.3.3 Multi-Head Attention (多头注意力) (PPT P24-P25)
        - 25.3.4 位置编码 (Positional Encoding) (PPT P26)
        - 25.3.5 Add & Normalize (PPT P27-P28)
    - 25.4 Decoder 细节与完整流程 (PPT P29-P32)
        - 25.4.1 Decoder 的特殊结构
        - 25.4.2 输出层 (PPT P30)
    - 25.5 训练、损失函数与评估 (PPT P33-P35)
        - 25.5.1 损失函数 (Loss Function) (PPT P33-P34)
        - 25.5.2 生成策略：Beam Search (集束搜索) (PPT P33)
        - 25.5.3 性能评估 (PPT P35)
    - 25.6 后续发展 (BERT vs GPT) (PPT P36)
        - 25.6.1 BERT
        - 25.6.2 GPT
    - 25.7 考前终极速记清单 (Cheat Sheet)
- 第26章 Representation Learning (表示学习)
    - 26.1 表示学习概论 (PPT P1-7)
        - 1. 什么是表示学习?
    - 26.2 基于迁移学习与自编码器的方法 (PPT P8-14)
        - 1. 基于迁移学习的方法 (Transfer Learning) (PPT P8-10)
        - 2. 自编码器 (Autoencoders) (PPT P12-13)

- 26.3 对比学习：SimCLR (PPT P15-21)
  - 1. SimCLR 核心机制 (PPT P15-17)
- 26.4 理论基础：InfoNCE与互信息 (PPT P22-25)
  - 1. 互信息 (Mutual Information) (PPT P22)
  - 2. InfoNCE 与互信息的联系 (PPT P23-25)
- 26.5 对比学习：MoCo (PPT P26-31)
  - 1. MoCo (Momentum Contrast) 的动机 (PPT P27)
  - 2. MoCo 架构与动量更新 (⚠️ 必考核心)
  - 3. MoCo v2 (PPT P29-30)
- 总结：SimCLR vs. MoCo (核心对比表)

第5章 多变量线性回归与逻辑回归 (Multivariate Linear Regression & Logistic Regression)

5.1 多变量线性回归 (Multivariate Linear Regression)

理论核心

多变量线性回归旨在寻找一个线性函数 $h_\theta(x) = \theta_0 + \theta_1 x_1 + ... + \theta_n x_n$，使得预测值与真实值之间的均方误差（MSE）最小。

- **模型形式**：$h_\theta(x) = \theta^T x$ (其中 $x_0 = 1$)。
- **优化方法**：
  - **梯度下降 (Gradient Descent, GD)**：利用所有样本计算梯度，更新参数。收敛稳定但计算量大。
  - **随机梯度下降 (Stochastic Gradient Descent, SGD)**：每次仅利用一个样本计算梯度。收敛速度快但路径震荡。

作业真题解析：Exercise One (Linear Regression)

题目背景
数据集包含广州海珠区的房价信息（50个训练样本）。

- **特征 (X)**：公寓面积 (平方米)、距离双鸭山职业技术学院的距离 (千米)。
- **标签 (Y)**：房价 (十亿元 RMB)。
- **任务**：建立多变量线性回归模型预测房价。

题目 (a)：模型参数与梯度下降训练

> **Q:** You need to use how many parameters to tune this linear regression model? Please use Gradient Descent to obtain the optimal parameters. Set iterations=1,500,000, learning rate=0.00015, initial values=0.0. Report training/testing error at every 100,000 iterations.

详解：

1. **参数数量**：
   需要 **3个参数** ($\theta_0, \theta_1, \theta_2$)。
   - θ_0：偏置项 (Bias/Intercept)。
   - θ_1：对应“公寓面积”的权重。
   - θ_2：对应“距离”的权重。
   - *注意*：在处理数据时，需要在特征矩阵 X 中添加一列全为1的列向量对应 θ_0。
2. **数据预处理（关键步骤）**：
   - 由于面积（如100 m^2）和距离（如5 km）的量纲差异巨大，直接训练会导致梯度下降难以收敛。**必须进行特征缩放（Feature Scaling/Normalization）**，例如将特征标准化为均值为0，方差为1。
3. **梯度下降算法实现逻辑**：
   - 损失函数 (Cost Function): $J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})^2$
   - 更新规则: $\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$
   - 按照题目要求：$\alpha = 0.00015$，迭代 1,500,000 次。
4. **预期结果分析**：
   - 随着迭代次数增加（10w, 20w...），**Training Error 应逐渐下降并趋于平稳**。
   - **Testing Error** 也应下降，但如果在极高迭代次数下 Training Error 继续下降而 Testing Error 上升，则说明出现了**过拟合 (Overfitting)**。但由于只有2个特征且样本量少，线性模型大概率会收敛到一个稳定值，过拟合风险较低。

题目 (b)：学习率 (Learning Rate) 的影响

> **Q:** Change the learning rate to different values (e.g., 0.0002). What can you find?

考点标记：学习率对收敛性的影响。

详解：

- **如果学习率过大 (e.g., > 0.0002)**：损失函数可能不会下降，反而会**发散 (Diverge)** 或在最小值附近剧烈震荡，导致 Error 变成 `NaN` 或无穷大。
- **如果学习率过小**：收敛速度极慢，需要更多的迭代次数才能达到同样的 Error 水平。
- **结论**：学习率 α 需要精细调节。在实验中，若增加到 0.0002 导致误差爆炸，说明该学习率超出了梯度下降的稳定范围。

题目 (c)：随机梯度下降 (SGD)

> **Q:** Can you use Stochastic Gradient Descent to get the optimal parameters? Plot errors and compare with Exercise 1。

考点标记：GD 与 SGD 的对比。

详解：

- **算法差异**：SGD 每次更新只用 1 个样本 (i)：

$$\theta_j := \theta_j - \alpha(h_\theta(x^{(i)}) - y^{(i)})x_j^{(i)}$$

- **实验对比结论**：
  i. **收敛速度**：SGD 在初期 loss 下降非常快（以 epoch 为单位），通常比 Batch GD 快得多。
  ii. **曲线平滑度**：Exercise 1 (GD) 的误差曲线是平滑下降的；Exercise 2 (SGD) 的误差曲线会有**剧烈震荡 (Fluctuations)**，因为它试图拟合每一个单独的样本，而不是整体趋势。
  iii. **最终解**：SGD 最终会在最优解附近游走（walk around），而不会像 GD 那样精确停在极值点，但通常精度已足够。

5.2 逻辑回归与极大似然估计 (Logistic Regression & MLE)

理论核心

逻辑回归用于分类问题，使用 Sigmoid 函数 $g(z) = \frac{1}{1+e^{-z}}$ 将输出映射到 (0,1)。

- **假设函数**：$h_\theta(x) = g(\theta^T x) = P(y=1|x;\theta)$。
- **目标函数**：我们不使用 MSE，而是最大化**对数似然函数 (Log Likelihood)**。

作业真题解析：Exercise Two (Part A & B)

题目背景
数据集包含6个特征，最后一列为类别标签（0或1）。

题目 (a)：对数似然函数推导

> **Q:** Write down a formula for the conditional log likelihood of the training data in terms of class labels $y^{(i)}$, features $x^{(i)}$, and parameters w。

考点标记：逻辑回归的目标函数定义。

详解：
假设样本独立同分布，似然函数 $L(w) = \prod_{i=1}^{m} P(y^{(i)}|x^{(i)};w)$。
由于 $P(y=1|x) = h_w(x)$ 且 $P(y=0|x) = 1 - h_w(x)$，可以写为：

$$P(y|x) = (h_w(x))^y(1-h_w(x))^{1-y}$$

取对数得到**对数似然函数 (Log Likelihood)**：

$$l(w) = \log L(w) = \sum_{i=1}^{m} \left[y^{(i)} \log(h_w(x^{(i)})) + (1-y^{(i)}) \log(1-h_w(x^{(i)})) \right]$$

其中 $h_w(x^{(i)}) = \frac{1}{1+e^{-w^T x^{(i)}}}$。

题目 (b)：梯度推导

> **Q:** Compute the partial derivative of the objective function with respect to w_0 and arbitrary w_j. Show all derivatives in finite sum form。

考点标记：链式法则与梯度计算。

详解：
我们要对 $l(w)$ 求偏导。利用 Sigmoid 函数的性质 $g'(z) = g(z)(1-g(z))$。

对于单个样本的导数推导：

$$\frac{\partial}{\partial w_j}[y\log(g(z))+(1-y)\log(1-g(z))]=(y-g(z))x_j$$

（这里 $z=w^Tx$）。

将所有样本求和，得到最终形式：

$$\frac{\partial l}{\partial w_j}=\sum_{i=1}^{m}\left(y^{(i)}-h_w(x^{(i)})\right)x_j^{(i)}$$

- 对于 w_0 (截距项)，$x_0^{(i)}=1$，故：$\frac{\partial l}{\partial w_0}=\sum_{i=1}^{m}(y^{(i)}-h_w(x^{(i)}))$。
- 这就是**梯度上升 (Gradient Ascent)** 的更新方向。

5.3 逻辑回归的训练与评估

理论核心

- **梯度上升**：因为我们要**最大化**似然函数，所以参数更新是 $w:=w+\alpha\nabla l(w)$（注意是加号）。
- **学习曲线 (Learning Curves)**：用于诊断偏差（Bias）和方差（Variance）。
  - **High Bias (欠拟合)**：训练集少时误差低，增加数据后训练误差升高，测试误差也高，两者收敛且接近。
  - **High Variance (过拟合)**：训练误差极低，测试误差高，两者之间有很大 Gap。

作业真题解析：Exercise Two (Part C - F)

题目 (c), (d), (e)：训练与收敛分析

> **Q:** Train logistic regression classifier. Report misclassified examples. Plot objective function value vs. iterations using Stochastic Gradient Ascent. Report iterations to converge。

详解：

1. **训练策略**：使用 (b) 中推导的梯度公式进行 SGD 更新。

$$w_j:=w_j+\alpha(y^{(i)}-h_w(x^{(i)}))x_j^{(i)}$$

2. **预测**：计算 $p=h_w(x)$。若 $p\geq 0.5\rightarrow\hat{y}=1$，否则 $\hat{y}=0$。
3. **收敛图 (Plot)**：
   - X轴：迭代次数，Y轴：对数似然值 $l(w)$。
   - **预期形态**：曲线应呈现**上升趋势**（因为是最大化似然），最终趋于平缓。由于是 SGD，曲线会有局部锯齿状震荡。
4. **错误率**：统计测试集中预测标签与真实标签不一致的数量。

题目 (f)：学习曲线 (Learning Curve) 分析

> **Q:** For $k\in\{10,20,...,400\}$, choose random subset of size k. Re-train and calculate train error and test error. Plot Train Error (Blue) and Test Error (Red) against k. Describe and explain behavior。

考点标记：学习曲线分析与泛化能力。

详解：
这是一道非常经典的分析题，预期图像与解释如下：

- **图像描述**：
  - **蓝色线 (Training Error)**：
    - 当 k 很小 (e.g., 10) 时，模型很容易“死记硬背”这几个样本，因此**训练误差接近 0**。
    - 随着 k 增大，数据变多，模型很难完美拟合所有噪点，**训练误差会逐渐上升**。
  - **红色线 (Testing Error)**：
    - 当 k 很小是，模型严重过拟合（泛化能力差），**测试误差非常高**。
    - 随着 k 增大，模型学到了更普遍的规律，泛化能力增强，**测试误差逐渐下降**。
- **最终趋势**：
  - 随着 $k\rightarrow 400$，红线下降，蓝线上升，两条线会逐渐**靠近 (Converge)**。
  - **解释**：增加训练数据通常能减轻过拟合，提高模型在未见数据上的表现，但会略微牺牲在训练集上的拟合精度。

第6章 决策树 (Decision Tree)

6.1 机器学习任务分类与基本概念 (PPT P1-3)

(1) 学习任务分类

在进入决策树之前，我们需要明确它在机器学习版图中的位置（这也是基本概念题的高频点）：

- **监督学习 (Supervised Learning)**：训练数据拥有标记信息 (Labels)。
  - **分类 (Classification)**：预测离散值（如：好瓜/坏瓜）。
  - **回归 (Regression)**：预测连续值（如：西瓜的含糖率）。
  - *数据形式*：$\{(x_1, y_1), (x_2, y_2), ..., (x_m, y_m)\}$。
- **无监督学习 (Unsupervised Learning)**：训练数据没有标记信息。
  - **聚类 (Clustering)**：将数据自动分组。
- **半监督学习 (Semi-supervised Learning)**：介于两者之间，输入数据部分被标识，部分未被标识。利用未标识数据来辅助学习。

(2) 决策树模型概述

- **定义**：一种树形结构，基于特征属性对样本进行分类或回归。
- **常见算法**：ID3, C4.5, CART (Classification And Regression Tree)。
- **结构**：
  - **根结点 (Root Node)**：包含样本全集。
  - **内部结点 (Internal Node)**：对应一个属性测试（例如："色泽=？"）。
  - **叶结点 (Leaf Node)**：对应决策结果（例如："好瓜"）。

6.2 决策树基本流程：Hunt 算法 (PPT P4-5)

这是决策树构建的骨架，考试中常考察**递归停止的条件**。

(1) 算法核心机制

决策树的生成是一个递归过程，函数定义为 `TreeGenerate(D, A)`，其中 D 是训练集，A 是属性集。

(2) 递归返回的三种情形 (⚠️ 逻辑考点)

在递归过程中，有三种情况会导致当前结点变为叶结点（停止生长）：

1. **当前结点包含的样本全属于同一类别**：
   - 无需划分，直接标记为该类叶结点。
2. **属性集为空 ($A = \emptyset$) 或 D 中样本在 A 上取值相同**：
   - 无法划分。
   - **处理策略**：将当前结点标记为叶结点，类别设定为 D **中样本数最多** 的类。（利用**后验分布**）
3. **当前结点包含的样本集为空 ($D_v = \emptyset$)**：
   - 即在某个属性值上没有对应的样本。
   - **处理策略**：同样标记为叶结点，但类别设定为 **父结点中样本数最多** 的类。（利用**先验分布**）

(3) Exam Hacks: 潜在考题

> - **Q**: 在决策树生成算法中，情形(2)和情形(3)虽然都选"样本最多的类"，有何本质区别?
> - **A**: **情形(2)** 是基于当前结点的数据分布（后验），因为特征用光了也分不开；**情形(3)** 是基于父结点的数据分布（先验），因为当前分支根本没有数据，只能参考父辈的统计规律。这是"后验"与"先验"的区别。

6.3 划分选择：纯度度量 (PPT P7-17)

这是本章**最核心的计算与推导模块**。决策树的关键在于：如何选择最优划分属性？目标是让结点的"纯度 (Purity)"越来越高。

(1) 信息增益 (Information Gain) —— ID3算法

适用场景：ID3 决策树算法。

- **信息熵 (Information Entropy)**：
  度量样本集合纯度的指标。假定样本集合 D 中第 k 类样本所占比例为 p_k ($k = 1, 2, ..., |\mathcal{Y}|$):

$$Ent(D) = -\sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k$$

  - *性质*：$Ent(D)$ 越小，纯度越高。当只有一类时，$Ent(D) = 0$；当各类均匀分布时，熵最大。
- **信息增益 (Information Gain)**：
  考虑属性 a 有 V 个可能的取值 $\{a^1, ..., a^V\}$。使用属性 a 对 D 进行划分，产生 V 个分支结点，第 v 个分支结点包含了 D 中在属性 a 上取值为 a^v 的样本，记为 D^v。

$$Gain(D, a) = Ent(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} Ent(D^v)$$

  - *直观理解*：划分前的信息熵 - 划分后加权平均的信息熵。增益越大，说明通过该属性划分获得的“纯度提升”越大。
  - **缺陷**：信息增益对**可取值数目较多**的属性有所偏好（例如“编号”属性，每个样本一个编号，纯度极高但无泛化意义）。

(2) 增益率 (Gain Ratio) —— C4.5算法

目的：解决 ID3 偏好“多值属性”的问题。

- **固有值 (Intrinsic Value)**：

$$IV(a) = -\sum_{v=1}^{V} \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

  - *含义*：属性 a 的取值数目越多（V越大），$IV(a)$ 通常越大。它充当分母来进行惩罚。
- **增益率公式**：

$$Gain_ratio(D, a) = \frac{Gain(D, a)}{IV(a)}$$

- **C4.5 的启发式策略** (⚠️ 细节考点)：
  C4.5 并不是直接选择增益率最大的属性（因为增益率偏好取值数目较少的属性）。**策略流程**：
  i. 先从候选属性中找出 **信息增益** 高于平均水平的属性。
  ii. 再从中选择 **增益率** 最高的。

(3) 基尼指数 (Gini Index) —— CART算法

适用场景：CART (Classification and Regression Tree)。

- **基尼值 (Gini Value)**：
  反映了从数据集 D 中随机抽取两个样本，其类别标记不一致的概率。

$$Gini(D) = \sum_{k=1}^{|\mathcal{Y}|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|\mathcal{Y}|} p_k^2$$

  - *性质*：$Gini(D)$ 越小，纯度越高。
- **基尼指数 (Gini Index)**：
  属性 a 的基尼指数定义为：

$$Gini_index(D, a) = \sum_{v=1}^{V} \frac{|D^v|}{|D|} Gini(D^v)$$

  - **选择准则**：选择使得划分后基尼指数 **最小** 的属性作为最优划分属性：$a_* = \arg\min_{a \in A} Gini_index(D, a)$。

(4) Exam Hacks: 计算题考点

> - **Q**: 给定西瓜数据集（如 PPT P11），计算“色泽”的信息增益。
> - **解题步骤** (不许用计算器，通常会给 $\log_2$ 的值或只列式子)：
>   i. 计算根结点熵 $Ent(D)$：统计正负例比例。
>   ii. 按“色泽”分组（青绿、乌黑、浅白），统计每组的正负例。
>   iii. 计算每组的熵 $Ent(D^v)$。
>   iv. 计算加权和 $\sum \frac{|D^v|}{|D|} Ent(D^v)$。
>   v. 相减得到 $Gain$。

6.4 剪枝处理 (Pruning) (PPT P18-24)

核心目的：解决 **过拟合 (Overfitting)** 问题。

- **过拟合**：学习能力过强，把训练样本自身的特点（噪声）当成了所有潜在样本的一般性质。
- **欠拟合**：学习能力低下，一般性质还没学好。

(1) 预剪枝 (Pre-pruning)

- **机制**：在决策树生成过程中，对每个结点在划分前先进行估计。若当前结点的划分不能带来决策树 **泛化性能提升**（通常使用**验证集**精度判断），则停止划分，标记为叶结点。
- **流程** (结合 PPT P21)：
  i. 计算划分前的验证集精度。
  ii. 假设按照某属性划分，生成子结点，计算划分后的验证集精度。
  iii. 若 **划分后精度 > 划分前精度** $\rightarrow$ 允许划分；否则 $\rightarrow$ 禁止划分。
- **优缺点**：
  - **优点**：降低过拟合风险，显著减少训练和测试的时间开销。
  - **缺点**：基于“贪心”策略，可能导致 **欠拟合**（因为某些分支虽然当前划分不能提升精度，但后续划分可能显著提升，预剪枝直接把路堵死了）。

(2) 后剪枝 (Post-pruning)

- **机制**：先从训练集生成一棵完整的决策树，然后 **自底向上** 地对非叶结点进行考察。若将该结点对应的子树替换为叶结点能带来泛化性能提升，则进行替换（剪枝）。
- **流程** (结合 PPT P23)：
  i. 生成完全树。
  ii. 找到最底层的非叶结点，计算剪枝前（保留子树）的验证集精度。
  iii. 计算剪枝后（替换为叶结点）的验证集精度。
  iv. 若 **剪枝后精度** $\geq$ **剪枝前精度** $\rightarrow$ 执行剪枝。
- **优缺点**：
  - **优点**：欠拟合风险很小，泛化能力通常优于预剪枝。
  - **缺点**：训练时间开销大（需要先生成全树，再回头检查）。

6.5 连续值与缺失值处理 (PPT P26-31)

(1) 连续属性离散化 (C4.5 采用二分法)

决策树只能处理离散属性，对于连续属性（如密度、含糖率），需要转化为离散判断。

- **算法流程**：
  i. **排序**：将样本在连续属性 a 上的 n 个不同取值从小到大排序：$\{a^1, a^2, ..., a^n\}$。
  ii. **确定候选划分点**：相邻两个取值的中位点作为候选划分点。

$$T_a = \left\{ \frac{a^i + a^{i+1}}{2} \mid 1 \leq i \leq n-1 \right\}$$

  集合中包含 $n-1$ 个元素。
  iii. **计算增益**：像离散属性一样考察每个划分点 t。

$$Gain(D, a) = \max_{t \in T_a} Gain(D, a, t)$$

$$Gain(D, a, t) = Ent(D) - \sum_{\lambda \in \{-,+\}} \frac{|D_t^\lambda|}{|D|} Ent(D_t^\lambda)$$

  其中 D_t^- 是 a 值 $\leq t$ 的样本，D_t^+ 是 a 值 $> t$ 的样本。
- **关键区别**：与离散属性不同，若当前结点划分属性为连续属性，该属性在后代结点中 **仍可再次被选作划分属性**（因为可以切分不同的区间）。

6.6 多变量决策树 (Multivariate Decision Tree) (PPT P32-34)

(1) 分类边界的几何解释

- **单变量决策树 (Univariate)**：
  - 每个非叶结点只测试一个属性（如 $Density \leq 0.381$）。
  - 形成的分类边界是 **轴平行 (Axis-parallel)** 的，即与坐标轴平行的分段直线。
  - *缺点*：当真实分类边界倾斜时，需要非常复杂的阶梯状近似，导致树过于庞大（图 4.12）。

(2) 多变量决策树

- **核心思想**：
  - 非叶结点不再是针对单个属性，而是对属性的 **线性组合** 进行测试。
  - 即建立一个线性分类器：

$$\sum_{i=1}^{d} w_i a_i = t$$

  - 若 $\sum w_i a_i \leq t$ 走左支，否则走右支。
- **几何意义**：
  - 分类边界可以是 **斜的 (Oblique)**，不再局限于轴平行。
  - 模型更加简洁，但计算线性组合参数 w_i 的开销更大。

6.7 最终复习总结 (Exam Hacks)

基于 PPT 和考试情报，请重点复习以下推导和逻辑：

1. **纯度计算**：必须熟练默写 $Entropy$, $Gain$, $Gain_ratio$, $Gini$ 四个公式，并清楚它们分别是哪个算法（ID3, C4.5, CART）的核心。
2. **Hunt 算法递归停止条件**：特别是当特征用尽或样本为空时，类别是如何判定的（一个看自己，一个看爸爸）。
3. **剪枝逻辑**：预剪枝看验证集是否提升决定是否展开；后剪枝看验证集是否提升决定是否收缩。预剪枝快但易欠拟合，后剪枝慢但泛化好。
4. **连续值处理**：记得是“排序”后取“中位点”，且连续属性可以“重复使用”。

第7章 支持向量机 (SVM) 深度解析

7.1 SVM 概论与线性分类器 (PPT P1-11)

7.1.1 核心概念 (PPT P1-10)

- **支持向量机 (SVM)**：一种基于统计学习理论的二分类模型 [cite: 4]。
- **核心思想**：在特征空间中寻找一个**超平面 (Hyperplane)**，使得正负样本之间的**间隔 (Margin)** 最大化 [cite: 190, 191]。
- **历史地位**：在深度学习爆发前，SVM 是最成功的分类算法，手写数字识别错误率仅 1.1%，与 LeNet 4 相当 [cite: 8]。它不仅是一个算法，更是“核方法”的代表 [cite: 9]。

7.1.2 线性分类器模型

- **决策函数**：

$$f(x, w, b) = \text{sign}(w \cdot x + b)$$

  [cite: 24]
  - w (Weight Vector)：法向量，决定超平面的方向 [cite: 25]。
  - b (Bias)：偏置，决定超平面与原点的距离 [cite: 24]。
- **几何直观**：
  - 超平面方程：$w \cdot x + b = 0$ [cite: 145]。
  - $f(x) > 0$ 判为正类 (+1)，$f(x) < 0$ 判为负类 (-1) [cite: 19, 20]。

7.2 间隔 (Margin) 的计算与原始问题 (PPT P12-17)

7.2.1 点到超平面的距离 (PPT P12-15)

⚠️ **必考推导**：这是 SVM 的几何基石。

- **公式**：
  对于任意样本点 x，其到超平面 $w \cdot x + b = 0$ 的几何距离为：

$$d(x) = \frac{|w \cdot x + b|}{||w||_2} = \frac{|w \cdot x + b|}{\sqrt{\sum w_i^2}}$$

  [cite: 164]
- **向量投影证明 (PPT P14-15)** [cite: 167-186]：
  i. 设 $P(x_0, y_0)$ 是平面外一点，$Q(x_1, y_1)$ 是平面上任意一点（满足 $ax_1 + by_1 + c = 0$）[cite: 170]。
  ii. 距离 d 等于向量 $\vec{QP}$ 在法向量 n 上的投影长度 [cite: 173]。
  iii. 投影公式：

$$d = \frac{|\vec{QP} \cdot n|}{||n||}$$

  [cite: 180]
  iv. 展开分子：$\vec{QP} \cdot n = a(x_0 - x_1) + b(y_0 - y_1) = ax_0 + by_0 - (ax_1 + by_1)$ [cite: 184, 185]。
  v. 因为 Q 在线上，故 $-(ax_1 + by_1) = c$ [cite: 186]。
  vi. 代入得证：$d = \frac{|ax_0 + by_0 + c|}{\sqrt{a^2 + b^2}}$ [cite: 185]。

7.2.2 最大间隔分类器的原始问题 (Primal Problem) (PPT P16-17)

- **间隔的定义**：
  - **函数间隔 vs 几何间隔**：为了消除缩放影响，我们强制支持向量满足 $|w^T x + b| = 1$ [cite: 208]。
  - 此时，正负超平面分别为 $w^T x + b = 1$ 和 $w^T x + b = -1$ [cite: 196, 199]。
  - **Margin (间隔宽度)**：两个超平面之间的距离为 $\frac{2}{||w||}$ [cite: 195]。
- **优化目标构建**：
  - **目标**：最大化间隔 $\frac{2}{||w||}$ $\Leftrightarrow$ 最小化 $\frac{1}{2}||w||^2$（为了凸优化方便求导）[cite: 212]。
  - **约束**：所有样本点必须被正确分类且在间隔外：

$$y_i(w^T x_i + b) \geq 1, \quad \forall i$$

  [cite: 206]
  (注：$y_i \in \{+1, -1\}$) [cite: 204]

7.3 优化理论与拉格朗日乘子法 (PPT P18-73)

7.3.1 核心数学工具

- **对偶性 (Duality)**：原问题 (Min) 难解时，转为对偶问题 (Max) 求解 [cite: 229, 258]。SVM 满足强对偶性 (Strong Duality)，即 $P - D = 0$ [cite: 282]。
- **拉格朗日乘子法**：用于解决带约束的优化问题 [cite: 442]。核心思想是寻找目标函数梯度 ∇f 与约束函数梯度 ∇g 平行的点，即 $\nabla f(x, y) = \lambda \nabla g(x, y)$ [cite: 703, 716]。

7.3.2 经典例题演示 (PPT P62-65)

- **问题**：最小化 $f(x, y) = x^2 + y^2$，约束条件 $g(x, y) = x + y - 1 = 0$ [cite: 733, 734]。
- **步骤**：
  i. 构造 Lagrangian：$L(x, y, \lambda) = x^2 + y^2 - \lambda(x + y - 1)$ [cite: 739]。
  ii. 求梯度并令为 0 [cite: 751]：
    - $2x - \lambda = 0 \Rightarrow x = \lambda/2$
    - $2y - \lambda = 0 \Rightarrow y = \lambda/2$
    - $-x - y + 1 = 0 \Rightarrow x + y = 1$
  iii. 联立求解：$\frac{\lambda}{2} + \frac{\lambda}{2} = 1 \Rightarrow \lambda = 1$ [cite: 755]。
  iv. 得到解：$x = 0.5, y = 0.5$ [cite: 754]。

7.4 SVM 对偶问题完整推导 (PPT P74-93)

⚠️ **红色警报**：这是考试中推导题的**最高频考点**。请务必能够默写以下全过程。

7.4.1 Step 1: 构造拉格朗日函数 (The Lagrangian)

将约束 $y_i(w^T x_i + b) \geq 1$ 改写为 $1 - y_i(w^T x_i + b) \leq 0$ [cite: 941]。引入拉格朗日乘子 $\alpha_i \geq 0$：

$$L(w, b, \alpha) = \frac{1}{2}||w||^2 + \sum_{i=1}^{m} \alpha_i (1 - y_i(w^T x_i + b))$$

[cite: 938]

7.4.2 Step 2: 求解极小值 (Minimize L w.r.t w, b)

根据对偶性，先求 $\min_{w,b} L$。令偏导为 0：

1. **对 w 求导**：

   $$\frac{\partial L}{\partial w} = w - \sum_{i=1}^{m} \alpha_i y_i x_i = 0 \quad \Rightarrow \quad w = \sum_{i=1}^{m} \alpha_i y_i x_i$$

   [cite: 945, 952]
   (物理意义：权重向量 w 是支持向量的线性组合) [cite: 1008]
2. **对 b 求导**：

   $$\frac{\partial L}{\partial b} = -\sum_{i=1}^{m} \alpha_i y_i = 0 \quad \Rightarrow \quad \sum_{i=1}^{m} \alpha_i y_i = 0$$

   [cite: 945, 953]

7.4.3 Step 3: 导出对偶问题 (The Dual Problem)

将 w 的表达式代回 L 中消去 w 和 b [cite: 956]：

$$L = \frac{1}{2}(\sum \alpha_i y_i x_i)^T (\sum \alpha_j y_j x_j) + \sum \alpha_i - \sum \alpha_i y_i (\sum \alpha_j y_j x_j)^T x_i - b \sum \alpha_i y_i$$

利用 $\sum \alpha_i y_i = 0$，化简得最终对偶形式：

- **目标函数 (Maximize)**：

  $$W(\alpha) = \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j (x_i^T x_j)$$

  [cite: 957, 990]
- **约束条件**：
  i. $\alpha_i \geq 0$ [cite: 991]
  ii. $\sum_{i=1}^{m} \alpha_i y_i = 0$ [cite: 994]

7.4.4 Step 4: KKT 条件与稀疏性 (PPT P89)

最优解必须满足 **互补松弛条件 (Complementary Slackness)**：

$$\alpha_i (1 - y_i(w^T x_i + b)) = 0$$

[cite: 941]

- 若 $\alpha_i > 0$，则必须有 $y_i(w^T x_i + b) = 1$，该样本为**支持向量** [cite: 979, 1010]。
- 若样本不在边界上，则 $\alpha_i = 0$ [cite: 978]。这就是 SVM 的**稀疏性** [cite: 1009]。

7.5 软间隔与正则化 & 作业真题解析 (PPT P94-95)

7.5.1 理论基础：软间隔 (Soft Margin)

- **动机**：为了容忍噪声和异常点，允许部分样本违反间隔约束 [cite: 1037]。

- **松弛变量**：引入 $\xi_i \geq 0$，约束变为 $y_i(w^T x_i + b) \geq 1 - \xi_i$ [cite: 1054]。
- **原始目标函数 (Primal Objective)**：

$$\min_{w,b,\xi} \frac{1}{2}||w||^2 + C\sum_{i=1}^{n} \xi_i$$

[cite: 1058]
  - C：正则化参数 (Trade-off parameter)。C 越大，对错误惩罚越重（Hard Margin）；C 越小，容忍度越高（防止过拟合）[cite: 1059]。

7.5.2 🎯 作业真题解析 (对应 Homework 4)

题目背景：
作业要求使用 **SGD (随机梯度下降)** 训练 SVM [cite: 1153]，这就不能用上面的对偶问题 (QP) 求解了，而必须直接优化**原始问题**。这是一个非常重要的考点：**SVM 的两种解法**。

题目 (Source 2329)：

> **Gradient of SVM**[cite: 1156]:
> $$\nabla_a = \begin{cases} \lambda a & \text{if } y_k(a^T x_k + b) \geq 1 \\ \lambda a - y_k x_k & \text{otherwise} \end{cases}$$ [cite: 1157]
> $$\nabla_b = \begin{cases} 0 & \text{if } y_k(a^T x_k + b) \geq 1 \\ -y_k & \text{otherwise} \end{cases}$$ [cite: 1157]
> *(注：作业中的 a 即我们讲义中的 w，λ 对应正则项系数)*

教授的深度推导 (必看)：
这道题其实是在让你对 **Hinge Loss** 求导。我们来还原这个公式的来源。

1. **损失函数重写**：
   我们将软间隔优化目标 $\min \frac{1}{2}||w||^2 + C\sum \xi_i$ 改写为无约束形式（引入 Hinge Loss）：

$$J(w,b) = \frac{\lambda}{2}||w||^2 + \sum_{i=1}^{n} \max(0, 1 - y_i(w^T x_i + b))$$

   (这里 $\lambda \propto \frac{1}{C}$ 是正则化系数)
2. **求梯度 (对单样本 x_k, y_k)**：
   我们需要计算 ∇J。
   - **情况 1：分类正确且在间隔外** ($y_k(w^T x_k + b) \geq 1$)
     - 此时 $\max(0, \dots)$ 取值为 0，Loss 为 0。
     - 梯度只剩下正则项：$\nabla_w = \frac{\partial}{\partial w}(\frac{\lambda}{2}||w||^2) = \lambda w$。
     - 对 b 的梯度：$\nabla_b = 0$。
     - **这与作业公式第一行一致！**
   - **情况 2：分类错误或在间隔内** ($y_k(w^T x_k + b) < 1$)
     - 此时 $\max(0, \dots)$ 取值为 $1 - y_k(w^T x_k + b)$。
     - 对 w 求导：$\nabla_w = \lambda w + \frac{\partial}{\partial w}(1 - y_k w^T x_k) = \lambda w - y_k x_k$。
     - 对 b 求导：$\nabla_b = \frac{\partial}{\partial b}(1 - y_k b) = -y_k$。
     - **这与作业公式第二行一致！**

考点总结：
如果考试问“如何用梯度下降训练 SVM？”或者“写出 SVM 的 Hinge Loss 及其梯度”，请直接默写上述推导。

7.6 核技巧 (Kernel Trick) (PPT P96-102)

7.6.1 为什么要用核？(PPT P97)

- **问题**：数据在低维输入空间线性不可分 [cite: 1066]。
- **思路**：通过映射 $\phi(x)$ 将数据映射到高维特征空间，使其线性可分 [cite: 1065, 1124]。

7.6.2 核技巧 (The Kernel Trick) (PPT P98-99)

- **痛点**：高维向量 $\phi(x)$ 维度可能无限高 [cite: 1091]，直接计算 $\phi(x)^T\phi(z)$ 极其困难 [cite: 1089]。
- **定义**：如果存在函数 $K(x,z)$ 使得 $K(x,z) = \phi(x)^T\phi(z)$ [cite: 1101]，我们就不需要显式计算 $\phi(x)$，直接在低维计算 K 即可 [cite: 1109, 1111]。
- **联系**：对偶问题中数据只以内积形式 $x_i^T x_j$ 出现 [cite: 1098]，这正是应用核函数的完美场景。

7.6.3 常见核函数 (PPT P101)

- **多项式核 (Polynomial)**：$K(x,y) = (x^T y + 1)^d$ [cite: 1123]
- **高斯核 (RBF)**：$K(x,y) = \exp(-\frac{||x-y||^2}{2\sigma^2})$ (最常用，对应无限维) [cite: 1123]

7.7 教授的考前总结 (Final Remarks)

同学，请务必理清这两条线索，考试极有可能分别考察：

1. **理论线 (PPT 重点)**：
   - 原始问题 (Min w^2) $\rightarrow$ 拉格朗日函数 $\rightarrow$ 对偶问题 (Max α) $\rightarrow$ KKT 条件。
   - 这条线对应**核方法**和**小样本**场景。
2. **实战线 (作业 重点)**：
   - Hinge Loss $\rightarrow$ 原始目标函数 $\rightarrow$ 计算梯度 $\rightarrow$ SGD 迭代。
   - 这条线对应**线性 SVM** 和 **大规模数据**（如作业中的 Adult 数据集）。

第8章 分类算法：K-最近邻 (KNN)

8.1 基于实例的分类器 (Instance Based Classifiers) (PPT P1-P2)

(1) 核心概念与定义

- **基于实例的学习 (Instance-Based Learning)**：
  - *定义*：这类算法不显式地从训练数据中学习一个通用的函数模型（如 $w^T x + b$），而是直接把训练样本“存储”起来。当需要预测新样本时，直接利用存储的样本进行匹配 [cite: 5, 8, 9]。
  - *直观理解*：这是一种“死记硬背”或“类比学习”的方法，不做归纳总结，遇到问题直接查“题库”。

(2) 两种典型方法的对比

- **机械式学习器 (Rote-learner)**：
  - *机制*：记住所有的训练数据 [cite: 7, 8]。
  - *预测逻辑*：只有当新数据的属性与库里的某条记录**完全精确匹配**时，才给出分类结果 [cite: 9]。
  - *局限性*：泛化能力几乎为零，无法处理未见过的数据。
- **最近邻 (Nearest Neighbor)**：
  - *机制*：同样存储训练数据，但在预测时更灵活 [cite: 10, 11]。
  - *预测逻辑*：利用 k 个**“最近”**（最相似）的点的类别来推断新数据的类别 [cite: 11]。
  - *核心思想*：相似的输入往往产生相似的输出。

8.2 KNN 算法核心机制 (PPT P3-P5)

(1) 核心思想 (Duck Test)

PPT 引用了那句名言：“如果它走起来像鸭子，叫起来像鸭子，那它大概率就是一只鸭子” [cite: 16]。

- **在 KNN 中**：如果你周围最近的 k 个邻居大多数是“正类”，那你大概率也是“正类”。

(2) 算法的三大要素 (PPT P4) (⚠️ 考试必背)

要实现 KNN 分类，必须具备以下三个条件 [cite: 39]：

1. **带标签的记录集合 (The set of labeled records)**：即训练集 [cite: 40]。
2. **距离度量 (Distance Metric)**：用于计算记录之间相似度的数学公式（如欧氏距离）[cite: 40]。
3. **k 的值 (The value of k)**：一个超参数，决定了我们要参考多少个邻居的意见 [cite: 40]。

(3) 算法流程 (Algorithm Steps)

对于一个**未知类别**的测试记录 x [cite: 41]：

1. **计算距离 (Compute Distance)**：计算 x 与训练集中每一个样本 x_i 之间的距离 $d(x, x_i)$ [cite: 41]。
2. **寻找邻居 (Identify k nearest neighbors)**：将所有距离排序，选取距离最近的 k 个训练样本 [cite: 42]。
3. **决策分类 (Determine Class Label)**：
   - 统计这 k 个邻居的类别标签 [cite: 42]。
   - 通常采用**多数投票法 (Majority Vote)**，即哪个类别出现的次数多，就预测 x 属于哪个类别 [cite: 42]。

(4) K值的定义示例 (PPT P5)

PPT P5 展示了不同 k 值下的邻域范围 [cite: 68-70]：

- **1-NN**：只看最近的那**一个**点。
- **2-NN / 3-NN**：看最近的 2 个或 3 个点。
- *定义补充*：记录 x 的 k-最近邻是指训练集中距离 x 最小的 k 个数据点 [cite: 71, 72]。

(5) 潜在考题预测 (Exam Hacks)

> - **Q**: 在二分类问题中，为什么 k 通常建议取奇数?
> - **A**: 为了避免在多数投票时出现平票 (Tie) 的情况。如果 k 是偶数（如 $k = 2$），可能出现 1 正 1 负，导致无法决策。

8.3 几何解释：沃罗诺伊图 (Voronoi Diagram) (PPT P6)

(1) 1-NN 的决策边界

- **沃罗诺伊图 (Voronoi Diagram)**：
  - *定义*：这是一个几何概念。对于平面上的每个点，该图将其划分到离它最近的那个训练样本的区域中 [cite: 76]。
  - *在 KNN 中的意义*：PPT P6 的图展示了 **1-NN** 的决策边界。图中的多边形区域划分了空间，任何落在某个多边形内的测试点，其最近邻一定是该多边形内部的那个训练点 [cite: 75]。
- **关键性质**：
  - 1-NN 的决策边界是由线段构成的（分段线性）。
  - 边界非常复杂，紧贴着数据点，容易形成“孤岛”。

8.4 数学细节：距离与加权 (PPT P7)

(1) 距离度量 (Distance Metric) (⚠️ 需掌握公式)

PPT 明确指定了**欧氏距离 (Euclidean distance)** [cite: 94]：

$$d(p, q) = \sqrt{\sum_i (p_i - q_i)^2}$$

其中 p 和 q 是两个数据点，i 遍历特征的维度 [cite: 95]。

(2) 投票机制的改进

标准的 KNN 是“一人一票”，但这可能不公平（远的邻居和近的邻居权重一样）。

- **距离加权投票 (Distance-Weighted Voting)**：
  - *思想*：离得越近的邻居，其投票的权重应该越大 [cite: 98]。
  - *权重公式*：

$$w = \frac{1}{d(p, q)^2}$$

    （PPT中给出的具体权重因子） [cite: 98]。
  - *应用*：在计算得票数时，不再是 $\sum 1$，而是 $\sum w$。
  - *解决的问题*：当 k 较大时，防止大量较远的样本淹没少量极近样本的正确分类信息。

8.5 超参数选择：K 值的影响 (PPT P8) (⚠️ 核心考点)

KNN 模型没有显式的"训练"过程，但 k 的选择对模型性能至关重要 [cite: 102]。这是一个典型的**偏差-方差权衡 (Bias-Variance Tradeoff)**。

(1) K 值太小 (如 $k = 1$)

- **现象**：模型对每一个具体的训练数据点都非常敏感 [cite: 104]。
- **问题**：
  - **对噪声敏感 (Sensitive to noise)**：如果训练集中有一个错误的标注点（噪声），它会形成一个错误的决策"孤岛"。测试点如果不幸落在附近，就会被分错 [cite: 104]。
  - **过拟合 (Overfitting)**：模型捕捉了数据中的随机细节，导致泛化能力差。
  - **决策边界**：非常粗糙、锯齿状。

(2) K 值太大 (如 $k \to N$)

- **现象**：邻域范围变得非常大，包含了大量其他类别的点 [cite: 105]。
- **问题**：
  - **平滑过度**：甚至可能包含来自完全不同分布的点。
  - **欠拟合 (Underfitting)**：模型失去了捕捉局部特征的能力。如果 $k = N$（训练集总数），那么模型将永远预测训练集中占比最大的那个类别（先验概率），完全忽略输入特征 x。
  - **决策边界**：过于平滑，甚至消失。

(3) 潜在考题预测 (Exam Hacks)

> - **Q**: 随着 k 从 1 增加到 N，模型的偏差 (Bias) 和方差 (Variance) 如何变化?
> - **A**:
>   - k **很小**：低偏差，高方差（模型复杂，拟合强，不稳定）。
>   - k **很大**：高偏差，低方差（模型简单，拟合弱，稳定）。

8.6 数据预处理与缩放 (Scaling Issues) (PPT P9-P10)

(1) 为什么需要缩放 (Scaling)?

KNN 极其依赖距离计算，而距离计算对数值的**量纲 (Magnitude)** 非常敏感 [cite: 119]。

- **PPT 案例**：
  - 身高：1.5m - 1.8m (变化幅度 0.3) [cite: 122]。
  - 体重：90lb - 300lb (变化幅度 210) [cite: 122]。
  - 收入：$10K - $1M (变化幅度 990,000) [cite: 122]。
- **后果**：如果不归一化，**收入**这个特征将在欧氏距离公式 $\sqrt{(x_1 - y_1)^2 + \dots}$ 中占据绝对主导地位 [cite: 120]。身高和体重的差异会被完全淹没。
- **解决方案**：必须将所有属性标准化（例如归一化到 [0,1] 区间或 Z-score 标准化），防止某个属性"主宰"距离计算 [cite: 120]。

(2) 相似度度量的选择 (PPT P10)

除了数值缩放，选择正确的**度量方式** (Similarity measure) 也很关键 [cite: 126]。

- **PPT 案例 (二进制向量)**：
  - Pair A: `000...001` vs `100...000` (只有首尾不同) [cite: 127, 128]。
  - Pair B: `011...111` vs `100...000` (除了首位，其他全反) [cite: 130, 131]。
- **问题**：如果简单套用欧氏距离，这两个 Pair 的距离可能是一样的（如 PPT 所示都算出了 1.4142）[cite: 132]。但从语义上（例如文本分类或基因匹配），它们的相似度含义可能完全不同。
- **启示**：对于稀疏高维数据或二进制数据，欧氏距离可能失效，需考虑其他度量（如 Jaccard 系数或余弦相似度，虽然 PPT 没展开，但要知道欧氏距离不是万能的）。

8.7 KNN 的优缺点总结 (PPT P11)

(1) 优点

1. **决策边界灵活**：可以生成任意形状的决策边界（Arbitrarily shaped decision boundaries），适合复杂的非线性分类 [cite: 138]。

2. **无需显式训练**：没有训练参数 w 和 b，容易处理由局部信息决定的变量交互 [cite: 139]。

(2) 缺点与挑战 (⚠️ 考试常考)

1. **懒惰学习 (Lazy Learners)**：不建立显式模型 [cite: 136]。
2. **分类开销大 (Expensive Classification)**：
   - 预测每一个测试样本时，都要计算它与**所有**训练样本的距离 [cite: 137]。
   - 测试阶段极慢，计算量大。
3. **对噪声和冗余属性敏感**：
   - **冗余属性**（Superfluous attributes）会干扰距离计算 [cite: 141]。
   - **无关属性**（Irrelevant attributes）会制造“维度灾难”，让距离失去意义。
4. **缺失值难处理**：难以直接计算距离 [cite: 141]。

8.8 提升 KNN 效率的方法 (PPT P12)

由于 KNN 测试太慢，PPT 提出了两类加速策略 [cite: 144]：

(1) 避免计算所有距离 (索引与近似)

- **多维访问方法 (Multi-dimensional access methods)**：
  - 如 **k-d trees**：通过构建空间划分树，在搜索邻居时剪枝，避免遍历所有点 [cite: 146]。
- **快速近似相似度搜索 (Fast approximate similarity search)**：
  - 如 **LSH (Locality Sensitive Hashing, 局部敏感哈希)**：通过哈希函数将相近的点映射到同一个桶中，只在桶内搜索 [cite: 147]。

(2) 减少样本数量 (数据集缩减)

- **压缩 (Condensing)**：
  - *思路*：确定一个更小的对象集合，使其达到与全集相同的性能 [cite: 148, 149]。只保留对决策边界有贡献的样本。
- **编辑 (Editing)**：
  - *思路*：移除部分对象（如噪声或边界模糊点）以提高效率 [cite: 150, 151]。

8.9 扩展知识：邻近图 (Proximity Graphs) (PPT P13)

PPT 最后提及了 KNN 的理论基础——邻近图 [cite: 154]。

- **定义**：一个图，其中两个顶点（数据点）相连当且仅当它们满足特定的几何要求 [cite: 156]。
- **常见类型**：
  - Nearest Neighbor Graphs (最近邻图) [cite: 156]。
  - Minimum Spanning Trees (最小生成树, MST) [cite: 157]。
  - Delaunay Triangulations (德劳内三角剖分) [cite: 158]。
  - Gabriel Graphs [cite: 158]。
- *考试关联*：这部分主要是理论背景，引用了 Toussaint 的多篇论文，表明这是计算几何在机器学习中的应用 [cite: 159, 160]。

8.10 终极备考总结 (Next Steps)

1. **手推距离公式**：确保能写出欧氏距离公式和加权投票公式 $1/d^2$。
2. **逻辑串联**：能够口述 KNN 的完整流程（训练=存储，测试=计算距离+排序+投票）。
3. **情景分析**：
   - 如果是**高维数据**，KNN 会遇到什么问题？（维度灾难，距离失效）。
   - 如果**样本量巨大**，如何优化？（k-d tree, LSH, Condensing）。
   - 如果**数据单位不一**，必须做什么？（归一化）。
4. **K 的辩证法**：深刻理解小 K（过拟合、噪点敏感）与大 K（欠拟合、边界模糊）的区别。

第9章 K-Means 与层次聚类 (K-means and Hierarchical Clustering)

9.1 K-Means 核心概览 (PPT P1-2)

(1) 核心问题

在深入算法之前，PPT P2 提出了五个我们必须解决的核心问题，这往往也是考试简答题的切入点：

1. **优化目标 (Optimization)**：K-means 到底在试图最小化什么？
2. **终止性 (Termination)**：我们能确定算法一定会停下来吗？
3. **最优性 (Optimality)**：我们能确定它找到的是全局最优解吗？
4. **初始化 (Initialization)**：应该如何开始？（随机选点还是有策略？）
5. **K值的选择 (Choosing k)**：如何自动决定聚类的数量？

9.2 直观理解：有损压缩视角 (PPT P3-6)

(1) 场景设定

- **问题背景**：假设你要传输一组二维数据的坐标，但带宽受限，每个点只能用 **2 bits** 来传输。
- **限制**：这意味着你只能发送 4 种可能的值（00, 01, 10, 11）。这必然是一个**有损传输 (Lossy Transmission)**。
- **目标**：设计一个编码器（Encoder）和解码器（Decoder），使得**损失（Loss）最小**。
  - 这里的**损失**定义为：解码后的坐标与原始坐标之间的**残差平方和 (Sum Squared Error, SSE)**。

(2) 两种思路对比

- **思路一：网格法 (Grid, PPT P5)**
  - 将空间划分为规则的 4 个网格。
  - 解码时，取网格的**中心点**作为近似值。
  - *评价*：这种方法比较死板，且没有考虑数据的实际分布。
- **思路二：数据质心法 (Centroid, PPT P6)**
  - 根据数据密集的区域划分 4 个块。
  - 解码时，取该块内**所有实际数据点的质心 (Centroid)** 作为近似值。
  - *评价*：这显然比网格法更能降低损失，这正是 K-Means 的核心思想。

9.3 K-Means 算法流程详解 (PPT P7-21)

这是一个迭代算法。根据 PPT P12 引用 Dan Pelleg 的可视化，流程如下：

(1) 算法步骤

1. **输入 K 值**：用户决定聚类簇的数量，例如 $k = 5$。
2. **初始化 (Initialization)**：随机猜测 k 个聚类中心 (Cluster Centers) 的位置。
3. **分配阶段 (Assignment Step)**：
   - 遍历每一个数据点 x_i。
   - 计算它与当前 k 个中心的距离。
   - 将该点归属给**最近的**那个中心。（此时，每个中心“拥有”了一组数据点）。
   - *几何理解*：这一步实际上在空间中构建了沃罗诺伊图 (Voronoi Diagram)，即 PPT P9 中黑线分割的区域。
4. **更新阶段 (Update Step)**：
   - 每个中心 c_j 重新计算位置。
   - 新位置 = 该中心当前“拥有”的所有数据点的**质心 (Centroid/Mean)**。
   - 即：中心点“跳”到了数据点的平均位置。
5. **重复 (Repeat)**：重复步骤 3 和 4，直到满足终止条件（中心点不再移动，或移动距离小于阈值）。

(2) 潜在考题预测 (Exam Hacks)

> - **Q**: 结合 PPT P12-21 的图示，随着迭代进行，聚类中心是如何移动的？
> - **A**: 初始时中心是随机杂乱的。经过几次迭代，中心点迅速向数据密集的区域中心移动（例如蓝色和绿色的簇逐渐分离）。最终，中心点稳定在各个簇的几何中心，算法收敛。

9.4 数学原理与优化目标 (PPT P22-31) [⚠️ 重点必考]

这是本次复习的核心。PPT 从 P23 开始引入了符号定义，并推导了 K-Means 为什么包含“分配”和“更新”这两个步骤。

(1) 定义：畸变函数 (Distortion Function)

我们将“损失”数学化为**畸变 (Distortion)**。

- **给定**：
  - 编码函数 (Encoder)：$ENCODE : \mathbb{R}^m \to [1..k]$。输入一个数据点，返回它属于第几个簇（索引）。
  - 解码函数 (Decoder)：$DECODE : [1..k] \to \mathbb{R}^m$。输入簇的索引，返回该簇代表点（中心点）的坐标。
- **中心点表示**：令 c_j 为第 j 个簇的中心，则 $DECODE[j] = c_j$。
- **目标函数 (Loss Function)**：

$$Distortion = \sum_{i=1}^{R} (x_i - c_{ENCODE(x_i)})^2$$

其中，R 是数据点的总数，x_i 是第 i 个数据点。

(2) 最小化畸变的推导

为了最小化上述 Distortion，我们需要确定两个变量：**每个点的归属 (Encoder)** 和 **每个中心的位置 (c_j)**。这对应了 K-Means 的两步，通过**坐标下降法 (Coordinate Descent)** 交替优化。

步骤一：固定中心位置，优化归属 (The Assignment Step)

- **问题**：假设中心 $c_1, \ldots, c_k$ 是固定的，如何选择 $ENCODE(x_i)$ 来最小化 Distortion?
- **推导**：

$$c_{ENCODE(x_i)} = \arg \min_{c_j \in \{c_1, \ldots, c_k\}} (x_i - c_j)^2$$

- **结论**：每个数据点 x_i 必须被编码（分配）给离它**最近**的那个中心。
- *原因*：如果在求和公式中，某一项 $(x_i - c_j)^2$ 不是取最小值，那么我们可以简单地把 x_i 重新分配给更近的中心来减小总 Loss。

步骤二：固定归属，优化中心位置 (The Update Step)

- **问题**：假设每个点的归属 $OwnedBy(c_j)$ 已知，如何选择 c_j 的位置来最小化 Distortion?
- **推导 (PPT P29-30 详细推导)**：

i. 将总 Distortion 拆解为针对每个簇的求和：

$$Distortion = \sum_{j=1}^{k} \sum_{i \in OwnedBy(c_j)} (x_i - c_j)^2$$

ii. 我们要找最优的 c_j，即求偏导并令其为 0：

$$\frac{\partial Distortion}{\partial c_j} = \frac{\partial}{\partial c_j} \sum_{i \in OwnedBy(c_j)} (x_i - c_j)^2$$

iii. 利用链式法则求导（注意 $(x - c)^2$ 对 c 求导是 $2(x - c) \cdot (-1)$）：

$$= \sum_{i \in OwnedBy(c_j)} -2(x_i - c_j) = 0$$

iv. 消去 -2 并展开求和：

$$\sum_{i \in OwnedBy(c_j)} x_i - \sum_{i \in OwnedBy(c_j)} c_j = 0$$

v. 因为 c_j 是常数，后一项等于 $|OwnedBy(c_j)| \cdot c_j$（即簇内点数乘以中心坐标）：

$$\sum_{i \in OwnedBy(c_j)} x_i = |OwnedBy(c_j)| \cdot c_j$$

vi. **闭式解 (Closed-form solution)**：

$$c_j = \frac{1}{|OwnedBy(c_j)|} \sum_{i \in OwnedBy(c_j)} x_i$$

- **结论**：最优的中心 c_j 必须位于它所拥有的所有数据点的**算术平均值（质心）**处。

(3) 潜在考题预测 (Exam Hacks)

> - **Q**: 为什么 K-Means 算法包含“指派”和“移动”两步？请从数学优化角度解释。
> - **A**: 这是在最小化畸变函数 (Distortion)。第一步是固定中心优化分配（偏导为0无法求，直接取最小值）；第二步是固定分配优化中心（通过求偏导为0得到质心公式）。这实际上是**坐标下降 (Coordinate Descent)** 策略。

9.5 收敛性与最优性 (PPT P32-36)

(1) 算法会终止吗？(Convergence)

- **结论**：是的，K-Means 保证会终止。
- **证明逻辑 (PPT P33)**：
  i. **状态有限性**：将 R 个记录划分到 k 个组的方式是有限的（虽然很大，但是有限）。
  ii. **单调性**：算法的每一步（分配或更新）要么减小 Distortion，要么保持不变，**绝不会增加** Distortion。
  iii. **无循环**：因为每一个新状态都比上一个状态的 Distortion 更小（或相等且不再变化），所以算法永远不会回到之前的配置。
  iv. 因此，算法必然在有限步内到达一个状态，此时无论是重新分配还是重新计算中心都无法减少 Distortion，算法停止。

(2) 会找到全局最优解吗？(Optimality)

- **结论**：**不一定**。
- **局部最优 (Local Optima)**：K-Means 很容易陷入局部最优解。
- **反例 (PPT P35-36)**：PPT 提到了一个 "Fiendish k=3" 的例子（虽然图没画出来，但意图是让你想象）。
  - *场景*：如果数据确实有3个簇，但你初始化的点选得不好（比如两个中心挤在一个簇里，第三个中心在两个簇中间），算法可能收敛到一个错误的分割，且无法跳出来。

9.6 改进策略与参数选择 (PPT P37-39)

(1) 如何获得更好的结果？

针对局部最优问题，PPT 提出了两个思路：

1. **多轮运行 (Many Runs)**：运行多次 K-Means，每次使用不同的随机初始化，最后选择 Distortion 最小的那个结果。
2. **聪明的初始化 (Smart Initialization) - 考点**：
   - 第一个中心：随机选一个数据点。
   - 第二个中心：选离第一个点**最远**的数据点。
   - 第 j 个中心：选离当前已有的 $j-1$ 个中心**最远**（即距离最近中心的距离最大化）的数据点。
   - *这其实是 K-Means++ 的思想雏形。*

(2) 如何选择 K 值？(Choosing k)

- **难题**：随着 k 增加，Distortion 必然会减小（当 $k = R$ 时，每个点都是中心，Loss为0）。所以直接看 Loss 最小值没有意义。
- **Schwarz Criterion / BIC (贝叶斯信息准则)**：
  - PPT P39 提出了一个带惩罚项的公式：

$$Score = Distortion + \lambda \cdot (\#parameters) \cdot \log R$$

  - **公式解析**：
    - $Distortion$：越低越好（拟合程度）。
    - $\lambda \cdot (\#parameters) \cdot \log R$：惩罚项。模型越复杂（$k$ 越大），参数越多，惩罚越大。
    - $\#parameters \approx m \cdot k$ （m 是维度，k 是中心数）。
  - **目标**：寻找使这个 Score **最小** 的 k 值。

9.7 常见应用 (PPT P40)

- **探索性数据分析 (EDA)**：快速了解数据结构。

- **向量量化 (Vector Quantization)**：信号处理领域，例如将声波波形归类为 k 个类别，压缩数据。
- **色彩量化**：将图片中的数万种颜色减少到 k 种（旧式显示器调色板）。

9.8 层次聚类 (Hierarchical Clustering) (PPT P41-47)

PPT 重点介绍了 **Single Linkage (单连接)** 层次聚类。

(1) 算法流程 (Agglomerative / 自底向上)

1. **初始化**：将每一个数据点视为一个独立的簇 (Cluster)。
2. **查找**：在所有簇对中，找到**最相似**（距离最近）的一对。
3. **合并**：将这对簇合并为一个新的父簇。
4. **重复**：重复步骤 2-3，直到所有数据点合并为一个大簇。

(2) 簇间距离定义 (Similarity Measures)

如何定义两个"簇"之间的距离？PPT P46 列举了三种：

1. **Single Linkage (最小距离)**：
   - 定义：两个簇中**最近**两点之间的距离。
   - *特点*：容易产生链状结构 (Chaining effect)，即细长的簇。这也是 PPT 演示的方法。等价于生成**欧几里得最小生成树 (MST)**。
2. **Complete Linkage (最大距离)**：
   - 定义：两个簇中**最远**两点之间的距离。
3. **Average Linkage (平均距离)**：
   - 定义：两个簇中所有点对距离的平均值。

(3) 评价

- **优点**：生成树状图 (Dendrogram) 或分类法 (Taxonomy)，结构清晰，且如果不确定 k，可以在任意层级切断（例如剪断 $k-1$ 条最长的边）。
- **缺点**：缺乏统计学或信息论的坚实基础（PPT 原话：让你的讲师感到有点恶心 "queasy"）。计算复杂度通常较高。

9.9 总结：你应该掌握什么？(PPT P48)

作为考前自查清单：

1. **K-Means 细节**：从初始化到收敛的完整步骤。
2. **优化理论**：Distortion 函数的定义，以及如何通过偏导为0推导出均值更新规则。
3. **缺陷**：局部最优问题，以及如何通过初始化改进。
4. **层次聚类**：Single Linkage 的基本流程和簇间距离定义。
5. **算法对比**：能够区分何时使用 K-Means（大数据、球状簇），何时使用层次聚类（需要分类结构）。

第10章 聚类分析进阶 (Cluster Analysis)

10.1 软聚类 (Soft/Fuzzy Clustering)

10.1.1 硬聚类与软聚类的区别 (PPT P1-3)

- **硬聚类 (Hard/Crisp Clustering)**：
  - *定义*：每个数据点**明确且唯一**地属于某一个簇。
  - *代表算法*：K-Means。
  - *数学表达*：隶属度 $w_{ij} \in \{0, 1\}$。如果点 i 属于簇 j，则为1，否则为0。
- **软聚类 (Soft/Fuzzy Clustering)**：
  - *定义*：允许一个数据点以**一定的概率或权重**属于多个簇。
  - *核心思想*：用隶属度（Membership weight）来量化点与簇的关系，更符合现实世界中边界模糊的数据分布。
  - *数学表达*：隶属度 $w_{ij} \in [0, 1]$，且满足归一化约束 $\sum_{j=1}^{k} w_{ij} = 1$。

10.1.2 模糊C均值算法 (Fuzzy c-Means, FCM) (PPT P3-7)

(1) 目标函数 (Objective Function)

FCM 是 K-Means 的推广。我们需要最小化加权的误差平方和 (SSE)：

$$SSE = \sum_{j=1}^{k} \sum_{i=1}^{m} w_{ij}^{p} \cdot dist(x_i, c_j)^2$$

- **约束条件**：$\sum_{j=1}^{k} w_{ij} = 1$ (每个点对所有簇的隶属度之和为1)。
- **参数解释**：
  - x_i：第 i 个数据点。
  - c_j：第 j 个簇的中心（质心）。
  - w_{ij}：点 x_i 属于簇 c_j 的隶属度权重。
  - p **(Fuzzifier)**：模糊系数，必须 $p > 1$。
    - *作用*：控制聚类的"模糊"程度。p 越大，隶属度分布越平滑（越模糊）；p 趋近于 1，算法退化为硬聚类（K-Means）。

(2) 算法求解 (交替优化)

为了最小化 SSE，我们采用类似 EM 算法的迭代策略，固定一个变量求另一个：

1. **更新簇中心** c_j (固定 w_{ij})：
   簇中心不再是简单的算术平均，而是**加权平均**：

$$c_j = \frac{\sum_{i=1}^{m} w_{ij}^{p} x_i}{\sum_{i=1}^{m} w_{ij}^{p}}$$

   直观理解：隶属度越高的点，对簇中心位置的影响越大。
2. **更新隶属度** w_{ij} (固定 c_j)：
   通过拉格朗日乘子法求解（考试重点：记忆此结论公式）：

$$w_{ij} = \frac{1}{\sum_{k=1}^{K} \left(\frac{dist(x_i, c_j)^2}{dist(x_i, c_k)^2} \right)^{\frac{1}{p-1}}}$$

   直观理解：如果点 x_i 距离簇 c_j 越近（$dist$ 越小），分母越小，则 w_{ij} 越大。

(3) FCM 算法流程

1. **初始化**：随机选择权重 w_{ij}（满足归一化条件）。
2. **重复**以下步骤直到收敛：
   - 根据当前权重，利用公式更新簇中心 c_j。
   - 根据新的簇中心，利用公式更新权重 w_{ij}。

(4) 潜在考题预测 (Exam Hacks)

> - **Q**: 当 $p \to 1$ 时，FCM 会发生什么变化?
> - **A**: 此时目标函数变为线性，解会趋向于二值化（0或1），FCM 退化为标准的 K-Means 算法。
> - **Q**: FCM 与 K-Means 在更新质心时有何不同?
> - **A**: K-Means 是计算簇内所有点的简单平均；FCM 是计算所有点的加权平均，权重是隶属度的 p 次方。

10.2 概率聚类与混合模型 (Probabilistic Clustering & Mixture Models)

10.2.1 基本思想 (PPT P10-13)

- **假设**：数据是由 k 个不同的概率分布（通常是高斯分布）混合生成的。
- **目标**：估计这些分布的参数（均值、方差、混合系数），从而推断每个点属于某个分布的概率。
- **对比 FCM**：虽然都提供了"软"分配，但混合模型基于严格的统计推导（概率密度），可以处理不同大小、椭圆形状的簇（通过协方差矩阵），而不仅是球形。

10.2.2 高斯混合模型 (GMM) 与 EM 算法 (PPT P14-20)

(1) 模型定义

高斯混合模型的概率密度函数为多个高斯分布的加权和：

$$p(x) = \sum_{c=1}^{k} \pi_c \mathcal{N}(x | \mu_c, \Sigma_c)$$

其中：

- π_c：混合系数（Mixing coefficient），即选择第 c 个簇的先验概率，$\sum \pi_c = 1$。
- $\mathcal{N}(x|\mu_c, \Sigma_c)$：第 c 个高斯分量的概率密度函数。

$$\mathcal{N}(x;\mu,\Sigma) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right\}$$

(2) 目标函数：对数似然 (Log-Likelihood)

我们要最大化所有数据点生成的联合概率（似然）：

$$\mathcal{L}(\Theta) = \sum_{i=1}^{N} \log\left(\sum_{c=1}^{k} \pi_c \mathcal{N}(x_i|\mu_c,\Sigma_c)\right)$$

难点：由于 $\log$ 里面有求和符号 $\sum$，直接求导无法得到闭式解，因此必须使用 **EM 算法 (Expectation-Maximization)**。

(3) EM 算法详细推导 (⚠️ 考试必考核心)

Step 1: 初始化
随机初始化参数 μ_c, Σ_c, π_c（常用 K-Means 的结果作为初始化）。

Step 2: E步 (Expectation Step) - 计算责任值
计算第 i 个数据点由第 c 个高斯分量生成的后验概率（即责任值 r_{ic}）：

$$r_{ic} = p(c|x_i) = \frac{\pi_c \mathcal{N}(x_i|\mu_c,\Sigma_c)}{\sum_{j=1}^{k} \pi_j \mathcal{N}(x_i|\mu_j,\Sigma_j)}$$

解释：这是贝叶斯公式的应用。分子是点 i 属于簇 c 的加权似然，分母是归一化因子。

Step 3: M步 (Maximization Step) - 更新参数
利用 E 步计算出的 r_{ic}，最大化期望似然，更新参数：

1. **有效样本数**：$N_c = \sum_{i=1}^{N} r_{ic}$
2. **更新混合系数**：$\pi_c = \frac{N_c}{N}$
3. **更新均值**：$\mu_c = \frac{1}{N_c}\sum_{i=1}^{N} r_{ic} x_i$ （加权平均）
4. **更新协方差**：$\Sigma_c = \frac{1}{N_c}\sum_{i=1}^{N} r_{ic}(x_i-\mu_c)(x_i-\mu_c)^T$

Step 4: 迭代
重复 E 步和 M 步，直到对数似然函数收敛。

(4) EM 算法的优缺点 (PPT P32)

- **优点**：
  - 提供完整的概率描述。
  - 可以处理椭圆形簇（通过协方差矩阵）和不同大小的簇。
  - K-Means 是 EM 的一个特例（当协方差矩阵为单位阵且 $\epsilon \to 0$ 时）。
- **缺点**：
  - **局部最优**：容易陷入局部极值，对初始化敏感。
  - **收敛慢**。
  - **参数多**：参数数量随维度 d 的平方增长 ($O(d^2)$，因为协方差矩阵是 $d \times d$ 的)，在高维数据上容易过拟合。

(5) 潜在考题预测 (Exam Hacks)

> - **Q**: 为什么 EM 算法在 M 步更新协方差矩阵时可以发现椭圆形的簇？
> - **A**: 因为协方差矩阵 Σ 描述了数据在不同方向上的展布情况和相关性。如果 Σ 不是对角阵，等高线就是椭圆，这使得 GMM 能拟合拉伸的形状。
> - **Q**: 请简述 EM 算法与 K-Means 的联系。
> - **A**: K-Means 是硬分配（责任值 $r_{ic} \in \{0,1\}$），且假设所有簇为球形分布（协方差为常数 $\cdot I$）。EM 是软分配，允许任意协方差。

10.3 自组织映射 (SOM: Self-Organizing Maps)

10.3.1 基本概念与架构 (PPT P34-35)

- **定义**：一种无监督神经网络，将高维输入数据映射到低维（通常是2D）的离散网格上，同时保持数据的**拓扑结构**（Topology Preserving）。
- **架构**：
  - **输入层**：接收高维数据 x。
  - **计算层 (输出层)**：神经元排列成网格（如六边形或矩形）。每个神经元 j 都有一个权重向量 w_j，维度与输入数据相同。

10.3.2 SOM 四大过程 (PPT P36-40) (⚠️ 流程重点)

1. **初始化 (Initialization)**：
   - 将所有神经元的权重向量 w_j 初始化为小的随机值。
2. **竞争 (Competition)**：
   - 对于每个输入样本 x，找到与其“最相似”的神经元（获胜神经元，Winner）。
   - *判别函数*：通常使用欧氏距离平方。

$$d_j(x) = \sum_{i=1}^{D} (x_i - w_{ji})^2$$

   - 距离最小的神经元 $I(x)$ 被宣布为获胜者。
3. **合作 (Cooperation)**：
   - 不仅获胜神经元更新，其**邻域 (Neighborhood)** 内的神经元也参与更新。这使得相邻的神经元对相似的输入模式做出反应。
   - *拓扑邻域函数*：通常使用高斯函数，随距离衰减。

$$T_{j,I(x)} = \exp\left(-\frac{S_{j,I(x)}^2}{2\sigma^2}\right)$$

     - $S_{j,I(x)}$：神经元 j 与获胜神经元 $I(x)$ 在**网格上**的侧向距离。
     - σ：邻域半径，随时间 t 衰减（范围逐渐缩小）。
4. **适应/更新 (Adaptation)**：
   - 调整获胜神经元及其邻居的权重，使其向当前输入 x 靠拢。
   - *权重更新公式*：

$$\Delta w_{ji} = \eta(t) \cdot T_{j,I(x)}(t) \cdot (x_i - w_{ji})$$

     - $\eta(t)$：学习率，随时间衰减。
     - *直观含义*：权重 w_{ji} 加上（输入 x 与权重 w 的差值 $\times$ 学习率 $\times$ 邻域影响）。

10.3.3 结果可视化 (PPT P42-45)

- SOM 训练完成后，网格在输入空间中会“展开”并扭曲，以拟合数据的密度分布。
- 在低维输出网格上，相邻的节点代表输入空间中相似的数据点。这是一种**降维**和**可视化**工具。

10.4 基于网格与子空间的聚类 (Grid-based & Subspace)

10.4.1 基本网格聚类 (PPT P52)

- **思路**：将数据空间划分为有限的单元（网格），基于网格单元的统计信息（如密度）进行聚类，而不是基于数据点。
- **优点**：速度快，独立于数据点数量，仅取决于网格数量。

10.4.2 子空间聚类：CLIQUE 算法 (PPT P53-61)

(1) 动机

在高维数据中，簇可能只存在于**部分属性**构成的子空间中（例如：文档聚类可能只涉及少量关键词）。全维度上的距离计算可能因“维数灾难”而失效。

(2) CLIQUE 算法逻辑 (类似 Apriori)

利用**单调性 (Monotonicity Property)**：

> 如果一组点在 k 维空间中形成一个稠密单元，那么它们在这一组维度的任意 $k-1$ 维子空间投影中也必定是稠密的。

(3) 算法步骤

1. **一维处理**：将每个维度划分为等宽区间，统计每个区间的密度，找出**稠密单元**（超过阈值 τ）。

2. **候选生成**：利用 $(k-1)$ 维的稠密单元组合生成 k 维候选单元（Bottom-up）。
3. **剪枝**：如果一个 k 维单元的某个 $(k-1)$ 维投影不稠密，则该 k 维单元也不稠密，直接删除。
4. **生成簇**：将所有相连的稠密单元合并成簇。
5. **描述**：使用不等式（如 $30 < age < 40, 50k < salary < 80k$）来描述簇。

(4) 优缺点

- *优点*：能发现重叠簇，自动发现子空间。
- *缺点*：参数（网格大小、密度阈值）难以设定；随着维度增加，候选生成步骤仍可能有指数级复杂度。

10.5 基于密度的扩展算法 (DENCLUE & SNN)

10.5.1 DENCLUE (基于核密度估计) (PPT P62-65)

(1) 核心概念

- **核密度估计 (KDE)**：每个数据点对周围空间产生“影响”，这种影响用核函数（如高斯核）描述。

$$K(y) = \exp\left(-\frac{dist(x,y)^2}{2\sigma^2}\right)$$

- **总密度**：空间中某一点的密度是所有数据点在该点产生的影响之和。
- **密度吸引子 (Density Attractor)**：密度函数的局部极大值点。

(2) 聚类过程

1. **爬山法 (Hill Climbing)**：对于每个数据点，沿着密度梯度的方向移动，直到收敛到某个密度吸引子。
2. **归类**：收敛到同一个局部峰值（吸引子）的点属于同一个簇。
3. **合并**：如果两个吸引子之间存在一条路径，且路径上的密度都高于阈值 ξ，则合并这两个簇。

- *特点*：数学基础扎实，能发现任意形状的簇。

10.5.2 SNN (共享最近邻) 聚类 (PPT P92-101)

(1) 动机：解决变密度问题

传统的 DBSCAN 使用固定半径 ϵ，无法同时处理高密度簇和低密度簇（Jarvis-Patrick 算法也有类似问题）。SNN 试图解决这个问题。

(2) SNN 相似度定义

- 首先构建 k-近邻图。
- 两点 i, j 之间的相似度定义为：**它们共享的邻居数量**（前提是它们互为近邻）。
  - *直观理解*：无论是在高密度区还是低密度区，只要两点“共享”了同样的朋友圈，它们就是紧密连接的。这具有**自适应性**。

(3) SNN-DBSCAN 算法流程

1. 计算相似度矩阵（基于共享邻居数）。
2. 计算每个点的 **SNN 密度**（在 Eps 范围内有多少个强相似的点）。
3. **寻找核心点**：SNN 密度 > MinPts。
4. **聚类**：将核心点及其距离在 Eps 内的核心点合并；将非核心点分配给最近的核心点；剔除噪声。

- *优势*：能极其有效地处理**不同密度、不同大小**的簇。

10.6 基于图的聚类 (Graph-Based Clustering)

10.6.1 基本概念 (PPT P66)

- 将数据看作图的节点，相似度看作边的权重。
- 聚类问题转化为图的**连通分量**或**图切分 (Graph Partitioning)** 问题。
- *Sparsification (稀疏化)*：为了提高效率和鲁棒性，通常先将全连接图转化为稀疏图（如只保留 k-NN 边，PPT P75-76）。

10.6.2 CURE 算法 (Clustering Using REpresentatives) (PPT P67-73)

(1) 解决了什么问题?

- 解决了 K-Means 不能处理非球形、大小差异大簇的问题。

- 解决了单链接（Single-link）层次聚类容易受离群点（链式效应）影响的问题。

(2) 核心机制

- **代表点 (Representative Points)**：不使用单一质心，而是为每个簇选择 c 个分散的代表点。
- **收缩 (Shrink)**：将这些代表点向簇中心收缩一个因子 α（例如 0.2）。
  - *作用*：收缩使得边缘的点向中心靠拢，减少了离群点的影响。
- **距离计算**：两个簇之间的距离是**两个簇代表点集之间最近点对的距离**。

(3) 考题预测

> - **Q**: CURE 算法中 α 的作用是什么？
> - **A**: 当 $\alpha = 0$ 时，代表点聚到一点，退化为基于质心的聚类（无法处理非球形）；当 $\alpha = 1$ 时，代表点不收缩，退化为全链接/单链接聚类（受噪声影响）。α 在中间值平衡了形状捕获和抗噪能力。

10.6.3 CHAMELEON (变色龙) 算法 (PPT P74-91)

(1) 核心思想：动态建模 (Dynamic Modeling)

现有的算法（如 CURE）通常使用静态的合并标准。CHAMELEON 认为：**两个簇是否合并，取决于它们之间的连接紧密程度是否与它们内部的连接紧密程度相当。**

(2) 两个关键指标 (⚠️ 公式必考)

1. **相对互连性 (Relative Interconnectivity, RI)**：
   衡量两个簇之间的连接数，相对于它们内部连接数的比例。

$$RI(C_i, C_j) = \frac{EC(C_i, C_j)}{\frac{1}{2}(EC(C_i) + EC(C_j))}$$

   - $EC(C_i, C_j)$：连接簇 C_i 和 C_j 的边的权重和（Edge Cut）。
   - $EC(C_i)$：平分簇 C_i 所需切断的边的权重和（Min-Cut of the cluster）。
2. **相对近似度 (Relative Closeness, RC)**：
   衡量两个簇之间边的平均权重，相对于它们内部边的平均权重的比例。

$$RC(C_i, C_j) = \frac{\bar{S}_{EC}(C_i, C_j)}{\frac{m_i}{m_i+m_j}\bar{S}_{EC}(C_i) + \frac{m_j}{m_i+m_j}\bar{S}_{EC}(C_j)}$$

   - $\bar{S}_{EC}(C_i, C_j)$：连接两簇的边的**平均权重**。
   - $\bar{S}_{EC}(C_i)$：簇 C_i 内部边的平均权重。
   - m_i：簇的大小。

(3) 算法流程

1. **构建 k-NN 图**。
2. **阶段 1 (Partitioning)**：使用图切分算法（如 METIS）将图切分成许多小的子簇（Sub-clusters）。
3. **阶段 2 (Merging)**：使用基于 RI 和 RC 的动态层次聚类，合并子簇以恢复真正的簇结构。

10.7 算法综合对比 (Exam Summary) (PPT P105-114)

这是期末考试最喜欢出的**综合简答题**或**选择题**。

10.7.1 K-Means vs. DBSCAN

特性	K-Means	DBSCAN
簇形状	仅球形 (Globular)	任意形状
噪声/离群点	敏感 (会被拉偏)	能处理 (标记为 Noise)
簇重叠	不重叠 (硬分配)	不重叠 (但能处理接触)
参数	k (簇数)	Eps, MinPts
复杂度	$O(n)$ (高效)	$O(n^2)$ (一般)
确定性	不确定 (受初始化影响)	确定 (除边界点外)

10.7.2 K-Means (MIN) vs. EM (GMM)

特性	K-Means (MIN in PPT)	EM Clustering
类型	划分式 / 原型基础	划分式 / 模型基础 (概率)
分配方式	硬分配 (0/1)	软分配 (概率)
簇参数	仅均值	均值 + 协方差 + 权重
处理不同大小	困难	容易 (通过方差)
处理不同密度	困难	容易
复杂度	$O(n)$	$O(n)$ (但迭代次数多)

10.7.3 CURE vs. CHAMELEON

- **CURE**：通过代表点收缩处理非球形，但对**不同密度**的簇处理能力有限（PPT P73）。
- **CHAMELEON**：通过考虑内部连接性（自适应），能完美处理**不同密度、嵌套、长条形**的复杂簇，但计算复杂度高。

10.8 期末备考建议 (Final Tips)

1. **公式记忆**：重点记忆 **FCM 的权重更新公式**、**GMM 的 E-Step 责任值公式**、以及 **CHAMELEON 的 RI/RC 定义**（只需记住分子分母的物理含义：互连 vs. 内部）。
2. **流程复述**：能够用自然语言清晰描述 **SOM 的竞争-合作-适应** 过程，以及 **CLIQUE 的从低维到高维** 的生成过程。
3. **图示理解**：PPT 中 CURE 的收缩示意图（P69）、CHAMELEON 的两阶段图（P77）是理解算法逻辑的关键，考试可能会给图让你解释算法步骤。
4. **对比分析**：如果考题问“为什么 K-Means 不好？”，不要只说“因为它只能聚球形”，要结合 DBSCAN 或 CURE 来说明后者是如何改进这一点的。

第11章 EM算法与蒙特卡洛方法

11.1 问题背景与核心难点 (PPT P3)

(1) 核心概念与定义

- **观测变量 (Observed Variable)** x：我们可以直接获取的数据 [cite: 22]。
- **隐变量 (Latent Variable)** z：模型中存在但无法直接观测到的变量（例如GMM中样本属于哪个高斯分布的标签） [cite: 22]。
- **核心矛盾**：
  - 我们想要最大化观测数据的**对数似然 (Log Likelihood)**：$\theta = \arg\max_\theta \log p(x;\theta)$ [cite: 22, 25]。
  - 但是，观测数据的边缘分布 $p(x;\theta)$ 是通过对隐变量 z 积分（或求和）得到的：$p(x;\theta) = \sum_z p(x,z;\theta)$ [cite: 25]。
  - 这就导致目标函数变为：$\log(\sum_z p(x,z;\theta))$ [cite: 25]。
- **为什么难算？**：对数函数 $\log$ 里面包含求和符号 $\sum$。这使得求导极其困难，因为参数 θ 耦合在一起，通常没有闭式解（Closed-form solution）。

11.2 EM算法通用框架 (PPT P4-P5)

(1) 算法核心思想

EM算法是一种迭代优化算法，用于解决含有隐变量的概率模型参数估计问题。它通过交替执行两个步骤（E步和M步）来寻找参数的局部最优解。

(2) 算法流程

- **初始化**：随机初始化参数 $\theta^{(0)}$ [cite: 40]。
- **E步 (Expectation Step)**：
  - 利用上一轮的参数 $\theta^{(t)}$，计算隐变量 z 的后验分布 $p(z|x;\theta^{(t)})$ [cite: 44]。
  - 构建**Q函数 (Q-function)**，即在后验分布下，完全数据对数似然（Log Joint Likelihood）的期望：

$$\mathcal{Q}(\theta;\theta^{(t)}) = \mathbb{E}_{p(z|x;\theta^{(t)})}[\log p(x,z;\theta)]$$

$$= \sum_z p(z|x;\theta^{(t)}) \log p(x,z;\theta)$$

[cite: 40]

- **M步 (Maximization Step)**：
  - 最大化Q函数，更新参数：

$$\theta^{(t+1)} = \arg\max_{\theta} \mathcal{Q}(\theta; \theta^{(t)})$$

[cite: 43]

- **收敛**：重复上述步骤直到 θ 收敛 [cite: 143]。

(3) 潜在考题预测 (Exam Hacks)

> - **Q**: 为什么E步要算期望?
> - **A**: 因为 z 未知，我们无法直接优化 $\log p(x, z; \theta)$。我们只能基于当前对 z 的认知（后验概率），去优化它的平均表现（期望） [cite: 45]。

11.3 理论保证：为什么EM能增加似然？ (PPT P7-P13)

⚠️ **高频考点预警**：这是考试中考察数学原理的重灾区，尤其是关于KL散度和下界（ELBO）的推导 [cite: 63, 117]。

(1) 对数似然的分解 (Re-representing Log-likelihood)

对于任意分布 $q(z)$，我们可以将对数似然分解为两部分（PPT P7）：

$$\log p(x; \theta) = \mathcal{L}(q, \theta) + KL(q||p(z|x; \theta))$$

[cite: 62]

推导过程：

1. 根据条件概率公式：$p(x, z; \theta) = p(z|x; \theta)p(x; \theta)$，所以 $p(x; \theta) = \frac{p(x,z;\theta)}{p(z|x;\theta)}$ [cite: 59]。
2. 两边取对数并对分布 $q(z)$ 求期望（或者说在公式右边引入 $\frac{q(z)}{q(z)}$）：

$$\log p(x; \theta) = \sum_z q(z) \log \left(\frac{p(x, z; \theta)}{p(z|x; \theta)} \cdot \frac{q(z)}{q(z)} \right)$$

[cite: 60]

3. 利用对数乘法拆分：

$$= \underbrace{\sum_z q(z) \log \frac{p(x, z; \theta)}{q(z)}}_{\mathcal{L}(q,\theta)} + \underbrace{\sum_z q(z) \log \frac{q(z)}{p(z|x; \theta)}}_{KL(q||p(z|x;\theta))}$$

[cite: 61]

- $\mathcal{L}(q, \theta)$：被称为证据下界 (Evidence Lower Bound, ELBO) 或变分下界 [cite: 62]。
- $KL(q||p)$：KL散度，衡量 $q(z)$ 和真实后验 $p(z|x; \theta)$ 的距离。性质是 $KL \geq 0$，当且仅当两个分布相等时为0 [cite: 63, 64]。

(2) EM算法的几何解释 (PPT P8-P12)

- **E步的本质**：
  - 固定 $\theta^{(t)}$，我们希望 KL 散度最小化（为0），从而使下界 $\mathcal{L}$ 紧贴目标函数 $\log p(x; \theta^{(t)})$ [cite: 82, 84]。
  - 取 $q(z) = p(z|x; \theta^{(t)})$。此时 $KL = 0$，$\log p(x; \theta^{(t)}) = \mathcal{L}(p(z|x; \theta^{(t)}), \theta^{(t)})$ [cite: 85, 96]。
- **M步的本质**：
  - 固定 $q(z)$（即固定后验分布），最大化下界 $\mathcal{L}(q, \theta)$ 关于 θ 的值 [cite: 99]。
  - 由于 $\log p(x; \theta) = \mathcal{L} + KL$，且 $KL \geq 0$，最大化 $\mathcal{L}$ 必然导致 $\log p(x; \theta)$ 增加（至少不减少） [cite: 114, 116]。

(3) 收敛性证明 (Monotonicity)

我们需要证明 $\log p(x; \theta^{(t+1)}) \geq \log p(x; \theta^{(t)})$：

$$\log p(x; \theta^{(t+1)}) \geq \mathcal{L}(p(z|x; \theta^{(t)}), \theta^{(t+1)}) \geq \mathcal{L}(p(z|x; \theta^{(t)}), \theta^{(t)}) = \log p(x; \theta^{(t)})$$

1. 第一个不等号：因为 $KL \geq 0$ [cite: 112, 114]。
2. 第二个不等号：因为M步就是为了找让 $\mathcal{L}$ 最大的 $\theta^{(t+1)}$ [cite: 99, 101]。
3. 等号：因为E步使得 $KL = 0$ [cite: 84, 85]。

11.4 实例一：高斯混合模型 (GMM) (PPT P14-P22)

(1) 模型定义

- **公式**：$p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x; \mu_k, \Sigma_k)$ [cite: 160]。
- **隐变量** z：一个One-hot向量。若 $z_k = 1$，表示样本属于第 k 个高斯分量 [cite: 165, 173]。
- **参数** θ：$\{\pi_k, \mu_k, \Sigma_k\}_{k=1}^{K}$ [cite: 206]。

(2) GMM的E步 (PPT P16-P18)

目标是计算 $Q(\theta; \theta^{(t)}) = \mathbb{E}_z[\log p(x, z; \theta)]$ [cite: 180]。
关键在于计算**后验概率（Responsibility）** γ_{nk}：

$$\gamma_{nk} = p(z_n = k | x_n; \theta^{(t)}) = \frac{\pi_k^{(t)} \mathcal{N}(x_n; \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_{j=1}^{K} \pi_j^{(t)} \mathcal{N}(x_n; \mu_j^{(t)}, \Sigma_j^{(t)})}$$

[cite: 171, 172, 207]
直观理解：γ_{nk} 表示第 n 个数据点是由第 k 个高斯分布生成的概率。

Q函数展开：

$$Q(\theta, \theta^{(t)}) = \sum_{n=1}^{N} \sum_{k=1}^{K} \gamma_{nk} \left[\log \pi_k + \log \mathcal{N}(x_n; \mu_k, \Sigma_k) \right]$$

注意：这里利用了 z 是One-hot向量的性质，z_k 的期望就是 $p(z_k = 1|x)$，即 γ_{nk} [cite: 181, 183, 193]。

(3) GMM的M步 (PPT P19-P20)

对Q函数求导并令导数为0，得到参数更新公式 [cite: 197]：

1. **均值** μ_k（加权平均）：

   $$\mu_k^{(t+1)} = \frac{\sum_{n=1}^{N} \gamma_{nk} x_n}{\sum_{n=1}^{N} \gamma_{nk}}$$

   [cite: 198, 212]
   - $N_k = \sum_{n=1}^{N} \gamma_{nk}$ 可以看作属于第 k 类的“有效样本数” [cite: 199, 211]。
2. **协方差** Σ_k（加权协方差）：

   $$\Sigma_k^{(t+1)} = \frac{\sum_{n=1}^{N} \gamma_{nk} (x_n - \mu_k^{(t+1)})(x_n - \mu_k^{(t+1)})^T}{N_k}$$

   [cite: 198, 213]
3. **混合系数** π_k：

   $$\pi_k^{(t+1)} = \frac{N_k}{N}$$

   [cite: 200, 213]
   注意：推导 π_k 时需要引入拉格朗日乘子，因为有约束条件 $\sum \pi_k = 1$。

(4) 与软K-Means的关系 (PPT P22)

- 如果将GMM的协方差矩阵固定为 $\Sigma_k = \sigma^2 I$ 且 $\sigma^2 \to 0$ [cite: 318]：
  - 后验概率 γ_{nk} 会趋向于0或1（Hard assignment） [cite: 320]。
  - 此时GMM退化为K-Means算法。
- GMM可以看作是**Soft K-Means**，因为它给出了属于某类的概率，而不是硬性分类 [cite: 317, 320]。

11.5 实例二：概率PCA (PPCA) (PPT P23-P30)

这部分是考试的高阶难点，主要考察矩阵形式的推导和Completing the Square技巧。

(1) 模型定义 (PPT P24)

- **隐变量先验**：$p(z) = \mathcal{N}(z; 0, I)$ [cite: 337]。

- **条件概率（似然）**：$p(x|z) = \mathcal{N}(x; Wz + \mu, \sigma^2 I)$ [cite: 338]。
- **关系**：$x = Wz + \mu + \epsilon$，其中噪音 $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$。

(2) PPCA的E步 (PPT P26, P28)

我们需要计算 Q 函数，其中涉及到隐变量 z 的期望。
由于 $p(x, z)$ 是联合高斯分布，后验 $p(z|x)$ 也是高斯分布 [cite: 365, 387]。

后验分布推导结果 (PPT P28, P29)：

$$p(z|x) = \mathcal{N}(z; M^{-1}W^T(x - \mu), \sigma^2 M^{-1})$$

[cite: 387, 400]
其中辅助矩阵 $M = W^T W + \sigma^2 I$ [cite: 389]。

我们需要计算两个统计量的期望（用于代入Q函数）：

1. **一阶矩**：$\mathbb{E}[z_n] = M^{-1}W^T(x_n - \bar{x})$ [cite: 391]。
2. **二阶矩**：$\mathbb{E}[z_n z_n^T] = \text{Cov}(z_n) + \mathbb{E}[z_n]\mathbb{E}[z_n]^T = \sigma^2 M^{-1} + \mathbb{E}[z_n]\mathbb{E}[z_n]^T$ [cite: 393]。

(3) "配方法" (Completing the Square) (PPT P29)

⚠️ **必考推导**：如何证明后验 $p(z|x)$ 是高斯分布?

1. 写出联合分布的对数形式（忽略常数）：
$$\log p(x, z) \propto -\frac{1}{2\sigma^2}||x - Wz - \mu||^2 - \frac{1}{2}||z||^2$$
[cite: 396]
2. 展开关于 z 的二次项和一次项：
$$= -\frac{1}{2} z^T \left(\frac{W^T W}{\sigma^2} + I \right) z + \frac{1}{\sigma^2}(x - \mu)^T W z + \text{const}$$
[cite: 397]
3. 令 $M = W^T W + \sigma^2 I$，这正是高斯分布指数部分的二次型形式：
$$-\frac{1}{2}(z - m)^T \Sigma^{-1}(z - m) = -\frac{1}{2} z^T \Sigma^{-1} z + m^T \Sigma^{-1} z + \dots$$
[cite: 398]
4. 通过对比系数（Matching coefficients）：
   - **精度矩阵** (协方差的逆)：$\Sigma^{-1} = \frac{1}{\sigma^2} M \Rightarrow \Sigma = \sigma^2 M^{-1}$ [cite: 399]。
   - **均值项**：$m^T \Sigma^{-1} = \frac{1}{\sigma^2}(x - \mu)^T W \Rightarrow m = M^{-1}W^T(x - \mu)$ [cite: 399, 400]。

(4) PPCA的M步 (PPT P27)

目标：最大化 Q 函数关于 W。

1. **Q函数**中包含 W 的项（PPT P26）：
$$\sum_{n=1}^{N} \left(\frac{1}{\sigma^2}(x_n - \mu)^T W \mathbb{E}[z_n] - \frac{1}{2\sigma^2} \text{Tr}(W^T W \mathbb{E}[z_n z_n^T]) \right)$$
[cite: 369]
(这里用到了迹的性质 $x^T A x = \text{Tr}(x^T A x) = \text{Tr}(A x x^T)$) [cite: 372]
2. **求导**：对 W 求偏导并令其为0。
$$\frac{\partial Q}{\partial W} \propto \sum_{n=1}^{N} \left((x_n - \bar{x})\mathbb{E}[z_n]^T - W \mathbb{E}[z_n z_n^T] \right) = 0$$
[cite: 380]
3. **解析解**：
$$W^{(t+1)} \leftarrow \left[\sum_{n=1}^{N} (x_n - \bar{x})\mathbb{E}[z_n]^T \right] \left[\sum_{n=1}^{N} \mathbb{E}[z_n z_n^T] \right]^{-1}$$
[cite: 382]

11.6 总结与复习策略 (教授寄语)

1. **抓住主线**：EM算法的核心就是 **Lower Bound Maximization**。只要记住 $\log p(x) = \mathcal{L} + KL$ 这个分解式，很多理论证明题就能迎刃而解 [cite: 58, 62]。
2. **公式记忆**：
   - **GMM**：务必背诵 γ_{nk} 的公式和M步三个参数的加权更新公式 [cite: 206, 207, 213]。
   - **PPCA**：记住 $M = W^T W + \sigma^2 I$ 这个辅助矩阵，以及如何通过配方法得到后验分布 [cite: 389, 395]。
3. **复习重点**：PPT P7-P11的理论推导是**选择/判断/简答题**的来源；GMM的流程是**计算流程题**的来源（即使不带计算器，也可能让你写出前两步的表达式）；PPCA的配方法是**数学证明题**的来源。

11.7 蒙特卡洛方法 (Homework 1 真题详解)

11.7.1 蒙特卡洛求 π (Exercise 1) (PPT P409-420)

🎯 **作业真题解析**

题目：利用蒙特卡洛模拟求 π 值。在单位正方形内产生均匀分布的点，计算落在内切四分圆内的比例 [cite: 410, 411, 413, 414]。

- **考点**：拒绝采样 (Rejection Sampling) 的基础思想、频率估计概率。

详解：

1. **模型建立**：
   - **区域定义**：正方形面积 $A_{square} = 1 \times 1 = 1$ [cite: 412]。四分圆面积 $A_{circle} = \frac{1}{4}\pi r^2 = \frac{\pi}{4}$（$r = 1$） [cite: 412]。
   - **概率关系**：如果点是均匀分布的，那么点落在圆内的概率 $P(\text{in circle}) = \frac{A_{circle}}{A_{square}} = \frac{\pi}{4}$ [cite: 413, 414]。
   - **估计式**：$\pi \approx 4 \times \frac{N_{in}}{N_{total}}$ [cite: 414]。
2. **算法流程 (代码逻辑)**：
   - 循环 `N` 次：
     a. 产生两个 0 到 1 之间的均匀随机数 $x \sim U(0,1), y \sim U(0,1)$。
     b. 判断是否在圆内：计算 $d = x^2 + y^2$。
     c. 如果 $d \leq 1$，则计数器 `count` 加 1。
   - 计算结果：$\hat{\pi} = 4 \times \frac{count}{N}$ [cite: 416]。
3. **均值与方差分析**：
   - 这是一个二项分布问题（点要么在圆内，要么在圆外）。
   - 单次实验成功的概率 $p = \frac{\pi}{4}$。
   - N 次实验中，$count \sim B(N, p)$。
   - **估计值的期望**：$\mathbb{E}[\hat{\pi}] = 4 \times \mathbb{E}[\frac{count}{N}] = 4 \times p = \pi$（无偏估计） [cite: 418]。
   - **估计值的方差**：

$$Var(\hat{\pi}) = 16 \times Var(\frac{count}{N}) = 16 \times \frac{p(1-p)}{N} = \frac{16}{N} \cdot \frac{\pi}{4}(1 - \frac{\pi}{4}) = \frac{\pi(4-\pi)}{N}$$

     [cite: 418]
   - *结论*：随着 N 增大，方差以 $1/N$ 的速度减小，估计值越来越稳定 [cite: 416, 417]。

11.7.2 蒙特卡洛定积分：简单函数 (Exercise 2) (PPT P421-429)

🎯 **作业真题解析**

题目：用蒙特卡洛方法计算 $\int_0^1 x^3 dx$ [cite: 422, 423]。

- **解析解**：$\left[\frac{1}{4}x^4\right]_0^1 = 0.25$ [cite: 424]。
- **问题**：选择什么分布采样？N 取不同值时的表现？ [cite: 424, 425]

详解：

1. **采样分布选择**：
   - 题目积分区间是 $[0,1]$，最自然的选择是 **均匀分布** $U(0,1)$ [cite: 424]。
   - 令 $p(x) = 1, x \in [0,1]$。
   - 原积分转化为期望形式：

$$I = \int_0^1 x^3 dx = \int_0^1 x^3 \cdot p(x) dx = \mathbb{E}_{x \sim U(0,1)}[x^3]$$

2. **蒙特卡洛估计量**：
   - 采样 N 个点 $x_i \sim U(0,1)$。
   - 估计值 $\hat{I} = \frac{1}{N} \sum_{i=1}^{N} x_i^3$ [cite: 425]。
3. **误差分析 (理论方差)**：
   - 为了评估"结果有多好"，我们需要计算被积函数 $g(x) = x^3$ 在 $U(0,1)$ 下的方差 [cite: 425, 426]。
   - $\mathbb{E}[g(x)] = 0.25$。
   - $\mathbb{E}[g(x)^2] = \int_0^1 (x^3)^2 dx = \int_0^1 x^6 dx = \frac{1}{7}$。
   - **单样本方差** $\sigma^2 = \mathbb{E}[g^2] - (\mathbb{E}[g])^2 = \frac{1}{7} - (\frac{1}{4})^2 = \frac{1}{7} - \frac{1}{16} = \frac{16-7}{112} = \frac{9}{112} \approx 0.08$。
   - **估计量的标准差 (Standard Error)**：$SE = \frac{\sigma}{\sqrt{N}}$。这解释了为什么 N 越大，结果越好 [cite: 426]。

11.7.3 蒙特卡洛定积分：复杂二重积分 (Exercise 3) (PPT P430-438)

🎯 **作业真题解析**

题目：计算 $I = \int_2^4 \int_{-1}^1 f(x,y) dy dx$，其中 $f(x,y) = \frac{y^2 e^{-y^2} + x^4 e^{-x^2}}{x e^{-x^2}}$ [cite: 432, 437]。

- **考点**：高维蒙特卡洛积分、积分区域体积归一化 [cite: 433]。

详解：

1. **能否解析求解?**
   - 观察函数形式，分母包含 xe^{-x^2}，分子第一项包含 e^{-y^2}。x 和 y 的耦合度不高，可能可以拆分，但形式复杂，非常适合蒙特卡洛 [cite: 433]。
2. **采样策略**：
   - **积分区域 Ω**：$x \in [2,4], y \in [-1,1]$ [cite: 432]。
   - 这是一个矩形区域，面积（体积）$V = (4-2) \times (1-(-1)) = 2 \times 2 = 4$。
   - **采样分布**：在区域 Ω 上均匀采样 [cite: 433]。
     - $x \sim U(2,4)$
     - $y \sim U(-1,1)$
     - 联合概率密度 $p(x,y) = \frac{1}{V} = \frac{1}{4}$。
3. **估计公式**：

$$I = \iint_\Omega f(x,y) dx dy = \iint_\Omega f(x,y) \cdot \frac{p(x,y)}{1/V} dx dy$$

$$= V \cdot \mathbb{E}_{x,y \sim U}[f(x,y)]$$

   - **蒙特卡洛估计器**：

$$\hat{I} = 4 \times \frac{1}{N} \sum_{i=1}^{N} f(x_i, y_i)$$

   - **注意**：很多同学考试时会**忘记乘体积系数 $V=4$**，导致结果缩小4倍。切记公式是 **(区域体积) × (函数平均值)** [cite: 434, 435]。

11.7.4 随机游走 (Random Walk) 路径规划 (Exercise 4) (PPT P439-447)

🎯 **作业真题解析**

题目：蚂蚁从 (1,1) 走到 (7,7) 的 7×7 网格 [cite: 440, 441]。

- **移动规则**：上下左右 [cite: 442]。
- **约束条件**：
  i. 不出界 [cite: 444]。
  ii. 中心点 (4,4) 允许访问 0, 1 或 2 次 [cite: 445]。
  iii. 其余点允许访问 0 或 1 次（**即不能走回头路/不能重复访问非中心点**） [cite: 445]。
- **求**：到达终点的概率 P [cite: 446]。

详解：
这是一个典型的**带约束随机过程模拟**。解析解非常难算（涉及自回避随机游走的变体），必须用蒙特卡洛。

算法流程：

1. **初始化**：设置计数器 `success_count = 0` 。进行 `20,000` 次循环 [cite: 446]。
2. **单次模拟**：
   - 当前位置 `pos = (1,1)` [cite: 441]。
   - 路径记录 `visited = {(1,1): 1}` (用字典记录访问次数)。
   - 循环直到：到达(7,7) [成功] 或 无路可走/陷入死胡同 [失败] 或 步数过长 [截断]。
     - **生成下一步**：随机选择 上下左右 一个方向 [cite: 442]。
     - **检查约束**：
       a. 是否出界？若出界，该方向无效 [cite: 444]。
       b. 目标点如果是 (4,4)：检查 `visited[(4,4)]` 是否 < 2 [cite: 445]。
       c. 目标点如果是其他点：检查 `visited[new_pos]` 是否 == 0 [cite: 445]。
     - **执行移动**：如果有合法的移动方向，随机选一个走，更新 `pos` 和 `visited` 。如果没有合法移动方向，该次模拟结束（蚂蚁死掉了/卡住了），标记为失败。
   - **判定**：如果 `pos == (7,7)` ，则 `success_count += 1` 。
3. **结果**：$P \approx \frac{success_count}{20000}$ [cite: 446]。

考试Tips：

- 如果考试让你手写伪代码，重点在于**如何高效存储 `visited` 状态**（哈希表/二维数组）以及**死胡同的处理**（当所有方向都不满足约束时，路径中断，概率贡献为0）。

11.7.5 系统可靠性仿真 (Exercise 5) (PPT P448-458)

🎯 **作业真题解析**
题目：给定系统结构图，Component A (0.85), B (0.95), C (0.90) [cite: 450, 451]。

- **结构逻辑**：输入有 50% 走上路 (A)，50% 走下路 (B -> C) [cite: 452, 455]。
- **理论计算**：
  - PPT中的公式有点奇怪，它写的是 `reliability_sys = 1.0 - [(1.0 - 0.85) * (1.0 - 0.855)]` 。这个公式其实是**并联系统**（A **或者** BC 成功即成功）的公式，即 `1 - P(A坏)P(BC坏)` [cite: 454]。
  - **但是**，题目描述说 "half the time input travels through A... other half... lower half" [cite: 455, 456]。这描述的是**互斥选择**逻辑，不是并联。
  - **修正理解**：如果题目意思是“输入随机选择路径”，那么可靠性应该是加权平均：$R = 0.5 \times R_A + 0.5 \times R_{BC}$。
  - **然而**，根据PPT给出的公式结果 `0.97825` ，这明显是**并联结构**（Redundancy）的计算结果 [cite: 454]。这意味着题目描述中的 "half the time" 可能是一种误导性的物理描述，实际上系统逻辑是：**只要有一条路通，系统就Work**。我们以PPT中的数学公式为准（并联逻辑）。

模拟逻辑设计：

1. **目标**：验证并联系统的可靠性 $R = P(A \cup (B \cap C))$。
2. **仿真步骤**：
   - 循环 `N` 次 [cite: 458]：
     - **模拟 A**：生成随机数 $r_1 \sim U(0,1)$。若 $r_1 \leq 0.85$，记 `A_working = True` [cite: 455]。
     - **模拟 B和C**：生成 $r_2, r_3 \sim U(0,1)$。若 $r_2 \leq 0.95$ 且 $r_3 \leq 0.90$，记 `BC_working = True` [cite: 457]。
     - **系统判定**：
       - **情况1 (依据PPT公式 - 并联)**： `if A_working or BC_working: success_count += 1` 。
       - *情况2 (依据文字描述 - 分流)*：生成 r_4 决定走哪条路。这种情况下结果会远低于 0.97，不符合PPT给出的 0.97825。**所以考试时请务必采用情况1（并联）的逻辑代码**，除非题目明确删除了那个公式 [cite: 454]。
3. **收敛性**：当 N 很大时，模拟结果应逼近 0.97825 [cite: 458]。

第12章 线性降维：主成分分析 (PCA)

12.1 动机与背景 (PPT P1-P5)

(1) 核心概念与定义

- **维数灾难 (Curse of Dimensionality)**：
  - *直观理解*：许多真实数据（如图像、基因序列）维度极高。例如一张 256×256 的图片，维度高达 65,536。计算复杂度通常是 $\mathcal{O}(N^2)$ 或更高，这在计算上是不可行的 [cite: 18, 19, 21]。
- **本征维度 (Intrinsic Dimension)**：
  - *定义*：高维数据通常并非均匀分布，而是近似分布在一个低维的**本征子空间**上 [cite: 26]。

- *图解*：三维空间中的数据点可能主要分布在一个二维平面上（$D=3 \to d=2$），或者二维数据分布在一条直线上（$D=2 \to d=1$） [cite: 28, 31]。

- **数据预处理**：
  - **向量化**：PCA需要实数值矩阵作为输入。对于非数值数据（如基因碱基 A, T, C, G），通常需要进行 One-Hot 编码或二值化转换 [cite: 421]。

> 🎯 **作业真题解析 (对应知识点：数据维度与特征表示)**
>
> **题目 (Homework 5 - Part a)**：
> 假设我们将基因数据转换为一个二值矩阵 X（如果个体 i 在位置 j 拥有该位置众数碱基则 $X_{i,j}=0$，否则为1）。该矩阵有 995 行（个体）和 10101 列（核碱基位置）。如果我们在这个矩阵 X 上运行 PCA，返回的向量（即主成分）的维度是多少？ [cite: 411, 413, 425]
>
> **详解**：
>
> - **答案**：**10101 维**。
> - **解析**：
>   - PCA 的核心是寻找数据方差最大的**方向** [cite: 34, 163]。
>   - 数据 X 中的每一个样本（即每一行）都是一个 $D=10101$ 维的向量 [cite: 413]。
>   - 数据所在的原始空间是 $\mathbb{R}^{10101}$。
>   - 因此，在这个空间中定义的任何“方向”(即主成分向量 v)，必须与原始数据的特征维度保持一致。
>   - **考点**：主成分是原始特征的线性组合，其维度等于特征数 D，而不是样本数 N。

12.2 视角一：最小化重构误差 (PPT P6-P17)

(1) 核心概念

- **正交基变换**：我们希望在 D 维空间中找到 M 个正交方向（基向量）u_i，其中 $u_i^T u_j = \delta_{ij}$（当 $i=j$ 时为1，否则为0） [cite: 55, 56]。
- **数据重构**：任何数据点 x 可以被这组基近似表示为 $\tilde{x}$：

$$\tilde{x} = \sum_{i=1}^{M} \alpha_i u_i$$

  [cite: 59]
- **最佳系数**：投影系数 α_i 就是 x 在方向 u_i 上的投影长度：

$$\alpha_i = u_i^T x$$

  [cite: 61, 68]
- **中心化 (Centering)**：PCA对数据的均值敏感，必须先减去均值 $\bar{x}$，使数据云中心位于原点 [cite: 89, 416]。

(2) 核心公式与推导 (⚠️ 必考推导)

目标函数：重构误差 E

我们首先需要对数据进行**中心化 (Centering)** 处理，即将所有数据的均值移到原点。
令 $\bar{x} = \frac{1}{N}\sum_{n=1}^{N} x^{(n)}$，则中心化后的数据为 $x^{(n)} - \bar{x}$ [cite: 91]。
最佳投影系数变为 $\alpha_i^{(n)} = u_i^T(x^{(n)} - \bar{x})$ [cite: 95]。

我们定义**均方重构误差** E 为原始数据与重构数据之间距离的平方和的均值：

$$E = \frac{1}{N}\sum_{n=1}^{N} \|(x^{(n)} - \bar{x}) - \tilde{x}^{(n)}\|^2$$

其中近似值 $\tilde{x}^{(n)} = \sum_{i=1}^{M} \alpha_i^{(n)} u_i$ [cite: 93]。

推导步骤：

1. **展开误差项**：
   将 $\tilde{x}^{(n)}$ 代入 E，利用向量范数性质 $\|a-b\|^2 = \|a\|^2 - 2a^Tb + \|b\|^2$：

$$\|(x^{(n)} - \bar{x}) - \sum_{i=1}^{M} \alpha_i^{(n)} u_i\|^2 = \|x^{(n)} - \bar{x}\|^2 - 2\sum_{i=1}^{M} \alpha_i^{(n)} (x^{(n)} - \bar{x})^T u_i + \sum_{i=1}^{M} (\alpha_i^{(n)})^2$$

(注意：利用了正交性 $u_i^T u_j = \delta_{ij}$，使得交叉项消失，仅剩平方项和) [cite: 66, 100]

2. **代入最优系数**：
   已知 $\alpha_i^{(n)} = (x^{(n)} - \bar{x})^T u_i = u_i^T (x^{(n)} - \bar{x})$，代入上式化简中间项和最后一项，发现它们部分抵消，最终得到：

$$E = \frac{1}{N} \sum_{n=1}^{N} \left(\|x^{(n)} - \bar{x}\|^2 - \sum_{i=1}^{M} ((x^{(n)} - \bar{x})^T u_i)^2 \right)$$

   [cite: 102]
3. **矩阵形式转换**：
   第一项 $\frac{1}{N} \sum \|x^{(n)} - \bar{x}\|^2$ 是常数（数据的总方差），记为 C [cite: 107]。
   第二项可以写成矩阵形式。定义协方差矩阵（散度矩阵） S：

$$S = \frac{1}{N} \sum_{n=1}^{N} (x^{(n)} - \bar{x})(x^{(n)} - \bar{x})^T$$

   于是目标函数变为：

$$E = \text{const} - \sum_{i=1}^{M} u_i^T S u_i$$

   [cite: 107]
4. **等价优化问题**：
   要**最小化**重构误差 E，等价于**最大化**第二项：

$$\max_{u_1, \dots, u_M} \sum_{i=1}^{M} u_i^T S u_i$$

   约束条件：$u_i^T u_i = 1$ (单位向量) [cite: 110, 111]。
5. **拉格朗日乘子法求解 (Lagrange Multipliers)**：
   考虑 $M = 1$ 的情况（找第一个主成分）：

$$\mathcal{L}(u_1, \lambda) = u_1^T S u_1 - \lambda (u_1^T u_1 - 1)$$

   [cite: 118]
   对 u_1 求导并令为 0：

$$\frac{\partial \mathcal{L}}{\partial u_1} = 2 S u_1 - 2 \lambda u_1 = 0$$

$$\Rightarrow S u_1 = \lambda u_1$$

   [cite: 120]
   结论：u_1 必须是协方差矩阵 S 的**特征向量 (Eigenvector)**，对应的 λ 是**特征值 (Eigenvalue)** [cite: 121]。
   因为我们要最大化 $u_1^T S u_1 = u_1^T (\lambda u_1) = \lambda u_1^T u_1 = \lambda$，所以应该选择**最大的特征值**对应的特征向量 [cite: 121]。

(3) 潜在考题预测 (Exam Hacks)

> **Q**: 为什么在进行PCA之前必须对数据进行中心化（Centering）？
> **A**: PCA的目的是捕获数据的方差方向。如果不进行中心化，计算出的“主成分”可能会是从原点指向数据云中心的向量，而不是数据自身分布的主方向，这会导致第一主成分产生误导，变成均值向量而非方差向量 [cite: 89, 416]。

> **Q**: 证明重构误差最小化等价于方差最大化。
> **A**: 答题思路如上推导。关键点在于写出 $E = \text{const} - \sum u_i^T S u_i$。由于 $u_i^T S u_i$ 正是投影后的方差（见下文），所以最小化 E 等同于最大化投影方差 [cite: 107, 109, 186]。

12.3 视角二：最大化方差 (PPT P18-P21)

(1) 核心概念

- **直观理解**：降维后的投影点应尽可能散开（方差最大），以保留最多信息 [cite: 179]。

(2) 核心公式

- **投影方差**：
  数据点 $x^{(n)}$ 在方向 u_1 上的投影是 $u_1^T x^{(n)}$ [cite: 182]。
  投影后的方差（假设已中心化）为：

$$Var = u_1^T S u_1$$

  [cite: 186]
- **方差贡献率 (Explained Variance Ratio)**：
  - 第 k 个主成分解释的方差比例 = $\frac{\lambda_k}{\sum_{i=1}^{D} \lambda_i}$ [cite: 451]。
  - 衡量降维效果的重要指标。

> 🎯 **作业真题解析 (对应知识点：方差解释与维度选择)**
>
> **题目 (Homework 5 - Part g)**：
> 第一主成分解释了数据中多少比例的方差？换句话说，当我们将所有基因组投影到第一主成分上时，基因组的平方长度（Squared Length）平均减少了多少百分比？如果投影到前三个主成分构成的子空间呢？ [cite: 450, 451, 452]
>
> **详解**：
>
> - **理论解法**：
>   i. 计算协方差矩阵 S 的特征值 $\lambda_1, \lambda_2, \ldots, \lambda_D$（按从大到小排序）。
>   ii. **总方差**（Total Variance）等于所有特征值之和：$T = \sum_{i=1}^{D} \lambda_i$。
>   iii. **第一主成分解释的比例**：$R_1 = \frac{\lambda_1}{T}$。
>   iv. **前三个主成分解释的比例**：$R_{1-3} = \frac{\lambda_1+\lambda_2+\lambda_3}{T}$。
> - **代码实现思路 (Python/sklearn)**：
>
> ```
> pca = PCA(n_components=3)
> pca.fit(X)
> # 第一主成分方差比例
> print(pca.explained_variance_ratio_[0])
> # 前三主成分方差比例之和
> print(sum(pca.explained_variance_ratio_[0:3]))
> ```
>
> - **直观含义**：如果 R_1 很低（例如 5%），说明数据非常复杂，单一维度无法概括；如果很高（例如 90%），说明数据主要沿一条线分布。基因数据通常维度极高，单维解释度往往不高，但仍具有显著的生物学意义 [cite: 452]。

12.4 视角三：奇异值分解 (SVD) (PPT P22-P25)

(1) SVD 定义与 PCA 的关系

- 任意 $M \times N$ 矩阵 A 分解：$A = U\Sigma V^T$ [cite: 209, 210]。
- 数据矩阵 $\tilde{X}$ (已中心化) 的 SVD 分解：$\tilde{X} = U\Sigma V^T$ [cite: 275]。
- PCA 的主方向（特征向量）即为 V 的列向量（注意：如果是 $X_{N\times D}$ 格式，sklearn 中是 V^T 的行；PPT中定义 $S = XX^T$ 还是 X^TX 决定了是 U 还是 V，需根据维度 D 判断） [cite: 222, 223]。
- **PPT P23 定义**：$S = \frac{1}{N}\tilde{X}^T\tilde{X}$ (假设 X 是 $N \times D$)，其特征向量对应 SVD 中的右奇异向量 V [cite: 271, 272]。

(2) 潜在考题预测 (Exam Hacks)

> **Q**: 给定数据矩阵 X，如何利用 SVD 求 PCA 的主方向?
> **A**: 1. 对 X 的每一列减去均值得到 $\tilde{X}$。 2. 对 $\tilde{X}$ 进行 SVD 分解 $\tilde{X} = U\Sigma V^T$。 3. V 的列向量即为主成分方向 [cite: 275]。

12.5 PCA 的应用与解释 (PPT P26-P30)

这一部分是本次作业的重头戏，考察如何“看图说话”。

(1) 常见应用场景

- **图像压缩/去噪**：保留大特征值对应的分量（信号），丢弃小特征值对应的分量（噪声） [cite: 286, 363]。
- **降维可视化**：将高维数据投影到前2维或前3维平面进行观察 [cite: 426]。
- **聚类分析**：在低维空间中观察数据点是否自然聚集成簇 [cite: 442]。

> 🎯 **作业真题解析 (对应知识点：PCA结果的可视化与生物学解释)**
>
> **题目 (Homework 5 - Part b, c, d, e, f)**：
> 我们将基因数据投影到主成分空间。
>
> - **(b)**: 绘制 PC1 vs PC2 的散点图，用不同颜色标记人群 [cite: 426, 437]。
> - **(c)**: 解释前两个主成分捕获了什么信息？(提示：思考历史和地理) [cite: 439, 440]
> - **(e)**: 观察 PC1 vs PC3 的图，第三主成分捕获了什么信息？ [cite: 441, 445]
> - **(f)**: 绘制“核碱基索引 (Index)” vs “第三主成分对应值的绝对值”。你发现了什么？(提示：思考染色体) [cite: 447, 449]
>
> **详解**：
> 这是一道经典的生物信息学考题，即便你无法运行代码，也**必须记住标准答案的逻辑**，这在考试中属于“案例分析题”。
>
> 1. **PC1 和 PC2 的解释 (地理/种群结构)**：
>   - **现象**：在散点图上，不同的人群（Population）会聚集成明显的簇 [cite: 412]。
>   - **解释**：前两个主成分通常捕获了人类的**地理起源（Geography）和祖源差异（Ancestry）** [cite: 440]。
>   - *具体例子*：通常 PC1 会把非洲人群（Africa）与非非洲人群分开（因为人类起源于非洲，遗传多样性最大）；PC2 可能会把欧洲人（Europe）和东亚人（East Asia）分开。这反映了人类迁徙的历史轨迹。
> 2. **PC3 的解释 (性别/染色体)**：
>   - **现象**：在 PC1 vs PC3 的图中，数据点可能会分裂成两个非常清晰、分离很远的“条带”或“簇”，且这两个簇与种群无关，而是与每个种群内部的一半一半分布有关 [cite: 441, 442]。
>   - **解释**：第三主成分通常捕获了**性别（Sex）**差异 [cite: 412, 449]。
>   - *逻辑*：如果数据中包含了性染色体（X和Y），男性（XY）和女性（XX）在这些位置的碱基模式会有巨大差异。PCA 会敏锐地捕捉到这种全基因组范围内的系统性方差。
> 3. **Loading Plot 分析 (题目 f)**：
>   - **操作**：画出 PC3 向量中每个分量（对应每个基因位点）的绝对值 [cite: 447]。
>   - **现象**：你会发现绝大多数位点的值接近 0，但有某一特定区域的索引位置，其值非常高（Spike）。
>   - **结论**：这些高权重的索引位置对应于**性染色体（第23对染色体）**上的基因位点。这验证了 PC3 确实是在通过性染色体的差异来区分样本 [cite: 449]。

12.6 PCA 的局限性与扩展 (PPT P31-P35)

(1) PCA 的局限性

- **线性假设**：PCA 只能找到线性的低维子空间。如果数据分布在非线性的流形（如螺旋数据）上，PCA 效果很差 [cite: 383, 389]。
- **相关性 vs 独立性**：PCA 仅去除二阶相关性（Decorrelation），即让不同维度的协方差为 0。但它不能保证特征之间的**统计独立性 (Independence)** [cite: 374, 375]。

(2) 扩展算法（概念对比）

- **RCA / FDA**：FDA 是有监督的，目标是分类（最大化类间散度，最小化类内散度）；PCA 是无监督的，目标是最大化方差 [cite: 371, 372]。
- **ICA (独立成分分析)**：追求统计独立，基向量可以是非正交的，常用于盲源分离（鸡尾酒会问题） [cite: 375, 380]。
- **CCA / 流形学习**：如 Curvilinear Component Analysis，保留局部拓扑结构，展开非线性形状（如瑞士卷） [cite: 384, 386]。

12.7 考前复习总结 (Final Review Checklist)

请重点关注以下能够应对“不带计算器”考试的技能：

1. **数学推导能力**：
   - 必须能默写：从重构误差 E 出发 $\rightarrow$ 展开公式 $\rightarrow$ 转化为最大化 $u^T S u$ $\rightarrow$ 拉格朗日乘子法求导 $\rightarrow$ 得出特征值方程 $Su = \lambda u$ [cite: 93, 107, 120]。

2. **维度匹配能力**：
   - 如果数据 X 是 $N \times D$，S 是 $D \times D$，特征向量 u 是 $D \times 1$，投影后的数据 Y 是 $N \times M$ [cite: 425]。
3. **结果解释能力 (结合作业)**：
   - 看到 PCA 散点图聚类，首先往“类别差异”（如不同物种、不同种群）想 [cite: 427, 437]。
   - 看到方差解释率，知道这是评价降维损失的关键 [cite: 450]。

第15章 集成学习 (Ensemble Learning)

15.1 集成学习综述 (Ensemble Overview)

15.1.1 核心概念与动机 (PPT P1-16)

(1) 定义与直观理解

- **集成学习 (Ensemble Learning)**：
  - *定义*：通过构建并结合多个学习器（Learners）来完成学习任务。数学表达为 $f^*(x) = \text{Combine}(f_1(x), f_2(x), ..., f_k(x))$。
  - *直观含义*：“三个臭皮匠，顶个诸葛亮” (The Wisdom of Crowds)。与其训练一个可能过拟合或陷入局部最优的“超级模型”，不如训练多个略好于随机猜测的“弱学习器”，然后通过投票或加权来得到一个强学习器。
  - *解决了什么问题*：主要解决单一模型的泛化能力差、容易陷入局部极值、以及对数据分布假设不准确的问题。

(2) 为什么集成学习有效？(数学角度)

这里有两个核心解释，考试常考选择题或简答题。

- **角度一：误差缩减 (Error Reduction)** (PPT P13)
  - 假设我们有 k 个独立的分类器，每个分类器的错误率为 ϵ (例如 0.3)。
  - 采用**多数投票法 (Majority Voting)**，集成的错误率取决于“超过一半分类器都错了”的概率。
  - 根据二项分布，集成错误率会随着 k 的增加呈指数级下降（前提是分类器之间相互独立且准确率 > 0.5）。
  - *考试陷阱*：如果分类器之间完全正相关（犯错一样），集成无效。**多样性 (Diversity)** 是核心。
- **角度二：偏差-方差分解 (Bias-Variance Decomposition)** (PPT P26)
  - **Bagging**：主要降低**方差 (Variance)**。通过重采样训练不同的模型，平滑了数据的随机噪声。
  - **Boosting**：主要降低**偏差 (Bias)**。通过专注于难分的样本，逐步逼近真实分布。

15.2 监督集成学习 (Supervised Ensemble)

这是考试的绝对重灾区，尤其是 AdaBoost 的推导。

15.2.1 Bagging 与 随机森林 (PPT P28-30, P40-41)

(1) Bagging (Bootstrap Aggregating)

- **核心机制**：并行式集成。
- **算法流程**：
  i. **Bootstrap 采样**：从大小为 N 的原始数据集 D 中，**有放回**地随机采样 N 次，得到训练集 D_i。
     - *考点*：约有 36.8% $(1 - 1/e)$ 的样本未被选中，称为**袋外数据 (Out-of-Bag, OOB)**，可用于验证。
  ii. **训练**：基于 D_i 独立训练基学习器 f_i。
  iii. **结合**：分类任务用投票 (Voting)，回归任务用平均 (Averaging)。
- **公式推导 (MSE下降)** (PPT P30)：
  - 理想的 Bagging 估计量 $\bar{f}(x) = E[\hat{f}_z(x)]$（假设有无限个模型取期望）。
  - 根据 Jensen 不等式或方差分解：$E[Y - \bar{f}(x)]^2 \leq E[Y - \hat{f}_z(x)]^2$。即：组合后的模型均方误差通常小于单一模型的期望误差。

(2) 随机森林 (Random Forests)

- **定义**：Bagging 的进化版。**Random Forests = Bagging + Random Features**。
- **差异点 (必考)**：
  - Bagging 只对样本进行随机采样。
  - 随机森林在决策树的**每个节点分裂时**，随机选择 m 个特征（$m < M_{total}$），从中寻找最优分裂点。通常 $m \approx \sqrt{M}$ 或 $\log_2 M$。
- **优势**：进一步降低了树之间的相关性，从而更有效地降低了方差。

15.2.2 Boosting 与 AdaBoost (PPT P31-39) ⚠️ ⚠️ ⚠️

这是整份 PPT 最可能考**手推公式**的部分。

(1) 核心思想

- **串行式集成**：下一个分类器主要为了纠正前一个分类器的错误。
- **权重调整**：提高被前一轮弱分类器错误分类样本的权重。

(2) AdaBoost 算法流程与推导 (PPT P34-36)

给定训练集 $T = \{(x_1, y_1), ..., (x_N, y_N)\}, y_i \in \{+1, -1\}$。

1. **初始化权重**：
$$D_1 = (w_{11}, ..., w_{1N}), \quad w_{1i} = \frac{1}{N}$$
2. **迭代训练** (对 $m = 1, ..., M$)：
   - **Step A**: 基于当前权重 D_m 训练弱分类器 $G_m(x)$。
   - **Step B**: 计算分类误差率 e_m (被错分样本的权重之和)：
$$e_m = \sum_{i=1}^{N} w_{mi} I(G_m(x_i) \neq y_i)$$
   - **Step C**: 计算该分类器的系数 (话语权) α_m：
$$\alpha_m = \frac{1}{2} \ln \left(\frac{1 - e_m}{e_m} \right)$$
     - *逻辑解析*：当 $e_m < 0.5$ 时，$\alpha_m > 0$，且准确率越高，权重越大。若 $e_m > 0.5$，则反向预测。
   - **Step D**: 更新样本权重 D_{m+1}：
$$w_{m+1,i} = \frac{w_{mi}}{Z_m} \exp(-\alpha_m y_i G_m(x_i))$$
     - 如果分对 ($y_i = G_m(x_i)$)，指数项为 $\exp(-\alpha)$，权重下降。
     - 如果分错 ($y_i \neq G_m(x_i)$)，指数项为 $\exp(\alpha)$，权重上升。
     - Z_m 是规范化因子，确保权重和为 1。
3. **最终集成**：
$$G(x) = \text{sign} \left(\sum_{m=1}^{M} \alpha_m G_m(x) \right)$$

(3) 损失函数推导 (PPT P39)

- **AdaBoost 本质**：是在最小化**指数损失函数 (Exponential Loss)**：
$$L(y, f(x)) = \exp(-y f(x))$$
- 这解释了为什么 AdaBoost 对噪声敏感（异常值的 $yf(x)$ 为大负数，导致 Loss 指数级爆炸）。

15.3 无监督集成学习 (Clustering Ensemble)

PPT P49-87 花了大量篇幅讲这个，说明是教授的研究重点，务必重视算法细节。

15.3.1 核心问题与挑战 (PPT P49-51)

- **问题**：给定 k 个不同的聚类结果（Base Clusterings），如何产生一个共识聚类（Consensus Clustering）？
- **难点**：**标签对应问题 (Correspondence Problem)**。基聚类 1 把某组分为 "Cluster A"，基聚类 2 把它分为 "Cluster 1"，机器不知道 A 和 1 是否对应。

15.3.2 解决方法分类 (PPT P53)

(1) 基于共识函数 (Consensus Function) - 软/硬对应

- **硬对应 (Hard Correspondence)**：
  - 使用匈牙利算法 (Hungarian method) 寻找不同聚类结果间的一一映射，然后投票。
- **软对应 (Soft Correspondence)** (PPT P56-57)：
  - *定义*：引入成员矩阵 M_j 和对应矩阵 S_j。
  - *目标函数*：最小化不一致性 (Disagreement)。

$$\min \sum_{j=1}^{k} ||M - M_j S_j||^2$$

- *求解*：使用 **EM 算法**。E步更新共识矩阵 M，M步用梯度下降更新对应矩阵 S。

(2) 基于对象 (Object-based) (PPT P59-61)

- **共联矩阵 (Co-association Matrix)**：
  - 构建一个 $N \times N$ 的矩阵 T。
  - T_{ij} 表示对象 i 和对象 j 在所有基聚类中被分到**同一个簇**的频率（次数/总基聚类数）。
  - 最后对矩阵 T 进行传统的聚类（如层次聚类）。

(3) 基于图 (Graph/Cluster-based) (PPT P69-76)

这部分常考算法名称及其对应的图结构。

- **MCLA (Meta-Clustering Algorithm)**：
  - 把每个基聚类的“簇”看作超图的节点，计算簇之间的重叠度（Jaccard系数），对簇进行聚类（Meta-clustering）。
- **HGPA (HyperGraph-Partitioning Algorithm)** (PPT P71)：
  - **构图**：节点是数据点。如果多个点在某个基聚类中属于同一簇，就用一条**超边 (Hyperedge)** 连接它们。
  - **目标**：切分超图，最小化切断的超边数量 (Min-cut)。
- **二部图划分 (Bipartite Graph Partitioning)** (PPT P74)：
  - **构图**：左侧节点是数据对象，右侧节点是所有基聚类的簇。如果对象属于某簇，连边。
  - **求解**：使用谱聚类 (Spectral Clustering) 对二部图进行划分。

15.4 半监督与多视图集成 (Semi-supervised & Multi-view)

15.4.1 多视图学习 (Multi-view Learning) (PPT P90-95)

- **场景**：数据有两套特征（View）。例如网页分类：View 1 是网页文本，View 2 是指向该网页的超链接文本。
- **核心假设**：
  i. **相容性 (Compatibility)**：两个视图都能独立且正确地分类数据。
  ii. **独立性 (Independence)**：给定类别标签，两个视图的特征条件独立。

15.4.2 协同训练 (Co-Training) 算法 (PPT P95) ⚠️ 常考流程

1. **输入**：标记数据集 L，未标记数据集 U。
2. **初始化**：分别在 View 1 和 View 2 上利用 L 训练两个分类器 h_1, h_2。
3. **循环迭代**：
   - h_1 从 U 中选取置信度最高的 p 个正例和 n 个负例，打上伪标签加入 L。
   - h_2 同理，从 U 中选取置信度最高的样本，打上伪标签加入 L。
   - *直观理解*：互相教学。h_1 认为很有把握的样本，对 h_2 来说可能很难，把它加进去能扩充 h_2 的边界。

15.4.3 正则化框架 (Co-Regularization) (PPT P102-104)

- **思想**：不是迭代加样本，而是把“两个视图预测一致”作为一个**约束项 (Regularization Term)** 加入目标函数。
- **目标函数**：

$$\min(R(f_1, L_1) + R(f_2, L_2) + \lambda \cdot \text{Disagreement}(f_1, f_2, U))$$

  - $R(f, L)$：在有标数据上的风险（如最小二乘误差）。
  - Disagreement：在无标数据 U 上的不一致性。
  - *常用不一致性度量*：最小二乘误差 $\sum(f_1(x) - f_2(x))^2$ 或 Bhattacharyya 距离。

15.5 共识最大化 (Consensus Maximization) (PPT P107-118)

这是 PPT 后半段的难点，涉及较多数学形式。

15.5.1 问题定义

结合多个监督模型和无监督模型的输出，利用无标数据提升准确率。

15.5.2 目标函数 (PPT P114)

假设我们有 Groups (模型输出的簇或类) 和 Objects (数据点)。我们希望优化**对象属于某个类别的概率**。

- **定义**：
  - u_i：对象 i 的真实类别概率向量（待求）。
  - q_j：Group j 的类别概率向量（待求）。
  - a_{ij}：如果对象 i 被分到了 Group j，则为 1。
- **优化目标 (Minimize Disagreement)**：

$$O = \sum_{i,j} a_{ij} ||u_i - q_j||^2 + \alpha \sum_j ||q_j - y_j||^2$$

  - 第一项：如果对象 i 在 Group j 里，那么它们的类别分布应该相似。
  - 第二项：Group 的类别分布不应偏离其初始预测太多（如果是监督模型）。
- **解法**：这是一个凸优化问题，可以通过**迭代更新 (Iterative Update)** 求解闭式解（类似坐标下降法）。

15.6 期末考试预测 (Exam Hacks)

基于助教的情报，以下是针对这套 PPT 的必考点预测：

1. **Q: 请写出 AdaBoost 权值更新公式，并解释为什么当分类器错误率 $e_m > 0.5$ 时，权值更新逻辑会反转?**
   - **A**: 必须默写 $w_{m+1,i}$ 和 α_m 的公式。解释：由 $\alpha_m = \frac{1}{2}\ln((1-e_m)/e_m)$ 可知，当 $e_m > 0.5$ 时，$\alpha_m < 0$。此时分错的样本权重乘数为 $\exp(\alpha_m) < 1$，反而权重降低；分对的样本权重升高。这实际上利用了“反向指标”，如果一个人总是说错，反着听他对的就是对的。
2. **Q: 随机森林 (Random Forest) 与 Bagging 的核心区别是什么？这对偏差-方差分解有何影响?**
   - **A**: 区别在于**特征随机采样**。Bagging 仅构建样本的 Bootstrap，RF 在节点分裂时引入特征子集随机性。这对偏差影响不大，但能显著降低树之间的**相关性 (Correlation)**，从而更有效地降低**方差 (Variance)**。
3. **Q: 在聚类集成中，如何解决标签不对应 (Label Correspondence) 问题？请列举两种方法。**
   - **A**:
     a. **基于图的方法 (Graph-based)**：如 HGPA 或 MCLA，不直接匹配标签，而是通过超图切分或元聚类重新发现结构。
     b. **共联矩阵 (Co-association Matrix)**：将问题转化为“两个点是否同类”的频率统计，完全避开了标签匹配。
4. **Q: Co-Training 算法成功的两个必要假设是什么?**
   - **A**:
     a. **相容性 (Compatibility)**：每个视图都包含足够的信息来学习目标函数。
     b. **条件独立性 (Conditional Independence)**：在给定类别的条件下，两个视图相互独立。

第16章 半监督学习 (Semi-Supervised Learning) 深度复习讲义

你好！我是你的机器学习课程教授。针对这份关于**半监督学习 (Semi-Supervised Learning, SSL)** 的课件，我为你整理了这份深度复习讲义。

根据助教提供的考试情报，本章的**核心考点**在于：

1. **Inductive vs. Transductive** 的概念辨析。
2. **三大类方法（EM、Co-Training、Manifold Regularization）** 的背后的数学假设和优化目标。
3. **流形正则化 (Manifold Regularization)** 的拉普拉斯矩阵推导。
4. **结构化预测**中如何利用未标记数据。

请仔细阅读以下内容，它完全覆盖了 PPT 的逻辑，并补充了考试所需的推导细节。

16.1 半监督学习基础与动机 (PPT P1-18)

1. 为什么需要半监督学习？(Motivation)

(1) 现实困境 (Pragmatic Motivation)

- **标记数据的昂贵性**：在语音识别、医疗诊断、蛋白质分类等领域，获取标记数据（Labeled Data, L）需要耗费大量专家时间和金钱。例如，Switchboard 语音数据集每标注1小时音频需要400小时的人力。
- **未标记数据的廉价性**：未标记数据（Unlabeled Data, U）通常很容易获取（如互联网爬取的网页、无标注的图片）。
- **核心思想**：利用廉价的 U 来辅助少量的 L，从而提升模型的泛化能力。

(2) 哲学/认知层面 (Philosophical Motivation)

- 人类的学习过程本身就是半监督的。大脑能够利用大量未标记的感官输入来构建对世界的认知，而不需要每时每刻都有老师在旁指导。

2. 定义与学习范式 (Definitions)

(1) 基本定义

- **监督学习 (Supervised Learning)**：给定 (x_i, y_i)，寻找预测函数 $f : x \to y$。
- **无监督学习 (Unsupervised Learning)**：仅给定 x_i，寻找数据内在结构（如聚类）。
- **半监督学习 (SSL)**：监督学习 + 额外的未标记数据；或者无监督学习 + 额外的标记数据。通常指前者。

(2) Inductive vs. Transductive (⚠️ 核心考点 - PPT P16-18)

这是考试中极易混淆的概念，请务必区分：

特性	Inductive Learning (归纳学习)	Transductive Learning (直推学习)
目标	学习一个通用的预测函数 f。	仅对**当前手中**的未标记数据 U 进行预测。
适用范围	f 可以应用于**未来**见到的任何新测试数据。	不产生通用模型，不关心未来的数据，只关心当前给定的 U 的标签。
测试集	测试集在训练时不可见。	训练时的未标记集 U 本身就是最终的“测试集”。
例子	训练一个垃圾邮件过滤器（处理未来的邮件）。	给定一堆已有的未分类文档，只要求把这堆文档分好类。

16.2 基于分类器的方法 (Classifier-based Methods) (PPT P21-33)

这部分方法的核心逻辑是：利用现有的分类器给未标记数据打标签，然后迭代更新。

1. 生成式模型与 EM 算法 (EM Algorithm) (PPT P21-24)

(1) 数学建模

假设数据由混合模型（如混合高斯模型 GMM）生成。我们利用 EM 算法最大化标记数据和未标记数据的**联合对数似然 (Joint Log-Likelihood)**。

- **目标函数**：

$$\mathcal{L}_{total}(\theta) = \sum_{i \in L} \log P(y_i|\pi)P(x_i|y_i,\theta) + \sum_{j \in U} \log(\sum_{y} P(y|\pi)P(x_j|y,\theta))$$

  其中第二项是对未标记数据隐变量 y 的边缘化。

(2) 信息的稳定混合 (Stable Mixing) - 引入权重 λ

为了控制未标记数据的影响力（避免其噪声淹没标记数据），引入权重参数 λ (PPT P22)：

$$\text{Objective} = (1-\lambda)L_l + \lambda L_u$$

- EM_λ **算子**：将 E 步和 M 步视为一个算子，最优参数 θ 是该算子的**不动点 (Fixed Point)**：

$$\theta^{new} = EM_\lambda(\theta)$$

(3) 相变与参数选择 (⚠️ 考试图解 P24)

PPT 第24页展示了一个分叉图（Bifurcation）。

- **现象**：随着 λ（未标记数据权重）的变化，最优解 θ 的路径可能会发生分叉或突变。
- **如何选择 λ**：
  i. 寻找解路径发生**分叉 (Bifurcation)** 或不连续之前的点。因为在分叉之后，标记数据可能不再影响解。
  ii. 或者使用交叉验证 (Cross-validation)。

2. 自训练 (Self-Training / Yarowsky) (PPT P26)

- **流程**：
  i. 利用现有 L 训练分类器 (SL)。
  ii. 用分类器预测 U。
  iii. 选取**置信度最高 (High Confidence)** 的样本，将其预测标签作为“伪标签”，加入到 L 中。
  iv. 重复上述步骤。

- **风险**：如果初期分类器错误，错误会被自我放大（Error Propagation）。

3. 协同训练 (Co-Training) (PPT P27-30)

(1) 核心假设 (Blum & Mitchell 1998)

数据必须具备两个**视图 (Views)**，即特征可以分为两组 $x = (x_1, x_2)$（例如网页分类中：x_1 是网页正文，x_2 是指向该网页的超链接文字）。

- **假设1：充分性 (Sufficiency)**：每个视图本身都足以训练出一个好的分类器。
- **假设2：条件独立性 (Conditional Independence)**：给定类别 y，两个视图相互独立：

$$P(x_1|x_2, y) = P(x_1|y)$$

- **一致性假设**：存在分类器使得两个视图的预测一致。

(2) 算法流程

1. 在视图1上训练分类器 C_1，在视图2上训练 C_2。
2. C_1 挑选其最有把握的未标记样本，打上标签，传给 C_2 作为训练数据。
3. C_2 同理，挑选最有把握的样本传给 C_1。
4. **直观理解**：两个分类器互为老师，互相补充对方视野的盲区。

- **Agreement Maximization (P30)**：Co-Training 的副作用（或显式目标）是最大化两个视图分类结果的一致性。

4. 转导支持向量机 (Transductive SVM / S3VM) (PPT P31-33)

(1) 核心思想：低密度分离假设 (Low Density Separation)

我们相信决策边界应该穿过数据分布的**低密度区域**，而不是切穿高密度的聚类中心。

(2) 优化目标 (⚠️ 考试重点)

标准 SVM 寻找最大化标记数据间隔的超平面。S3VM 寻找最大化**标记数据 + 未标记数据**间隔的超平面。

- **目标函数**（概念性描述）：
  寻找一个分离超平面，使其在 L 和 U 上的间隔最大化。
  隐式包含项：$\min_{w,b,\hat{y}_U} \frac{1}{2}||w||^2 + C\sum_{i\in L}\xi_i + C^*\sum_{j\in U}\xi_j^*$
  其中 $\hat{y}_U$ 是未标记数据的预测标签（也是变量！）。

(3) 求解困难

由于我们需要同时寻找 w 和未标记数据的标签 $\hat{y}_U$，这变成了一个混合整数规划问题，是 **NP-Hard** 的。

- **解决方法**：局部搜索。先用 L 训练 SVM 给 U 初始标签，然后通过**翻转 (Flipping)** 某些样本的标签来尝试增大整体间隔 (Margin)，直到无法优化。

16.3 基于数据的方法 (Data-based Methods) (PPT P34-42)

这一部分不再单纯依赖分类器迭代，而是挖掘数据的几何结构（流形）。

1. 流形假设 (Manifold Assumption) (PPT P35-37)

- **假设**：高维数据实际分布在一个低维的流形 (Manifold) 上。
- **平滑性假设 (Smoothness Assumption)**：如果两个点 x_i, x_j 在流形上很近，那么它们的标签 y_i, y_j（或条件概率 $P(y|x)$）也应该相似。即感兴趣的函数在高密度区域变化不大。
- **直观图示**：PPT P35 的双螺旋图。如果只看欧氏距离，红色点和蓝色点很近；但在流形结构上，它们相距很远。SSL 必须利用未标记数据来估计几何结构。

2. 流形正则化 (Manifold Regularization) (⚠️ 必考推导 PPT P39-40)

(1) 平滑性的数学定义

我们需要定义一个惩罚项，当函数 f 在流形上变化剧烈时，惩罚项变大。
在流形 $\mathcal{M}$ 上，函数的平滑度惩罚定义为梯度的积分：

$$\mathcal{S}(f) = \int_{\mathcal{M}} ||\nabla_{\mathcal{M}} f(x)||^2 p(x) dx$$

由于 $p(x)$ 未知且流形未知，我们利用未标记数据构建的**近邻图 (Nearest Neighbor Graph)** 来离散化近似这个积分。

(2) 离散化近似：拉普拉斯正则项 (Laplacian Regularization)

定义图的权重矩阵 W_{ij}（若 x_i, x_j 相邻则非零）。上述积分近似为：

$$\sum_{i,j}(f(x_i)-f(x_j))^2 W_{ij}$$

推导其矩阵形式（非常重要）：

$$\begin{aligned}\sum_{i,j}(f(x_i)-f(x_j))^2 W_{ij} &= \sum_{i,j}(f^2(x_i)-2f(x_i)f(x_j)+f^2(x_j))W_{ij} \\ &= \sum_i f^2(x_i)\sum_j W_{ij} + \sum_j f^2(x_j)\sum_i W_{ij} - 2\sum_{i,j} f(x_i)W_{ij}f(x_j) \\ \text{令 } D_{ii} = \sum_j W_{ij} \text{ (度矩阵)} & \\ &= 2\sum_i f^2(x_i)D_{ii} - 2\sum_{i,j} f(x_i)W_{ij}f(x_j) \\ &= 2\mathbf{f}^T D\mathbf{f} - 2\mathbf{f}^T W\mathbf{f} \\ &= 2\mathbf{f}^T(D-W)\mathbf{f} \\ &= 2\mathbf{f}^T L\mathbf{f}\end{aligned}$$

其中 $L = D - W$ 称为**组合拉普拉斯矩阵 (Combinatorial Laplacian)**。
结论：**$\mathbf{f}^T L\mathbf{f}$ 越小，函数 f 在图上越平滑。**

(3) 总目标函数 (PPT P40)

结合了标准监督学习和流形正则化：

$$f^{opt} = \arg\min_{f\in H} \underbrace{\frac{1}{l}\sum_{i=1}^{l}(f(x_i)-y_i)^2}_{\text{Fitting to Labeled Data}} + \underbrace{\lambda_k||f||_k^2}_{\text{Complexity Control}} + \underbrace{\lambda_I||f||_I^2}_{\text{Manifold Smoothness (SSL)}}$$

其中 $||f||_I^2 = \mathbf{f}^T L\mathbf{f}$。

(4) 表示定理 (Representer Theorem) (PPT P41)

根据表示定理，最优解 f^{opt} 可以写成核函数的线性组合，**注意求和范围包括了未标记数据**：

$$f^{opt}(.) = \sum_{i=1}^{l+u}\alpha_i k(x_i, .)$$

这与标准 SVM 不同（标准 SVM 仅涉及支持向量，通常在 labeled set 中）。

3. 调和混合 (Harmonic Mixtures) (PPT P42)

- **模型**：数据由高斯混合模型建模，且高斯分量的均值分布在低维流形上。
- **目标**：最大化 $\lambda L(\theta) - (1-\lambda)\epsilon(\theta)$。
  - $L(\theta)$ 是数据似然。
  - $\epsilon(\theta)$ 是组合拉普拉斯（图的能量）。
- **调和性质**：其解具有调和性质，即未标记点的预测值是其邻居的加权平均。

16.4 信息正则化 (Information Regularization) (PPT P43-46)

1. 核心思想

- 我们希望分类器不仅拟合标记数据，还要在未标记数据的高密度区域保持预测的确定性。
- **直观理解**：如果决策边界穿过高密度区域，该区域点的预测概率 $P(y|x)$ 会接近 0.5（不确定，互信息低）。我们要避免这种情况，即希望 $P(y|x)$ 要么接近 1，要么接近 0。

2. 互信息 (Mutual Information)

利用互信息 $I(x, y)$ 来衡量 x 和 y 的相关性。如果标签由 x 所在的区域决定，那么互信息应该高。

3. 优化目标 (Szummer & Jaakkola 2002)

最大化后验概率，同时减去正则项：

$$p^{opt}(y|x) = \arg\max_{p(y|x)} \sum_{i=1}^{l} \log p(y_i|x_i) - \lambda \int_{\mathcal{X}} p(x) \mathrm{Tr}[F(x)] dx$$

这里的惩罚项迫使 $P(y|x)$ 在 $P(x)$ 高的地方变化平缓（即保持确定的分类）。

16.5 结构化预测的半监督学习 (SSL for Structured Prediction) (PPT P48-53)

这部分是进阶内容，主要针对如**词性标注 (POS Tagging)** 等任务，输入 x 是句子，输出 y 是序列。

1. 结构分解 (Decomposition)

- 由于 y 的空间呈指数级增长，无法直接在 (x, y) 层面构建流形。
- **方法**：将 (x, y) 分解为简单的**部件 (Parts)**。
  - 例如：边缘特征 (Label-Label edge, Observation-Label edge)。
  - PPT P50 展示了将句子分解为 "AT-NN" (Article-Noun) 这样的简单结构。

2. 部件流形 (Parts Manifold)

- 在**部件空间**构建最近邻图（而非在整个句子空间）。
- 假设：相似的部件应该有相似的评分贡献。

3. 修改后的优化目标 (PPT P52-53)

$$\arg\min_{\alpha} \sum_{i} \mathrm{Loss}(f_\alpha(x_i), y_i) + \alpha^T Q \alpha$$

- **Loss**：可以是 SVM 的 Hinge Loss（基于汉明距离），也可以是 CRF 的 Log-Likelihood。
- $\alpha^T Q \alpha$：正则项，包含核范数和基于部件的拉普拉斯平滑项。

16.6 Exam Hacks (考题预测与解题技巧)

> **Q1 (概念题): 为什么说半监督学习中未标记数据必须还要满足某些假设才能起作用?**
> **A:** 如果 $P(x)$（数据分布）和 $P(y|x)$（预测任务）相互独立，那么知道 x 的分布对推断 y 没有任何帮助。SSL 有效的前提是两者有关联，例如：
>
> 1. **聚类假设**：同聚类的数据标签相同。
> 2. **流形/平滑假设**：流形上邻近点标签相似。
> 3. **低密度分离假设**：分类边界通过低密度区。

> **Q2 (推导题): 请写出 Laplacian Regularization 的矩阵形式并解释其含义。**
> **A:** 必须写出从 $\sum (f_i - f_j)^2 W_{ij}$ 到 $2\mathbf{f}^T L \mathbf{f}$ 的推导过程（见本文第三部分 16.3）。
>
> - **含义**：L 是拉普拉斯矩阵。该项衡量了预测函数 f 在数据几何结构上的平滑程度。最小化该项使得相似的样本倾向于拥有相似的预测值。

> **Q3 (对比题): S3VM 和标准 SVM 的区别是什么？为什么 S3VM 更难解?**
> **A:**
>
> - **区别**：SVM 只最大化 L 的间隔；S3VM 最大化 $L + U$ 的间隔，且要求边界穿过低密度区。
> - **难点**：S3VM 需要推断 U 的标签 $\hat{y}$，这些离散变量的引入使得原来的凸优化问题变成了非凸的组合优化问题 (NP-Hard)。

> **Q4 (图示题): 解释 PPT P24 的 EM 算法分叉图。**
> **A:** 横轴是 λ（未标记数据权重），纵轴是参数 θ。当 λ 很小时，结果主要由标记数据决定；随着 λ 增大，未标记数据的影响力增强，可能导致优化目标出现多个局部极值（分叉），此时未标记数据的分布（可能存在的偏差）开始主导模型，可能导致性能下降。应选择分叉前的点。

复习建议：请重点练习**拉普拉斯矩阵的二次型推导**，并熟记 **Inductive vs Transductive** 的定义。祝考试顺利！

第19章 反向传播算法 (Back-Propagation Algorithm)

19.1 感知机与激活函数 (Perceptron & Activation Functions) (PPT P1-7, P36, P40)

(1) 核心概念与定义 (PPT P1-3, P8-9)

- **感知机 (Perceptron)**：这是神经网络最基本的构建单元。它模拟了神经元的工作方式：接收多个输入，进行加权求和，然后通过一个激活函数输出。
- **内积 (Inner-product)**：
  - *定义*：神经元的输入计算本质上是权重向量 $\vec{w}$ 和输入向量 $\vec{x}$ 的内积。
  - *公式*：$net =< \vec{w}, \vec{x} >= \sum_{i=1}^{n} w_i \cdot x_i$。
  - *几何意义*：内积代表一个向量在另一个向量上的投影。在分类问题中，这定义了一个超平面（Decision Boundary）。

(2) 激活函数 (Activation Functions) (PPT P4-7, P36, P40)

考点警示：考试常考“为什么要引入非线性激活函数？”以及“写出Sigmoid或ReLU的导数”。

- **为什么要引入激活函数?**
  - 如果没有激活函数（或仅有线性激活函数），无论神经网络有多少层，其最终输出都只是输入的线性组合。**只有引入非线性激活函数，神经网络才具备拟合非线性函数的能力**（这一点在 PPT P18 和 P22 强调）。
- **常见激活函数及其导数 (需背诵)**：
  i. **符号函数 (Sign/Step function)** (PPT P4, P13):
    - $f(x) = 1$ if $x \geq 0$, else -1 (或0)。
    - *缺点*：不可导（或导数处处为0），无法用于基于梯度的学习算法（如BP）。
  ii. **Sigmoid (Logistic) 函数** (PPT P5, P36, P40):
    - *公式*：$\sigma(x) = \frac{1}{1+e^{-ax}}$ (通常 $a = 1$)。
    - *特点*：将输出压缩到 $(0, 1)$ 之间，平滑且可导。
    - *导数推导 (必考)*：

$$f'(x) = f(x)(1 - f(x))$$

      推导技巧：在计算梯度时，利用这个性质可以极大简化运算。
  iii. **双曲正切 (TanH)** (PPT P6):
    - *公式*：$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$
    - *导数*：$f'(x) = 1 - f(x)^2$
  iv. **ReLU (Rectified Linear Unit)** (PPT P7):
    - *公式*：$f(x) = \max(0, x)$
    - *导数*：当 $x > 0$ 时为 1，当 $x < 0$ 时为 0。
    - *变体*：**Leaky ReLU** (解决死神经元问题，负区间给一个小斜率，如 $0.01x$)；**PReLU** (负区间斜率可学习)。

19.2 梯度下降算法基础 (Gradient Descent Basics) (PPT P8-14)

(1) 目标函数与优化

- **目标**：我们要找到一组权重 W，使得预测值 o 与真实值 t 之间的误差最小。
- **平方误差损失函数 (Squared Error)**：

$$E[\vec{w}] \equiv \frac{1}{2} \sum_{d \in D} (t_d - o_d)^2$$

  - *注意*：系数 $\frac{1}{2}$ 是为了在求导时抵消指数下来的 2，使公式更简洁。

(2) 梯度推导 (重点：链式法则)

我们要计算误差 E 对权重 w_i 的偏导数：

1. **展开导数**：

$$\frac{\partial E}{\partial w_i} = \frac{\partial}{\partial w_i}\frac{1}{2}\sum_d (t_d - o_d)^2$$

2. **应用链式法则**：

$$= \frac{1}{2}\sum_d 2(t_d - o_d)\frac{\partial}{\partial w_i}(t_d - o_d)$$

$$= \sum_d (t_d - o_d)\frac{\partial}{\partial w_i}(t_d - \vec{w}\cdot\vec{x_d})$$

3. **得到梯度**：

$$\frac{\partial E}{\partial w_i} = \sum_d (t_d - o_d)(-x_{i,d}) = -\sum_d (t_d - o_d)x_{i,d}$$

(3) 权重更新规则 (Update Rule)

- **标准梯度下降 (Batch Gradient Descent)**：

$$\Delta w_i = -\eta\frac{\partial E}{\partial w_i} = \eta\sum_{d\in D}(t_d - o_d)x_{id}$$

  - *特点*：利用**所有**训练样本 D 计算梯度后才更新一次权重。收敛稳定但计算慢。
- **随机梯度下降 (Stochastic Gradient Descent, SGD)** (PPT P14):

$$\Delta w_i = \eta(t_d - o_d)x_{id}$$

  - *特点*：每处理**一个**样本就更新一次权重。也称为 LMS (Least Mean Square) 规则或 Delta 规则。收敛较快但路径震荡。

(4) 潜在考题预测 (Exam Hacks)

> - **Q**: 为什么感知机无法解决 XOR 问题？(PPT P15-16, P21)
> - **A**: 感知机本质上是一个**线性分类器**，只能解决线性可分问题。XOR（异或）问题在几何上是线性不可分的（无法用一条直线将 (0,0), (1,1) 与 (0,1), (1,0) 分开）。这促使了多层网络和非线性激活函数的诞生。

19.3 多层前馈网络结构与前向传播 (Multi-layer Networks & Forward Pass) (PPT P23-28)

(1) 符号定义 (对应 PPT P24 图示)

为了推导清晰，我们要严格遵守 PPT 的符号系统：

- **网络结构**：输入层 (k) -> 隐层 (j) -> 输出层 (i)。
- **输入**：x_k (输入层第 k 个单元)。
- **隐层权重**：w_{jk} (连接输入 k 到隐层 j 的权重)。
- **隐层输出**：V_j。
- **输出层权重**：W_{ij} (连接隐层 j 到输出层 i 的权重)。**注意大小写区分**。
- **最终输出**：o_i。
- **目标值**：t_i。

(2) 前向传播 (Forward Pass)

1. **隐层计算**：

$$net_j = \sum_k w_{jk}x_k \quad \Rightarrow \quad V_j = f(net_j)$$

2. **输出层计算**：

$$net_i = \sum_j W_{ij}V_j \quad \Rightarrow \quad o_i = f(net_i)$$

19.4 反向传播算法推导 (Back-Propagation Derivation) (PPT P29-35, P38)

⚠️ **警告：这是本章最核心、最难、考试最可能出现的推导题。**

我们定义总误差为：$E(\vec{w}) = \frac{1}{2}\sum_d \sum_i (t_i - o_i)^2$。
核心思想：利用链式法则，将误差从输出层向后传播。

(1) 情况一：更新“隐层到输出层”的权重 W_{ij} (PPT P29)

我们需要计算 $\frac{\partial E}{\partial W_{ij}}$。

1. **链式法则展开**：
$$\frac{\partial E}{\partial W_{ij}} = \frac{\partial E}{\partial o_i} \cdot \frac{\partial o_i}{\partial net_i} \cdot \frac{\partial net_i}{\partial W_{ij}}$$
2. **分步求导**：
   - $\frac{\partial E}{\partial o_i} = -(t_i - o_i)$
   - $\frac{\partial o_i}{\partial net_i} = f'(net_i)$ (激活函数的导数)
   - $\frac{\partial net_i}{\partial W_{ij}} = \frac{\partial}{\partial W_{ij}}(\sum W_{ij}V_j) = V_j$
3. **合并结果**：
$$\frac{\partial E}{\partial W_{ij}} = -(t_i - o_i) f'(net_i) V_j$$
4. **定义误差项 δ_i**：
   令 $\delta_i = f'(net_i)(t_i - o_i)$。这是**输出层单元的误差信号**。
5. **最终更新公式**：
$$\Delta W_{ij} = \eta \delta_i V_j$$

(2) 情况二：更新“输入层到隐层”的权重 w_{jk} (PPT P30-31)

我们需要计算 $\frac{\partial E}{\partial w_{jk}}$。这是难点，因为 w_{jk} 通过隐层单元 j 影响所有输出单元 i。

1. **链式法则展开**：
$$\frac{\partial E}{\partial w_{jk}} = \frac{\partial E}{\partial V_j} \cdot \frac{\partial V_j}{\partial net_j} \cdot \frac{\partial net_j}{\partial w_{jk}}$$
2. **分步求导**：
   - $\frac{\partial net_j}{\partial w_{jk}} = x_k$
   - $\frac{\partial V_j}{\partial net_j} = f'(net_j)$
   - **关键点** $\frac{\partial E}{\partial V_j}$：$V_j$ 影响了所有输出 o_i，所以需要对所有 i 求和：
$$\frac{\partial E}{\partial V_j} = \sum_i \left(\frac{\partial E}{\partial net_i} \frac{\partial net_i}{\partial V_j} \right)$$
   利用前面算过的 $\frac{\partial E}{\partial net_i} = -\delta_i$，以及 $\frac{\partial net_i}{\partial V_j} = W_{ij}$。
   所以：$\frac{\partial E}{\partial V_j} = -\sum_i \delta_i W_{ij}$
3. **合并结果**：
$$\frac{\partial E}{\partial w_{jk}} = \left(-\sum_i \delta_i W_{ij} \right) \cdot f'(net_j) \cdot x_k$$
4. **定义隐层误差项 δ_j**：
   令 $\delta_j = f'(net_j) \sum_i W_{ij}\delta_i$。这是**隐层单元的误差信号**（从后一层传回来的误差加权和，乘上当前的激活导数）。
5. **最终更新公式**：
$$\Delta w_{jk} = \eta \delta_j x_k$$

(3) 总结：通用的 BP 更新公式 (PPT P33)

无论在哪一层，权重的更新量总是遵循以下形式：

$$\Delta w = \eta \cdot \delta_{\text{output}} \cdot \text{input}$$

- η: 学习率。
- δ_{output}: 该连接指向的那一端（输出端）神经元的误差项。
- input: 该连接来源的那一端（输入端）神经元的激活值。

(4) 算法完整流程 (PPT P38)

1. **初始化**：将所有权重设为随机小数值。
2. **输入**：选取样本 x，输入网络。
3. **前向传播**：计算每一层的输出 V^m。
4. **计算输出层 Delta**：$\delta_i^M = f'(net_i^M)(t_i - V_i^M)$。
5. **反向传播 Delta**：从最后一层向前计算 $\delta_i^{m-1} = f'(net_i^{m-1}) \sum_j w_{ji}^m \delta_j^m$。
6. **更新权重**：$\Delta w_{ij}^m = \eta \delta_i^m V_j^{m-1}$。

19.5 BP 算法的收敛性与动量 (Convergence & Momentum) (PPT P39-44)

(1) 局部最小值 (Local Minima)

- **性质**：梯度下降保证收敛到局部最小值，而不一定是全局最小值。
- **解决方法**：
  - 使用**动量 (Momentum)**。
  - **随机梯度下降 (SGD)**：利用随机性跳出局部极小。
  - **多重训练**：使用不同的随机初始化权重多次训练，取最好的结果。

(2) 动量项 (Momentum) (PPT P40)

- **问题**：如果 η 太小，收敛太慢；如果 η 太大，会在峡谷两边震荡。
- **解决方案**：引入动量项 α (通常取 0.9)，使当前的权重更新保留一部分上一次的更新方向。
- **公式** (常考填空)：

$$\Delta w(t+1) = -\eta \frac{\partial E}{\partial w} + \alpha \Delta w(t)$$

- **作用**：起到平滑震荡、加速收敛的作用（类似物理中的惯性）。

(3) 泛化能力 (Generalization) (PPT P41-42)

- **过拟合 (Overfitting)**：如果在训练集上误差极低，但在测试集上误差很高，说明网络只是“记住”了样本，而非学习了规律。
- **PPT P42 图示解析**：
  - 图(a) 展示了良好的泛化，曲线平滑地穿过数据点。
  - 图(b) 展示了过拟合，曲线为了穿过每一个噪声点而剧烈震荡，失去了预测能力。

19.6 神经网络的表达能力 (Expressive Capabilities) (PPT P45)

(1) 通用逼近定理 (Universal Approximation Theorem)

- **布尔函数**：任何布尔函数都可以用**单隐层**网络表示（但可能需要指数级的隐层单元）。
- **连续函数**：任何有界连续函数都可以被**单隐层**网络以任意精度逼近（Cybenko 1989）。
- **任意函数**：任何函数都可以被**双隐层**网络以任意精度逼近。
- *结论*：多层前馈网络是**通用函数逼近器 (Universal Approximator)**。

19.7 经典案例分析 (Case Studies) (PPT P46-52)

(1) NETtalk (PPT P46-47)

- **任务**：将英语文本转换为语音（音素）。
- **网络结构**：
  - **输入**：滑动窗口（7个字符），每个字符用29维向量表示。输入层大小 $7 \times 29 = 203$。
  - **架构**：203 (输入) - 80 (隐层) - 26 (输出，对应音素编码)。
- **关键发现**：

- **分布式表示**：隐层神经元并不单独代表某个规则，而是通过组合来编码（如元音 vs 辅音）。
- **优雅降级 (Graceful Degradation)**：即使损坏部分神经元，性能也不会突然崩溃，而是缓慢下降，且能通过重训练快速恢复。这模拟了人脑的特性。

(2) 其他案例 (PPT P48-52)

- **邮政编码识别 (Zipcode)**：Yann LeCun 的早期工作，手写数字识别。
- **人脸朝向识别 (Face Recognition)**：Mitchell 的工作，通过 30×32 的图像输入，预测人脸的朝向（上下左右）。PPT 展示了可视化的权重图（Weight Visualization），说明网络学到了类似面部特征的模式。

19.8 终极复习建议 (Exam Hack Summary)

1. **公式背诵**：
   - Sigmoid 导数：$\sigma'(x) = \sigma(x)(1-\sigma(x))$。
   - 输出层误差：$\delta_i = (t_i - o_i) f'(net_i)$。
   - 隐层误差：$\delta_j = f'(net_j) \sum_i w_{ji}\delta_i$。
   - 权重更新：$\Delta w = \eta \delta_{out} V_{in}$。
2. **流程默写**：能够用中文描述 BP 算法的完整迭代步骤（前向 -> 算误差 -> 反向传误差 -> 更新）。
3. **概念辨析**：清楚解释 Batch GD 与 Stochastic GD 的区别，以及为什么要加 Momentum。

第20章 Word Embeddings (词嵌入)

20.1 词的意义与表示 (Word Meaning & Representation)

1. 传统词义表示及其局限性 (PPT P1-P7)

(1) 核心概念与定义

- **词的意义 (Meaning)**：
  - *定义*：根据韦氏词典，是词语所代表的概念或想要表达的思想。
  - *符号学观点*：语言学中常将其视为 **Signifier (能指/符号)** $\leftrightarrow$ **Signified (所指/概念)** 的映射。这被称为**指称语义学 (Denotational Semantics)**。
- **计算机中的传统表示 (WordNet)**：
  - *机制*：使用类似 WordNet 的电子词典，构建同义词集 (Synonyms) 和上位词 (Hypernyms, 即 "is-a" 关系) 的网络。
  - *代码示例解读* (PPT P6)：在 NLTK 中， `good` 可以被映射到 `goodness`，`commodity` 等不同的同义词集。

(2) 传统方法的缺陷 (考试重点)

为什么我们要抛弃 WordNet 这种资源库，转向深度学习？（请背诵以下四点，简答题常考）

1. **缺失细微差别 (Missing Nuance)**：例如 "proficient" (精通) 和 "good" (好) 被列为同义词，但在很多语境下它们程度不同，不能互换。
2. **新词缺失 (Missing New Meanings)**：语言是动态的，像 "badass", "ninja", "wicked" 这些网络俚语或新含义无法实时更新。
3. **主观性 (Subjective)**：由专家构建，带有主观偏见。
4. **难以计算相似度 (Can't compute accuracy word similarity)**：这是最致命的。WordNet 是离散的图结构，难以量化两个词到底有多相似（比如 "hotel" 和 "motel" 的距离）。

20.2 离散符号 vs. 分布式表示 (Discrete vs. Distributed)

1. 独热编码 (One-hot Representation) (PPT P8-P9)

(1) 核心概念

- **独热编码 (One-hot vector)**：
  - *定义*：一种**局部主义 (localist)** 表示。将词汇表中的每一个词表示为一个长向量。向量维度 $|V|$ 等于词汇表大小（例如 500,000）。
  - *形式*：该词所在索引位置为 1，其余全为 0。

$$motel = [0, 0, \dots, 0, 1, 0, \dots, 0]$$

$$hotel = [0, 0, \dots, 0, 0, 1, \dots, 0]$$

(2) 独热编码的问题 (数学视角)

- **正交性问题**：
  在搜索中，用户搜 "Seattle motel"，我们希望匹配到 "Seattle hotel"。但在 One-hot 空间中，这两个向量是**正交 (Orthogonal)** 的。

$$motel^T \cdot hotel = 0$$

  直观理解：由于点积为 0，模型认为这两个词**毫无关系**，无法自然地捕捉相似度。

2. 分布式语义与词向量 (Word Vectors) (PPT P10-P12)

(1) 核心思想：分布语义学 (Distributional Semantics)

- **J.R. Firth (1957) 的名言**："You shall know a word by the company it keeps"（通过一个词的“邻居”来认识这个词）。
- **机制**：一个词的意义由它在上下文中频繁出现的词决定。
- **上下文 (Context)**：当词 w 出现时，其前后固定窗口大小（window size）内的词集。

(2) 词嵌入 (Word Embeddings/Vectors)

- **定义**：为每个词构建一个**稠密向量 (Dense Vector)**，通常维度 d (如 300) 远小于词汇表大小 $|V|$。
- **数学特性**：
  - 向量不再是稀疏的（不是大部分为0），而是充满实数。
  - **相似度**：语义相似的词，其向量在空间中距离更近（点积更大）。
  - *PPT P12 可视化*：图中展示了 `banking` 的向量数值。同时展示了 `come`，`go`，`give` 等动词在空间中聚在一起，体现了语义聚类。

20.3 Word2Vec 模型详解 (Word2Vec Overview)

1. 算法框架 (PPT P13-P15)

(1) 基本流程

- **提出者**：Mikolov et al. (2013)。
- **核心思想**：
  i. 拥有一个庞大的语料库 (Corpus)。
  ii. 每个词由向量表示。
  iii. 遍历文本中的每个位置 t，有一个**中心词 (center word)** c 和**上下文词 (context words)** o。
  iv. 利用 c 的向量和 o 的向量的相似度，来计算 $P(o|c)$（给定中心词预测上下文的概率）。
  v. **不断调整向量**，使得该概率最大化。

(2) 窗口机制 (可视化描述)

- *PPT P14-P15 演示*：
  - 句子："problems turning into **banking** crises as ..."
  - 当 t 指向 "banking" 时，如果窗口大小为 2：
    - 中心词 c: `banking`
    - 上下文 o: `turning`，`into` (前2个) 和 `crises`，`as` (后2个)。
  - 算法会计算 $P(\text{turning}|\text{banking}), P(\text{into}|\text{banking})$ 等。

20.4 目标函数与梯度推导 (Objective Function & Gradients)

⚠️ **警告：这是本章最核心的考点，请务必掌握 LaTeX 推导。**

1. 目标函数 (Objective Function) (PPT P16-P17)

(1) 似然函数 (Likelihood)

我们要最大化整个语料库中，给定中心词预测周围词的概率：

$$L(\theta) = \prod_{t=1}^{T} \prod_{-m \le j \le m, j \neq 0} P(w_{t+j}|w_t;\theta)$$

其中：

- T 是语料库总长度。
- m 是窗口大小。
- θ 是所有待优化的参数（所有词向量）。

(2) 损失函数 (Loss Function)

为了方便计算（将乘积转化为求和）并进行最小化，我们取**负对数似然 (Negative Log Likelihood)**，并除以 T 进行平均：

$$J(\theta) = -\frac{1}{T}\log L(\theta) = -\frac{1}{T}\sum_{t=1}^{T}\sum_{-m\le j\le m, j\neq 0}\log P(w_{t+j}|w_t;\theta)$$

目标：最小化 $J(\theta)$。

2. 预测概率计算：Softmax (PPT P17-P19)

(1) 双向量设计 (关键细节)

为了数学推导方便，每个词 w 有两个向量：

- v_w: 当 w 做**中心词 (center word)** 时的向量。
- u_w: 当 w 做**上下文词 (context word)** 时的向量。

(2) Softmax 公式

给定中心词 c 和上下文词 o，其概率计算公式为：

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w\in V}\exp(u_w^T v_c)}$$

- **分子** $\exp(u_o^T v_c)$：$u_o^T v_c$ 是点积，代表相似度。exp 确保值为正数。
- **分母** $\sum_{w\in V}\ldots$：对词汇表中**所有**词进行归一化，确保加和为 1，构成概率分布。

(3) 潜在考题预测 (Exam Hacks)

> - **Q**: 为什么要用两个向量 u 和 v 表示同一个词?
> - **A**: 主要是为了优化时的数学推导更简单。训练结束后，通常将两个向量取平均或直接连接作为最终词向量。

3. 参数与梯度推导 (PPT P20-P25)

(1) 参数空间

模型包含多少参数?

- 参数 θ 包含每个词的 v 和 u。
- 若词汇量为 $|V|$，向量维度为 d，则参数总量为 $2\times|V|\times d$。这是一个非常庞大的矩阵。

(2) 梯度推导 (The "Whiteboard" Derivation)

这是 PPT P22-25 要求“在白板上推导”的内容，考试必考！

我们需要对中心词向量 v_c 求偏导。
目标是计算 $\frac{\partial}{\partial v_c}\log P(o|c)$。

第一步：展开对数似然

$$\log P(o|c) = \log\frac{\exp(u_o^T v_c)}{\sum_{w\in V}\exp(u_w^T v_c)}$$

利用 $\log(a/b) = \log a - \log b$:

$$\log P(o|c) = \log(\exp(u_o^T v_c)) - \log\left(\sum_{w\in V}\exp(u_w^T v_c)\right)$$

$$\log P(o|c) = u_o^T v_c - \log\left(\sum_{w\in V}\exp(u_w^T v_c)\right)$$

第二步：对 v_c 求导
我们要计算 $\frac{\partial}{\partial v_c}(u_o^T v_c - \log(\sum\ldots))$。

- **第一项求导**:

$$\frac{\partial}{\partial v_c}(u_o^T v_c) = u_o$$

- **第二项求导** (使用链式法则):
  令 $Z = \sum_{w \in V} \exp(u_w^T v_c)$，则第二项为 $-\log Z$。

$$\frac{\partial}{\partial v_c}(-\log Z) = -\frac{1}{Z}\frac{\partial Z}{\partial v_c}$$

  计算内部梯度 $\frac{\partial Z}{\partial v_c}$:

$$\frac{\partial}{\partial v_c}\sum_{w \in V}\exp(u_w^T v_c) = \sum_{w \in V}\frac{\partial}{\partial v_c}\exp(u_w^T v_c)$$

$$= \sum_{w \in V}\exp(u_w^T v_c)\cdot u_w$$

第三步：合并与化简
将上述结果代回:

$$\frac{\partial}{\partial v_c}\log P(o|c) = u_o - \frac{1}{Z}\sum_{w \in V}\exp(u_w^T v_c)u_w$$

$$= u_o - \sum_{w \in V}\frac{\exp(u_w^T v_c)}{Z}u_w$$

注意 $\frac{\exp(u_w^T v_c)}{Z}$ 正是 Softmax 预测出的概率 $P(w|c)$。

最终结论 (Final Gradient):

$$\frac{\partial}{\partial v_c}\log P(o|c) = u_o - \sum_{w \in V}P(w|c)u_w$$

- **直观含义**:
  - u_o：这是我们**观察到**的上下文词向量（Ground Truth）。
  - $\sum P(w|c)u_w$：这是模型当前**期望**看到的上下文词向量（Expectation）。
  - 梯度 = 观察值 - 期望值。我们将 v_c 向着 u_o 的方向拉，同时推开其他的 u_w。

20.5 优化基础 (Optimization Basics)

1. 梯度下降法 (Gradient Descent) (PPT P27-P28)

(1) 算法机制

- **目的**：最小化代价函数 $J(\theta)$。
- **更新公式**:

$$\theta^{new} = \theta^{old} - \alpha\nabla_\theta J(\theta)$$

  其中 α 是**学习率 (Step size / Learning rate)**。
- **矩阵形式**：PPT P28 强调了 update equation in matrix notation，意味着我们是对所有参数同时进行更新。

2. 随机梯度下降 (SGD) (PPT P29)

(1) 为什么需要 SGD？(Exam Hacks)

> - **Q**: 在 Word2Vec 中，为什么不能使用标准的梯度下降 (Batch Gradient Descent)?
> - **A**:
>   i. $J(\theta)$ 是语料库中所有窗口的函数。语料库可能有数十亿个词。
>   ii. 计算一次 $\nabla_\theta J(\theta)$ 需要遍历整个语料库，极其昂贵且缓慢。
>   iii. 这样做会导致更新频率太低，长时间等待一次更新。

(2) SGD 算法流程

- **核心**：每次只采样**一个窗口 (one window)** 来进行更新。
- **伪代码**：

```
while True:
    window = sample_window(corpus)
    theta_grad = evaluate_gradient(J, window, theta)
    theta = theta - alpha * theta_grad
```

- 这样模型可以立即更新，学习速度快得多。

20.6 模型变体与后续 (More Details)

1. 两种模型架构 (PPT P26)

(1) Skip-gram (SG)

- **机制**：给定中心词，预测上下文 (Context given Center)。
- **特点**：本课件主要讲解的模型。适合处理生僻词。

(2) Continuous Bag of Words (CBOW)

- **机制**：给定上下文（袋子），预测中心词 (Center given Bag of Context)。
- **特点**：利用周围词的平均值来预测中间词。训练速度通常比 Skip-gram 快。

2. 训练效率优化

- **负采样 (Negative Sampling)**：
  - PPT P26 提到 "Focus on naive softmax"。在实际应用中，上述 Softmax 分母需要遍历整个词汇表 $|V|$，计算量太大。
  - *优化方法*：不遍历所有词，而是随机抽取几个“负例”（非上下文词）进行训练，近似分母的计算。

全文总结与复习建议

同学，这节课的核心在于**从离散到分布式的思维转变**，以及**Softmax 梯度的数学推导**。

复习时请务必能够默写以下内容：

1. Softmax 的公式 $P(o|c) = \frac{\exp(u_o^T v_c)}{\sum \exp(u_w^T v_c)}$。
2. 损失函数 $J(\theta)$ 的定义（负对数似然）。
3. 对中心词 v_c 的梯度推导过程：$u_o - \sum P(w|c)u_w$。
4. SGD 相比于 GD 在 NLP 任务中的必要性。

第22章 自编码器 (Autoencoders)

22.1 无监督学习与自编码器基础 (Introduction & Basics)

22.1.1 监督学习 vs 无监督学习 (PPT P3-P10)

这部分虽然简单，但常出现在选择题或简答题的第一问，考察你对数据结构的理解。

(1) 核心区别

- **监督学习 (Supervised Learning)**：
  - **数据**：包含 (X, Y)，即特征和标签。
  - **目标**：寻找映射函数 $f: X \to Y$ [cite: 43-45]。
  - **典型任务**：分类 (Classification)、目标检测 (Object Detection)、语义分割 (Instance Segmentation)、回归 (Regression) [cite: 37-41, 71]。
- **无监督学习 (Unsupervised Learning)**：
  - **数据**：只有 X，**没有标签 (No labels!)**。
  - **目标**：学习数据的**内在结构 (Structure)** 和特征间的**相关性 (Correlations)**。
  - **典型任务**：聚类 (Clustering)、压缩 (Compression)、降维 (Dimensionality Reduction)、生成模型 (Generative models)。

(2) 为什么需要无监督学习？ (PPT P7-P9)

当面临以下情况时，监督学习失效 [cite: 92-96]：

1. **标签噪声 (Noisy labels)**：人工标注错误。
2. **缺失值 (Missing values)**：数据不完整。
3. **完全无标签 (No labels)**：数据量巨大但无法人工标注（如海量图片）。

22.1.2 传统自编码器架构 (Traditional Autoencoder) (PPT P12-P17)

(1) 结构定义
自编码器是一个试图复现输入的神经网络，其核心思想是：**输入 ≈ 输出**，但通过中间层的限制迫使网络学习有意义的特征 [cite: 187-194]。

- **输入层 (Input Layer)**：x
- **编码器 (Encoder)**：$f(x)$
  - 将高维输入映射到潜在空间 (Latent Space)。
  - 公式：$z = f(x) = s(Wx + b)$
  - 其中 s 是激活函数（如 Sigmoid, ReLU），z 是编码/潜在表示 (Code/Latent representation)。
- **解码器 (Decoder)**：$g(z)$
  - 将潜在表示映射回原始空间。
  - 公式：$\hat{x} = g(z) = s(W'z + b')$
- **重构 (Reconstruction)**：$\hat{x} \approx x$，即 $h(x) = g(f(x)) = \hat{x}$。

(2) 损失函数 (Loss Functions) (⚠️ 考点：根据数据类型选择 Loss)
我们需要最小化输入 x 与重构 $\hat{x}$ 之间的差异。

1. **实数值输入 (Real-valued inputs)**：使用**均方误差 (Squared Error Loss)** [cite: 200-201]。
$$L(x, \hat{x}) = ||x - \hat{x}||^2$$
2. **二进制输入或概率值 (Bit vectors / Probabilities)**：使用**交叉熵 (Cross Entropy)** [cite: 202-203]。
$$H(p, q) = -\sum_x p(x) \log q(x)$$

(注：PPT P17 简写为上述形式，考试中如果遇到二分类问题，建议写完整的二分类交叉熵形式)

(3) 核心矛盾：恒等映射 (Identity Function)

- 如果网络没有任何限制，AE 仅仅会学习一个恒等映射 $h(x) = x$（即直接复制），这是微不足道的。
- **解决方案**：必须施加约束（限制隐层神经元数量，或添加正则化项），迫使网络捕捉数据的**分布 (Distribution)** [cite: 196-197]。

22.1.3 欠完备 vs 过完备 (Undercomplete vs Overcomplete) (PPT P18-P20)

(1) 欠完备 (Undercomplete)

- **定义**：隐层维度 < 输入维度 ($dim(z) < dim(x)$) [cite: 208-209]。
- **作用**：起到**压缩 (Compresses)** 作用。迫使网络学习训练分布中最重要的特征 [cite: 210-212]。
- **特性**：类似于 PCA（如果激活函数是线性的，欠完备 AE 等价于 PCA 的容量），但通过非线性激活函数可以捕捉更复杂的依赖 [cite: 163-168]。

(2) 过完备 (Overcomplete)

- **定义**：隐层维度 > 输入维度 ($dim(z) > dim(x)$) [cite: 217-218]。
- **风险**：网络可以简单地将输入“复制”到隐层，完全不学习任何特征（即学习恒等映射）[cite: 219-220]。
- **用途**：如果有适当的**正则化 (Regularization)**，过完备结构可以捕捉更丰富的特征，有助于建模更复杂的分布 [cite: 221-222]。

(3) 潜在考题预测 (Exam Hacks)

> - **Q**: 为什么在过完备（Overcomplete）设置下，我们必须引入正则化?
> - **A**: 在过完备设置中，隐层容量足够大，能够直接记忆或复制输入数据（恒等映射），导致模型无法提取有效特征且过拟合。引入正则化（如稀疏性、降噪或收缩惩罚）可以施加约束，迫使模型即使在容量富余的情况下也能学习到数据的鲁棒结构 [cite: 323-326]。

22.2 进阶架构：卷积与正则化 (Advanced Architectures)

22.2.1 卷积自编码器 (Convolutional AE) (PPT P26-P29)

(1) 架构逻辑
针对图像数据，全连接层参数过多。使用卷积层代替全连接层。

- **编码器 (Encoder)**：
  - **卷积 (Conv)**：提取特征。
  - **池化 (Max Pooling)**：降低空间维度 (Downsampling)，压缩信息。
- **解码器 (Decoder)**：
  - **卷积 (Conv)**：恢复特征。
  - **上采样 (UpSampling)**：恢复空间维度。
    (注：PPT P27 流程图中展示了 `U.S` (UpSampling) 操作，通常配合卷积层将小图变回大图)

(2) 结构特点 (PPT P27 图解)

- **对称性**：Encoder 和 Decoder 结构通常是对称的。
- **通道变化**：Encoder 过程中图像尺寸变小，通道数 (Filters) 增加（特征变厚）；Decoder 过程中图像尺寸变大，通道数减少回到原始通道（如 1 或 3）。

22.2.2 稀疏自编码器 (Sparse Autoencoders) (PPT P30-P37) (⚠️ 必考重点)

(1) 动机
即使是过完备 (Overcomplete) 的网络，如果我们限制神经元的**激活频率**（即大部分时间神经元是不活跃的），也能学习到有意义的特征。

(2) 数学定义

- **激活度 (Activation)**：
  令 $a_j^{(Bn)}(x)$ 为隐层 (Bottleneck) 第 j 个神经元对输入 x 的激活值。
- **平均激活度 (Average Activation)**：
  在整个训练集（m 个样本）上，第 j 个神经元的平均激活值为：

$$\hat{\rho}_j = \frac{1}{m}\sum_{i=1}^{m}[a_j^{(Bn)}(x^{(i)})]$$

- **稀疏性约束 (Sparsity Constraint)**：
  我们要强制 $\hat{\rho}_j$ 接近一个预设的**稀疏参数 (Sparsity Parameter)** ρ [cite: 359-360]。
  - ρ 通常是一个很小的值（如 0.05）。
  - 这意味着神经元大部分时间输出接近 0。

(3) 惩罚项：KL 散度 (KL Divergence) (⚠️ 公式背诵)
为了实现 $\hat{\rho}_j = \rho$，我们在损失函数中加入惩罚项。标准的方法是使用 Kullback-Leibler (KL) 散度来衡量两个伯努利分布 (ρ 和 $\hat{\rho}_j$) 之间的距离 [cite: 365-366]：

$$KL(\rho||\hat{\rho}_j) = \rho\log\frac{\rho}{\hat{\rho}_j} + (1-\rho)\log\frac{1-\rho}{1-\hat{\rho}_j}$$

- **性质**：
  - 当 $\hat{\rho}_j = \rho$ 时，$KL = 0$（最小值）[cite: 371-372]。
  - 当 $\hat{\rho}_j$ 偏离 ρ 时，KL 值单调增加（呈U型曲线）。

(4) 最终目标函数 (Objective Function)

$$J_S(W,b) = J(W,b) + \beta\sum_{j=1}^{Bn}KL(\rho||\hat{\rho}_j)$$

- $J(W,b)$：原始重构误差。
- β：控制稀疏惩罚权重的超参数。
- Bn：隐层神经元数量。

(5) 潜在考题预测 (Exam Hacks)

> - **Q**: 计算 $\hat{\rho}_j$ 需要什么操作？这在训练中有什么难点？
> - **A**: 计算 $\hat{\rho}_j$ 需要对**整个训练集**进行前向传播 (Forward pass)。这在批量梯度下降中是可行的，但在随机梯度下降 (SGD) 中，通常需要使用移动平均 (Moving Average) 来近似估计。

22.2.3 降噪自编码器 (Denoising Autoencoders, DAE) (PPT P38-P49) (⚠️ 核心考点)

(1) 核心直觉 (Intuition)

- **鲁棒性 (Robustness)**：一个好的表示应该能够抵抗输入的微小干扰。

- **流形学习 (Manifold Learning)**：数据集中在低维流形附近。损坏的样本 $\tilde{x}$ 会偏离流形，DAE 学习将 $\tilde{x}$ 投影回流形上的正确位置 x [cite: 479-483]。

(2) 训练流程 (Process) (PPT P42-P46)
这是考试中画图或描述流程的高频题：

1. **取样**：从数据集取原始输入 x。
2. **加噪**：通过随机过程 $q(\tilde{x}|x)$ 损坏 x，得到 $\tilde{x}$ [cite: 438-439, 466]。
   - *加噪方式*：高斯噪声 (Gaussian additive noise) 或 Masking noise (随机置0，类似 Dropout)。
3. **编码与解码**：将 $\tilde{x}$ 输入网络：

$$h = f(\tilde{x})$$

$$\hat{x} = g(h) = g(f(\tilde{x}))$$

4. **计算损失**：⚠️ **注意！这里是将重构输出 $\hat{x}$ 与原始纯净输入 x 进行比较，而不是与噪声输入 $\tilde{x}$ 比较。**

$$L_{DAE} = L(x, \hat{x}) = L(x, g(f(\tilde{x})))$$

(3) DAE 解决了什么?
它防止了仅仅学习“恒等映射”。因为输入是 $\tilde{x}$ 而输出要求是 x，网络必须学习数据特征间的**依赖关系 (Correlations)** 才能从部分损坏的数据中还原出完整数据。

22.2.4 堆叠自编码器 (Stacked Autoencoders, SAE) (PPT P50-P55)

(1) 动机
如何利用 AE 构建深度神经网络？利用 AE 进行**无监督预训练 (Unsupervised Pre-training)** [cite: 497-498]。

(2) 训练步骤 (Greedy Layer-wise Training)

1. **训练第一层 AE**：用原始输入 x 训练第一个 AE，得到编码器 f_1 和特征 z_1 [cite: 511-512]。
2. **训练第二层 AE**：用第一层的输出 z_1 作为输入，训练第二个 AE，得到 f_2 和 z_2 [cite: 515-516]。
3. **堆叠 (Stacking)**：重复此过程。扔掉所有的解码器，将编码器 $f_1, f_2, ...$ 堆叠起来。
4. **微调 (Fine-tuning)**：在最顶层接一个分类器 (Classifier, 如 Softmax)，使用有标签数据 (X, Y) 对整个深层网络进行监督微调 [cite: 504, 519-522]。

(3) 优势

- **初始化**：相比于随机初始化权重，SAE 提供了“更聪明”的权重初始值。
- **利用未标记数据**：可以使用大量无标签数据训练底层特征。

22.2.5 收缩自编码器 (Contractive Autoencoders, CAE) (PPT P56-P61) (⚠️ 高难度数学考点)

(1) 核心思想

- 目标与 DAE 类似：学习对输入微小变化不敏感（Invariant）的特征 [cite: 532-533]。
- 方法：DAE 是通过随机加噪实现的，而 CAE 是通过在损失函数中添加**解析性的正则项 (Analytic Regularizer)** 实现的。

(2) 雅可比矩阵 (Jacobian Matrix)
我们需要衡量隐层特征 $f(x)$ 对输入 x 的敏感度。这就是雅可比矩阵 $J_f(x)$：

$$J_f(x) = \frac{\partial f(x)}{\partial x} = \left[\frac{\partial f(x)_j}{\partial x_i}\right]$$

- 这里 i 对应输入维度，j 对应隐层维度。

(3) 收缩损失函数 (The Contractive Loss) (⚠️ 必背)
我们在重构误差 $L(x)$ 之外，加上雅可比矩阵的 **Frobenius 范数** [cite: 547-549]：

$$L^*(x) = L(x) + \lambda\Omega(x) = L(x) + \lambda||J_f(x)||_F^2$$

展开形式为：

$$L^*(x) = L(x) + \lambda \sum_{ij} \left(\frac{\partial f(x)_j}{\partial x_i}\right)^2$$

(4) 物理意义 (Trade-off)
这个公式体现了两个相互对抗的目标 [cite: 554-555]：

1. $L(x)$ **(重构误差)**：希望保留信息，要求 $f(x)$ 对 x 的变化敏感（否则无法区分不同的输入）。
2. $\Omega(x)$ **(正则项)**：希望抛弃信息，要求 $f(x)$ 尽可能平滑（Flat），对 x 的变化不敏感（导数为0）。

结果：网络只保留**训练数据变化方向**（切向量方向）上的敏感度，而抑制正交方向上的变化（即噪声方向）。

22.3 总结与对比 (Comparison) (PPT P62-P63)

22.3.1 DAE vs CAE

特性	降噪自编码器 (DAE)	收缩自编码器 (CAE)
抗扰动方式	**随机 (Stochastic)**：通过添加实际噪声样本。	**确定性 (Deterministic)**：通过惩罚导数（雅可比范数）。
扰动类型	抵抗**有限大小 (Finite sized)** 的扰动。	抵抗**无穷小 (Infinitesimal)** 的扰动。
实现难度	**简单**：只需几行代码添加噪声 [cite: 573-574]。	**困难**：计算隐层雅可比矩阵计算量大。
稳定性	基于随机采样，梯度可能有方差。	梯度是确定性的，可能更稳定 [cite: 575-576]。

22.4 复习建议与解题策略

1. **公式推导题**：如果考到 **KL 散度** 或 **CAE 的损失函数**，不要只写最后一行。要先定义符号（如 $\hat{\rho}_j$ 是什么），再写出通用的 Loss 形式，最后代入具体项。
2. **架构画图题**：对于 DAE，务必画出 $x \to \tilde{x} \to \text{Encoder} \to \text{Decoder} \to \hat{x}$ 的流程，并明确标注 Loss 是在 $\hat{x}$ 和 **原始** x 之间计算。
3. **概念辨析题**：对于“欠完备 vs 过完备”，关键词是“压缩” vs “正则化”。对于“DAE vs CAE”，关键词是“随机噪声” vs “雅可比惩罚”。
4. **Sparsity 参数**：记住 ρ 是一个很小的常数（目标），而 $\hat{\rho}_j$ 是训练集上的统计值（现状）。

第23章 卷积神经网络

23.1 神经网络基础回顾与CNN引入

23.1.1 Mini-batch SGD 与 训练流程 (PPT P2-P3)

(1) 核心概念与定义

- **小批量随机梯度下降 (Mini-batch SGD)**：
  - *定义*：一种优化算法，每次迭代不是使用单个样本（SGD）也不是全部样本（Batch GD），而是采样一小批数据来计算梯度并更新参数。
  - *直观理解*：就像蒙着眼睛下山，每次通过一小部分地形（Batch）来判断下降方向。相比全量数据计算快，相比单样本震荡小。
  - *关键细节*：PPT中强调了 Loop 循环四步走：Sample batch -> Forward prop (loss) -> Backprop (gradients) -> Update parameters。

(2) 算法流程/机制

- **训练循环 (The Loop)**：
  i. **采样 (Sample)**：从训练集中随机抽取 N 个样本（Batch size）。
  ii. **前向传播 (Forward prop)**：数据输入网络图（Graph），经过层层计算得到损失 (Loss)。
  iii. **反向传播 (Backprop)**：根据 Loss 对参数求偏导，计算梯度 (Gradients)。
  iv. **参数更新 (Update)**：利用梯度下降公式更新权重 $W \leftarrow W - \eta \nabla W$。

(3) 优化器演变 (Exam Hacks)

> **教授注**：PPT第3页展示了不同优化器的收敛轨迹。虽然未展开公式，但需记住演变路径：
> SGD -> Momentum (冲量) -> Nesterov -> Adagrad -> RMSProp -> Adam。
> *考试考点*：通常考察 Momentum 解决了SGD的什么问题（解决了在峡谷状损失面上的震荡，加速收敛）。

23.2 卷积层 (Convolution Layer) —— 核心考点

23.2.1 卷积层的运作机制 (PPT P9-P20)

(1) 核心概念与定义

- **卷积 (Convolution)**：
  - *定义*：在图像处理中，指滤波器（Filter/Kernel）在图像上滑动，通过点积运算提取特征的过程。
  - *直观理解*：滤波器就像一个“手电筒”，照到哪里就计算该区域与滤波器特征的匹配程度。
  - *解决了什么问题*：全连接层（FC）参数量过大，且忽略了图像的局部相关性。卷积层通过**局部连接**和**权值共享**大大减少了参数。

(2) 核心公式与推导 (⚠️ 重点：数学定义)

- **卷积公式 (1D/2D 离散形式)**：
  PPT P20 给出了信号处理中的标准定义：

$$f[x,y] * g[x,y] = \sum_{n_1=-\infty}^{\infty} \sum_{n_2=-\infty}^{\infty} f[n_1,n_2] \cdot g[x-n_1, y-n_2]$$

  - *机器学习中的简化*：在CNN中，我们通常不进行翻转（Flipping），而是直接做**元素对应相乘再求和 (Element-wise multiplication and sum)**。
  - *操作描述*：

$$Output_{i,j} = \sum_{u=0}^{F-1} \sum_{v=0}^{F-1} Image_{i+u,j+v} \cdot Filter_{u,v} + Bias$$

(3) 图像与滤波器的维度匹配

- **输入**：$32 \times 32 \times 3$ (Height × Width × Depth)。
- **滤波器**：必须与输入的**深度 (Depth)** 一致。例如 $5 \times 5 \times 3$。
  - *注意*：虽然滤波器主要在 H, W 维度滑动，但在 Depth 维度是全连接的（贯穿整个深度）。
- **输出**：一个滤波器产生一张**特征图 (Activation Map)**。如果有 K 个滤波器，输出深度就是 K。

23.2.2 空间维度计算 (Spatial Dimensions) (PPT P22-P43) —— 必考计算题

(1) 输出尺寸计算公式 (⚠️ 背诵)

给定：

- 输入尺寸：$W_1 \times H_1$
- 滤波器尺寸 (Filter/Receptive Field)：F
- 步长 (Stride)：S
- 零填充 (Zero Padding)：P

输出尺寸 $W_2 \times H_2$ 计算如下：

$$W_2 = \frac{W_1 - F + 2P}{S} + 1$$

$$H_2 = \frac{H_1 - F + 2P}{S} + 1$$

(2) 典型计算案例 (Exam Hacks)

> **Q**: 输入 $32 \times 32 \times 3$，使用 10 个 5×5 的滤波器，Stride=1, Pad=2。求输出体积和参数量。
>
> **A (解题步骤)**:
>
> 1. **输出体积 (Output Volume)**:
>   - $W_{out} = (32 - 5 + 2 \times 2)/1 + 1 = (31)/1 + 1 = 32$。
>   - 深度 = 滤波器数量 = 10。
>   - 结果：$32 \times 32 \times 10$。
> 2. **参数量 (Number of Parameters) (⚠️ 易错点)**:
>   - **权重 (Weights)**: 每个滤波器体积为 $5 \times 5 \times 3$ (注意深度是3)。
> $Weights = 5 \times 5 \times 3 = 75$。
>   - **偏置 (Bias)**: 每个滤波器有 1 个 bias。
> $Total = (75 + 1) = 76$ 参数/滤波器。

- **总参数**: $76 \times 10 = \mathbf{760}$。

(3) 1x1 卷积 (PPT P44)

- *定义*：滤波器尺寸为 $1 \times 1 \times Depth$。
- *作用*：
  i. **降维/升维**：改变通道数（Depth），不改变空间尺寸（W, H）。
  ii. **增加非线性**：配合 ReLU，在不损失分辨率的情况下增加网络深度。

23.3 卷积层的神经元视角 (Brain View) (PPT P48-P51)

23.3.1 局部连接与感受野

- **类比**：
  - $32 \times 32 \times 3$ 的图像是输入信号。
  - $5 \times 5 \times 3$ 的滤波器是神经元的**突触权重 (Synaptic weights)**。
  - 输出图中的一个点，对应一个神经元的激活值。
- **感受野 (Receptive Field)**：该神经元只“看”到原图中 5×5 的局部区域。

23.3.2 参数共享 (Parameter Sharing)

- **核心思想**：特征图上的所有神经元共用同一套权重（同一个滤波器）。
- *假设*：如果一个特征（如垂直边缘）在图像左上角有用，那么它在右下角也应该有用。

23.4 池化层 (Pooling Layer) (PPT P53-P56)

23.4.1 核心概念

- **目的**：对特征图进行**下采样 (Downsampling)**，减小数据空间尺寸，减少参数量和计算量，控制过拟合。
- **特性**：
  - 在每个深度切片（Depth slice）上独立操作。
  - **没有需要学习的参数 (Zero parameters)**。

23.4.2 最大池化 (Max Pooling)

- *操作*：在滤波器窗口内取最大值。
- *常见设置*：
  - 滤波器 $F = 2$，步长 $S = 2$。这将使图像的长宽各减半，丢弃 75% 的激活值。
  - 滤波器 $F = 3$，步长 $S = 2$。
- *公式*：同卷积层尺寸计算公式，一般 $P = 0$。

$$W_2 = \frac{W_1 - F}{S} + 1$$

23.5 经典架构案例分析 (Case Studies) —— 综合大题重灾区

23.5.1 LeNet-5 (PPT P59)

- **结构**：Conv -> Pool -> Conv -> Pool -> FC -> FC。
- **特点**：最早的商用CNN，用于手写数字识别。使用 5×5 卷积，2×2 池化。

23.5.2 AlexNet (PPT P60-P68) (⚠️必须掌握每一层的尺寸推导)

- **输入**：$227 \times 227 \times 3$。
- **第一层 (CONV1)**：96个 11×11 滤波器，Stride=4，Pad=0。
  - *输出尺寸*：$(227 - 11)/4 + 1 = 54 + 1 = 55$。结果：$55 \times 55 \times 96$。
  - *参数量*：$(11 \times 11 \times 3) \times 96 \approx 35K$。
- **第二层 (POOL1)**：3×3 滤波器，Stride=2。
  - *输出尺寸*：$(55 - 3)/2 + 1 = 26 + 1 = 27$。结果：$27 \times 27 \times 96$。
  - *参数量*：0。

- **关键特性**：
  - 首次使用 ReLU。
  - 使用 Dropout (0.5) 防止过拟合。
  - 重度数据增强 (Data Augmentation)。

23.5.3 VGGNet (PPT P70-P73)

- **核心设计哲学**：
  - **全部使用 3×3 小卷积核**。
  - 通过堆叠两个 3×3 卷积层，感受野等于一个 5×5，但参数更少，非线性更多。
- **内存与参数分布规律 (Exam Hacks)**：
  - **内存消耗**：主要集中在**前端卷积层**（因为特征图分辨率高）。
  - **参数数量**：主要集中在**后端全连接层**（FC层参数量巨大）。
  - *例如*：VGG-16 最后三个FC层贡献了绝大多数参数（约1亿+）。

23.5.4 GoogLeNet (Inception) (PPT P74-P75)

- **Inception 模块**：
  - *思想*：与其人为决定用 1×1 还是 3×3 或 5×5，不如**并行**使用它们，让网络自己去学。
  - *瓶颈层 (Bottleneck)*：在昂贵的 3×3 和 5×5 卷积前，先使用 1×1 **卷积降维**（减少深度 Depth），大幅降低计算量。
  - *结果*：去除了全连接层，参数量仅为 AlexNet 的 1/12 (500万 vs 6000万)。

23.5.5 ResNet (深度残差网络) (PPT P76-P86)

- **革命性突破**：训练了 152 层网络（之前只能训练约 20 层）。
- **核心模块：残差块 (Residual Block)**：
  - *原始问题*：网络加深会导致梯度消失/梯度爆炸，且会出现退化问题（Degradation problem，即深层网络误差反而比浅层高）。
  - *解决方案*：引入**跳跃连接 (Skip Connection)**。
  - *公式*：

$$H(x) = F(x) + x$$

    这里 $F(x)$ 是残差映射，$H(x)$ 是期望的输出。如果恒等映射是最优的，网络只需将 $F(x)$ 权重学为 0 即可。
- **瓶颈结构 (Bottleneck Design)** (PPT P83)：
  - 对于深层网络（如 ResNet-50/101/152），使用 1×1 (降维) -> 3×3 -> 1×1 (升维) 的结构，两头小中间大，类似沙漏，为了减少 3×3 卷积的计算量。

23.6 考题实战演练 (Exam Hacks)

基于“课件是唯一标准”和“侧重流程/推导”，请务必准备以下题型：

23.6.1 参数量计算 (计算题)

题目：假设输入为 $H \times W \times C$，当前层是卷积层，滤波器大小为 $F \times F$，滤波器数量为 K，步长 $S = 1$，填充 P 使得输出空间尺寸不变。请写出该层的**权重参数总量**和**输出张量体积**。
解答：

- **权重参数**：每个滤波器参数 = $F \times F \times C$。总权重 = $(F \times F \times C) \times K$。
- **偏置参数**：K 个。
- **总参数**：$K \times (F^2C + 1)$。
- **输出体积**：由于 P 保持了尺寸，输出为 $H \times W \times K$。

23.6.2 感受野理解 (简答题)

题目：为什么使用两个堆叠的 3×3 卷积层比直接使用一个 5×5 卷积层更好？(参考 VGGNet)
解答：

1. **感受野相同**：两个 3×3 层覆盖的区域等同于一个 5×5。
2. **参数更少**：$2 \times (3 \times 3 \times C \times C) = 18C^2$，而 $1 \times (5 \times 5 \times C \times C) = 25C^2$。参数减少了约 28%。
3. **非线性更强**：两层之间多了一次 ReLU 激活，增加了网络的表达能力。

23.6.3 1x1 卷积的作用 (概念题)

题目：GoogLeNet 和 ResNet 中都大量使用了 1×1 卷积，请问其主要作用是什么?
解答：
主要作用是**降维（Dimension Reduction）**。通过减少特征图的深度（通道数），从而减少后续计算量。例如，将 256 维的输入通过 64 个 1×1 卷积核，变为 64 维，大大降低了后续 3×3 卷积的运算压力。同时引入了额外的非线性变换。

第24章 变分自编码器 (Variational Autoencoders, VAE)

24.1 背景与传统自编码器回顾 (PPT P1-P6)

24.1.1 传统自编码器 (Autoencoders, AE) 的局限性

(1) 核心回顾

- **定义**：传统 AE 是旨在输出输入的重构的模型，它将输入数据解构为隐藏表示，再将其重构为原始输入。
- **特点**：模型基于数据自学习显著的特征表示，无需标签或启发式规则。
- **局限性**：
  - 传统 AE 学习的是确定性的映射，主要关注重构误差。
  - **潜在空间 (Latent Space) 问题**：普通 AE 的潜在空间往往是不连续的，难以进行有效的插值或新样本生成。

24.1.2 VAE 的动机 (Motivation) (PPT P4, P11)

- **定义**：VAE 是一种用于学习有用的潜在表示 (latent representations) 的深度学习技术。
- **核心能力**：它是对自编码器的概率化改进，具备以下功能：
  i. **新颖图像合成**：能够从随机样本中生成全新的图像。
  ii. **平滑过渡**：支持从图像到图像或从模态到模态的平滑过渡。
  iii. **聚集性**：将相似的图像聚合在潜在空间的相近位置。

24.2 信息论基础回顾 (Information Theory Recap) (PPT P8-P18)

> **教授提示**：这部分虽然是基础，但期末考试极有可能考查基本定义的性质，特别是 KL 散度为什么不是距离。

24.2.1 信息量与熵 (Entropy)

(1) 信息的定义 (PPT P9-P11)

- 定义信息函数 $I(P)$，对于概率为 P 的事件：
  i. **单调递减**：概率越大，观察到该事件的信息量越小。
  ii. **非负性**：$I(P) \geq 0$。
  iii. **可加性**：独立事件的信息量是可加的，$I(P_1P_2) = I(P_1) + I(P_2)$。
- **推导**：通过解微分方程 $u \cdot I'(u) = c$，结合边界条件，得出 $I(p) = -\log p$ [cite: 153-163]。

(2) 熵 (Entropy) (PPT P12-14)

- **定义**：随机变量信息的期望值。

$$H(X) = E[I(X)] = E[-\log P(x)] = -\sum P(x_i) \cdot \log P(x_i)$$

- **性质**：
  - 如果是连续分布，**高斯分布 (Normal Distribution)** 在给定均值和协方差的情况下具有最大的熵。这解释了 VAE 中先验分布选择高斯分布的合理性。

24.2.2 KL 散度 (Kullback-Leibler Divergence) (PPT P16-18)

(1) 定义

- 衡量两个分布 p 和 q 之间的相似度（或差异）。

$$KL(p||q) = \sum p(x) \log p(x) - \sum p(x) \log q(x)$$

- 直观理解：KL 散度衡量了使用针对 q 优化的编码来编码来自 p 的样本时，平均所需的额外比特数。

(2) 关键性质 (考试考点)

1. **非负性**：$KL(p||q) \geq 0$。

2. **非对称性**：$KL(p||q) \neq KL(q||p)$。
   - 因此，KL 散度**不是**一个距离度量 (Metric)，因为它不满足对称性条件。

24.3 VAE 的理论核心——从不可积到变分推断 (PPT P19-P26, P54-P60)

> **教授提示**：这是全篇最难也是最重要的数学部分。**ELBO 的推导过程是必考点**。

24.3.1 隐变量模型的问题 (PPT P20-23)

- **生成过程**：假设数据 x 由未观察到的隐变量 z 控制。
  i. 从先验分布采样：$z \sim p(z)$。
  ii. 从条件分布生成图像：$x \sim p(x|z)$。
- **推断困难 (Intractability)**：
  - 我们需要计算后验分布 $p(z|x)$。
  - 证据积分 (Evidence) $p(x) = \int p(x|z)p(z)dz$ 通常没有闭式解，或者计算时间是指数级的。
  - 因此，直接使用 EM 算法是行不通的，因为我们无法计算后验概率。

24.3.2 变分推断 (Variational Inference) (PPT P24-26)

- **思想**：既然 $p(z|x)$ 不可解，我们用一个可解的分布 $q(z|x)$ 来近似它。
- **目标**：找到能够最好地近似不可解后验 $p(z|x)$ 的 $q(z|x)$。
- **优化目标**：最小化近似分布与真实后验之间的 KL 散度：

$$\min_{\phi} KL[q_\phi(z|x)||p(z|x)]$$

24.3.3 ELBO (证据下界) 的推导 (PPT P54-P60) ⚠️ 重点背诵

我们将“最小化 KL”的问题转化为“最大化 ELBO”。

推导步骤：

1. **展开 KL 散度定义**：

$$KL(q(z|x)||p(z|x)) = \int q(z|x) \log \frac{q(z|x)}{p(z|x)} dz$$

2. **利用贝叶斯公式展开分母** ($p(z|x) = p(x,z)/p(x)$)：

$$= \int q(z|x) \log \frac{q(z|x)p(x)}{p(x,z)} dz$$

3. **拆分对数项**：

$$= \int q(z|x) \log \frac{q(z|x)}{p(x,z)} dz + \int q(z|x) \log p(x) dz$$

4. **提取常数项** (因为 $\log p(x)$ 与 z 无关)：

$$= \int q(z|x) \log \frac{q(z|x)}{p(x,z)} dz + \log p(x)$$

5. **移项整理**：

$$\log p(x) = KL(q(z|x)||p(z|x)) - \int q(z|x) \log \frac{q(z|x)}{p(x,z)} dz$$

$$\log p(x) = KL(q(z|x)||p(z|x)) + \int q(z|x) \log \frac{p(x,z)}{q(z|x)} dz$$

6. **定义 ELBO (Evidence Lower Bound)**：
   我们将右侧的积分项称为 ELBO，记为 $\mathcal{L}(\phi)$。

$$\mathcal{L}(\phi) = \int q(z|x) \log \frac{p(x,z)}{q(z|x)} dz$$

由于 KL 散度非负，所以 $\mathcal{L}(\phi)$ 是 $\log p(x)$ 的下界。

ELBO 的最终形式 (用于 Loss 计算)：
我们将 $\mathcal{L}(\phi)$ 进一步拆解：

$$\mathcal{L}(\phi) = -KL(q(z|x)||p(z)) + E_{q(z|x)}[\log p(x|z)]$$

1. **正则化项**：$-KL(q(z|x)||p(z))$，希望近似后验 q 接近先验 p (通常是标准正态)。
2. **重构项**：$E_{q(z|x)}[\log p(x|z)]$，希望从 z 能准确还原 x。

24.4 VAE 的具体实现与训练 (PPT P61-P77)

24.4.1 神经网络视角

- **Encoder (概率编码器)**：$q_\phi(z|x)$，输入 x，输出潜在变量的分布参数（均值 μ 和方差 σ）[cite: 642, 651-689]。
- **Decoder (生成解码器)**：$p_\theta(x|z)$，输入 z，输出重构数据 $\hat{x}$ [cite: 640, 690-692]。

24.4.2 重参数化技巧 (Reparameterization Trick) (PPT P69-74) ⚠️ 必考

(1) 问题

- 在网络中，我们需要从分布 $q(z|x)$ 中采样 z。
- **随机采样节点 (Random node)** 会切断反向传播的梯度流，导致无法计算 Encoder 的梯度。

(2) 解决方案

- 将随机性转移到一个外部的噪声变量 ϵ 上，使 z 变为确定性操作的结果。
- **公式**：

$$z = \mu + \sigma \odot \epsilon$$

  其中 $\epsilon \sim N(0, I)$。
- **作用**：现在 z 对 μ 和 σ 是可导的，梯度可以通过 z 传回 Encoder [cite: 902-906]。

24.4.3 高斯分布的 KL 散度计算 (PPT P75-77)

- VAE 的 Loss 中包含一项 $KL(N(\mu, \Sigma)||N(0, I))$。
- 这一项可以通过解析解直接计算，无需采样：

$$KL = -\frac{1}{2}[n + \log(\det(\Sigma)) - \mu^T\mu - tr(\Sigma)]$$

  (注：PPT P77 给出了具体的代码实现公式)

24.5 VAE 的性质与应用 (PPT P39-P53, P78-P86)

24.5.1 潜在空间的组织 (PPT P39-53)

- **混合潜在变量 (Blending)**：
  - VAE 强制潜在空间重组。通过引入噪声（SD σ），迫使编码器将潜在表示扩展为区域而不是单点 [cite: 378, 485-489]。
  - 相同类别的样本在潜在空间中聚集，不同类别的样本被推开，从而形成有意义的结构。

24.5.2 潜在空间操作 (Latent Space Arithmetic) (PPT P82-85)

- **插值 (Interpolation)**：在两个潜在向量之间进行线性插值，解码后的图像会显示出平滑的语义过渡（例如从一种数字变为另一种，或从一张人脸渐变到另一张）。
- **算术运算 (Arithmetic)**：可以提取特定属性的向量。
  - 例如：$z_{\text{戴眼镜男人}} - z_{\text{不戴眼镜男人}} + z_{\text{不戴眼镜女人}} \approx z_{\text{戴眼镜女人}}$ [cite: 1058, 1091-1094]。
  - 这证明了 VAE 学习到了解耦的、语义丰富的特征表示。

24.6 考试复习总结 (Exam Hacks)

24.6.1 潜在考题预测

> **Q1: 简述 VAE 与 AE 的主要区别?**
> **A**: AE 学习确定性的隐变量映射，潜在空间不连续，无法有效生成新样本；VAE 学习隐变量的概率分布，引入 KL 散度约束潜在空间接近标准正态分布，支持采样生成和平滑插值 [cite: 11-15]。

> **Q2: 为什么 VAE 需要重参数化技巧？请写出公式。**
> **A**: 为了解决采样操作不可导、导致无法进行反向传播的问题。公式为 $z = \mu + \sigma \odot \epsilon, \epsilon \sim N(0, I)$。

> **Q3: 推导 ELBO，并解释其中两项的物理含义。**
> **A**: (参考 24.3.3 节的推导)。含义：第一项是重建似然（保证生成质量），第二项是 KL 散度（正则化，保证潜在空间结构）。

24.6.2 必须掌握的数学符号

- x: 观测数据
- z: 隐变量 (Latent variable)
- $q_\phi(z|x)$: 编码器 (近似后验分布)
- $p_\theta(x|z)$: 解码器 (似然分布)
- $p(z)$: 先验分布 (通常为 $N(0, I)$)

第25章 Attention Mechanism & Transformer

你好！我是负责《机器学习与数据挖掘》课程的教授。
针对你提供的PPT《Attention and Transformers》，结合期末考试“**重逻辑、重推导、不考复杂计算但考矩阵形式**”的特点，我为你整理了这份复习讲义。
这份讲义完全覆盖了PPT内容，并将PPT中简略的公式补充完整，特别是Transformer核心的**Self-Attention矩阵运算**和**维度变化**，这是考试的重灾区。

25.1 基础回顾与序列模型演进 (PPT P1-P9)

虽然本章重点是Transformer，但PPT回顾了全连接网络(FNN)和卷积神经网络(CNN)作为铺垫，主要为了对比后续的计算模式。

25.1.1 基础神经网络回顾 (PPT P3-P7)

(1) 核心概念

- **全连接网络 (FNN)**：学习层与层之间所有节点对的权重。
- **卷积神经网络 (CNN)**：
  - *核心思想*：利用**滤波器 (Filter)** 提取局部特征（如3x3的模式）。
  - *计算方式*：点积 (Dot Product)。滤波器在输入矩阵上滑动，对应元素相乘后求和。
  - *局限性*：CNN擅长捕获局部特征，但在处理长距离依赖时，需要堆叠很多层。

25.1.2 循环神经网络 (RNN) 与 LSTM (PPT P8-P9)

(1) RNN 的结构与展开

- **结构**：RNN具有循环结构，允许信息在时间步（Time Step）上传递。
- **公式形式**（考试常考形式）：

$$h_t = \sigma(W x_t + U h_{t-1})$$

  其中 x_t 是当前输入，h_{t-1} 是上一时刻的隐藏状态，W, U 是共享权值。
- **Unfold (展开)**：将随时间循环的网络展开成一个序列链条。这意味着**计算必须是串行的**（Sequential），时刻 t 的计算必须等待 $t-1$ 完成。

(2) LSTM (Long Short-Term Memory)

- **目的**：解决标准RNN的梯度消失问题，以捕获长距离依赖。
- **核心组件**：引入了“门控机制”和细胞状态（Cell State），相比简单RNN（单一tanh层），LSTM拥有四个交互层（图示中的黄色框）。

(3) 潜在考题预测 (Exam Hacks)

> - **Q**: 为什么Transformer最终取代了RNN？（基于PPT P17的线索）

> - **A**: 核心在于**并行计算 (Parallelization)**。RNN必须按序列顺序计算，无法充分利用GPU并行加速；而Transformer利用Self-Attention，可以同时计算序列中所有位置的表示，无需循环。

25.2 Encoder-Decoder 与 Attention 的起源 (PPT P10-P16)

25.2.1 Encoder-Decoder 模型 (PPT P10-P11)

(1) 架构流程

- **应用场景**：机器翻译 (Machine Translation)。
- **Encoder (编码器)**：将输入序列（如法语句子）压缩成一个**固定长度的上下文向量 (Context Vector)**。
- **Decoder (解码器)**：利用这个固定向量生成输出序列（如英语句子）。
- **瓶颈 (Bottleneck)**：将长句子压缩成单一向量会导致信息丢失（PPT中提到的 "Encoder-Decoder bottleneck" 问题隐含在Attention的引入动机中）。

25.2.2 Attention 机制的引入 (PPT P12)

(1) 核心突破

- **直观理解**：在解码生成第 j 个词时，不只依赖单一的上下文向量，而是**动态地查看（Attend to）** 编码器中所有的隐藏状态 h_i，并根据相关性赋予不同的权重。
- **公式描述**：
  上下文向量不再是静态的，而是加权和：

$$c_j = \sum_i \alpha_{ji} h_i$$

  其中 α_{ji} 是**Attention Weight**，满足归一化条件：$\sum_j a_j = 1$。

25.2.3 图像描述生成 (Image Captioning) (PPT P13-P16)

- **机制**：CNN作为Encoder提取图像特征图（Feature Maps），RNN作为Decoder生成描述词。
- **Visual Attention**：在生成“frisbee”（飞盘）这个词时，模型会给图像中飞盘所在的区域分配高权重（高亮显示），忽略背景。这证明了Attention能让模型“聚焦”于相关信息。

25.3 Transformer 核心架构 (PPT P17-P29)

这是本次考试的绝对核心。PPT P17 提出了Transformer是第一个**完全依赖Self-Attention**而不使用RNN或CNN的转换模型。

25.3.1 整体架构概览 (PPT P18-P20)

- **结构**：由 **Stack of Encoders**（通常6层）和 **Stack of Decoders**（通常6层）组成。
- **单个 Encoder Layer 内部结构**：
  i. **Self-Attention Layer**：处理词与词之间的关系。
  ii. **Feed Forward Neural Network (FFNN)**：独立处理每个位置的向量，这也是可以并行化的原因。

25.3.2 Self-Attention 机制详解 (PPT P21-P23) —— ⚠️ 必考推导

请务必背诵此处的矩阵运算过程。

(1) Q, K, V 的定义

对于输入序列中的每个词向量 x_i，我们通过乘以三个可学习的权重矩阵 W^Q, W^K, W^V 得到三个向量：

- **Query (q)**：查询向量（我要找什么？）
- **Key (k)**：键向量（我是什么？）
- **Value (v)**：值向量（我的内容是什么？）
- 公式:

$$q_i = x_i W^Q, \quad k_i = x_i W^K, \quad v_i = x_i W^V$$

(2) 矩阵形式的计算流程 (PPT P23)

假设我们将所有输入的词向量拼成矩阵 X。

1. **计算 Score (注意力分数)**：
   计算 Query 和 Key 的点积，衡量匹配程度。
   $$Score = Q \cdot K^T$$
2. **缩放 (Scaling)**：
   除以 $\sqrt{d_k}$（Key向量维度的平方根，这里是8，因为$d_k = 64$）。
   - *原因*：防止点积结果过大，导致Softmax进入梯度极小的饱和区。
3. **归一化 (Softmax)**：
   将分数转换为概率分布。
   $$Attention_Weights = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)$$
4. **加权求和 (Weighted Sum)**：
   用权重乘以 Value 矩阵，得到最终输出 Z。
   $$Z = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

(3) 潜在考题预测 (Exam Hacks)

> - **Q**: 给定输入 X 维度为 $[2, 4]$ (2个词，嵌入维度4)，W^Q, W^K, W^V 维度均为 $[4, 3]$。求输出 Z 的维度。
> - **A**:
>   i. Q, K, V 的维度都是 $[2, 4] \times [4, 3] = [2, 3]$。
>   ii. QK^T 维度为 $[2, 3] \times [3, 2] = [2, 2]$ (表示2个词两两之间的分数)。
>   iii. Softmax后仍为 $[2, 2]$。
>   iv. 最后乘以 V，维度为 $[2, 2] \times [2, 3] = [2, 3]$。
>   *结论*：输出维度与 Value 向量维度一致。

25.3.3 Multi-Head Attention (多头注意力) (PPT P24-P25)

(1) 机制

- **动机**：给模型多个“表示子空间 (Representation Subspaces)”，扩展模型关注不同位置的能力。
- **流程**：
  i. 独立初始化多组 W^Q, W^K, W^V 矩阵（通常8个头）。
  ii. 并行计算 h 个 Attention Head，得到 $Z_0, Z_1, \ldots, Z_7$。
  iii. **拼接 (Concatenate)**：将所有 Z_i 拼接在一起。
  iv. **线性投影**：乘以输出权重矩阵 W^O，将拼接后的长向量压缩回原始维度。

25.3.4 位置编码 (Positional Encoding) (PPT P26)

- **问题**：Transformer 没有循环（RNN）和卷积（CNN），如果不加位置信息，模型无法感知序列顺序。
- **解决方案**：创建一个与词嵌入 (Embeddings) 维度相同的**位置向量**。
- **操作**：**Embedding + Positional Encoding** (直接相加，不是拼接)。
- *原理*：这些向量遵循特定模式，使模型能确定词的距离和位置。

25.3.5 Add & Normalize (PPT P27-P28)

每个子层（Self-Attention 和 FFNN）之后都有两个操作：

(1) 残差连接 (Residual Connection, "Add")

- 公式：$LayerNorm(x + \text{Sublayer}(x))$。
- *作用*：允许梯度直接流向深层，缓解梯度消失。

(2) 层归一化 (Layer Normalization, "Normalize")

- **区别于 Batch Normalization (BN)**：
  - **BN**：对**Batch**方向归一化（计算同一特征在不同样本间的均值），参数对所有样本相同。
  - **LN**：对**Feature**方向归一化（计算同一样本内所有特征的均值），参数对所有特征维度相同。
- *操作*：使每个特征列具有相同的均值和方差。

25.4 Decoder 细节与完整流程 (PPT P29-P32)

25.4.1 Decoder 的特殊结构

Decoder 也是堆叠结构，但比 Encoder 多了一个层，且有特殊限制。

(1) Masked Self-Attention (掩码自注意力) (PPT P32, 594)

- **问题**：训练时我们知道完整的目标句子，但在预测时（Self-Attention），模型**不应该**看到未来的词。
- **实现**：将未来位置的值设为 $-\infty$。
- *结果*：Softmax($-\infty$) = 0，有效地切断了未来信息的连接。

(2) Encoder-Decoder Attention (PPT P29, 509)

- 这是连接 Encoder 和 Decoder 的桥梁。
- **Key (K) & Value (V)**：来自 **Encoder 的最终输出**。
- **Query (Q)**：来自 **Decoder 上一层的输出**。
- *直观理解*：Decoder 每生成一个词（Q），都去 Encoder 的输出库（K, V）里查询："我该关注源句子的哪部分？"

25.4.2 输出层 (PPT P30)

- **Linear Layer**：将向量投影到词汇表大小 (vocab_size) 的维度。
- **Softmax**：输出下一个词的概率分布（Logits -> Probabilities）。

25.5 训练、损失函数与评估 (PPT P33-P35)

25.5.1 损失函数 (Loss Function) (PPT P33-P34)

(1) 交叉熵 (Cross Entropy)

- 用于衡量模型输出概率分布 P 与真实分布 Q 之间的差异。
- 公式：

$$H(P, Q) = -\sum_{i} P(i) \log Q(i)$$

PPT中指出交叉熵是使用最优编码 Q 的期望编码长度。

(2) KL 散度 (Kullback-Leibler Divergence)

- 公式：$D_{KL}(P||Q) = \sum_i P(i) \log \frac{P(i)}{Q(i)}$。
- *关系*：Cross Entropy 与 KL 散度密切相关，优化前者通常等价于优化后者。

25.5.2 生成策略：Beam Search (集束搜索) (PPT P33)

- **方法**：不只保留概率最高的一个词（Greedy），而是保留前几个（Beam Size）候选词，最终选择整体概率最高的序列。

25.5.3 性能评估 (PPT P35)

- **BLEU Score**：标准评价指标。
- *结果*：Transformer 在训练成本（FLOPs）大幅降低（降低了几个数量级，如 10^{18} vs 10^{20}）的情况下，BLEU 分数超过了 ConvS2S 和 RNN 变体。

25.6 后续发展 (BERT vs GPT) (PPT P36)

PPT最后提到了基于Transformer衍生的两个最重要的模型。

25.6.1 BERT

- **架构**：仅使用 Transformer 的 **Encoder** 部分。
- **特性**：双向，能同时利用上下文信息。

25.6.2 GPT

- **架构**：仅使用 Transformer 的 **Decoder** 部分。
- **特性**：单向（Autoregressive），只能利用上文信息进行生成。

25.7 考前终极速记清单 (Cheat Sheet)

1. **矩阵维度**：Q, K, V 是 $X \cdot W$，其中 X 是 (N, d_{model})，W 是 (d_{model}, d_k)。
2. **Attention 公式**：$\text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$。分母 $\sqrt{d_k}$ 是为了梯度稳定。
3. **多头拼接**：Concat 后要做一次线性变换 W^O。
4. **Layer Norm**：对**每个样本**的所有特征求均值方差（横向），而不是对Batch（纵向）。
5. **Decoder Mask**：将未来位置设为 $-\infty$。
6. **Encoder-Decoder Attention**：Q 来自 Decoder，K, V 来自 Encoder。

第26章 Representation Learning (表示学习)

26.1 表示学习概论 (PPT P1-7)

1. 什么是表示学习?

(1) 核心概念与定义

- **表示学习 (Representation Learning)**：
  - *定义*：旨在将每个数据实例（如图像、文档、音频）映射到 $\mathbb{R}^d$ 空间中一个紧凑的向量（Vector/Embedding）。
  - *直观理解*：计算机无法直接理解原始像素或波形。我们需要将这些高维、嘈杂的原始数据，“翻译”成计算机能理解的、低维的、由数字组成的“语义特征向量”。
  - *关键细节*：
    - 输入：图像、文档、音频。
    - 过程：通过**嵌入模型 (Embedding Model)** 进行映射。
    - 输出：向量（例如 `[0.6, 0.3, 0.1, ...]`）。
    - **核心难点**：关键在于**如何得到这个映射**！(PPT P2)
- **表示学习的目标** (PPT P3-4)：
  - **保留语义**：尽可能多地保留原始数据的**语义信息**（Semantic Information），而不是所有信息（例如背景噪声）。
  - **几何特性**：
    - **拉近 (Pull)**：来自同一语义（如同一只狗的不同照片）的表示应在空间中彼此接近。
    - **推远 (Push)**：来自不同语义（如猫和狗）的表示应在空间中彼此远离。

(2) 为什么需要表示学习? (PPT P5-6)

- **对下游任务友好**：与原始数据相比，表示向量更适合后续处理。
  - *特点*：丢弃无关信息（如图片背景），保留重要语义；更加**紧凑**（低维）。
- **通用性**：同一个表示可以应用于各种下游应用：
  - 分类 (Classification)
  - 聚类 (Clustering)
  - 相似性搜索 (Similarity Search)
  - 异常检测 (Anomaly Detection)

(3) 潜在考题预测 (Exam Hacks)

> - **Q**: 什么样的表示才算“好”的表示?
> - **A**: 好的表示应尽可能保留原始数据的**语义信息**，具有**紧凑性**，且能使语义相似的样本在向量空间中距离更近，不相似的样本距离更远。

26.2 基于迁移学习与自编码器的方法 (PPT P8-14)

1. 基于迁移学习的方法 (Transfer Learning) (PPT P8-10)

(1) 核心机制

- **基本思想**：利用在大规模数据集（如 ImageNet）上训练好的模型，作为通用特征提取器。
- **流程步骤**：
  i. **预训练 (Pre-Training)**：在带有标签的大型辅助数据集（如 ImageNet）上训练一个 CNN（卷积神经网络）。

ii. **特征提取 (Feature Extraction)**：
   - 输入新数据集的图像到预训练好的 CNN。
   - **提取点**：通常提取**最后一个卷积层输出的特征图** (Feature Map) 或者 **全连接层倒数第二层** (FC Layer) 的输出作为表示向量 (PPT P9)。

iii. **微调/应用**：
   - **Transfer Learning**：直接使用提取的特征训练简单的分类器。
   - **Fine-Tuning**：在新数据集上对整个网络或部分层进行微调（更新参数）。

(2) 潜在考题预测 (Exam Hacks)

> - **Q**: 在迁移学习中，为什么可以使用 ImageNet 预训练模型的中间层输出作为新任务的图像表示?
> - **A**: 因为 CNN 的浅层和中层学习到了通用的视觉特征（如边缘、纹理、形状），这些特征在不同图像数据集中是共享的，即模型成为了一个通用的特征提取器。

2. 自编码器 (Autoencoders) (PPT P12-13)

(1) 核心概念

- **定义**：一种无监督学习方法，通过训练网络将输入“压缩”再“解压”来学习表示。
- **架构**：
  - **编码器 (Encoder)** g_ϕ：将输入 x 映射为低维表示 z（Bottleneck）。
  - **解码器 (Decoder)** f_θ：将 z 映射回重构输入 x'。
- **目标**：重构后的 x' 应尽可能接近原始输入 x，即 $x \approx x'$。

(2) 核心公式与推导 (⚠️ 重点)

- **PCA 的线性自编码器视角** (PPT P12)：
  - 如果限制编码器和解码器为线性变换，且使用均方误差，则自编码器退化为 PCA（主成分分析）。
  - 设主成分为 U，则编码过程为 $z = U^T x$，解码过程为 $x' = Uz$。
  - 重构：$x' = UU^T x$。
- **一般自编码器损失函数** (PPT P13)：
  - 网络参数通过最小化**重构误差 (Reconstruction Error)** 来学习。
  - **损失函数公式**：

$$L(\theta, \phi) = \frac{1}{N} \sum_{i=1}^{N} ||x_i - f_\theta(g_\phi(x_i))||^2$$

    - 其中 x_i 是输入，g_ϕ 是编码器，f_θ 是解码器，$|| \cdot ||^2$ 通常指 L2 范数（欧几里得距离的平方）。

26.3 对比学习：SimCLR (PPT P15-21)

1. SimCLR 核心机制 (PPT P15-17)

(1) 核心思想

SimCLR (Simple Framework for Contrastive Learning of Visual Representations) 不使用生成/重构，而是通过**对比**来学习。

- **正样本对 (Positive Pairs)**：同一张图片经过两次不同的**数据增强**（Data Augmentation）得到的两个视图。
- **负样本对 (Negative Pairs)**：同一张图片与其他不同图片及其增强视图。
- **目标**：**拉近**正样本对的表示，**推离**负样本对的表示。

(2) 算法流程 (Pipeline)

1. **数据增强 (Data Augmentation)**：
   - 对给定图像 x，应用两种随机增强 $t \sim \mathcal{T}$ 和 $t' \sim \mathcal{T}$。
   - 得到两个视图：$\tilde{x}_i$ 和 $\tilde{x}_j$（PPT P16图中标记）。
   - *常用增强*：随机裁剪(Crop)、缩放(Resize)、颜色失真(Color distort)、高斯模糊(Gaussian blur) (PPT P15)。
2. **编码器 (Encoder)**：
   - 使用神经网络 $f(\cdot)$ (如 ResNet) 提取特征向量。
   - $h_i = f(\tilde{x}_i), h_j = f(\tilde{x}_j)$。这里 h 是 ResNet 全局平均池化层的输出。
3. **投影头 (Projection Head)**：
   - 使用一个非线性映射头 $g(\cdot)$ (通常是两层 MLP) 将 h 映射到对比损失空间 z。
   - $z_i = g(h_i), z_j = g(h_j)$。

- **注意**：训练完成后，通常丢弃 $g(\cdot)$，只保留 $f(\cdot)$ 作为特征提取器 (PPT P17)。

4. **对比损失计算**：在 z 空间计算 InfoNCE Loss。

(3) 核心公式：InfoNCE Loss (⚠️ 必考)

PPT P16 给出了具体的损失函数公式，这通过 Softmax 形式体现了“拉近正样本，推远负样本”。

对于一个正样本对 (i, j)（即 z_i 和 z_i^+），其损失函数为：

$$Loss = -\log \frac{\exp(\text{sim}(z_i, z_i^+)/\tau)}{\exp(\text{sim}(z_i, z_i^+)/\tau) + \sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$$

- **符号解析**：
  - $\text{sim}(u, v) = \frac{u^T v}{||u|| \cdot ||v||}$：余弦相似度（Cosine Similarity）。
  - τ：温度系数 (Temperature parameter)，控制分布的平滑程度。
  - 分母包含了一对正样本和 $2(N-1)$ 个负样本（Batch size 为 N，除了自己对应的那个增强图，Batch里其他所有图及其增强图都是负样本）。

(4) 关键设计选择 (PPT P20-21)

- **投影头 (Projection Head) 的重要性**：
  - PPT P20 数据显示，使用**非线性 (Non-linear)** 投影头比线性或无投影头性能好得多。
  - *原因*：z 空间对对比任务过拟合（丢弃了颜色、方位等对分类有用但对对比任务是干扰的信息），而 h 空间（投影前）保留了更多原始语义信息。
- **Batch Size 的重要性**：
  - PPT P21 数据显示，SimCLR 性能随 Batch Size 增大而显著提升。
  - *原因*：对比学习需要大量的负样本 (Negative Samples) 来提供足够的对比信号。Batch 越大，负样本越多，效果越好。这也导致了对显存 (GPU Memory) 的巨大需求。

26.4 理论基础：InfoNCE与互信息 (PPT P22-25)

1. 互信息 (Mutual Information) (PPT P22)

(1) 核心概念

- **定义**：互信息 $I(X; Y)$ 衡量变量 X 和 Y 之间的依赖程度，即知道 X 能减少多少关于 Y 的不确定性。
- **公式**：

$$I(X; Y) = \int p(x, y) \log \frac{p(x, y)}{p(x)p(y)} dxdy$$

$$I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

2. InfoNCE 与互信息的联系 (PPT P23-25)

(1) 理论推导 (⚠️ 极可能考证明思路)

- **下界 (Lower Bound)**：证明 InfoNCE Loss 的最小化等价于互信息的最大化。
- PPT P24-25 展示了推导逻辑：
  i. 定义随机变量对 (Z, Z^+) 来自联合分布（正样本），其他 Z_k^+ 来自边缘分布（负样本）。
  ii. 互信息 $I(Z; Z^+)$ 有一个下界（Lower Bound），称为 InfoNCE bound。
  iii. PPT P25 明确指出：

$$I(Z; Z^+) \geq \log(N) - \mathcal{L}_{\text{InfoNCE}}$$

  或者写作：

$$\mathcal{L}_{\text{InfoNCE}} \geq \log(N) - I(Z; Z^+)$$

- **结论**：**最小化 InfoNCE Loss，就是在最大化输入视图之间的互信息**。

(2) 潜在考题预测 (Exam Hacks)

> - **Q**: 为什么 SimCLR 的损失函数被称为 InfoNCE？它与互信息有什么关系？

> - **A**: InfoNCE 是 Noise Contrastive Estimation 的一种形式。最小化 InfoNCE 损失函数在数学上等价于最大化两个视图表示向量之间的互信息 (Mutual Information) 的下界。

26.5 对比学习：MoCo (PPT P26-31)

1. MoCo (Momentum Contrast) 的动机 (PPT P27)

- **SimCLR 的痛点**：SimCLR 极度依赖大 Batch Size 来提供负样本，导致显存爆炸，硬件要求极高。
- **MoCo 的解决方案**：解耦（Decouple）Batch Size 和负样本队列的大小。使用一个**队列 (Queue/Memory Bank)** 来存储大量的负样本。

2. MoCo 架构与动量更新 (⚠️ 必考核心)

(1) 两个编码器

- **Query Encoder (f_q, 参数 θ_q)**：
  - 处理当前的 Anchor 样本。
  - 使用梯度下降 (Gradient Descent) 更新参数。
- **Momentum Encoder (f_k, 参数 θ_k)**：
  - 处理正样本（生成 Key）。
  - **不使用梯度下降更新**，而是使用动量更新。

(2) 动量更新公式 (Momentum Update)

PPT P27 给出了关键公式：

$$\theta_k \leftarrow m\theta_k + (1-m)\theta_q$$

- m：动量系数 (Momentum Coefficient)，通常取接近 1 的值（如 0.999）。
- **意义**：使 Key Encoder 的参数更新非常平滑，保持特征提取的一致性，防止队列中的特征向量因为网络变化太快而失效。

(3) 队列机制 (Queue)

- **FIFO (先进先出)**：当前 Batch 计算完的特征作为新的负样本入队，最老的特征出队。
- **优势**：负样本数量不再受限于 Batch Size，可以用很小的 Batch（如 256）配合很大的队列（如 65536）进行训练。

3. MoCo v2 (PPT P29-30)

(1) 改进点

MoCo v2 吸取了 SimCLR 的成功经验，融入到 MoCo 框架中：

1. **MLP Projection Head**：在编码器后加入非线性投影头（SimCLR 的策略）。
2. **Strong Augmentation**：使用了更强的数据增强（如模糊等）。
3. **保留 MoCo 结构**：依然使用动量更新和队列。

(2) 性能对比 (PPT P31)

- **小 Batch 优势**：在 Batch Size 较小（如 256）时，MoCo v2 的性能远超 SimCLR（SimCLR 需要 Batch 4096+ 才能达到高性能）。
- **内存/显存**：MoCo 更加节省显存。

(4) 潜在考题预测 (Exam Hacks)

> - **Q**: MoCo 中的动量编码器 (Momentum Encoder) 为什么要使用动量更新而不是梯度下降?
> - **A**: 因为 MoCo 使用了一个巨大的队列来存储负样本，这些样本是不同步计算的（来自过去的 Iteration）。如果 Key Encoder 变化太快（梯度下降更新剧烈），队列中的旧特征就会和当前特征空间不一致，导致训练无法收敛。动量更新保证了编码器的缓慢、平滑演变，维持了队列特征的一致性。

总结：SimCLR vs. MoCo (核心对比表)

特性	SimCLR	MoCo / MoCo v2
负样本来源	当前 Batch 内的其他样本	额外的队列 (Memory Queue)
负样本数量	受限于 Batch Size (需极大 Batch)	独立于 Batch Size (可极大)
编码器更新	两个分支共享参数，梯度下降	Query端梯度下降，Key端动量更新

特性	SimCLR	MoCo / MoCo v2
硬件需求	极高 (多卡/TPU)	较低 (普通 GPU 可跑)
关键组件	强数据增强 + 非线性投影头	动量更新 + 队列 (+ v2中的投影头/增强)

这是本章的所有核心考点。请重点练习 **InfoNCE 损失函数的书写** 和 **MoCo 动量更新公式的推导**。祝备考顺利！