# DCS440 最优化理论

## 第一章：凸集、凸函数与凸优化问题

杨 磊

yanglei39@mail.sysu.edu.cn

计算机学院，2024 秋

§ 绪论

§ 基础知识

§ 凸集

§ 凸函数

§ 凸优化问题

# 课程安排

- **上课时间：** 第01周至第09周：周五, 5-6节, 14:20–16:00, C206
  第10周至第17周：周三, 5-6节, 14:20–16:00, C206
  周五, 5-6节, 14:20–16:00, C206
- **考核方式：** 期末闭卷考试（60%）+ 平时成绩（40%）
  平时成绩：大/小作业 + 考勤 ← **非常重要！请按时提交，保证出勤！**
- **助教：** 胡静静（hujj53@mail2.sysu.edu.cn）
  陈宁浩（chennh6@mail2.sysu.edu.cn）
- **参考书目：**


[1] Stephen Boyd and Lieven Vandenberghe, *Convex Optimization*, 2004

[2] 刘浩洋，户将，李勇锋，文再文，最优化：建模、算法与理论，高教出版社，2021

[3] Jorge Nocedal and Stephen Wright, *Numerical Optimization*, Springer, 2006

[4] Wenyu Sun and Ya-Xiang Yuan, *Optimization Theory and Methods*, Springer, 2010

# 最优化简介

**最优化**（optimization）是一门运用数学方法研究各种问题的优化途径和方案，为决策者提供科学决策的学科。

它的研究范式主要包括以下几个步骤：

1. 收集有关数据和资料，了解问题背景和需求；
2. 建立恰当的最优化问题的数学模型，包括需要确定的变量，需要优化的目标函数和解需要满足的约束条件。模型一般可以描述为:

$$\begin{aligned} \text{miminize} \quad & f(x) \\ \text{subject to} \quad & x \in \Omega. \end{aligned}$$

3. 分析和研究模型的相关理论性质，选择或设计合适的优化算法，分析算法的理论性质，考察算法的计算性能等；
4. 通过编程实现算法，求解所关心的优化问题。

# 最优化简介

*"For since the fabric of the universe is most perfect and the work of a most wise Creator, nothing at all takes place in the universe in which some rule of maximum or minimum does not appear."*

— Leonhard Euler

**最优化问题无处不在：**

- 工程设计中，如何选取设计参数才能既满足要求、又降低成本；
- 资源分配中，如何分配有限资源才能既满足要求、又能获得好的经济效益；
- 金融投资中，如何决定投资组合才能在可接受的风险范围内获得最大的收益；
- 产品设计中，如何搭配各种原料的比例才能既降低成本、又提高产品质量；
- 信息科学中，图像的高效处理；
- 交通、物流问题中，如何设置物流调度以降低成本、提高效益；
- 机器学习中，如何快速训练大模型以满足应用需求等。

# 最优化的应用案例

## 例：营养搭配问题

一个人每天需摄入 $m$ 种营养成分，而市场提供 $n$ 种不同食材，每单位的 $j$ 种食材售价为 $c_j$，且含有 $a_{ij}$ 单位的 $i$ 种营养成分。假设每天对 $i$ 种营养成分的需求量不少于 $b_i$，试设计一份在满足营养要求下的最经济食谱。

建立数学模型：

1. 根据问题的需要设置决策变量：设每人每天需要各种食品的数量分别为 $x_1, x_2, \ldots, x_n$；
2. 利用所设置的决策变量把所追求的目标和所受的约束，用数学语言表述出来，建立该问题的数学模型：

$$\min_{x_1,\ldots,x_n} \quad \sum_{j=1}^{n} c_j x_j \qquad \text{(最小化购买费用)}$$

$$\text{s.t.} \quad \sum_{j=1}^{n} a_{ij} x_j \geq b_i, \quad i = 1, 2, \ldots, m, \qquad \text{(满足营养需求)}$$

$$x_j \geq 0, \quad j = 1, 2, \ldots, n. \qquad \text{(购买量不得小于0)}$$

# 最优化的应用案例

## 例：最小二乘回归问题 (Least Squares Regression Problem)

经分析，影响本市房价 $y$ 的因素有 $m$ 个。现考察并收集了 $n$ 处房源的价格 $\{y_i\}_{i=1}^n$ 和相关因素 $\{\boldsymbol{x}_i\}_{i=1}^n$，其中 $y_i \in \mathbb{R}$ 以及 $\boldsymbol{x}_i \in \mathbb{R}^m$。问：如何分析房价 $y$ 和不同因素 $\boldsymbol{x}$ 之间的线性关系？

假设 $y$ 和 $\boldsymbol{x}$ 之间的线性关系可表示为线性函数 $y = \sum_{j=1}^m \omega_j x_j + b$。为简便，用向量形式 $y = \boldsymbol{\omega}^\top \boldsymbol{x}$ 来表示，其中 $\boldsymbol{\omega} = [\omega_1, \ldots, \omega_m, b]^\top$ 即是我们需要估计的参数！

1. 用矩阵 $X$ 和向量 $\boldsymbol{y}$ 表示所收集的数据：

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1m} & 1 \\ x_{21} & x_{22} & \cdots & x_{2m} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} & 1 \end{pmatrix} = \begin{pmatrix} \boldsymbol{x}_1^\top & 1 \\ \boldsymbol{x}_2^\top & 1 \\ \vdots & \vdots \\ \boldsymbol{x}_n^\top & 1 \end{pmatrix}, \qquad \boldsymbol{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

2. $\boldsymbol{\omega}$ 可根据“最小二乘”规则来估计：

$$\min_{\boldsymbol{\omega}} \ \frac{1}{2} \|X\boldsymbol{\omega} - \boldsymbol{y}\|_2^2$$

3. 进一步，可以根据应用需求增加合适的正则项，如 $\|\boldsymbol{\omega}\|_2^2$， $\|\boldsymbol{\omega}\|_1$ 等

# 最优化的应用案例

**例：鲁棒主成分分析 (Robust Principal Component Analysis)**

假设一个数据矩阵 $M \in \mathbb{R}^{m\times n}$ 具有如下结构：

$$M = \underbrace{L_0}_{\textbf{low rank}} + \underbrace{S_0}_{\textbf{sparse}}$$

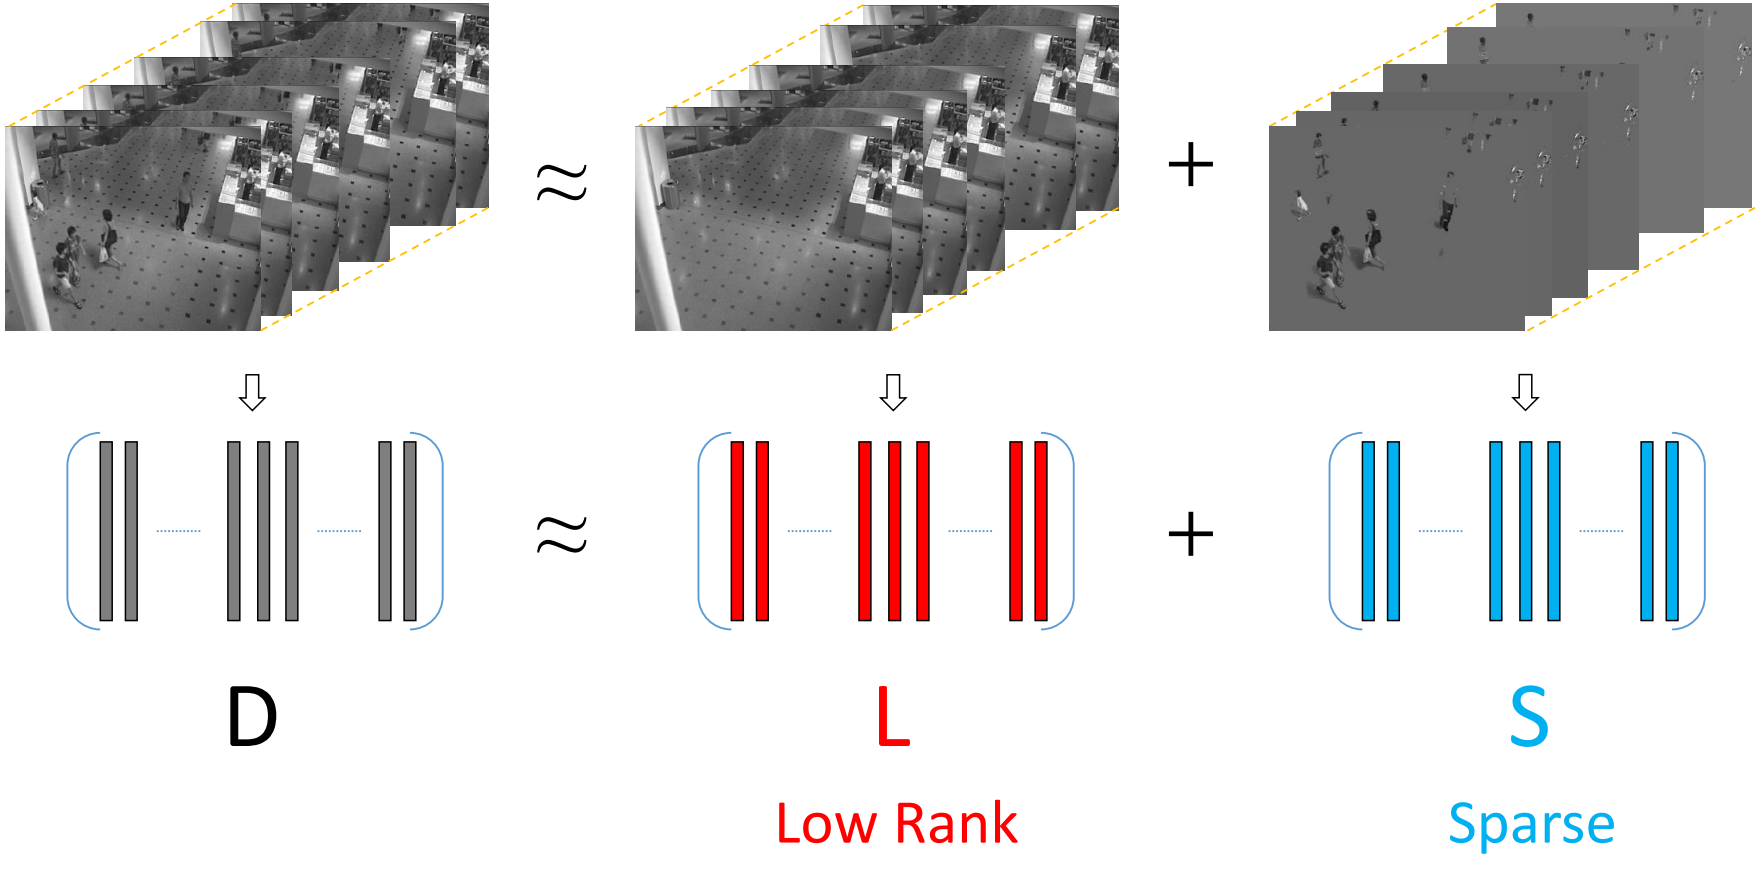
鲁棒主成分分析旨在通过 $M$ 同时恢复低秩矩阵 $L_0$ 和稀疏矩阵 $S_0$。

在当代许多重要的应用中，数据可以自然地建模为低秩加上稀疏部分，例如：

- 给定一个监控视频帧序列，将视频帧拉伸成向量作为矩阵 $M$ 的每一列；
- 实际中，我们经常需要识别那些在视频中移动的物体，或提取视频中的背景；
- 低秩部分 $L_0$ 可用来刻画视频中变化平稳的背景；
- 稀疏部分 $S_0$ 可用来刻画视频中少量移动的物体；

# 最优化的应用案例

视频前景/背景分离：



# 最优化的应用案例

假设一个数据矩阵 $M \in \mathbb{R}^{m\times n}$ 具有如下结构：$M = \underbrace{L_0}_{\text{low rank}} + \underbrace{S_0}_{\text{sparse}}$.

低秩矩阵 $L_0$ 和稀疏矩阵 $S_0$ （在一定的假设条件下）可由以下凸优化问题的解恢复：

$$\begin{aligned} \min_{L,\,S} \quad & \|L\|_* + \lambda\|S\|_1 \\ \text{s.t.} \quad & L + S = M \end{aligned}$$

- 最小化核范数（nuclear norm）$\|L\|_*$ 用于诱导矩阵 $L$ 的低秩性
  - ▷ $\|L\|_*$ 是 $\mathrm{rank}(L)$ 的“最佳”凸逼近
- 最小化 $\ell_1$ 范数 $\|S\|_1$ 用于诱导矩阵 $S$ 的稀疏性
  - ▷ $\|S\|_1$ 是 $\|S\|_0$ 的“最佳”凸逼近，其中 $\|S\|_0$ 表示矩阵 $S$ 中非零元素的个数
- $\lambda$ 用于控制低秩和稀疏部分之间的权衡

# 最优化的发展简史

## 运筹学 (Operational Research)

- 人们一般认为，运筹学起源于第二次世界大战初期；
- 在中国，1956年中国科学院即组织开展运筹学研究。1964年，借鉴《史记•汉高祖本记》中“夫运筹帷幄之中，决胜千里之外”一语，把“Operational Research”译名为“运筹学”。
- 中国数学会运筹学分会成立于1980年。随后，1991年成立中国运筹学会（国家一级学会）。之后，1994年成立中国运筹学会数学规划分会。



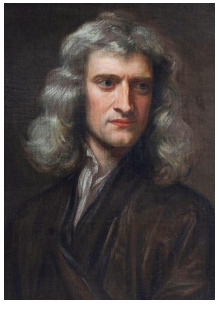





# 最优化的发展简史

## 最优化的起源

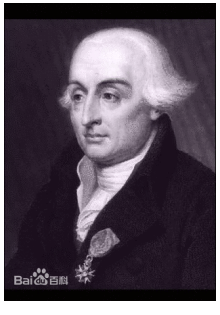
- **1687年**，英国数学家 Isaac Newton 发明微积分的时代，就已提出了与力学相关的极值问题。1740年，Leonhard Euler 出版了研究变分学一般理论的著作。
- **1788年**，Joseph-Louis Lagrange 发明了求解约束优化问题的方法，称为“拉格朗日乘子法”。
- **1847年**，Augustin Louis Cauchy 提出最速下降法。
- **1944年**，John von Neumann 与 Oskar Morgenstern 合著《博弈论与经济行为》
- **1947年**，George Bernard Dantzig 提出了解决线性规划问题的单纯形方法，John von Neumann 建立了线性规划问题的对偶理论。



Newton



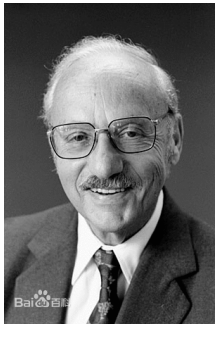
Euler



Lagrange



Cauchy



Dantzig



von Neumann

# 最优化的发展简史

20世纪30年代起，最优化逐步发展成为运筹学的一门新兴、独立学科。



徐文伟
华为技术有限公司董事
华为战略研究院院长




后香农时代

面向数学的十大挑战问题

1. 语义信息论--有损信源编码的极限和可行算法
2. 挑战无损熵编码的极限
3. 网络基本业务模型问题
4. MassiveMIMO 容量域问题
5. 非线性信道补偿问题
6. 大规模通信网络的最优控制问题
7. 反问题高精度快速求解问题
8. 高效的纠删码问题
9. DNN可解释性
10. 超大规模数据近似计算



2020年诺贝尔经济学奖获得者之一
Robert B.Wilson（1937-）

北京时间2020年10月12日17时45分，2020年诺贝尔经济学奖获奖名单公布。获奖者为 Paul Robert Milgrom 和 Robert B.Wilson，以表彰他们对拍卖理论的改进和新拍卖形式的发明。其中，Robert B.Wilson是美国经济学家，斯坦福大学运筹学专业杰出教授兼荣誉退休教授，主要研究运筹学和商业经济学。

Wilson同时还是非线性规划先驱之一。1963年，在深入研究非线性规划经典的Lagrange-Newton法的基础之上，27岁的Wilson在他的博士论文中开创性地提出了逐步二次规划（Sequential Quadratic Programming，简称SQP）算法，经过Han和Powell的发展形成了求解约束非线性规划最基础的算法之一，并被国际上称为WHP方法。

# 课程内容

以“相对容易”的凸优化为主，介绍：

- **基本概念：**凸集、凸函数、凸优化问题；
- **对偶理论；**
- **无约束优化：**算法结构、一阶方法、二阶方法；
- **有约束优化：**罚方法、增广拉格朗日乘子法、交替方向乘子法；
- ⋆现代优化算法⋆

§ 绪论

§ 基础知识

§ 凸集

§ 凸函数

§ 凸优化问题

# 向量和矩阵

**定义 1 (范数)**

称一个从向量空间 $\mathbb{R}^n$ 到实数域 $\mathbb{R}$ 的非负函数 $\|\cdot\|$ 为范数，如果:

- （**正定性**）：$\|\boldsymbol{v}\| \geq 0,\ \forall \boldsymbol{v} \in \mathbb{R}^n$ 且 $\|\boldsymbol{v}\| = 0$ 当且仅当 $\boldsymbol{v} = 0$;
- （**齐次性**）：$\|\alpha \boldsymbol{v}\| = |\alpha| \|\boldsymbol{v}\|,\ \forall \boldsymbol{v} \in \mathbb{R}^n,\ \alpha \in \mathbb{R}$;
- （**三角不等式**）：$\|\boldsymbol{v} + \boldsymbol{w}\| \leq \|\boldsymbol{v}\| + \|\boldsymbol{w}\|,\ \forall \boldsymbol{v}, \boldsymbol{w} \in \mathbb{R}^n$。

对于给定向量 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$，

- $\boldsymbol{x} \leq \boldsymbol{y}$ 表示 $x_i \leq y_i,\ i = 1, 2, \ldots, n$
- 内积：$\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \boldsymbol{x}^\top \boldsymbol{y} = \sum_{i=1}^n x_i y_i$
- $\ell_2$ 范数：$\|\boldsymbol{x}\|_2 = \left( \sum_{i=1}^n |x_i|^2 \right)^{\frac{1}{2}}$ （为简便，经常省略下角标2）
- $\ell_1$ 范数：$\|\boldsymbol{x}\|_1 = \sum_{i=1}^n |x_i|$
- $\ell_\infty$ 范数：$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$
- $\ell_p$ 范数 $(p \geq 1)$：$\|\boldsymbol{x}\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$
- $\ell_0$ “范数” $\|x\|_0$：$x$ 的所有分量中非零元素的个数（注：$\|x\|_0$ 不是真正的范数）

**命题 1**

对任意的 $\boldsymbol{x} \in \mathbb{R}^n$，有：

$$\|\boldsymbol{x}\|_\infty \leq \|\boldsymbol{x}\|_2 \leq \|\boldsymbol{x}\|_1 \leq n\|\boldsymbol{x}\|_\infty.$$

- **Cauchy-Schwarz 不等式**：对任意的 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$，有

$$-\|\boldsymbol{x}\|\|\boldsymbol{y}\| \leq \langle \boldsymbol{x}, \boldsymbol{y} \rangle \leq \|\boldsymbol{x}\|\|\boldsymbol{y}\|$$

- **Hölder 不等式**：对任意的 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$，有

$$\left|\boldsymbol{x}^\top \boldsymbol{y}\right| \leq \|\boldsymbol{x}\|_p \|\boldsymbol{y}\|_q = \left(\sum_{i=1}^n |x_i|^p\right)^{1/p} \left(\sum_{i=1}^n |y_i|^q\right)^{1/q},$$

  其中 $p$ 和 $q$ 是大于 1 的实数且满足 $\frac{1}{p} + \frac{1}{q} = 1$.

- **Minkowski 不等式**：对任意的 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n, p \in [1, \infty)$, 有

$$\|\boldsymbol{x} + \boldsymbol{y}\|_p \leq \|\boldsymbol{x}\|_p + \|\boldsymbol{y}\|_p = \left(\sum_{i=1}^n |x_i|^p\right)^{1/p} + \left(\sum_{i=1}^n |y_i|^p\right)^{1/p}$$

# 向量和矩阵

对任意的 $A = (a_{ij}) \in \mathbb{R}^{m\times n}$ 和 $B = (b_{ij}) \in \mathbb{R}^{m\times n}$：

- 内积：$\langle A, B\rangle = \operatorname{tr}\left(AB^T\right) = \sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij}b_{ij}$.
- Frobenius 范数：$\|A\|_F = \sqrt{\sum_{i,j}|a_{ij}|^2} = \sqrt{\operatorname{tr}\left(A^\top A\right)}$
- 矩阵的诱导范数：

$$\|A\| \triangleq \sup_{\|x\|=1} \|Ax\| = \sup_{\|x\|\neq 0} \frac{\|Ax\|}{\|x\|}$$

- 诱导 $\ell_2$ 范数：$\|A\|_2 = \sqrt{\lambda_{\max}\left(A^\top A\right)}$
- 诱导 $\ell_1$ 范数：$\|A\|_1 = \max_{1\le j\le n}\sum_{i=1}^{n}|a_{ij}|$
- 诱导 $\ell_\infty$ 范数：$\|A\|_\infty = \max_{1\le i\le n}\sum_{j=1}^{n}|a_{ij}|$
- 核范数：$\|A\|_* = \sum_{i=1}^{r}\sigma_i$，其中 $\{\sigma_i\}$ 为 $A$ 的非零奇异值，$r = \operatorname{rank}(A)$

**命题 2**

对任意的 $A, B \in \mathbb{R}^{n\times n}$ 和 $\boldsymbol{x} \in \mathbb{R}^n$, 有

$$\|AB\| \le \|A\|\|B\|, \quad \|A\boldsymbol{x}\| \le \|A\|\|\boldsymbol{x}\|.$$

对于 $A \in \mathbb{R}^{n\times n}$,

- 称 $A$ 是对称的，如果 $A^\top = A$.
- 称 $A$ 是对称正定的（记为 $A \succ 0$），如果 $A^\top = A$，而且对于任意的 $\boldsymbol{x} \neq 0$，有 $\boldsymbol{x}^\top A\boldsymbol{x} > 0$.
- 称 $A$ 是对称半正定的（记为 $A \succeq 0$），如果 $A^\top = A$，而且对于任意的 $\boldsymbol{x} \in \mathbb{R}^n$，有 $\boldsymbol{x}^\top A\boldsymbol{x} \ge 0$.

# 梯度和海瑟矩阵

**定义 2 (梯度 (Gradient))**

给定函数 $f:\mathbb{R}^n \to \mathbb{R}$，且 $f$ 在点 $x$ 的一个领域内有意义，若存在向量 $g \in \mathbb{R}^n$ 满足

$$\lim_{d\to 0} \frac{f(x+d)-f(x)-g^\top d}{\|d\|} = 0,$$

其中 $\|\cdot\|$ 是任意的向量范数，就称 $f$ 在点 $x$ 处可微（或 Fréchet 可微）。此时，称 $g$ 为 $f$ 在点 $x$ 处的梯度(Gradient)，记作 $\nabla f(x)$。如果对区域 $D$ 上的每一个点 $x$ 都有 $\nabla f(x)$ 存在，则称 $f$ 在 $D$ 上可微。

若 $f$ 在点 $x$ 处可微，在上式中令 $d=\varepsilon e_i$，其中 $e_i$ 是第 $i$ 个分量为 1 的单位向量，可知 $\nabla f(x)$ 的第 $i$ 个分量即为 $\frac{\partial f(x)}{\partial x_i}$。因此，我们有

$$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \cdots, \frac{\partial f(x)}{\partial x_n}\right)^\top.$$

# 梯度和海瑟矩阵

## 定义 3 (海瑟(Hessian)矩阵)

如果函数 $f:\mathbb{R}^n \to \mathbb{R}$ 在点 $x$ 处的二阶偏导数 $\frac{\partial^2 f}{\partial x_i \partial x_j}(x),\ i,j=1,2,\ldots,n$ 都存在，则

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_3} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} & \frac{\partial^2 f(x)}{\partial x_2 \partial x_3} & \cdots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \vdots & & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} & \frac{\partial^2 f(x)}{\partial x_n \partial x_3} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix}$$

称为 $f$ 在点 $x$ 处的海瑟(Hessian)矩阵。当 $\nabla^2 f(x)$ 在区域 $D$ 上的每个点 $x$ 处都存在，且 $\nabla^2 f(x)$ 在区域 $D$ 上连续，则称 $f$ 在 $D$ 上二阶（次）连续可微[1]，此时海瑟矩阵是对称矩阵。

[1]此时，$\nabla f$ 在 Fréchet 意义下可微。本课程不再讨论向量值函数的可微性，主要考虑连续可微的情况。

# 梯度和海瑟矩阵

**例：**给定对称矩阵 $Q \in \mathbb{R}^{n\times n}$，向量 $q \in \mathbb{R}^n$，以及数 $r \in \mathbb{R}$，考虑二次函数 $f(x) = \frac{1}{2}x^\top Qx + q^\top x + r$，则

$$\nabla f(x) = Qx + q, \quad \nabla^2 f(x) = Q.$$

**例：**给定矩阵 $A \in \mathbb{R}^{m\times n}$，向量 $b \in \mathbb{R}^m$，考虑函数 $f(x) = \frac{1}{2}\|Ax - b\|^2$，则

$$\nabla f(x) = A^\top(Ax - b), \quad \nabla^2 f(x) = A^\top A.$$

# 梯度和海瑟矩阵

**定理 1 (Taylor's 展开定理)**

若 $f:\mathbb{R}^n \to \mathbb{R}$ 连续可微，有如下一阶展开式

$$f(x+d) = f(x) + \nabla f(x)^\top d + o(\|d\|),$$

且存在 $t \in (0,1)$ 使得

$$f(x+d) = f(x) + \nabla f(x+td)^\top d.$$

进一步地，若 $f$ 二阶（次）连续可微，有如下二阶展开式

$$f(x+d) = f(x) + \nabla f(x)^\top d + \frac{1}{2} d^\top \nabla^2 f(x) d + o(\|d\|^2),$$

且存在 $\gamma \in (0,1)$ 使得

$$f(x+d) = f(x) + \nabla f(x)^\top d + \frac{1}{2} d^\top \nabla^2 f(x+\gamma d) d.$$

# 优化中的一些基本概念

## 最优化问题的基本数学模型

$$\begin{aligned} \text{miminize} \quad & f(x) \\ \text{subject to} \quad & x \in \Omega. \end{aligned}$$

- 决策变量 $x = (x_1, \ldots, x_n)^\top$;
- 目标函数 $f : \Omega \to \mathbb{R}$;
- 可行域（决策集） $\Omega \subseteq \mathbb{R}^n$，$\Omega$ 中的所有点称为可行点。

若 $\Omega = \mathbb{R}^n$，称为无约束优化问题。否则，称为约束优化问题。特别地，$\Omega$ 常用一些等式和不等式来定义，即

$$\Omega := \{x \in \mathbb{R}^n \ : \ h(x) = 0, \ \ c(x) \leq 0\},$$

其中 $h(x) = (h_1(x), \ldots, h_m(x))^\top$ 和 $c(x) = (c_1(x), \ldots, c_s(x))^\top$。称

- $h_i(x) = 0$, $i = 1, \ldots, m$ 为等式约束;
- $c_j(x) \leq 0$, $j = 1, \ldots, s$ 为不等式约束。

# 优化中的一些基本概念

## 一些基本定义

- 可行域 $\Omega$ 中的点，或满足约束条件的点称为可行点；
- 对 $x^* \in \Omega$，若对任意的 $x \in \Omega$，都有 $f(x^*) \leq f(x)$，则称 $x^*$ 是问题的全局最优解；对应的目标函数值，即 $f(x^*)$ 为全局最优值。记为 $x^* \in \arg\min_{x \in \Omega} f(x)$。
- 特别的，若 $x^*$ 还满足对任意的 $x \in \Omega \backslash x^*$，有 $f(x^*) < f(x)$，则称 $x^*$ 为严格全局最优解；
- 设 $x^* \in \Omega$，若存在 $x^*$ 点的邻域 $\mathcal{B}(x^*, \delta) = \{x : \|x - x^*\| \leq \delta\}$ 使得对任意的 $x \in \Omega \cap \mathcal{B}(x^*, \delta)$，有 $f(x^*) \leq f(x)$，则称 $x^*$ 为其局部最优解；
- 特别的，若 $x^* \in \Omega$ 还满足对任意的 $x \in \Omega \cap \mathcal{B}(x^*, \delta)$，$x \neq \{x^*\}$，有 $f(x^*) < f(x)$，则称 $x^*$ 为严格局部最优解。

## 求解方法类型

- 解析方法；
- 图解法；
- 遍历法；
- 迭代算法；
- ...

迭代算法的基本框架：

- **步 1.** 取初始点 $x^0 \in \mathbb{R}^n$ 及其他有关参数，令 $k = 0$。
- **步 2.** 验证停机准则。
- **步 3.** 求 $x^k$ 点处的搜索方向 $d^k \in \mathbb{R}^n$。通常，我们要求 $d^k$ 是 $f_0$ 在点 $x^k$ 处的下降方向（使 $f_0$ 从点 $x^k$ 处沿着该方向在一定范围内函数值可下降），满足 $\left(\nabla f_0(x^k)\right)^\top d^k < 0$。
- **步 4.** 计算迭代步长 $\alpha_k > 0$，通常要求 $f_0\left(x^k + \alpha_k d^k\right) < f_0\left(x^k\right)$。
- **步 5.** 产生下一个迭代点：令 $x^{k+1} := x^k + \alpha_k d^k$，$k := k + 1$，转**步 2**。

# 优化中的一些基本概念

最优化问题形形色色，对应的最优化模型多种多样，可从不同角度对其分类：

- 约束优化 & 无约束优化
- 连续优化 & 非连续优化：
  (1) 若 $f, h, c$ 都是线性的，则称为线性规划
  (2) 若 $f, h, c$ 中至少有一个是非线性的，则称为非线性规划
  (3) 若 $f$ 是二次函数，$h, c$ 是线性函数，则称为二次规划
- 凸优化 & 非凸优化：
  - 凸优化：目标函数为凸函数，可行域为凸集
  - 非凸优化：目标函数或可行域至少有一个非凸
- 光滑优化 & 非光滑优化，确定优化 & 不确定优化（随机优化，鲁棒优化）
  ...

## 算法评价标准（优化的角度）：全局收敛与局部收敛

- 若 $\lim\limits_{k\to\infty} \|x^k - x^*\| = 0$，则称 $\{x^k\}$ 收敛于 $x^*$。
- 若存在 $\{x^k\}$ 的一个子序列收敛于 $x^*$，则称 $x^*$ 是 $\{x^k\}$ 的一个聚点。
- **全局收敛性**：指从任意的初始点出发，算法产生的迭代序列 $\{x^k\}$ 都收敛于问题的一个最优点。
- **局部收敛性**：指算法只有在初始点与最优点比较靠近时才能保证迭代序列 $\{x^k\}$ 收敛于问题的一个最优点。

## 算法评价标准（优化的角度）：收敛速度

设算法产生的迭代序列 $\{x^k\}$ 收敛于 $x^*$（范数意义下）：

- 若存在 $r \in (0,1)$ 使得，对充分大的 $k$ 有

$$\frac{\left\|x^{k+1}-x^*\right\|}{\left\|x^k-x^*\right\|} \leq r,$$

称 $\{x^k\}$ $Q$-线性收敛于 $x^*$。（这里的 “$Q$” 表示单词 “quotient”）

- 如果

$$\lim_{k\to\infty} \frac{\left\|x^{k+1}-x^*\right\|}{\left\|x^k-x^*\right\|} = 0,$$

称$\{x^k\}$ $Q$-超线性收敛于 $x^*$。

- 若存在 $p>1$ 和一个正数 $\gamma$ 使得，对充分大的 $k$ 有

$$\frac{\left\|x^{k+1}-x^*\right\|}{\left\|x^k-x^*\right\|^p} \leq \gamma,$$

称 $\{x^k\}$ $Q$-$p$ 阶收敛于 $x^*$，有时简单地称 $\{x^k\}$ $p$-阶收敛于$x^*$。其中最常见的是 $Q$-2 阶收敛。

# 优化中的一些基本概念

另一种弱化一些的收敛速度标准：

- 若存在一个 $Q$-线性收敛于 0 的非负序列 $\{\nu_k\}$，使得

$$\|x^k - x^*\| \leq \nu_k \quad \forall\, k,$$

则称 $\{x^k\}$ 是 $R$-线性收敛于 $x^*$。（这里的 “$R$” 表示单词 “root”）

- 若存在一个 $Q$-超线性收敛于 0 的非负序列 $\{\nu_k\}$，使得

$$\|x^k - x^*\| \leq \nu_k \quad \forall\, k,$$

则称 $\{x^k\}$ 是 $R$-超线性收敛于 $x^*$。

# 优化中的一些基本概念

其它算法评价标准:

- 二次终止性;
- 稳定性;
- 计算复杂性;
- 调参复杂度;
- 存储消耗;
- 数值效果;
- ...

§ 绪论

§ 基础知识

§ 凸集

§ 凸函数

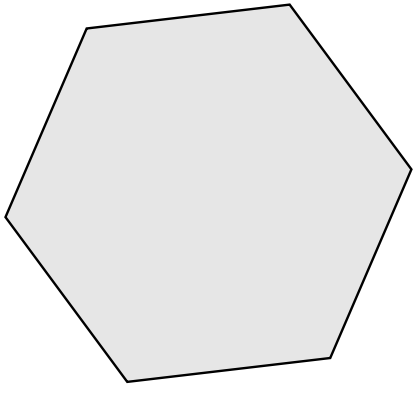
§ 凸优化问题

# 凸集

## 定义 4 (凸集 (convex set))

如果过集合 $C$ 中任意两点的线段都在 $C$ 内，则称 $C$ 为凸集，即：

$$x_1, x_2 \in C \quad \Rightarrow \quad \theta_1 x_1 + \theta_2 x_2 \in C, \quad \forall\, \theta_1 + \theta_2 = 1,\ \theta_1, \theta_2 \geq 0.$$



一个包含边界的六边形是凸的，因为该图形中任意两点之间的线段仍在该图形中。

思考：如果某个边去掉一部分呢？如果把边界全部去掉呢？

## 定义 5 (凸组合 (convex combination))

对于 $x_1, \cdots, x_m \in \mathbb{R}^n$, $\theta_1, \cdots, \theta_m \geq 0$ 满足 $\theta_1 + \cdots + \theta_m = 1$，称

$$\theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_m x_m$$

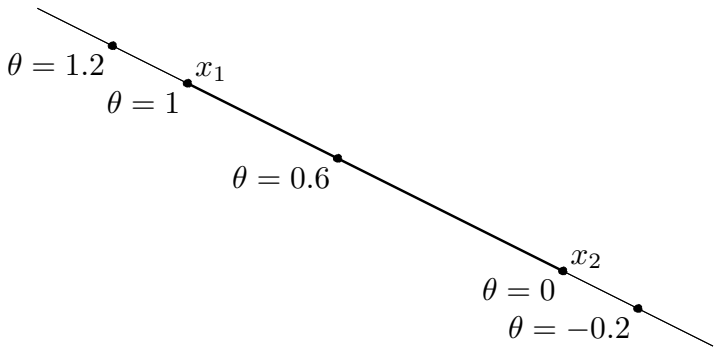
为 $x_1, \cdots, x_m \in \mathbb{R}^n$ 的一个凸组合。

# 仿射集

## 定义 6 (仿射集 (affine set))

如果过集合 $C$ 中任意两点的直线都在 $C$ 内，则称 $C$ 为仿射集，即：

$$x_1, x_2 \in C \quad \Rightarrow \quad \theta_1 x_1 + \theta_2 x_2 \in C, \quad \forall\, \theta_1 + \theta_2 = 1.$$




通过 $x_1$ 和 $x_2$ 的直线: $\theta x_1 + (1-\theta)x_2$，其中 $\theta \in \mathbb{R}$。

介于 $x_1$ 和 $x_2$ 之间的线段由深色所示，对应 $\theta \in [0, 1]$。

思考：仿射集是凸集吗？反之呢？

## 定义 7 (仿射组合 (affine combination))

对于 $x_1, \cdots, x_m \in \mathbb{R}^n$, $\theta_1, \cdots, \theta_m \in \mathbb{R}$ 满足 $\theta_1 + \cdots + \theta_m = 1$，称

$$\theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_m x_m$$

为 $x_1, \cdots, x_m \in \mathbb{R}^n$ 的一个仿射组合。

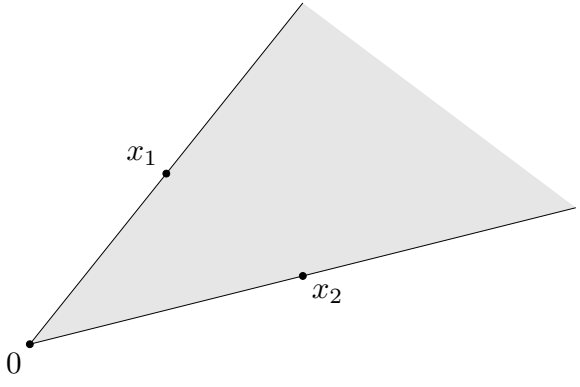
# 凸锥

## 定义 8 (凸锥 (convex cone))

对于集合 $C \subseteq \mathbb{R}^n$，若对任意的 $x \in C$，$\theta \geq 0$，都有 $\theta x \in C$，则称 $C$ 为锥。若 $C$ 为凸集，则称 $C$ 为凸锥，即：

$$x_1, x_2 \in C \;\Rightarrow\; \theta_1 x_1 + \theta_2 x_2 \in C, \quad \forall\, \theta_1, \theta_2 \geq 0.$$

若 $C$ 为闭凸集，则称 $C$ 为闭凸锥。（注：锥包含 0 点）




扇形显示了所有具有形式 $\theta_1 x_1 + \theta_2 x_2$ 的点，其中 $\theta_1, \theta_2 \geq 0$。扇形的顶点 $(\theta_1 = \theta_2 = 0)$ 在 $\mathbf{0}$；其边界 (对应于 $\theta_1 = 0$ 或 $\theta_2 = 0$) 穿过点 $x_1$ 和 $x_2$。

## 定义 9 (凸锥组合 (conic combination))

对于 $x_1, \cdots, x_m \in \mathbb{R}^n$, $\theta_1, \cdots, \theta_m \geq 0$，称

$$\theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_m x_m$$

为 $x_1, \cdots, x_m \in \mathbb{R}^n$ 的一个凸锥组合。

# 凸包、仿射包、锥包

- **凸包** (convex hull)：集合 $C$ 中任意元素的凸组合构成的集合称作 $C$ 的凸包，记作 **conv** $C$

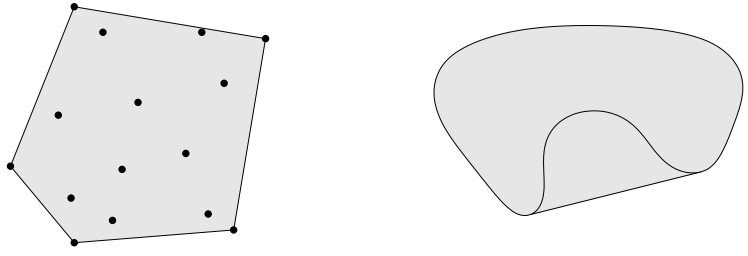


Fig. 左侧：15个散点的凸包；右侧：非凸集合 $C$ 的凸包.

- **仿射包** (affine hull)：集合 $C$ 中任意元素的仿射组合构成的集合称作 $C$ 的仿射包，记作 **aff** $C$
- **凸锥包** (conic hull)：集合 $C$ 中任意元素的凸锥组合构成的集合称作 $C$ 的凸锥包，记作 **cone** $C$

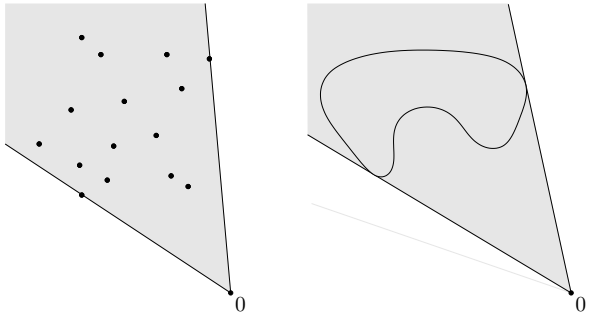



Fig. 左侧：15个散点的凸锥包；右侧：非凸集合 $C$ 的凸锥包.

# 三种组合总结

给定 $x_1, x_2, \cdots, x_m \in \mathbb{R}^n$：

- 三种组合：（同样的加权组合，不同的权重要求）
  - **凸组合：** $\left\{ \sum_{i=1}^{m} \theta_i x_i \;\middle|\; \forall\, \theta_i \in [0,1]\,, \quad \sum_{i=1}^{m} \theta_i = 1 \right\}$
  - **仿射组合：** $\left\{ \sum_{i=1}^{m} \theta_i x_i \;\middle|\; \forall\, \theta_i \in \mathbb{R}, \quad \sum_{i=1}^{m} \theta_i = 1 \right\}$
  - **凸锥组合：** $\left\{ \sum_{i=1}^{m} \theta_i x_i \;\middle|\; \forall\, \theta_i \geq 0 \right\}$

# 三种组合总结

- 三种集合：
  - **凸集**：$x_1, x_2 \in C \;\Rightarrow\; \theta_1 x_1 + \theta_2 x_2 \in C, \quad \forall\, \theta_1 + \theta_2 = 1,\ \theta_1, \theta_2 \geq 0$
  - **仿射集**：$x_1, x_2 \in C \;\Rightarrow\; \theta_1 x_1 + \theta_2 x_2 \in C, \quad \forall\, \theta_1 + \theta_2 = 1,\ \theta_1, \theta_2 \in \mathbb{R}$
  - **凸锥**：$x_1, x_2 \in C \;\Rightarrow\; \theta_1 x_1 + \theta_2 x_2 \in C, \quad \forall\, \theta_1, \theta_2 \geqslant 0$
- 三种包：
  - **凸包**：集合 $C$ 中任意元素的凸组合构成的集合
  - **仿射包**：集合 $C$ 中任意元素的仿射组合构成的集合
  - **凸锥包**：集合 $C$ 中任意元素的凸锥组合构成的集合

# 凸集的例子

- 空集 $\emptyset$;
- 一个点 $C = \{x\}$;
- $\mathbb{R}^n$ 空间及其任意子空间;
- 任意直线、任意射线、任意线段;
- 任意凸包[1]、仿射包、凸锥包;
- 线性方程组的解集 $\{x \in \mathbb{R}^n \mid Ax = b,\ A \in \mathbb{R}^{m\times n},\ b \in \mathbb{R}^n\}$（该集合也是仿射集）;
- 线性等式和不等式约束的交集
  $\{x \in \mathbb{R}^n \mid Ax \leq b,\ Cx = d,\ A, C \in \mathbb{R}^{m\times n},\ b, d \in \mathbb{R}^n\}$;

[1]集合 $C$ 的凸包是包含 $C$ 的最小凸集。

# 凸集的例子：超平面与半空间

- $\mathbb{R}^n$ 空间中的超平面是具有下列形式的集合：

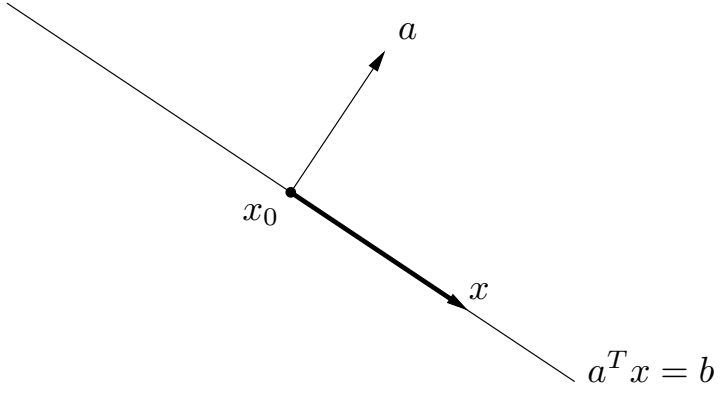
$$\left\{x \in \mathbb{R}^n \mid a^\top x = b\right\},$$

其中 $a \in \mathbb{R}^n$, $a \neq 0$ 且 $b \in \mathbb{R}$。

- 另一种理解：以 $a$ 为法向量，过点 $x_0$ 的 $n-1$ 维的“面”

$$\left\{x \in \mathbb{R}^n \mid a^\top (x - x_0) = 0\right\},$$

其中 $x_0$ 是超平面上的任意一点（即任意满足 $a^\top x_0 = b$ 的点）。




几何上，超平面 $\left\{x \in \mathbb{R}^n \mid a^\top x = b\right\}$ 可以解释为与给定向量 $a$ 的内积为常数的点的集合，是凸集，也是仿射集；过原点（$b = 0$）时为凸锥

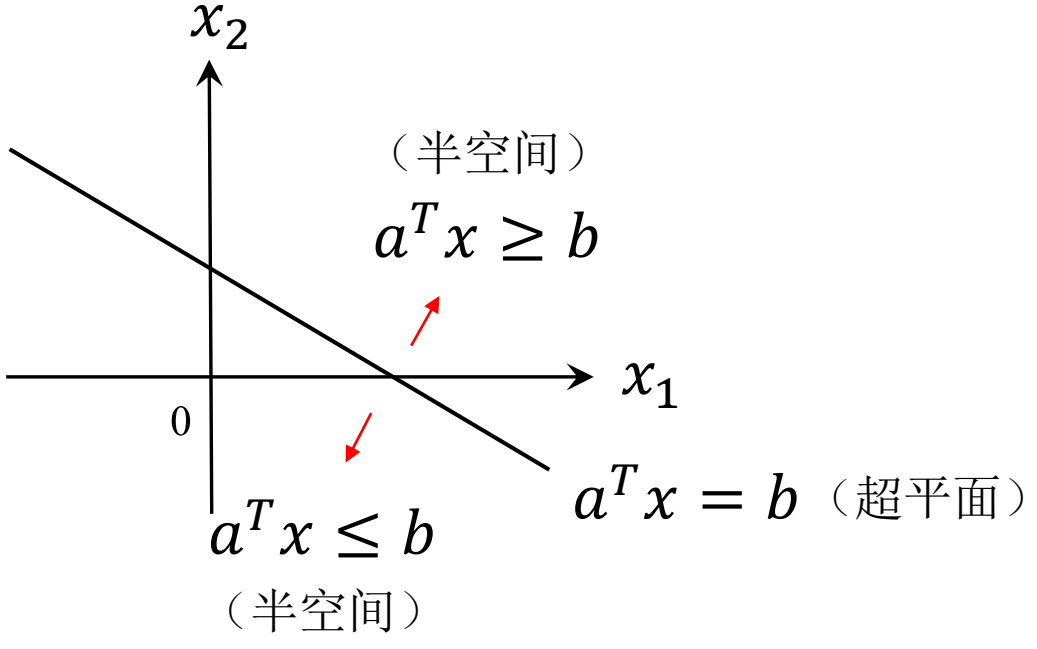
# 凸集的例子：超平面与半空间

- 一个超平面将 $\mathbb{R}^n$ 空间划分为两个半空间。（闭的）半空间是具有下列形式的集合：

$$\left\{x \in \mathbb{R}^n \mid a^\top x \leqslant b\right\},$$

其中 $a \in \mathbb{R}^n$, $a \neq 0$ 且 $b \in \mathbb{R}$。

- 半空间是凸集，但不是仿射集，过原点（$b = 0$）时为凸锥




$\mathbb{R}^2$ 上由 $a^\top x = b$ 定义的超平面决定了两个半空间，分别由 $a^\top x \geqslant b$ 和 $a^\top x \leqslant b$ 决定。

# 凸集的例子：范数球

- $\mathbb{R}^n$ 空间中的范数球 (norm ball) 的数学形式：

$$\left\{x \in \mathbb{R}^n \mid \|x - x_c\|_p \leq r\right\},$$

其中 $r$ 为半径，$x_c$ 为球心，$\|\cdot\|_p$ 是任意 $\ell_p$-范数（$p \geq 1$）。

- 常见的范数球由 $\ell_2$-范数（也叫作 Euclidean 范数）定义：

$$B(x_c, r) = \{x \in \mathbb{R}^n \mid \|x - x_c\|_2 \leq r\}.$$

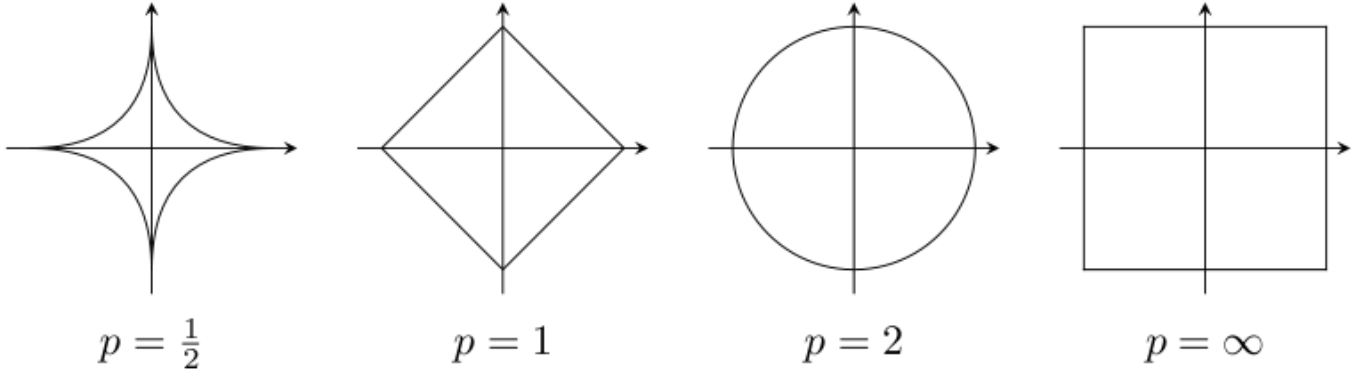



Fig. 左1：由于 $p < 1$，不满足范数定义；左2：$\ell_1$-范数球；右2：$\ell_2$-范数球；右1：$\ell_\infty$-范数球.

# 凸集的例子：范数球

**命题 3 (范数球是凸集)**

$\ell_p$-范数球（$p \geq 1$）是凸集，且当 $r \neq 0$ 时不可能为仿射集和凸锥。

**证明：**（以 $\ell_2$-范数球为例）

$$\forall\, x_1, x_2 \in B(x_c, r) \quad \Rightarrow \quad \|x_1 - x_c\|_2 \leq r,\ \|x_2 - x_c\|_2 \leq r,$$

$$\forall\, \theta \in [0,1],\ \text{需要证明}\ \|\theta x_1 + (1-\theta)x_2 - x_c\|_2 \leq r \quad ???$$

为此，我们有

$$\begin{aligned}
&\|\theta x_1 + (1-\theta)x_2 - x_c\|_2 \\
&= \|\theta\,(x_1 - x_c) + (1-\theta)\,(x_2 - x_c)\|_2 \\
&\leq \|\theta\,(x_1 - x_c)\|_2 + \|(1-\theta)\,(x_2 - x_c)\|_2 \quad \text{(范数的三角不等式)} \\
&= \theta\,\|x_1 - x_c\|_2 + (1-\theta)\,\|x_2 - x_c\|_2 \quad \text{(范数的齐次性)} \\
&\leq \theta r + (1-\theta) r \\
&= r \quad \text{(得证)}
\end{aligned}$$

# 凸集的例子：欧氏空间内的椭球

- 欧氏空间 $\mathbb{R}^n$ 中的某个对称正定矩阵 $P$ 可以定义椭球如下：

$$\mathcal{E} = \left\{ x \in \mathbb{R}^n \mid (x - x_c)^\top P (x - x_c) \leqslant 1 \right\},$$

  其中 $P$ 是对称正定矩阵，向量 $x_c \in \mathbb{R}^n$ 为椭球的中心。

- 矩阵 $P$ 决定了椭球从 $x_c$ 向各个方向扩展的幅度。$\mathcal{E}$ 的半轴长度由 $P$ 的特征值 $\sqrt{\lambda_i}$ 给出。当 $P = r^2 I$ 时，$\mathcal{E}$ 即为球。

- 椭球也是凸集。

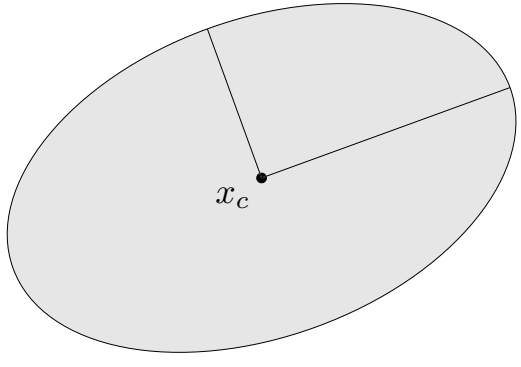
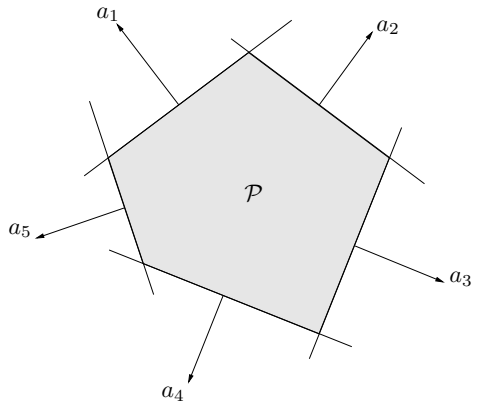



Fig. 阴影所示为 $\mathbb{R}^2$ 中的一个椭球。中心 $x_c$ 由黑点显示，两个半轴由线段显示。

# 凸集的例子：多面体

- $\mathbb{R}^n$ 空间中的多面体定义为有限个线性不等式解集的交集：

$$\mathcal{P} = \left\{ x \in \mathbb{R}^n \ : \ a_i^\top x \leq b_i, \ i = 1, \cdots, m \right\}.$$

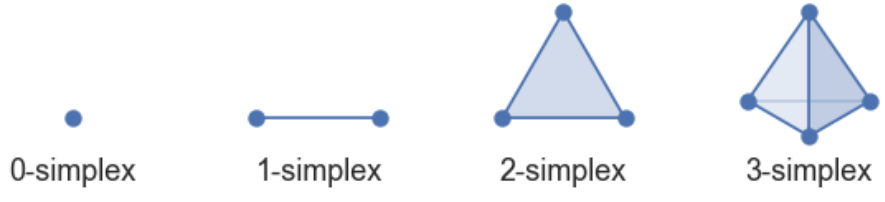



多面体也可解释为有限个半空间的交集。易分析，多面体是凸的。

- 超平面、直线、射线、线段和半空间等都是多面体；

- 一类重要的多面体是单纯形：设 $k+1$ 个点 $v_0, v_1, \cdots, v_k \in \mathbb{R}^n$ 仿射独立，即 $v_1 - v_0, \cdots, v_k - v_0$ 线性独立，那么这些点定义一个单纯形如下：

$$C = \operatorname{conv}\{v_0, \cdots, v_k\} = \left\{ \theta_0 v_0 + \cdots + \theta_k v_k \ \middle| \ \sum_{i=1}^{k} \theta_i = 1, \ \theta \geq 0 \right\}.$$



# 更抽象的凸集

**命题 4 (对称矩阵集合是凸锥)**

**证明：** 令 $S^n = \left\{A \in \mathbb{R}^{n\times n} \mid A = A^\top\right\}$，则

$$\forall\, A_1, A_2 \in S^n,\ \forall\, \theta_1, \theta_2 \geq 0 \quad \Rightarrow \quad \theta_1 A_1 + \theta_2 A_2 \in S^n.$$

**命题 5 (对称半正定矩阵集合是凸锥)**

**证明：** 令 $S_+^n = \left\{A \in \mathbb{R}^{n\times n} \mid A = A^\top, A \succeq 0\right\}$，则 $\forall\, A_1, A_2 \in S_+^n,\ \forall\, \theta_1, \theta_2 \geq 0$, 有：

$$\forall\, x \in \mathbb{R}^n, \quad x^\top (\theta_1 A_1 + \theta_2 A_2)\, x = \theta_1 x^\top A_1 x + \theta_2 x^\top A_2 x \geq 0.$$

$$\Rightarrow \quad \theta_1 A_1 + \theta_2 A_2 \in S_+^n.$$

**命题 6 (对称正定矩阵集合是凸集（但不是凸锥）)**

**证明：** 令 $S_{++}^n = \left\{A \in \mathbb{R}^{n\times n} \mid A = A^\top, A \succ 0\right\}$，

1. 反例：$n = 1$ 时，$S_{++}^1 = \{x \in \mathbb{R} \mid x > 0\}$ 不过原点，因此 $S_{++}^1$ 不是凸锥；
2. $\forall\, A_1, A_2 \in S_{++}^n,\ \forall\, \theta_1, \theta_2 \geq 0,\ \forall\, \theta_1 + \theta_2 = 1$，有：

$$\forall\, x \in \mathbb{R}^n, \quad x^\top (\theta_1 A_1 + \theta_2 A_2)\, x = \theta_1 x^\top A_1 x + \theta_2 x^\top A_2 x > 0.$$

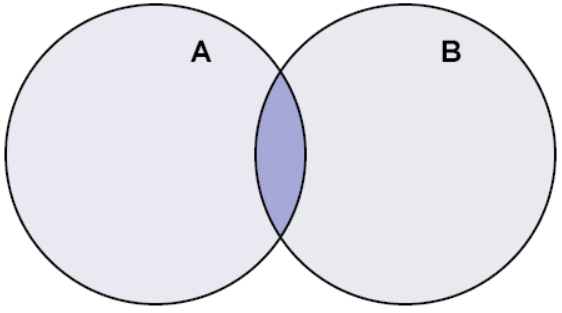
$$\Rightarrow \quad \theta_1 A_1 + \theta_2 A_2 \in S_{++}^n.$$

# 凸集的保凸运算

**交集**：若 $A, B$ 为凸集，则 $A \cap B$ 也为凸集。

若 $A_i, i = 1, 2, ...,$ 为凸集，则 $\bigcap_{i=1}^{\infty} A_i$ 为凸集。

应用例子：多面体




思考：并集是否保持凸性？

**仿射变换**：若 $f(x) = Ax + b$，其中 $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$，称 $f : \mathbb{R}^n \to \mathbb{R}^m$ 是仿射的。

- 若 $S \subseteq \mathbb{R}^n$ 是凸集，$f : \mathbb{R}^n \to \mathbb{R}^m$ 是仿射的，则 $S$ 在 $f$ 下的映射 $f(S) = \{f(x) \mid x \in S\}$ 也是凸集；
- 若 $C \subseteq \mathbb{R}^m$ 是凸集，$g : \mathbb{R}^n \to \mathbb{R}^m$ 是仿射的，则 $C$ 在 $g$ 下的逆映射 $g^{-1}(C) = \{x \mid g(x) \in C\}$ 也是凸集；

# 凸集的保凸运算

- 对凸集 $S$ 的缩放与位移保持凸性：

$$\alpha S = \{\alpha x \mid x \in S\}$$

$$a + S = \{a + x \mid x \in S\}$$

- 两个凸集 $S_1, S_2$ 的和与直积保持凸性：

$$S_1 + S_2 = \{x + y \mid x \in S_1, y \in S_2\}$$

$$S_1 \times S_2 = \{(x, y) \mid x \in S_1, y \in S_2\}$$

# 凸集的保凸运算

**例：椭球可由单位球通过仿射映射得到，因此是凸的。** 给定 $x_c \in \mathbb{R}^n$ 和 $P \in S^n_{++}$，可定义椭球如下：

$$\mathcal{E}(x_c, P) = \left\{ x \in \mathbb{R}^n \mid (x - x_c)^\top P (x - x_c) \leq 1 \right\}.$$

**分析：** 考虑将单位球 $\{u \in \mathbb{R}^n \mid \|u\|_2 \leq 1\}$ 通过仿射映射 $f(u) = P^{-\frac{1}{2}} u + x_c$ 映射为集合 $\{f(u) \mid \|u\|_2 \leq 1\}$，其中 $P^{-\frac{1}{2}}$ 表示 $P^{\frac{1}{2}}$ 的逆矩阵，$P^{\frac{1}{2}}$ 表示某一个正定矩阵满足 $P^{\frac{1}{2}} \cdot P^{\frac{1}{2}} = P$。具体如下：

$$\begin{aligned}
&\{f(u) \mid \|u\|_2 \leq 1\} \\
=&\left\{ P^{-\frac{1}{2}} u + x_c \mid \|u\|_2 \leq 1 \right\} \quad \text{令 } x := P^{-\frac{1}{2}} u + x_c \Leftrightarrow u = P^{\frac{1}{2}} (x - x_c) \\
=&\left\{ x \mid \left\| P^{\frac{1}{2}} (x - x_c) \right\|_2 \leq 1 \right\} \quad \Leftrightarrow \quad \left\{ x \mid \left\| P^{\frac{1}{2}} (x - x_c) \right\|_2^2 \leq 1 \right\} \\
=&\left\{ x \mid (x - x_c)^\top \underbrace{P^{\frac{1}{2}} \cdot P^{\frac{1}{2}}}_{P} (x - x_c) \leq 1 \right\}
\end{aligned}$$

# 凸集的保凸运算

**透视函数 (perspective function)**：称 $\mathcal{P}:\mathbb{R}^n\times\mathbb{R}_{++}\to\mathbb{R}^n$ 是透视函数，若 $\mathcal{P}(z,t)=\frac{z}{t}$，其中 $z\in\mathbb{R}^n, t>0$。

对于一个透视函数 $\mathcal{P}$，我们有以下两个结论：

- 如果 $C\subseteq\operatorname{dom}\mathcal{P}$ 是凸集，那么它的象

$$\mathcal{P}(C):=\{\mathcal{P}(x)\mid x\in C\}$$

  也是凸集。

- 如果 $C\subseteq\mathbb{R}^n$ 为凸集，那么它的原象

$$\mathcal{P}^{-1}(C):=\left\{(x,t)\in\mathbb{R}^{n+1}\mid\frac{x}{t}\in C,\ t>0\right\}$$

  也是凸集。

# 凸集的保凸运算

如何证明 $\mathcal{P}^{-1}$ 保持集合的凸性?

考虑 $(x,t)\in\mathcal{P}^{-1}(C)$，$(y,s)\in\mathcal{P}^{-1}(C)$，是否对 $\forall\,\theta\in[0,1]$，都有

$$\theta\,(x,t)+(1-\theta)(y,s)\in\mathcal{P}^{-1}(C)\quad ???$$

上式等价为

$$\begin{aligned}
&\Leftrightarrow\quad \mathcal{P}\big(\theta\,(x,t)+(1-\theta)(y,s)\big)\in C\\
&\Leftrightarrow\quad \frac{\theta x+(1-\theta)y}{\theta t+(1-\theta)s}\in C\\
&\Leftrightarrow\quad \frac{\theta t}{\theta t+(1-\theta)s}\cdot\underbrace{\frac{x}{t}}_{=\mathcal{P}(x,t)\in C}+\left(1-\frac{\theta t}{\theta t+(1-\theta)s}\right)\cdot\underbrace{\frac{y}{s}}_{=\mathcal{P}(y,s)\in C}\in C.
\end{aligned}$$

根据凸集的定义可知 $\mathcal{P}^{-1}$ 保持凸性。

§ 绪论

§ 基础知识

§ 凸集

§ 凸函数

§ 凸优化问题

# 凸函数的定义

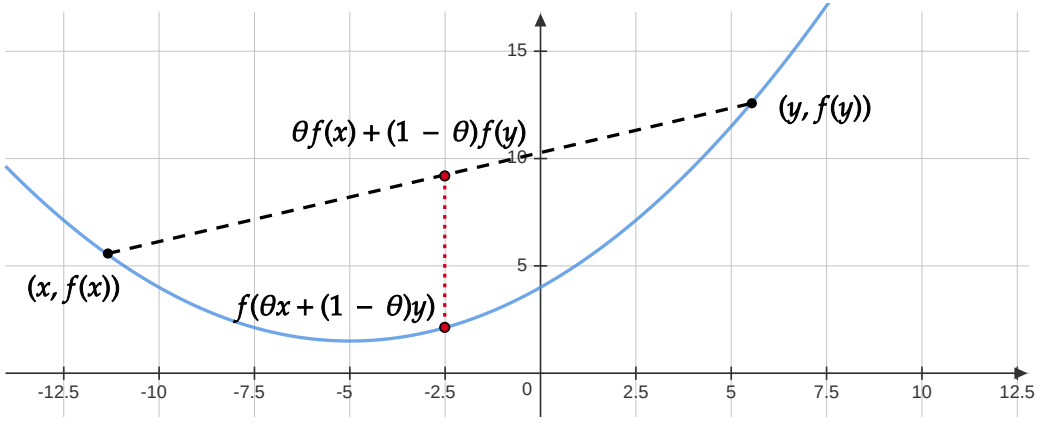
**定义 10 (凸函数(convex function)的基本定义)**

对于函数 $f:\mathbb{R}^n \to \mathbb{R}$，如果 $\operatorname{dom} f$ 是凸集，且对于 $\forall\, x, y \in \operatorname{dom} f$ 和 $\forall\, \theta \in [0,1]$，有

$$f(\theta x + (1-\theta)y) \le \theta f(x) + (1-\theta) f(y),$$

则称 $f$ 是凸函数。

- 凸集与凸函数的定义中均有凸组合的概念
- 任意两点凸组合的函数值小于等于函数值的凸组合




- $\operatorname{dom} f$ 是凸集很重要！否则 $\theta x + (1-\theta)y$ 不一定在 $\operatorname{dom} f$ 内

# 凸函数的定义

**定义 11 (凸函数的等价定义)**

对于函数 $f:\mathbb{R}^n\to\mathbb{R}$，如果 $\operatorname{dom} f$ 是凸集，且对 $\forall x\in\operatorname{dom} f$ 和 $\forall v\in\mathbb{R}^n$，（一元）函数 $g(t):=f(x+tv)$ 关于 $t$ 是凸的，其中 $\operatorname{dom} g=\{t\in\mathbb{R}\mid x+tv\in\operatorname{dom} f\}$，则称函数 $f$ 是凸函数。

**定义 12 (严格凸函数)**

对于函数 $f:\mathbb{R}^n\to\mathbb{R}$，如果 $\operatorname{dom} f$ 是凸集，且对 $\forall x\neq y\in\operatorname{dom} f$ 和 $\forall\theta\in(0,1)$，有

$$f(\theta x+(1-\theta)y)<\theta f(x)+(1-\theta)f(y),$$

则称函数 $f$ 是严格凸函数。

# 凸函数的定义

**定义 13 (强凸函数)**

对于函数 $f:\mathbb{R}^n\to\mathbb{R}$，如果 $\operatorname{dom} f$ 是凸集，且对于 $\forall\, x,y\in\operatorname{dom} f$ 和 $\forall\,\theta\in[0,1]$，有

$$f(\theta x+(1-\theta)y)\leqslant\theta f(x)+(1-\theta)f(y)-\frac{\theta(1-\theta)\mu}{2}\|x-y\|^2,$$

则称函数 $f$ 是 $\mu$-强凸函数。

**定义 14 (强凸函数的等价定义)**

对于函数 $f:\mathbb{R}^n\to\mathbb{R}$，若存在 $\mu>0$ 使得

$$g(x):=f(x)-\frac{\mu}{2}\|x\|_2^2,$$

是凸函数，则称函数 $f$ 是 $\mu$-强凸函数。

“凹”：若 $-f$ 为（严格、强）凸函数，则 $f$ 为（严格、强）凹函数

# 凸函数的扩展

对于一个实值函数 $f:\mathbb{R}^n\to\mathbb{R}$，我们可以将 $f$ 扩展为一个广义实值函数 $\tilde{f}:\mathbb{R}^n\to\mathbb{R}\cup\{+\infty\}$，定义如下：

$$\tilde{f}(x):=\begin{cases} f(x), & x\in\operatorname{dom} f,\\ +\infty, & x\notin\operatorname{dom} f.\end{cases}$$

于是，$\operatorname{dom}\tilde{f}=\mathbb{R}^n$。验证 $\tilde{f}$ 是否为凸，只需验证

$$\tilde{f}(\theta x+(1-\theta)y)\leqslant\theta\tilde{f}(x)+(1-\theta)\tilde{f}(y),\quad \forall\, x,y\in\mathbb{R}^n,\ \forall\,\theta\in[0,1].$$

同时，易分析

$$f\text{ 凸}\quad\Longleftrightarrow\quad\tilde{f}\text{ 凸}$$

# 凸函数的扩展：重要例子

对于一个集合 $C \subseteq \mathbb{R}^n$，定义集合 $C$ 的示性函数 (indicator function) $\delta_C : \mathbb{R}^n \to \mathbb{R} \cup \{+\infty\}$ 如下：

$$\delta_C(x) = \begin{cases} 0, & x \in C, \\ \infty, & x \notin C. \end{cases}$$

易分析

$$C \text{ 是凸集} \iff \delta_C \text{ 是凸函数}$$

**思考：** 若定义 $\delta'_C(x) = \begin{cases} 0, & x \in C \\ 1, & x \notin C \end{cases}$，该函数是否为凸函数？

**答：** 不是凸函数！

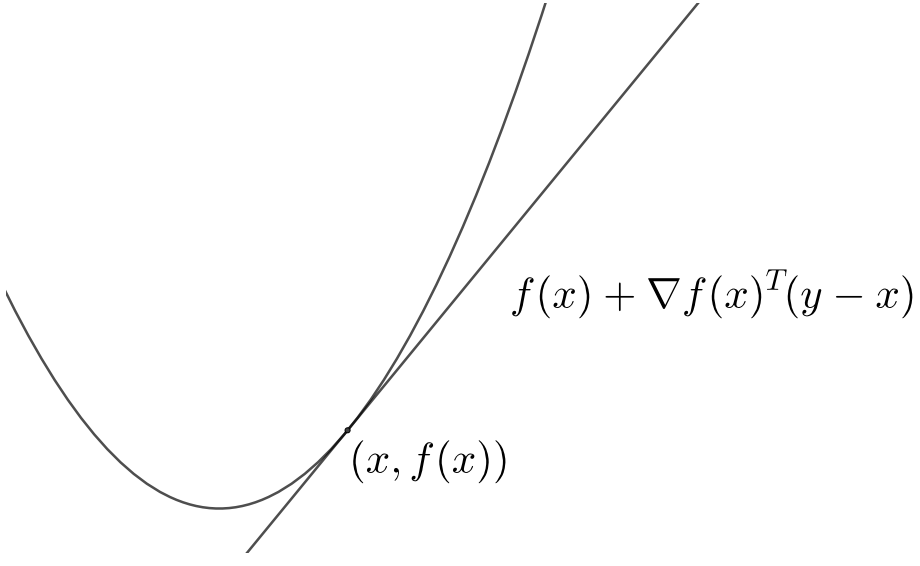
# 凸函数的性质：一阶条件

**定理 2 (凸函数的一阶条件，一阶连续可微情况下的等价定义)**

若 $f:\mathbb{R}^n \to \mathbb{R}$ 在 $\operatorname{dom} f$ 上是一阶连续可微的，则 $f(x)$ 是凸函数。 $\Longleftrightarrow$

$$f(y) \geq f(x) + \nabla f(x)^{\top}(y-x), \quad \forall\, x, y \in \operatorname{dom} f.$$

上面不等式称作凸函数的**一阶条件**。




一阶条件是凸函数的重要性质，也是凸分析的重要工具。

# 凸函数的性质：一阶条件

**推论 1 (一阶连续可微凸函数的极小值点)**

若 $f:\mathbb{R}^n \to \mathbb{R}$ 在 $\operatorname{dom} f$ 上是一阶连续可微的凸函数，且 $\exists x^* \in \operatorname{dom} f$ 满足 $\nabla f(x^*) = 0$，则

$$f(y) \geq f(x^*) + \underbrace{\nabla f(x^*)^\top}_{=0}(y - x^*) = f(x^*), \quad \forall y \in \operatorname{dom} f,$$

即 $x^*$ 是 $\min\limits_x \{f(x)\}$ 的一个解。若 $\operatorname{dom} f = \mathbb{R}^n$，则反之亦然，此时有

$$\nabla f(x^*) = 0 \quad \Longleftrightarrow \quad x^* \in \arg\min_{x\in\mathbb{R}^n} f(x).$$

**推论 2 (梯度单调性)**

在 $\operatorname{dom} f$ 上连续可微凸函数的梯度映射 $\nabla f:\mathbb{R}^n \to \mathbb{R}^n$ 是单调的，即满足

$$\left(\nabla f(y) - \nabla f(x)\right)^\top (y - x) \geq 0, \quad \forall\, x, y \in \operatorname{dom} f.$$

# 凸函数的性质：一阶条件

**推论 3 (严格凸、凹函数、强凸函数的等价定义)**

- $f(x)$ 是严格凸函数 $\iff$

$$f(y) > f(x) + \nabla f(x)^\top (y - x), \quad \forall\, x \neq y \in \operatorname{dom} f.$$

- $f(x)$ 是凹函数 $\iff$

$$f(y) \leq f(x) + \nabla f(x)^\top (y - x), \quad \forall\, x, y \in \operatorname{dom} f.$$

- $f(x)$ 是强凸函数 $\iff$

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|_2^2, \quad \forall\, x, y \in \operatorname{dom} f.$$

# 凸函数的性质：二阶条件

**定理 3 (凸函数的二阶条件)**

若 $f:\mathbb{R}^n\to\mathbb{R}$ 在 $\operatorname{dom} f$ 上是二阶连续可微的，则

$$f(x)\text{ 是凸函数}\quad\Longleftrightarrow\quad\nabla^2 f(x)\succeq 0,\ \forall\, x\in\operatorname{dom} f.$$

不等式 $\nabla^2 f(x)\succeq 0$（即 Hessian 矩阵半正定）称作凸函数的**二阶条件**。

**推论 4 (二阶条件的相关推论)**

- $f(x)$ 是严格凸函数 $\quad\Longleftarrow\quad \nabla^2 f(x)\succ 0,\quad \forall\, x\in\operatorname{dom} f$
- $f(x)$ 是凹函数 $\quad\Longleftrightarrow\quad \nabla^2 f(x)\preceq 0,\quad \forall\, x\in\operatorname{dom} f$
- $f(x)$ 是强凸函数 $\quad\Longleftrightarrow\quad \exists\,\mu>0,\ \nabla^2 f(x)\succeq \mu I,\ \forall\, x\in\operatorname{dom} f$

**注：**严格凸函数不一定保证 $\nabla^2 f(x)\succ 0,\ \forall\, x\in\operatorname{dom} f$。例如：$f(x)=x^4$

# 凸函数的性质：二阶条件

**例：**考虑二次函数

$$f(x) = \frac{1}{2}x^\top Qx + q^\top x + r$$

的凸性，其中 $Q \in S^n$ 是对称矩阵，以及 $q \in \mathbb{R}^n, r \in \mathbb{R}$。容易计算可知

$$\nabla f(x) = Qx - q,$$
$$\nabla^2 f(x) = Q.$$

由一阶条件和二阶条件，可以得出以下结论：

- 二次函数 $f(x)$ 是凸函数 $\iff$ $Q \succeq 0$
- 二次函数 $f(x)$ 是严格凸函数 $\iff$ $Q \succ 0$
- 二次函数 $f(x)$ 是凹函数 $\iff$ $Q \preceq 0$
- 二次函数 $f(x)$ 是强凸函数 $\iff$ $\exists \mu > 0,\ Q \succeq \mu I$

# 凸函数的性质

**定理 4 (连续可微凸函数的等价叙述)**

若 $f:\mathbb{R}^n \to \mathbb{R}$ 在 $\operatorname{dom} f$ 上连续可微，则下述条件等价:

(1) $f$ 是凸函数

(2) （一阶条件） $f(y) \geq f(x) + \nabla f(x)^\top (y-x), \quad \forall\, x, y \in \operatorname{dom} f$

(3) （梯度单调） $(\nabla f(y) - \nabla f(x))^\top (y-x) \geqslant 0, \quad \forall\, x, y \in \operatorname{dom} f$

进一步，若 $f$ 在 $\operatorname{dom} f$ 上二阶连续可微，则 $f$ 为凸函数等价于

(4) （二阶条件） $\nabla^2 f(x) \succeq 0, \ \forall\, x \in \operatorname{dom} f$

# 重要的凸函数

**线性（仿射）函数：** $f(x) = Ax + b$ 既是凸函数，也是凹函数；

**二次函数：** $f(x) = \frac{1}{2}x^\top Qx + q^\top x + r$，当 $\nabla^2 f(x) = Q \succeq 0$ 时为凸；

**指数函数：** $f(x) = \exp(\alpha x),\ x \in \mathbb{R}$。由 $f''(x) = \alpha^2 \exp(\alpha x) \geq 0$ 可知为凸；

**幂函数：** $f(x) = x^\alpha,\ x \in \mathbb{R}_{++}$.

$$f'(x) = \alpha x^{\alpha-1},$$

$$f''(x) = \alpha(\alpha-1)x^{\alpha-2} = \begin{cases} \geq 0, & \alpha \geq 1 \text{ or } \alpha \leq 0, \\ \leq 0, & 0 \leq \alpha \leq 1. \end{cases}$$

**思考：** 将限制 $x \in \mathbb{R}_{++}$ 减弱

- $f(x) = \dfrac{1}{x^2},\ x \neq 0$ 是不是凸函数？
- 绝对值的幂函数 $f(x) = |x|^p$ 是不是凸函数？在何时是凸函数？

# 重要的凸函数

- $f(x)=\frac{1}{x^2}$，$x\neq 0$ 是不是凸函数？

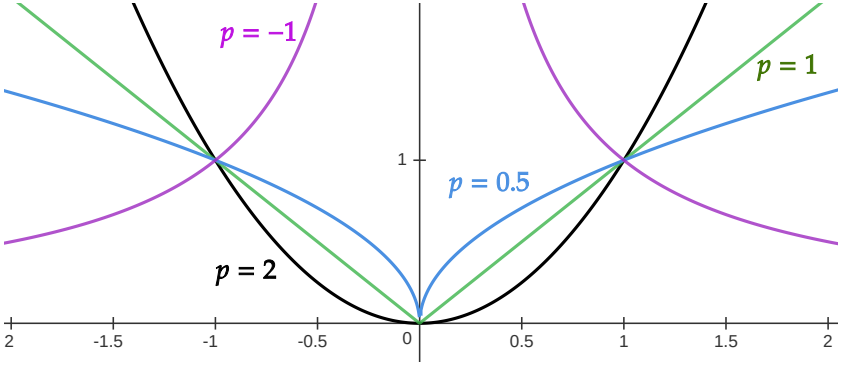
  不是。因为它的定义域 $x\in\mathbb{R}\backslash\{0\}$ 不是凸集。

- 绝对值的幂函数 $f(x)=|x|^p$ 在何时是凸函数？

容易计算：

$$f'(x)=\begin{cases} px^{p-1}, & x>0,\\ -p(-x)^{p-1}, & x<0,\end{cases}\qquad f''(x)=\begin{cases} p(p-1)x^{p-2}, & x>0,\\ p(p-1)(-x)^{p-2}, & x<0,\end{cases}$$

1. $p\geq 2$ 时，$f$ 二阶连续可微，由二阶条件可知为凸；
2. $p\in[1,2)$ 时，$f$ 不是二阶连续可微，不能用二阶条件判定，但可由定义结合一阶条件判断为凸；
3. $p<1$ 时，情况复杂，不一定凸，也不一定凹；



# 重要的凸函数

负对数（**log barrier**）函数：$f(x) = -\log(x)$，$\operatorname{dom} f = \mathbb{R}_{++}$：

$$\left.\begin{aligned} f'(x) &= -\frac{1}{x}, \\ f''(x) &= \frac{1}{x^2} > 0, \end{aligned}\right. \quad \Longrightarrow \quad \text{凸}$$

熵（**entroy**）函数：$f(x) = x\log(x)$，$\operatorname{dom} f = \mathbb{R}_{+}$，特别注意 $\operatorname{dom} f' = \mathbb{R}_{++}$ 以及 $\operatorname{dom} f'' = \mathbb{R}_{++}$：

$$\left.\begin{aligned} f'(x) &= \log x + 1, \\ f''(x) &= \frac{1}{x} > 0, \end{aligned}\right. \quad \Longrightarrow \quad \text{凸}$$

# 重要的凸函数

$\mathbb{R}^n$ 空间中的所有范数均为凸。

**回顾范数的性质：**

若 $p(x)$ 是 $\mathbb{R}^n$ 空间内的范数，则有

(1) $p(ax) = |a|p(x)$, (正齐次性)

(2) $p(x+y) \le p(x) + p(y)$, (三角不等式)

(3) $p(x) \ge 0, \forall x \in \mathbb{R}^n$，且 $p(x) = 0 \Leftrightarrow x = 0$, (正定性)

**证明：**根据范数的性质，对于 $\forall x, y \in \mathbb{R}^n$, $\forall \theta \in [0,1]$，有

$$p(\theta x + (1-\theta)y) \underbrace{\leqslant p(\theta x) + p((1-\theta)y)}_{\text{三角不等式}} \underbrace{= \theta p(x) + (1-\theta)p(y)}_{\text{正齐次性}}$$

**思考：**$\ell_0$-范数 $\|x\|_0$ 是指 $x$ 中非零元素的个数，它是范数吗？是凸函数吗？

**答：**不是范数，也不是凸函数！

# 重要的凸函数

**最大值函数**：$f(x)=\max\{x_1,\cdots,x_n\},\quad \forall\, x=(x_1,\cdots,x_n)^\top\in\mathbb{R}^n.$

证明：$\forall\, x,y\in\mathbb{R}^n,\ \forall\,\theta\in[0,1]$，有

$$\begin{aligned} f(\theta x+(1-\theta)y) &= \max_{i=1,\cdots,n}\{\theta x_i+(1-\theta)y_i\} \\ &\le \max_{i=1,\cdots,n}\{\theta x_i\}+\max_{i=1,\cdots,n}\{(1-\theta)y_i\} \\ &= \theta\max_{i=1,\cdots,n}\{x_i\}+(1-\theta)\max_{i=1,\cdots,n}\{y_i\} \\ &= \theta f(x)+(1-\theta)f(y) \end{aligned}$$

**log-sum-exp 函数**：$f(x)=\mu\log\left(e^{x_1/\mu}+e^{x_2/\mu}+\cdots+e^{x_n/\mu}\right)$，
$\forall\, x=(x_1,\cdots,x_n)^\top\in\mathbb{R}^n$，其中 $\mu>0$ 为任意正数。该函数可以作为最大值函数 $\max_{i=1,\cdots,n}\{x_i\}$ 的光滑近似：

$$\max\{x_1,\cdots,x_n\}\leqslant\mu\log\left(e^{x_1/\mu}+\cdots+e^{x_n/\mu}\right)\leqslant\max\{x_1,\cdots,x_n\}+\mu\log n.$$

# log-sum-exp 的凸性 I

下面分析 log-sum-exp 的凸性。为方便讨论，以下设 $\mu = 1$。

容易计算可知 Hessian 矩阵 $\nabla^2 f(x)$ 的第 $i$ 行第 $j$ 列元素为

$$\frac{\partial f}{\partial x_i} = \frac{e^{x_i}}{e^{x_1} + \cdots + e^{x_n}},$$

$$(i \neq j) \quad \frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{-e^{x_i} e^{x_j}}{\left(e^{x_i} + \cdots + e^{x_n}\right)^2},$$

$$(i = j) \quad \frac{\partial^2 f}{\partial x_i^2} = \frac{-e^{x_i} e^{x_i}}{\left(e^{x_1} + \cdots + e^{x_n}\right)^2} + \frac{e^{x_i}\left(e^{x_1} + \cdots + e^{x_n}\right)}{\left(e^{x_1} + \cdots + e^{x_n}\right)^2},$$

$$\nabla^2 f(x) = \frac{1}{\left(e^{x_1} + \cdots + e^{x_n}\right)^2} \left\{ \begin{bmatrix} e^{x_1}\left(e^{x_1} + \cdots + e^{x_n}\right) & & \\ & \ddots & \\ & & e^{x_n}\left(e^{x_1} + \cdots + e^{x_n}\right) \end{bmatrix} - \begin{bmatrix} e^{x_1} \\ \vdots \\ e^{x_n} \end{bmatrix} \left[e^{x_1}, \cdots, e^{x_n}\right] \right\}$$

# log-sum-exp 的凸性 II

令 $z = [e^{x_1}, \cdots, e^{x_n}]^\top$，$\operatorname{diag}(z) = \begin{bmatrix} z_1 & & \\ & & \\ & & z_n \end{bmatrix}$，则 $\nabla^2 f(x)$ 可以改写为:

$$\nabla^2 f(x) = \frac{1}{(e^\top z)^2} \underbrace{\left((e^\top z)\operatorname{diag}(z) - zz^\top\right)}_{K}.$$

下面讨论 $H$ 的半正定性：对于 $\forall v \in \mathbb{R}^n$，有

$$\begin{aligned} v^\top K v &= (e^\top z)\, v^\top \operatorname{diag}(z) v - v^\top z z^\top v \\ &= \left(\sum_{i=1}^n z_i\right)\left(\sum_{i=1}^n v_i^2 z_i\right) - \left(\sum_{i=1}^n v_i z_i\right)^2. \end{aligned}$$

令 $a_i = v_i\sqrt{z_i}$，$b_i = \sqrt{z_i}$，$a = [a_1 \ldots a_n]^\top$，$b = [b_1 \ldots b_n]^\top$。由 Cauchy-schwatz 不等式：$(b^\top b)(a^\top a) - (a^\top b)^2 \geqslant 0$ 可知，$v^\top K v \geq 0$，即证明了 $K$ 的半正定性，因此 $\nabla^2 f(x)$ 半正定。于是，由二阶条件可知 $f$ 凸。

# 负行列式对数的凸性 I

负行列式对数：$f(X) = -\log\det(X)$，$\operatorname{dom} f = S^n_{++}$，它是否为凸函数？

- 当 $n = 1$ 时，$f(x) = -\log x$，易知在 $\mathbb{R}_{++}$ 为凸；
- 当 $n > 1$ 时，情况较为复杂，需用**定义 11**（凸函数的等价定义）进行如下分析：

事实上，任取 $Z \succ 0$ 以及方向 $V \in S^n$，将 $f$ 限制在直线 $Z + tV$（$t$ 满足 $Z + tV \in \operatorname{dom} f = S^n_{++}$）上，考虑函数 $g(t) := f(Z + tV)$：

$$
\begin{aligned}
g(t) &= f(Z + tV) \\
&= -\log\det(Z + tV) \\
&= -\log\det\left(Z^{\frac{1}{2}}\left(I + tZ^{-\frac{1}{2}}VZ^{-\frac{1}{2}}\right)Z^{\frac{1}{2}}\right) \quad (Z = Z^{\frac{1}{2}}Z^{\frac{1}{2}},\ Z^{-\frac{1}{2}} \text{ 是 } Z^{\frac{1}{2}} \text{ 的逆}) \\
&= -\log\det\left(Z^{\frac{1}{2}}\right) - \log\det\left(I + tZ^{-\frac{1}{2}}VZ^{-\frac{1}{2}}\right) - \log\det\left(Z^{\frac{1}{2}}\right) \\
&\overset{(\star)}{=} -\log\det(Z) - \sum_{i=1}^{n}\log\left(1 + t\lambda_i\right) \quad (\lambda_i \text{ 是 } Z^{-\frac{1}{2}}VZ^{-\frac{1}{2}} \text{ 的第 } i \text{ 个特征值})
\end{aligned}
$$

# 负行列式对数的凸性 II

下面考察函数 $g(t)$ 的二阶导数：

$$g'(t) = -\sum_i^n \frac{\lambda_i}{1+t\lambda_i}, \quad g''(t) = \sum_i^n \frac{\lambda_i^2}{(1+t\lambda_i)^2} \geq 0.$$

于是，对每个 $Z \succ 0$ 以及方向 $V \in S^n$，$g$ 关于 $t$ 是凸的，因此 $f$ 是凸的。

**补充：为何式 $(\star)$ 成立？**

因为 $Z^{-\frac{1}{2}} V Z^{-\frac{1}{2}}$ 对称，有特征值分解：$Z^{-\frac{1}{2}} V Z^{-\frac{1}{2}} = Q\Lambda Q^\top$，其中 $Q$ 是特征向量构成的正交矩阵，$\Lambda$ 为特征值构成的对角矩阵：

$$\begin{aligned}
\det\left(I + tZ^{-\frac{1}{2}} V Z^{-\frac{1}{2}}\right) &= \det\left(I + tQ\Lambda Q^\top\right) = \det\left(Q(I+t\Lambda)Q^\top\right) \\
&= \det(Q)\det(I+t\Lambda)\det\left(Q^\top\right) \\
&= \det(Q)\det\left(Q^\top\right)\det(I+t\Lambda) \\
&= \det(I+t\Lambda) = \textstyle\prod_{i=1}^n \left(1+t\lambda_i\right)
\end{aligned}$$

# 保凸运算：非负加权和

**非负加权和**：若 $f_1, \cdots, f_m$ 均为定义在 $\mathbb{R}^n$ 上的凸函数，则

$$f := \sum_{i=1}^{m} w_i f_i, \quad w_i \geq 0, \ \forall\, i = 1, \cdots, m,$$

为凸函数。

# 保凸运算：仿射复合

**仿射复合**：给定函数 $f:\mathbb{R}^m\to\mathbb{R}$，$A\in\mathbb{R}^{m\times n}$，$b\in\mathbb{R}^m$，函数 $g$ 由 $f$ 复合仿射映射得到：

$$g(x):=f(Ax+b),\quad \operatorname{dom} g=\left\{x\in\mathbb{R}^n\mid Ax+b\in\operatorname{dom} f\right\}.$$

于是，若 $f$ 为凸，则 $g$ 为凸。

**证明**：首先，易知 $\operatorname{dom} g$ 为凸集。其次，对 $\forall\, x,y\in\operatorname{dom} g$, $\forall\,\theta\in[0,1]$，有

$$\begin{aligned}
&g\big(\theta x+(1-\theta)y\big)\\
&=f\big(A(\theta x+(1-\theta)y)+b\big)\\
&=f\big(\theta(Ax+b)+(1-\theta)(Ay+b)\big)\\
&\leqslant \theta f(Ax+b)+(1-\theta)f(Ay+b)\\
&=\theta g(x)+(1-\theta)g(y).
\end{aligned}$$

因此，$g$ 为凸函数。

**重要例子**：最小二乘损失函数 $\frac{1}{2}\|Ax-b\|^2$

# 保凸运算：逐点最大

**逐点最大**：若 $f_1, f_2$ 为凸函数，则

$$f(x) := \max\left\{f_1(x),\ f_2(x)\right\}$$

为凸函数，其中 $\operatorname{dom} f = \operatorname{dom} f_1 \cap \operatorname{dom} f_2$。

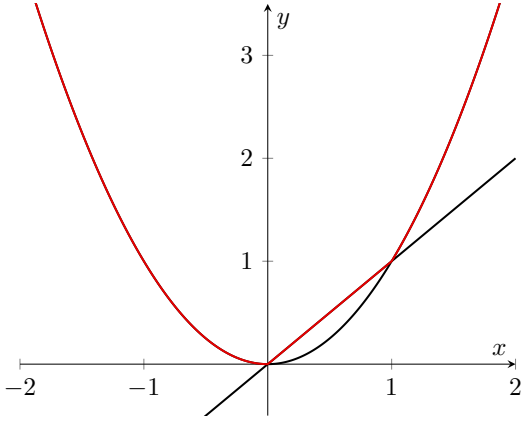
**证明**：首先，由 $f_1, f_2$ 为凸可知 $\operatorname{dom} f = \operatorname{dom} f_1 \cap \operatorname{dom} f_2$ 为凸集。其次，对 $\forall\, x, y \in \operatorname{dom} f$, $\forall\, \theta \in [0,1]$，有

$$\begin{aligned}
f(\theta x + (1-\theta)y) &= \max\left\{f_1(\theta x + (1-\theta)y),\ f_2(\theta x + (1-\theta)y)\right\} \\
&\le \max\left\{\theta f_1(x) + (1-\theta) f_1(y),\ \theta f_2(x) + (1-\theta) f_2(y)\right\} \\
&\le \max\left\{\theta f_1(x),\ \theta f_2(x)\right\} + \max\left\{(1-\theta) f_1(y),\ (1-\theta) f_2(y)\right\} \\
&= \theta \max\left\{f_1(x), f_2(x)\right\} + (1-\theta)\max\left\{f_1(y), f_2(y)\right\} \\
&= \theta f(x) + (1-\theta) f(y).
\end{aligned}$$

因此，$f$ 为凸函数。

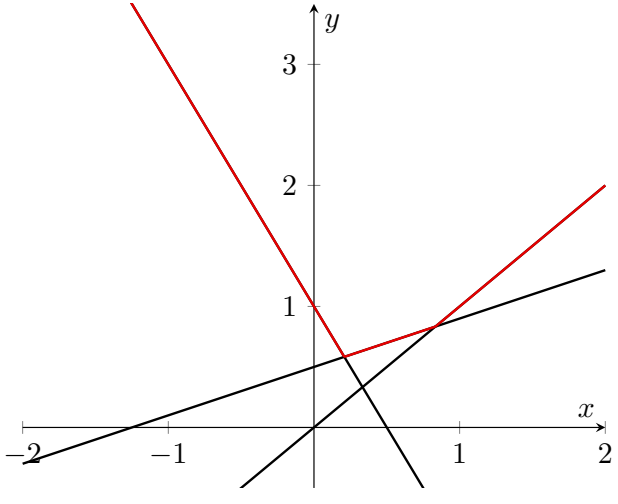
# 保凸运算：逐点最大

**例**：$f(x) = \max\left\{x^2, x\right\}$




**推广**：任意有限个凸函数的最大值函数也是凸的。例如，分段线性函数：

$f(x) = \max\left\{a_1^\top x + b_1, \cdots, a_n^\top x + b_n\right\}$



# 保凸运算：逐点上确界

进一步扩展 (无限情形)：若 $f(x,y)$ 对于每一个 $y \in \mathcal{Y}$ 关于 $x$ 都是凸的，则

$$g(x) := \sup_{y \in \mathcal{Y}} f(x,y)$$

是凸函数。 (注：这里对 $\mathcal{Y}$ 的凸性没有要求!)

例：

- 集合 $C \subseteq \mathbb{R}^n$（这里不要求 $C$ 为闭凸集）的支撑函数：
  $s_C(x) := \sup_{y \in C} y^\top x$，是凸函数。
- 点 $x$ 到集合 $C \subseteq \mathbb{R}^n$（这里不要求 $C$ 为闭凸集）的最远距离函数：
  $d_C(x) := \sup_{y \in C} \|y - x\|$，是凸函数。
- 实对称矩阵的最大特征值函数：$\lambda_{\max}(X) = \sup_{\|y\|_2 = 1} \{y^\top X y\}$，是凸函数。

# 保凸运算：函数的复合

设 $h:\mathbb{R}^m\to\mathbb{R}$，$g:\mathbb{R}^n\to\mathbb{R}^m$，则复合函数 $f:=h\circ g:\mathbb{R}^n\to\mathbb{R}$ 定义为

$$f(x):=h(g(x))=h(g_1(x),\cdots,g_m(x)),$$
$$\operatorname{dom} f:=\big\{x\in\operatorname{dom} g\mid g(x)\in\operatorname{dom} h\big\}.$$

**简单一维情况**：(1) 一维 $m=n=1$；(2) $\operatorname{dom} g=\operatorname{dom} h=\operatorname{dom} f=\mathbb{R}$；(3) $h$ 和 $g$ 是二阶连续可微的。考察二阶导数信息：

$$f'(x)=h'(g(x))g'(x)$$
$$f''(x)=h''(g(x))(g'(x))^2+h'(g(x))g''(x)$$

| $g''(x)$ | $h''(g(x))$ | $h'(g(x))$ | $f''(x)$ |
|---|---|---|---|
| $\geq 0$ | $\geq 0$ | $\geq 0$ | $\geq 0$ |
| $\leq 0$ | $\geq 0$ | $\leq 0$ | $\geq 0$ |
| $\leq 0$ | $\leq 0$ | $\geq 0$ | $\leq 0$ |
| $\geq 0$ | $\leq 0$ | $\leq 0$ | $\leq 0$ |

# 保凸运算：函数的复合

复杂高维情况：若以下两个条件之一成立：

(a) $g_i, h$ 是凸函数，且 $h$ 关于其每个分量是非减的；
(b) $g_i$ 是凹函数，$h$ 是凸函数，且 $h$ 关于其每个分量是 非增的；

则复合函数 $f := h \circ g$ 是凸函数。

**证明：**（只证明情况(a)，情况(b)留作练习）首先，由 $g_i, h$ 为凸容易验证 $\operatorname{dom} f$ 为凸集。其次，对 $\forall\, x, y \in \operatorname{dom} f$, $\forall\, \theta \in [0,1]$，有

$$
\begin{aligned}
& f(\theta x + (1-\theta)y) \\
&= h\big(g\big(\theta x + (1-\theta)y\big)\big) \\
&\le h\big(\theta g(x) + (1-\theta)g(y)\big) \quad \text{(因为 } g_i \text{ 为凸，且 } h \text{ 关于其每个分量是非减的)} \\
&\le \theta h(g(x)) + (1-\theta)h(g(y)) \quad \text{(因为 } h \text{ 为凸)} \\
&= \theta f(x) + (1-\theta) f(y).
\end{aligned}
$$

因此，$f$ 为凸函数。

# 保凸运算：函数的复合

例：

- $g:\mathbb{R}^n \to \mathbb{R}^m$ 为凸函数，$h(y)=\sum_{j=1}^m e^{y_j}$ 为凸函数，且 $h$ 关于其每个分量是非减的，则 $f(x)=\sum_{j=1}^m e^{g_j(x)}$ 为凸函数。

- $g:\mathbb{R}^n \to \mathbb{R}^m$ 为凹函数，且 $g>0$，$h(y)=\sum_{j=1}^m \frac{1}{y_j}$ 在 $y>0$ 上为凸函数，且 $h$ 关于其每个分量是非增的，则 $f(x)=\sum_{j=1}^m \frac{1}{g_j(x)}$ 为凸函数。

# 共轭函数

**定义 15 (共轭函数)**

给定函数 $f:\mathbb{R}^n \to \mathbb{R}$，定义函数 $f^*:\mathbb{R}^n \to \mathbb{R}$ 为

$$f^*(y) := \sup_{x \in \mathrm{dom} f} \left\{ y^\top x - f(x) \right\},$$

此函数称为函数 $f$ 的**共轭函数**。

- 使差值 $y^\top x - f(x)$ 在 $\mathrm{dom}\, f$ 有限的所有 $y \in \mathbb{R}^n$ 构成了 $f^*$ 的有效定义域。
- 无论 $f$ 是否是凸函数，$f^*$ 恒为凸函数。

# 共轭函数的例子

- 线性（仿射）函数：$f(x) = ax + b$，$\operatorname{dom} f = \mathbb{R}$，

$$f^*(y) = \sup_{x \in \operatorname{dom} f} \{yx - (ax + b)\} = \sup_{x \in \mathbb{R}} \{(y - a)x - b\},$$

$$f^*(y) = \begin{cases} -b, & y = a, \\ +\infty, & y \neq a. \end{cases}$$

- 负对数函数：$f(x) = -\log x, \quad \operatorname{dom} f = \mathbb{R}_{++}$，

$$f^*(y) = \sup_{x \in \operatorname{dom} f} \{yx + \log x\},$$

$$f^*(y) = \begin{cases} -1 - \log(-y), & y < 0, \\ +\infty, & y \geq 0. \end{cases}$$

- 二次函数：$f(x) = \frac{1}{2} x^\top Q x, \quad Q \in S^n_{++}, \quad \operatorname{dom} f = \mathbb{R}^n$，

$$f^*(y) = \sup_{x \in \operatorname{dom} f} \left\{y^\top x - \tfrac{1}{2} x^\top Q x\right\},$$

$$f^*(y) = \tfrac{1}{2} y^\top Q^{-1} y.$$

# $\alpha$-次水平集

**定义 16 ($\alpha$-次水平集 ($\alpha$-sublevel set))**

对于一个函数 $f:\mathbb{R}^n \to \mathbb{R}$，给定一个实数 $\alpha$，称集合

$$C_\alpha = \{x \in \operatorname{dom} f : f(x) \le \alpha\}$$

为 $f$ 的 $\alpha$-次水平集。

- 凸函数的任意非空$\alpha$-次水平集为凸集：

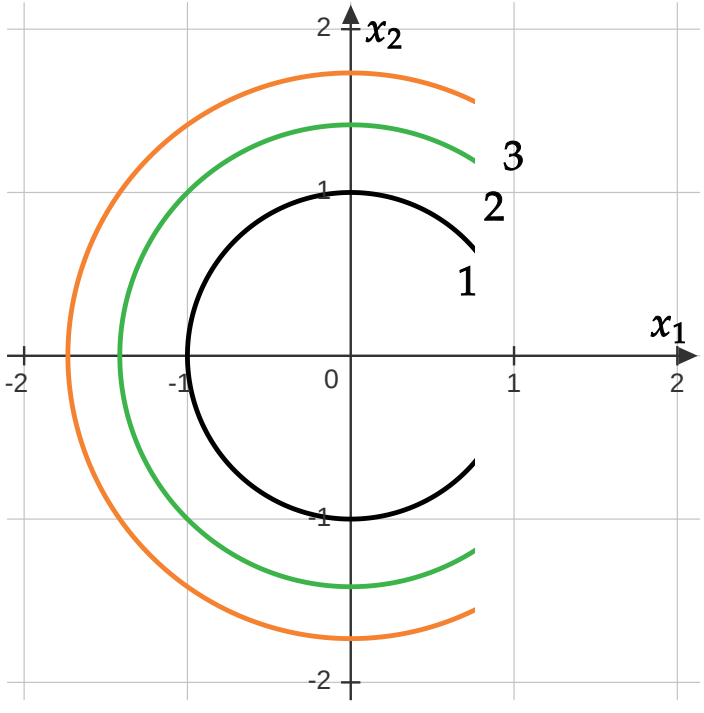
$$\forall\, x, y \in C_\alpha \quad \Rightarrow \quad f(x) \le \alpha,\ \ f(y) \le \alpha;$$

$$\forall\, \theta \in [0,1], \quad f(\theta x + (1-\theta)y) \leqslant \theta f(x) + (1-\theta) f(y) \le \alpha.$$

- 反之，若函数 $f$ 的任意非空$\alpha$-次水平集均为凸集，但 $f$ 不一定为凸函数。

# $\alpha$-次水平集

**例：** $f(x) = x_1^2 + x_2^2, \quad x = [x_1, x_2]^\top$，请画出$\alpha$-次水平集:




**注：** 在上图中，为方便可视化，我们只画出了边界（也称作等高线），边界及内部即是$\alpha$-次水平集，显然是凸集，但是边界自身不是凸集。

# 拟凸函数

**定义 17 (拟凸函数(quasi-convex function))**

函数 $f:\mathbb{R}^n \to \mathbb{R}$ 称为拟凸函数，如果其定义域及所有非空$\alpha$-次水平集

$$C_\alpha = \{x \in \operatorname{dom} f \mid f(x) \leq \alpha\}$$

都是凸集。

- 拟凹函数：如果其定义域及所有非空$\alpha$-上水平集 $\{x \in \operatorname{dom} f \mid f(x) \geq \alpha\}$ 都是凸集。
- 拟线性函数：既是拟凸函数又是拟凹函数，即其定义域和水平集 $\{x \in \operatorname{dom} f \mid f(x) = \alpha\}$ 都是凸集。

# 拟凸函数

**定义 18 (拟凸函数的等价定义)**

函数 $f:\mathbb{R}^n \to \mathbb{R}$ 是拟凸函数，等价于 $\operatorname{dom} f$ 是凸集，且对于任意 $x, y \in \operatorname{dom} f$ 及 $\theta \in [0,1]$，有

$$f(\theta x + (1-\theta)y) \leqslant \max\left\{f(x),\, f(y)\right\}.$$

# 拟凸函数案例

**线性分式函数：** $f(x)=\dfrac{a^{\top}x+b}{c^{\top}x+d}$, $\operatorname{dom} f=\left\{x \mid c^{T}x+d>0\right\}$

它既是拟凸函数，也是拟凹函数，所以此函数是拟线性函数。

线性分式函数的 $\alpha$-次水平集为

$$
\begin{aligned}
C_{\alpha} &= \left\{ x \middle| c^{T}x+d>0, \frac{a^{T}x+b}{c^{T}x+d} \leqslant \alpha \right\} \\
&= \left\{ x \mid c^{T}x+d>0, a^{T}x+b \leqslant \alpha\left(c^{T}x+d\right) \right\}.
\end{aligned}
$$

它是凸集，因为它是一个开的半平面和闭的半平面的交集。可以用同样的方法来判断其是拟凹和拟线性。

# 次梯度和次微分

类比连续可微凸函数的一阶条件，可为不连续可微的凸函数引入次梯度和次微分的概念。

**定义 19 (凸函数的次梯度(subgradient)和次微分(subdifferential))**

设 $f:\mathbb{R}^n \to \mathbb{R}$ 为凸函数，$x$ 为定义域 $\operatorname{dom} f$ 中的一点。若向量 $g \in \mathbb{R}^n$ 满足

$$f(y) \geq f(x) + g^\top (y - x), \quad \forall\, y \in \operatorname{dom} f,$$

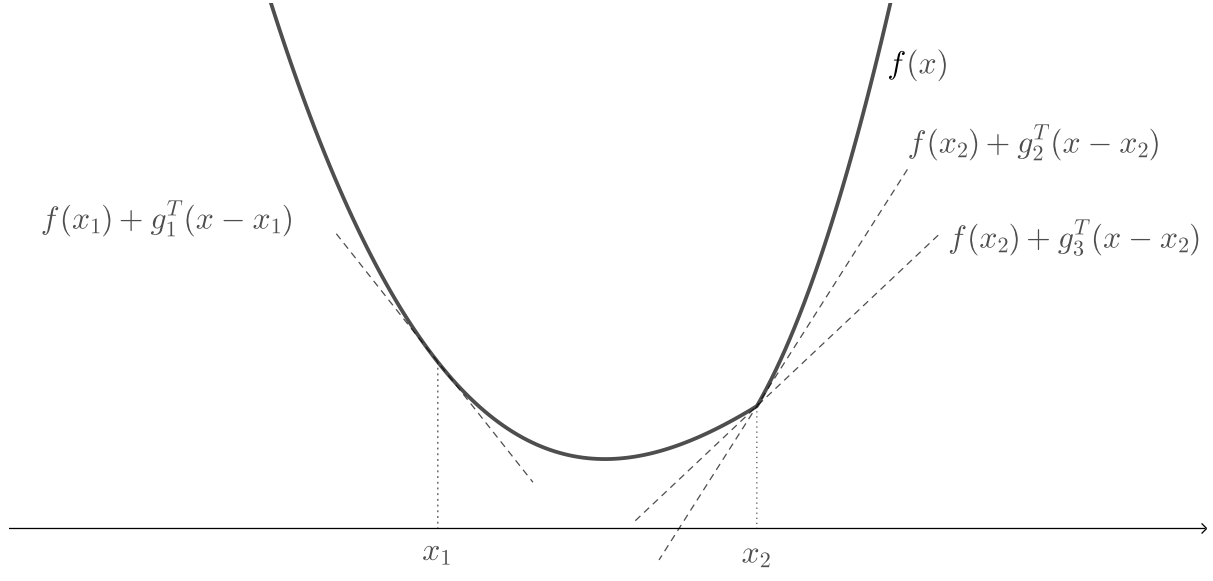
则称 $g$ 为 $f$ 在点 $x$ 处的一个次梯度。进一步地，称集合

$$\partial f(x) := \left\{ g \in \mathbb{R}^n \mid f(y) \geq f(x) + g^\top (y - x),\ \forall\, y \in \operatorname{dom} f \right\}$$

为 $f$ 在点 $x$ 处的次微分。

- 当凸函数 $f$ 连续可微时，次梯度即为梯度。

# 次梯度和次微分




**定理 5 (次梯度存在性)**

设 $f : \mathbb{R}^n \to \mathbb{R}$ 为凸函数，$\operatorname{dom} f$ 为其定义域。若 $x \in \operatorname{int} \operatorname{dom} f$，则 $\partial f(x)$ 是非空的，其中 $\operatorname{int} \operatorname{dom} f$ 的含义是定义域 $\operatorname{dom} f$ 的所有内点。

# 次梯度和次微分

**例：**计算 $\ell_2$ 范数 $f(x) := \|x\|_2$ 的次微分。

**解：**首先，注意到 $f$ 在任意 $x \neq 0$ 处连续可微，易计算有

$$\nabla f(x) = \frac{x}{\|x\|_2}, \quad \forall\, x \neq 0.$$

下面考虑 $x = 0$ 的情况，计算 $f$ 在该点处的次微分 $\partial f(0)$。注意到，对任意的 $g$ 满足 $\|g\|_2 \leq 1$，根据柯西不等式，有

$$g^\top (x - 0) \leq \|g\|_2 \|x\|_2 \leq \|x\|_2 - 0.$$

由此，我们有 $\{g \mid \|g\|_2 \leq 1\} \subseteq \partial f(0)$。

**解（续）：**接下来说明，若 $\|g\|_2 > 1$，则 $g \notin \partial f(0)$。

（反证）假设存在 $g \in \partial f(0)$ 满足 $\|g\|_2 > 1$，则由次微分的定义可知

$$f(y) \geq f(0) + g^\top (y - 0), \quad \forall\, y \in \operatorname{dom} f.$$

于是，取 $y = g \in \operatorname{dom} f$ 代入上式，可得

$$\|g\|_2 \geq g^\top g = \|g\|_2^2 > \|g\|_2.$$

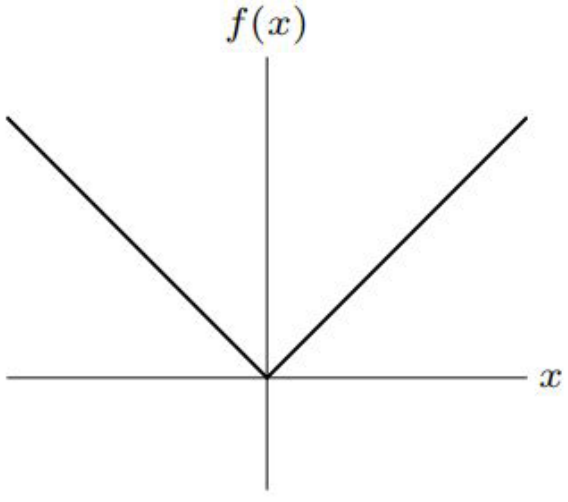
这显然是矛盾的。因此，我们有 $\{g \mid \|g\|_2 \leq 1\} = \partial f(0)$。

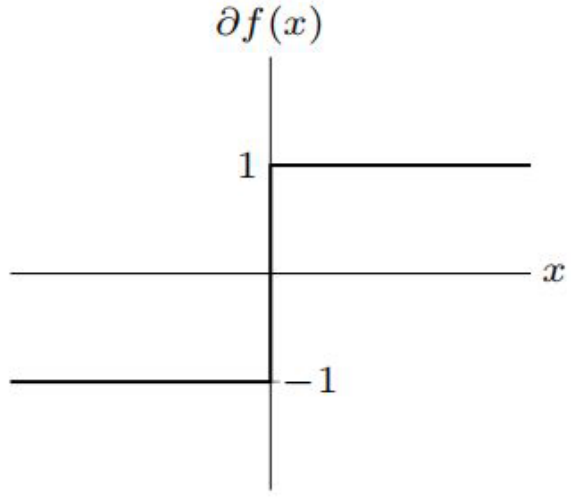
综上，可知

$$\partial f(x) = \begin{cases} \left\{ \dfrac{x}{\|x\|_2} \right\}, & x \neq 0, \\ \{g \mid \|g\|_2 \leq 1\}, & x = 0. \end{cases}$$

# 次梯度和次微分

**例：**计算绝对值函数 $f(x) := |x|$ 的次微分。




- 当 $x > 0$ 时，$f(x) = x$，$\partial f(x) = \{1\}$；
- 当 $x < 0$ 时，$f(x) = -x$，$\partial f(x) = \{-1\}$；
- 当 $x = 0$ 时，$f(0) = 0$，$\partial f(0) = [-1, 1]$；

§ 绪论

§ 基础知识

§ 凸集

§ 凸函数

§ 凸优化问题

# 凸优化问题 (Convex Problems)

## 凸优化问题的一般表述

目标函数为凸，可行集合为凸的极小化问题，即

$$\min_x \quad f(x) \qquad \text{s.t.} \qquad x \in \Omega,$$

其中 $f$ 是凸函数，$\Omega$ 是凸集。

回顾优化问题的一种具体表述形式：

$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leqslant 0, \quad i = 1, \cdots, m, \\ & h_j(x) = 0, \quad j = 1, \cdots, p. \end{aligned}$$

- $x \in \mathbb{R}^n$ 为优化变量；
- $f_0 : \mathbb{R}^n \to \mathbb{R}$ 为目标函数；
- $f_i(x) \leqslant 0$ 为不等式约束；$h_i(x) = 0$ 为等式约束；
- 如果没有约束（即 $m = p = 0$），称为无约束优化问题。

# 回顾优化问题的描述

- 定义域 (domain): $\mathcal{D} = \bigcap_{i=0}^{m} \operatorname{dom} f_i \cap \bigcap_{i=1}^{p} \operatorname{dom} h_i$.
- 可行域 (feasible set): $\mathcal{X} = \left\{ x \in \mathcal{D} \;\middle|\; \begin{array}{ll} f_i(x) \leq 0, & i = 1, \ldots, m \\ h_j(x) = 0, & j = 1, \ldots, p \end{array} \right\}$.

  同时，$\mathcal{X}$ 中的点 $x$（即 $x \in \mathcal{X}$）称作可行点 (feasible point)。
- 最优值 (optimal value):

$$p^\star := \inf \{ f_0(x) \mid x \in \mathcal{X} \}.$$

- （全局）最优解 ((global) optimal solution): 若存在 $x^* \in \mathcal{X}$，且 $f_0(x^*) = p^*$，则 $x^*$ 称为（全局）最优解。
- 最优解集 (optimal solution set): 所有最优解构成的集合称为最优解集

$$\mathcal{X}^* := \{ x^* \in \mathcal{X} \mid f_0(x^*) = p^* \}.$$

# 回顾优化问题的描述

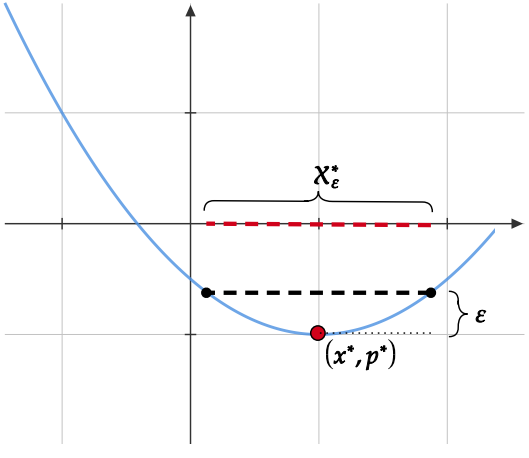
- $\varepsilon$-次优解集 ($\varepsilon$-suboptimal solution set):

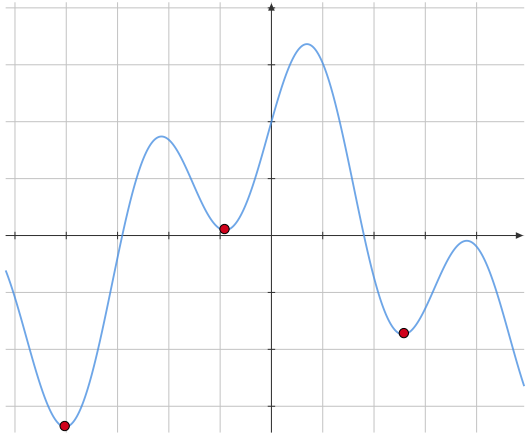
$$\mathcal{X}_\varepsilon := \{x \in \mathcal{X} \mid f_0(x) \le p^* + \varepsilon\}.$$

- 局部最优解 (local optimal solution): $\bar{x}$ 是局部最优解，若 $\exists R > 0$，使得

$$f_0(\bar{x}) = \min\{f_0(x) \mid x \in \mathcal{X},\ \|x - \bar{x}\|_2 \le R\}.$$

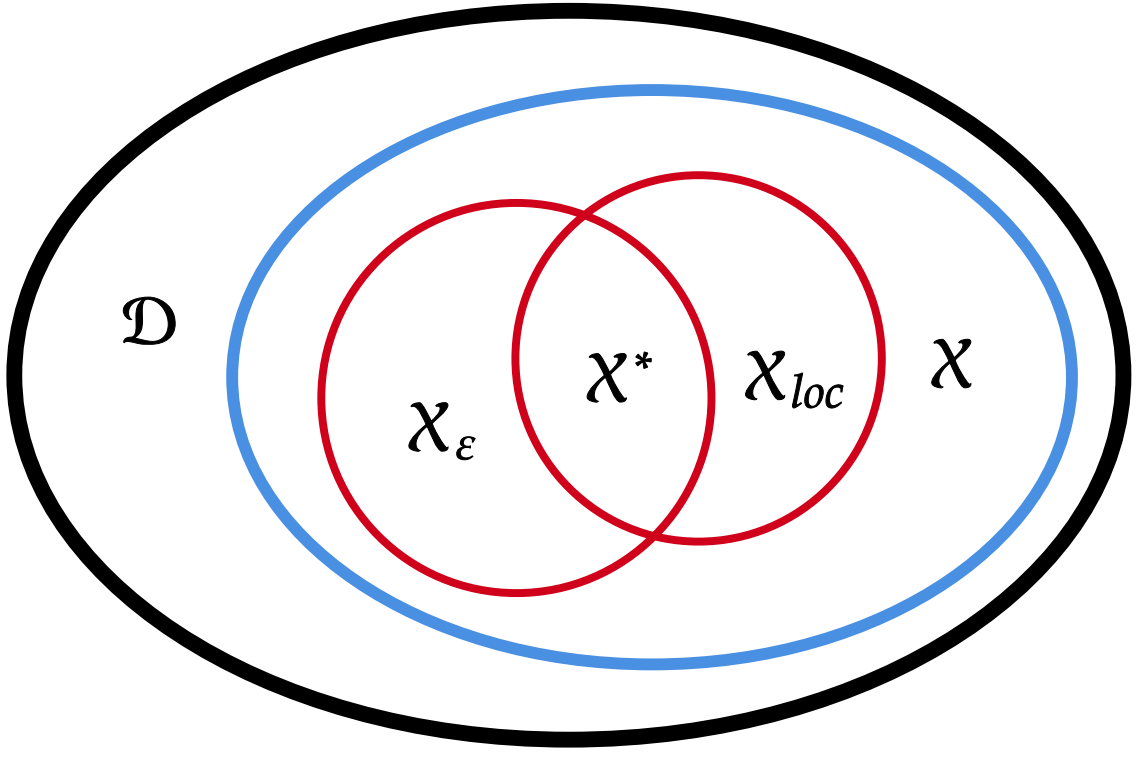
所有局部最优解构成的集合称为局部最优解集，记为 $\mathcal{X}_{loc}$。



# 集合之间的关系

$\mathcal{D}$: 定义域； $\mathcal{X}$: 可行域； $\mathcal{X}^*$: 最优解集；
$\mathcal{X}_\varepsilon$: $\varepsilon$-次优解集； $\mathcal{X}_{loc}$: 局部最优解集




**扩展思考**：在一般不等式约束中，为何考虑 $f_i(x) \leq 0$ 而非 $f_i(x) < 0$?

# 凸优化问题

**凸优化问题的一种具体表述形式：**

$$
\begin{aligned}
\min_{x} \quad & f_0(x) && && f_0：\text{凸函数}; \\
\text{s.t.} \quad & f_i(x) \leqslant 0, \quad i = 1, \cdots, m, && && f_i：\text{凸函数}; \\
& a_j^{\top} x = b_j, \quad j = 1, \cdots, p, && && a_j^{\top} x = b_j：\text{仿射函数}.
\end{aligned}
$$

**规定**：上述形式凸优化问题中的等式约束一定是 线性（仿射）约束。

**例1：**

$$
\begin{aligned}
\min_{x} \quad & f_0(x) = |x_1| + |x_2| && && f_0：\text{凸函数}; \\
\text{s.t.} \quad & f_1(x) = \frac{x_1}{1 + x_2^2} \leqslant 0, && && f_1：\text{非凸函数}; \\
& h_1(x) = x_1^2 + x_2^2 = 1, && && h_1：\text{非仿射函数};
\end{aligned}
$$

**例2：**

$$
\begin{aligned}
\min_{x} \quad & f_0(x) = x_1^2 + x_2^2 && && f_0：\text{凸函数}; \\
\text{s.t.} \quad & f_1(x) = x_1 \leqslant 0, && && f_1：\text{凸函数}; \\
& h_1(x) = x_1 + x_2 = 0, && && h_1：\text{仿射函数};
\end{aligned}
$$

# 凸优化问题的重要性质

**定理 6**

对于凸优化问题，局部最优解 $\Longleftrightarrow$ 全局最优解。

**证明：**“$\Longleftarrow$” 显然成立。

“$\Longrightarrow$”（反证法）假设 $\bar{x}$ 是一个局部最优解，但不是全局最优解。

于是，有以下两点：

- （局部最优）存在 $R > 0$，使得

$$f_0(\bar{x}) \leq f_0(x), \quad \forall\, x \in \mathcal{X} \;\&\; \|x - \bar{x}\|_2 \leq R.$$

- （非全局最优）存在 $y \in \mathcal{X}$，使得 $f_0(y) < f_0(\bar{x})$。显然，$\|y - \bar{x}\|_2 > R$

下面，考虑凸组合 $z = (1-\theta)\bar{x} + \theta y$，其中 $\theta = \dfrac{R}{2\|y - \bar{x}\|_2} \in (0, 1)$

# 凸优化问题的重要性质

因为可行域 $\mathcal{X}$ 是凸集，可知 $z \in \mathcal{X}$ 是可行解，且有

$$\|z-\bar{x}\|_2 = \|(1-\theta)\bar{x}+\theta y-\bar{x}\|_2 = \theta\|y-\bar{x}\|_2 = \frac{R}{2\|y-\bar{x}\|_2}\cdot\|y-\bar{x}\|_2 = \frac{R}{2} < R.$$

于是，由 $\bar{x}$ 是局部最优解，可知 $f_0(z) \geq f_0(\bar{x})$。

然而，根据 $f_0$ 的凸性有

$$f_0(z) = f_0((1-\theta)\bar{x}+\theta y) \leqslant (1-\theta)f_0(\bar{x})+\theta f_0(y) < f_0(\bar{x}),$$

产生矛盾，证毕。

故对于凸优化问题而言，局部最优解 $\Longleftrightarrow$ 全局最优解。

**进一步思考**：若 $f_0$ 严格凸或强凸，则最优解唯一！

# 连续可微问题的最优性理论

对于函数 $f_0$ 和点 $x \in \operatorname{dom} f_0$，若 $f_0$ 从点 $x$ 处沿着可行方向 $d$ 在一定范围内函数值可下降，即存在 $T > 0$ 使得，对于任意 $t \in (0, T)$ 有 $x + td \in \operatorname{dom} f_0$，

$$f_0(x + td) < f_0(x),$$

则称 $d$ 是 $f_0$ 在点 $x$ 处的一个下降方向。特别地，我们有以下结论。

**命题 7 (连续可微函数的下降方向)**

对于在定义域上连续可微函数 $f_0$ 和点 $x \in \operatorname{dom} f_0$，若可行方向 $d$ 满足

$$\big(\nabla f_0(x)\big)^\top d < 0,$$

则 $d$ 是 $f_0$ 在点 $x$ 处的一个下降方向。

**证明思路：** 若满足 $\big(\nabla f_0(x)\big)^\top d < 0$，利用一阶展开式，容易验证，存在 $T > 0$ 使得，对于任意 $t \in (0, T)$ 有 $f_0(x + td) < f_0(x)$。

# 连续可微问题的最优性理论

因此，容易知道，在 $f_0$ 的局部最优点 $x^*$ 处没有下降方向，于是有

$$\big(\nabla f_0(x^*)\big)^\top d \geq 0, \quad \forall \text{可行方向 } d.$$

进一步，我们有如下一阶必要条件：

**命题 8 (一般优化问题的一阶必要条件)**

函数 $f_0$ 在全空间 $\mathbb{R}^n$ 上连续可微，若点 $x^*$ 是一个局部最优点，则

$$\nabla f_0(x^*) = 0.$$

思考：反过来是否成立？即，若在点 $x^*$ 处，对于任意可行方向 $d$，都有 $\big(\nabla f_0(x^*)\big)^\top d \geq 0$，是否可以说明点 $x^*$ 是一个局部最优解？

答：不一定成立！考虑 $f_0(x) = x^3$ 在 $0$ 点处的情况。

# 连续可微问题的最优性理论

## 回顾凸函数一阶条件

若 $f_0$ 凸且在 $\mathrm{dom}\, f_0$ 上连续可微 $\iff$ $\mathrm{dom}\, f_0$ 凸

$$f_0(y) \geq f_0(x) + \nabla f_0(x)^\top (y - x), \quad \forall\, x,\, y \in \mathrm{dom}\, f_0.$$

## 命题 9 (凸优化问题的一阶充要条件)

若存在 $x^* \in \mathrm{dom}\, f_0$，对于 $\forall\, y \in \mathrm{dom}\, f_0$ 有 $\nabla f_0(x^*)^\top (y - x^*) \geq 0$，则 $x^*$ 是无约束凸优化问题 $\min\limits_x \{f_0(x)\}$ 的一个最优解。反之亦然！ 若 $\mathrm{dom}\, f_0 = \mathbb{R}^n$，则进一步有

$$x^* \in \arg\min_{x \in \mathbb{R}^n} \; f_0(x) \quad \iff \quad \nabla f_0(x^*) = 0.$$

## 命题 10

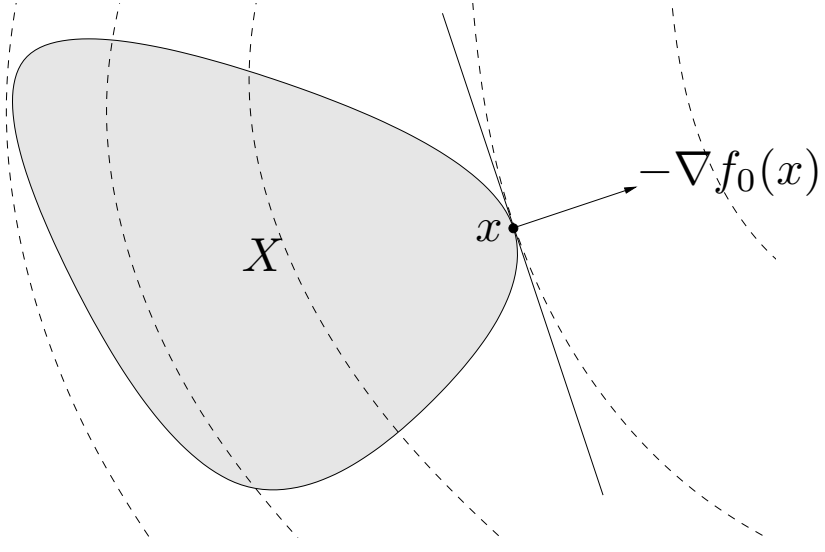
考虑有约束凸优化问题

$$\min_x \; f_0(x) \qquad \text{s.t.} \qquad x \in \mathcal{X},$$

则 $x^*$ 最优 $\iff$ $x^* \in \mathcal{X}$ 且 $\nabla f_0(x^*)^\top (y - x^*) \geq 0,\ \forall y \in \mathcal{X} \cap \mathrm{dom}\, f_0$。

**命题 10** 的几何解释：

- 可行域 $\mathcal{X}$ 由阴影表示；
- $f_0$ 的等值曲线由虚线表示（假设越往右越小）；
- 点 $x$ 是最优解：在 $x$ 处，任意可行方向 $y-x$ 都不是 $f_0$ 的下降方向，即 $y-x$ 与 $\nabla f_0(x)$ 的夹角都小于 $90°$。



**例1**：考虑如下线性约束的凸优化问题：（假设最优解存在，$\mathrm{dom}\, f_0 = \mathbb{R}^n$）

$$\min_x \quad f_0(x) \quad \text{s.t.} \quad Ax = b.$$

由**命题 10** 可知：

| **(a)** | | **(b)** |
|---|---|---|
| 若 $x^*$ 满足 $Ax^* = b$ 且使得 $f_0(x^*)$ 最小 | $\Longleftrightarrow$ | 对 $\forall y$ 满足 $Ay = b$，有 $\nabla f_0\,(x^*)^\top (y - x^*) \geq 0$ |

注意到，$x^*$ 可看成 $Ax = b$ 的一个特解。这样，对 $\forall y$ 满足 $Ay = b$，可知 $y = x^* + v$，$v \in \mathcal{N}(A)$，其中 $\mathcal{N}(A)$ 表示 $A$ 的零空间。

于是，**(b)** 可进一步等价于

$$\nabla f_0\,(x^*)^\top v \geqslant 0,\ \forall v \in \mathcal{N}(A) \Rightarrow \begin{cases} A \text{ 可逆}, & v = 0,\ x^* = A^{-1}b \\ A \text{ 不可逆}, & \nabla f_0(x^*) \perp \mathcal{N}(A) \end{cases}$$

# 连续可微问题的最优性理论

**例2**：考虑如下非负约束的凸优化问题：（假设最优解存在，$\mathrm{dom}\, f_0 = \mathbb{R}^n$）

$$\min_x \quad f_0(x) \quad \text{s.t.} \quad x \geq 0.$$

由**命题 10** 知：若 $x^*$ 最优 $\iff$ $x^* \geq 0$，且 $\nabla f_0(x^*)^\top (y - x^*) \geq 0,\ \forall y \geq 0$

对于该类约束凸优化问题，有如下结论：

- 首先，任取 $y_i = x^* + e_i$（其中 $e_i$ 为单位向量，即第 $i$ 个元素为 1，其余为0 ）有 $\nabla f_0(x^*)^\top (y - x^*) = [f_0(x^*)]_i \geq 0$，故有 $\nabla f_0(x^*) \geq 0$。
- 其次，取 $y = 0$ 有 $\nabla f_0(x^*)^\top x^* \leq 0$；取 $y = 2x^*$ 有 $\nabla f_0(x^*)^\top x^* \geq 0$。由此可知

$$\nabla f_0(x^*)^\top x^* = 0.$$

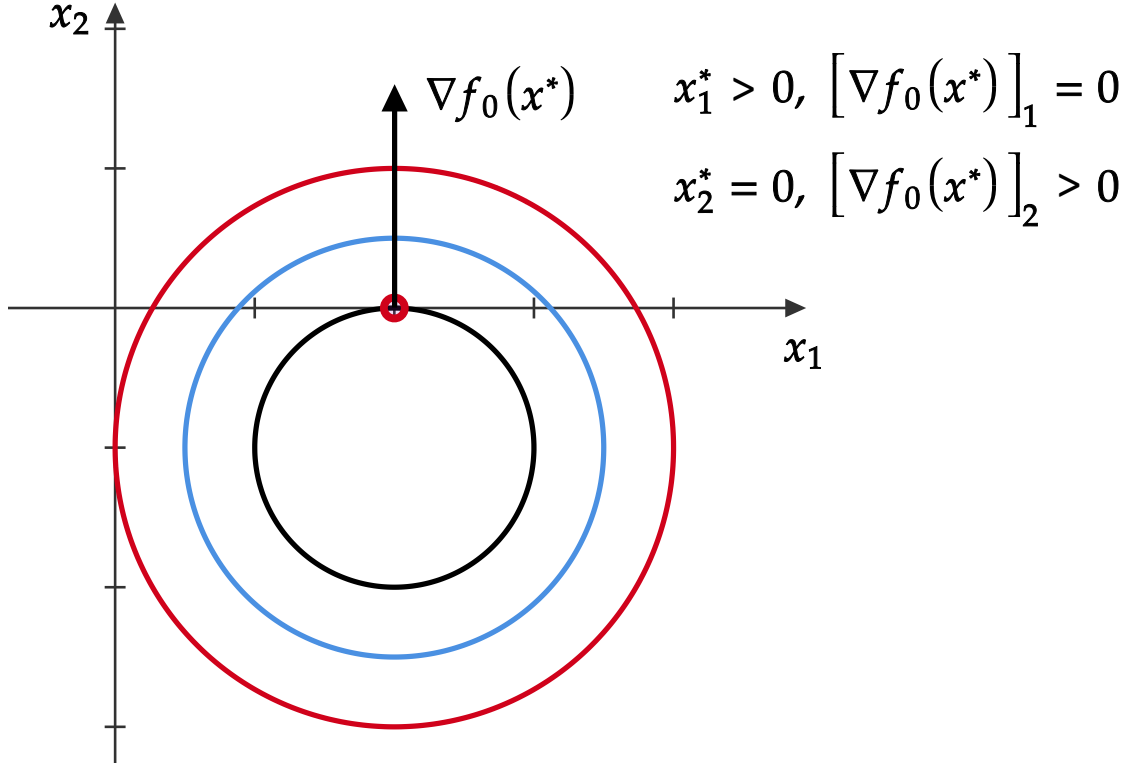
综上，可得该类约束凸优化问题的最优性条件：（**充要条件**，以后会讲）

$$x^* \geq 0, \quad \nabla f_0(x^*) \geq 0, \quad \underbrace{x_i^* \left[\nabla f_0(x^*)\right]_i = 0}_{\text{互补性 (complementarity)}}, \quad i = 1, 2, \cdots, n.$$

例：

$$\min_{x_1 \geq 0,\, x_2 \geq 0} \quad f(x_1, x_2) = (x_1 - 2)^2 + (x_2 + 1)^2.$$

易知，最优解为 $\begin{bmatrix} x_1^* \\ x_2^* \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$，且 $\nabla f(x_1^*, x_2^*) = \begin{bmatrix} 2(x_1^* - 2) \\ 2(x_2^* + 1) \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}$.



# 线性规划

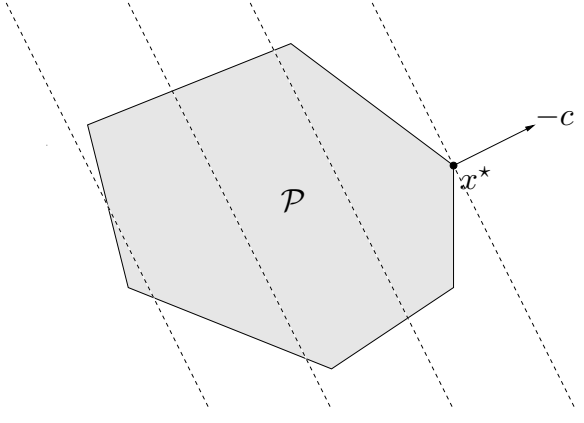
线性规划 (Linear Program, LP)：目标和约束都是线性的凸优化问题

$$\begin{array}{lll} \min\limits_{x} & c^\top x & (c \in \mathbb{R}^n) \\ \text{s.t.} & Gx \leq h, & \left(G \in \mathbb{R}^{m\times n},\ h \in \mathbb{R}^m\right) \\ & Ax = b. & \left(A \in \mathbb{R}^{p\times n},\ b \in \mathbb{R}^p\right) \end{array}$$

相关历史：

- Leonid Kantorovich (1912-1986) 给出线性规划的应用
- George Dantzig (1914-2005) 提出线性规划的单纯形算法
- John von Neumann (1903-1957) 完善线性规划的理论

**线性规划示意图：** 在多面体约束中，寻找线性目标函数的最小值。



# 线性规划案例

## 例：营养搭配问题

一个人每天需摄入 $m$ 种营养成分，而市场提供 $n$ 种不同食材，每单位的 $j$ 种食材售价为 $c_j$，且含有 $a_{ij}$ 单位的 $i$ 种营养成分。假设每天对 $i$ 种营养成分的需求量不少于 $b_i$，试设计一份在满足营养要求下的最经济食谱。

**分析：** 设每人每天需要各种食品的数量分别为 $x_1, x_2, \cdots, x_n$，于是可写出以下线性规划问题：

$$\min_{x_1,x_2,\cdots,x_n} \quad \sum_{j=1}^{n} c_j x_j \qquad [c_1, c_2, \ldots, c_n]\,[x_1, x_2, \ldots, x_n]^\top$$

$$\text{s.t.} \quad \sum_{j=1}^{n} a_{ij} x_j \geq b_i, \quad i \in [m], \qquad \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \geq \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix}$$

$$x_j \geq 0, \quad j \in [n]. \qquad [x_1, x_2, \ldots, x_n]^\top \geq 0$$

# 线性规划的标准化 I

线性规划问题的标准化：

$$\Longrightarrow \quad \begin{aligned} \min_{x,\,s} \quad & c^\top x \\ \text{s.t.} \quad & Gx + s = h, \\ & Ax = b, \\ & s \geq 0. \end{aligned} \quad \Longrightarrow \quad \begin{aligned} \min_{x',\,x'',\,s} \quad & c^\top x' - c^\top x'' \\ \text{s.t.} \quad & Gx' - Gx'' + s = h, \\ & Ax' - Ax'' = b, \\ & x' \geq 0, \quad x' \geq 0, \quad s \geq 0. \end{aligned}$$

（步骤1） 引入松弛变量 $s$，把不等式约束 $Gx \leq h$ 转化为等式约束 $Gx + s = h$ 和 简单的不等式约束 $s \geq 0$

（步骤2） 将 $x$ 分成两个非负向量的差，即 $x = x' - x''$ 且 $x',\, x'' \geq 0$，使得所有优化变量都非负

# 线性规划的标准化 II

于是，记 $I$ 为单位矩阵，

$$\boldsymbol{x} = \begin{bmatrix} x' \\ x'' \\ s \end{bmatrix}, \quad \boldsymbol{c} = \begin{bmatrix} c \\ -c \\ 0 \end{bmatrix}, \quad \boldsymbol{b} = \begin{bmatrix} h \\ b \end{bmatrix}, \quad \boldsymbol{A} = \begin{bmatrix} G & -G & I \\ A & -A & 0 \end{bmatrix}.$$

线性规划问题的标准形式：

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & \boldsymbol{c}^\top \boldsymbol{x} \\ \text{s.t.} \quad & \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}, \\ & \boldsymbol{x} \geq 0. \end{aligned}$$

标准形式可用于一般理论分析和通用算法设计，方便通用求解器的开发。

# *线性分式规划 I

**线性分式规划** (Linear Fractional Program)：

在多面体上极小化**线性函数比值**的优化问题

$$\begin{aligned} \min_{x} \quad & f_0(x) := \frac{c^\top x + d}{e^\top x + f} \\ \text{s.t.} \quad & Gx \leq h, \\ & Ax = b, \end{aligned} \tag{$P_0$}$$

其中 $\operatorname{dom} f_0 = \left\{x \in \mathbb{R}^n \mid e^\top x + f > 0\right\}$。注意，$f_0$ 拟凸，因此 $(P_0)$ 是一个拟凸问题。

若可行域 $\left\{x \in \mathbb{R}^n \mid Gx \leq h,\ Ax = b,\ e^\top x + f > 0\right\}$ 非空，则 $(P_0)$ 等价于如下凸的**线性规划**问题：

$$\begin{aligned} \min_{y,\,z} \quad & c^\top y + dz \\ \text{s.t.} \quad & Gy - hz \leq 0, \quad Ay - bz = 0, \\ & e^\top y + fz = 1, \quad z \geqslant 0. \end{aligned} \tag{$P_1$}$$

# *线性分式规划 II

**分析思路：**（作简单了解）

1. 易分析：若 $x$ 在 $(P_0)$ 中可行，则 $y=\dfrac{x}{e^\top x+f}$，$z=\dfrac{1}{e^\top x+f}$ 必在 $(P_1)$ 中可行，且目标函数值相同；
2. 另一方面，若 $(y,z)$ 在 $(P_1)$ 中可行，考虑以下两种情况：
   (a) 当 $z\neq 0$ 时，易知 $x=\dfrac{y}{z}$ 在 $(P_0)$ 中可行，且目标函数值相同，即 $f_0(x)=c^\top y+dz$；
   (b) 当 $z=0$ 时，设 $x_0$ 为 $(P_0)$ 的一个可行点（必存在，因为可行域非空），则对 $\forall t\geqslant 0$，$x=x_0+ty$ 也是 $(P_0)$ 的可行解，事实上

$$\begin{cases} Gx_0\leq h \\ Ax_0=b \\ e^\top x_0+f>0 \end{cases} \quad \& \quad \begin{cases} Gy\leq 0 \\ Ay=0 \\ e^\top y=1 \end{cases} \quad \Longrightarrow \quad \begin{cases} Gx=Gx_0+tGy\leq Gx_0\leq h \\ Ax=Ax_0+tAy=Ax_0=b \\ e^\top x+f=e^\top x_0+f+te^\top y>0 \end{cases}$$

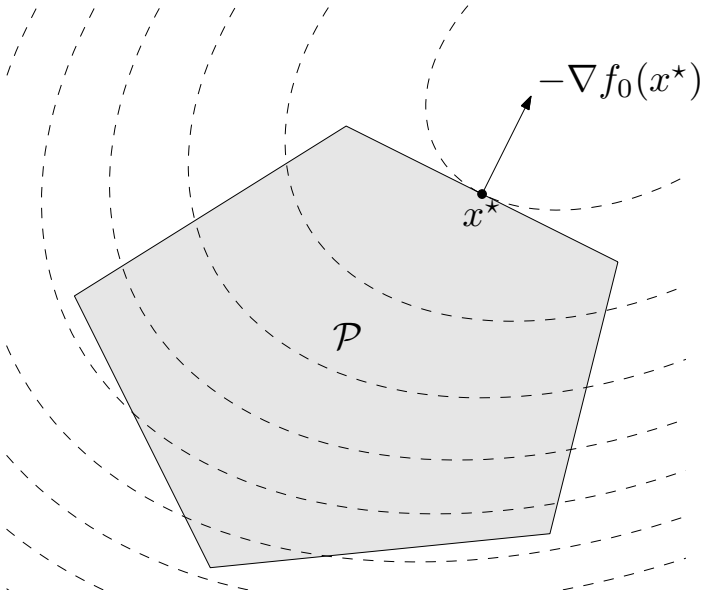
且 $f_0(x)=f_0(x_0+ty)=\dfrac{c^\top x_0+tc^\top y+d}{e^\top x_0+te^\top y+f}\overset{t\to\infty}{\longrightarrow} c^\top y.$

上式说明必能找到 $x$ 在 $(P_0)$ 中可行，且其目标函数值可以任意接近 $(P_1)$ 的函数值。这种情况意味着，原线性分式规划的目标函数有下界，但最优解不存在。

**二次规划** (Quadratic Program, QP)：

目标是凸二次型，约束是线性的凸优化问题

$$\begin{array}{lll} \min\limits_{x} & \dfrac{1}{2}x^\top Qx + q^\top x + r & \left(Q \in S_+^n,\ q \in \mathbb{R}^n,\ r \in \mathbb{R}\right) \\ \text{s.t.} & Gx \leq h, & \left(G \in \mathbb{R}^{m\times n},\ h \in \mathbb{R}^m\right) \\ & Ax = b. & \left(A \in \mathbb{R}^{p\times n},\ b \in \mathbb{R}^p\right) \end{array}$$

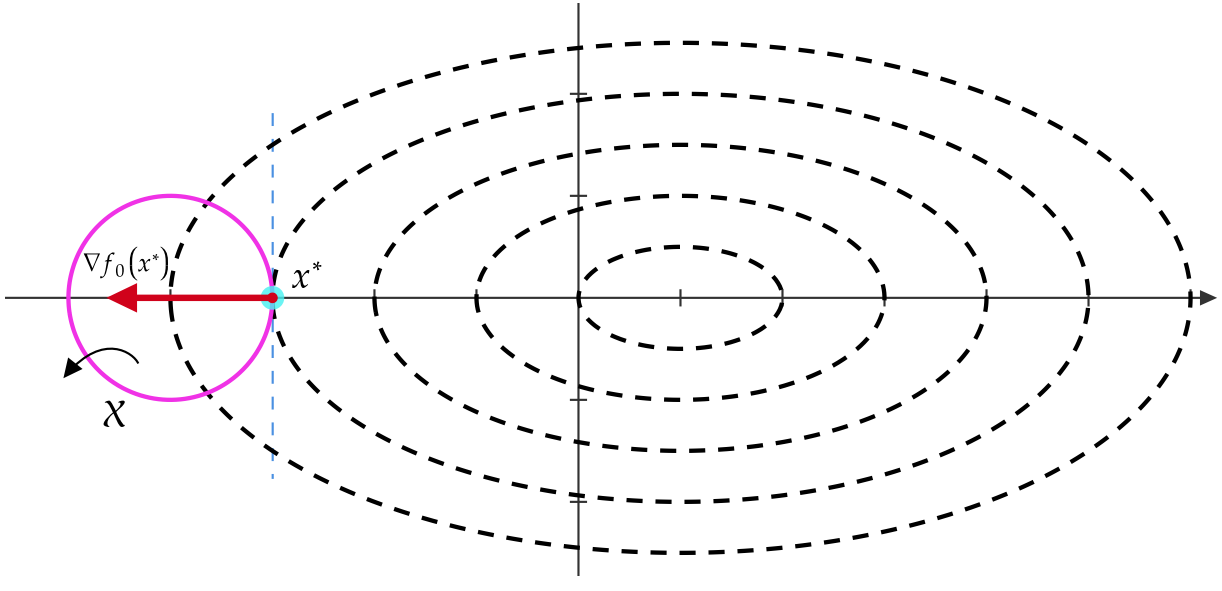


# 二次约束二次规划

**二次约束二次规划** (Quadratic Constrained Quadratic Program, QCQP)：

目标和不等式约束是凸二次型的凸优化问题

$$
\begin{aligned}
\min_{x} \quad & \frac{1}{2}x^\top Q_0 x + q_0^\top x + r_0 && \left(Q_0 \in S_+^n,\ q_0 \in \mathbb{R}^n,\ r_0 \in \mathbb{R}\right) \\
\text{s.t.} \quad & \frac{1}{2}x^\top Q_i x + q_i^\top x + r_i \leqslant 0,\ \ i \in [m], && \left(Q_i \in S_+^n,\ q_i \in \mathbb{R}^n,\ r_i \in \mathbb{R}\right) \\
& Ax = b. && \left(A \in \mathbb{R}^{p\times n},\ \ b \in \mathbb{R}^p\right)
\end{aligned}
$$



# 投资组合问题 I

**投资组合问题 (Portfolio Optimization)**：

假设市场上有 $n$ 只股票，用 $c_i$ 表示股票 $i$ 当前的单位价格。由于市场波动，经过时间 $T$ 后，股票 $i$ 的价格将变化为 $(1+p_i)c_i$：

| | 当前价格 | 价格变化率 | 经过时间 $T$ 后价格 |
|---|---|---|---|
| $\#1$ | $c_1$ | $p_1$ | $(1+p_1)c_1$ |
| $\vdots$ | $\vdots$ | $\vdots$ | $\vdots$ |
| $\#n$ | $c_n$ | $p_n$ | $(1+p_n)c_n$ |

问题：给定预算$B$，找出最佳投资组合，使得经过时间 $T$ 后的收益最大化。

(Linear Program)

$$\begin{aligned} \max_{x_1,\cdots,x_n} \quad & p_1c_1x_1 + \cdots + p_nc_nx_n \\ \text{s.t.} \quad & c_1x_1 + \cdots + c_nx_n \le B, \\ & x_1, \cdots, x_n \geqslant 0. \end{aligned}$$

**思考**：实际市场中，价格变化率 $p_1, \cdots, p_n$ 是随机的（未知的），上述模型并不一定能反应真实情况，应当作何修改？

# 投资组合问题 II

考虑价格变化率 $p_1, \cdots, p_n$ 是随机的情况。

记 $p = \left(p_1, \ldots, p_n\right)^\top$，设其均值为 $\bar{p} = \left(\bar{p}_1, \ldots, \bar{p}_n\right)^\top$，协方差矩阵为 $\Sigma$。

注意，这两个统计量一般也是未知的，实际计算时，可基于历史数据计算出样本均值和样本协方差矩阵来得到。

于是，可以建立如下风险极小化的投资模型 (Quadratic Program)：

$$
\begin{array}{lll}
\min\limits_{x_1,\cdots,x_n} & x^\top \Sigma x & \text{最小化风险} \\
\text{s.t.} & \bar{p}_1 c_1 x_1 + \cdots + \bar{p}_n c_n x_n \geq r_{min}, & \text{保证最小期望收益} \\
& c_1 x_1 + \cdots + c_n x_n \leq B, & \text{预算约束} \\
& x_1, \cdots, x_n \geqslant 0. & \text{投资非负}
\end{array}
$$

# 回归问题

- 最小二乘问题（带噪声测量 $b = Ax + \epsilon$）

$$x^* = \arg\min_x \frac{1}{2}\|Ax - b\|_2^2 = \arg\min_x \frac{1}{2}\left(x^\top A^\top Ax - 2b^\top Ax + b^\top b\right).$$

该问题显然是 QP.

- $\ell_1$ 范数正则化最小二乘问题（**LASSO**） $\rightarrow$ 希望解 $x^*$ 稀疏

$$x^* = \arg\min_x \frac{1}{2}\|Ax - b\|_2^2 + \lambda_1 \|x\|_1.$$

$$x^* = \arg\min_x \left\{\frac{1}{2}\|Ax - b\|_2^2 \mid \|x\|_1 \le \varepsilon_1\right\}.$$

- $\ell_2$ 范数正则化最小二乘问题（岭回归） $\rightarrow$ 希望解 $x^*$ 中各元素幅度相似

$$x^* = \arg\min_x \frac{1}{2}\|Ax - b\|_2^2 + \frac{\lambda_2}{2}\|x\|_2^2.$$

$$x^* = \arg\min_x \left\{\frac{1}{2}\|Ax - b\|_2^2 \mid \|x\|_2^2 \le \varepsilon_2\right\}.$$

# 半定规划

半定规划 (Semidefinite Programming, SDP)

优化变量是半正定矩阵的凸优化问题：

$$\begin{aligned} \min_{X} \quad & \operatorname{tr}(CX) && \left(C \in \mathbb{R}^{n\times n}\right) \\ \text{s.t.} \quad & \operatorname{tr}(A_i X) = b_i, \quad i = 1, \cdots, p, && \left(A_i \in \mathbb{R}^{n\times n},\ b_i \in \mathbb{R}\right) \\ & X \succeq 0. \end{aligned}$$

考虑特殊情况：当 $X$, $C$, $A_i$ 均为对角矩阵时，

$$\begin{aligned} \min \quad & (\operatorname{diag}(C))^{\top} \operatorname{diag}(X) \\ \text{s.t.} \quad & (\operatorname{diag}(A_i))^{\top} \operatorname{diag}(X) = b_i, \quad i = 1, \cdots, p, \\ & \operatorname{diag}(X) \geq 0. \end{aligned}$$

此时，半定规划退化为线性规划问题。

# 多目标优化问题

之前，我们所学的优化问题都只有一个目标函数 $f_0 : \mathbb{R}^n \to \mathbb{R}$（左侧案例），即极小化一个目标函数：

$$\begin{array}{ll} \min\limits_x & f_0(x) \\ \text{s.t.} & f_i(x) \leqslant 0, \quad i = 1, \cdots, m, \\ & h_j(x) = 0, \quad j = 1, \cdots, p. \end{array} \quad \Rightarrow \quad \begin{array}{ll} \min\limits_x & F(x) = (F_1(x), \cdots, F_q(x))^\top \\ \text{s.t.} & f_i(x) \leqslant 0, \quad i = 1, \cdots, m, \\ & h_j(x) = 0, \quad j = 1, \cdots, p. \end{array}$$

而多目标优化问题则有多个子目标函数 $F_1, \cdots, F_q$，即同时极小化多个量，其目标函数实际是一个向量值函数 $F(x) : \mathbb{R}^n \to \mathbb{R}^q$（右侧案例）。

如果约束条件 $f_1, \cdots, f_m$ 是凸的，$h_1, \cdots, h_p$ 是仿射的，并且所有子目标函数 $F_1, \cdots, F_q$ 是凸的，则称该多目标优化问题是凸的。

# 多目标优化问题

例：投资组合问题

$$\begin{array}{ll} \min & \text{风险} \\ \text{s.t.} & \text{期望收益} \geq r_{\min} \\ & \text{预算约束} \end{array} \quad \Rightarrow \quad \begin{array}{ll} \min & \begin{bmatrix} \text{风险} \\ \text{负期望收益} \end{bmatrix} \\ \text{s.t.} & \text{预算约束} \end{array}$$

容易看到，右侧的多目标优化问题不满足于固定的预期收益 $r_{\min}$，而是希望得到尽可能多的收益，模型更符合一些投资者的偏好。

# 多目标优化问题的最优解

**定义 20**

对于多目标优化问题

$$\begin{aligned} \min_{x} \quad & F(x) = (F_1(x), \cdots, F_q(x))^\top \\ \text{s.t.} \quad & f_i(x) \leqslant 0, \quad i = 1, \cdots, m, \\ & h_j(x) = 0, \quad j = 1, \cdots, p. \end{aligned}$$

假设 $x$ 和 $y$ 都是该问题的可行解：

- 如果 $F_i(x) \leqslant F_i(y)$，则称在第 $i$ 个目标上 $x$ 至少与 $y$ 一样好；
- 如果 $F_i(x) \leqslant F_i(y)$, $\forall i = 1, \cdots, q$，并且对于至少一个 $j$，有 $F_j(x) < F_j(y)$，则称 $x$ 比 $y$ 更优，或 $x$ 支配 $y$；
- 如果存在 $x^*$ 满足可行性，且对任意可行的 $y$ 有 $F_i(x^*) \leq F_i(y)$, $\forall i = 1, 2, \cdots, q$，则称 $x^*$ 是多目标优化问题的一个最优解。

**思考**：多目标优化问题的最优解 $x^*$ 一定存在吗？

# 多目标优化问题的最优解

在多目标优化中，最优解 $x^*$ 应当满足对于任意可行的 $y$，都有

$$F_i\left(x^*\right) \leqslant F_i(y), \quad i=1, \cdots, q.$$

等价地，$x^*$ 应当同时是以下 $q$ 个优化问题的最优解： $j=1,2, \cdots, q$,

$$\begin{aligned} \min_{x} \quad & F_j(x), \\ \text{s.t.} \quad & f_i(x) \leqslant 0, \quad i=1, \cdots, m, \\ & h_i(x)=0, \quad i=1, \cdots, p. \end{aligned}$$

显然，这样的最优解 $x^*$ 不一定存在!

1. 当 $x^*$ 存在时，每个 $F_j$ 都能在可行域上达到最小值；
2. 当 $x^*$ 不存在时，我们需要在目标函数 $F_j$ 之间做出权衡。

# 帕累托(Pareto)最优解

**定义 21 (帕累托(Pareto)最优解)**

对于多目标优化问题

$$\begin{aligned} \min_{x} \quad & F(x) = (F_1(x), \cdots, F_q(x))^\top \\ \text{s.t.} \quad & f_i(x) \leqslant 0, \quad i = 1, \cdots, m, \\ & h_j(x) = 0, \quad j = 1, \cdots, p. \end{aligned}$$

若对于一个可行解 $x$，不存在比 $x$ 更优的其它可行解，则称 $x$ 为一个**帕累托最优解**。

- 帕累托最优值：**帕累托最优解**所对应的函数值。
- 帕累托最优面：**帕累托最优值**所构成的曲面。

# 多目标优化问题的求解

一个简单的思路：求解子目标优化问题的加权组合 $(\lambda_j > 0,\ j = 1, \cdots, q)$ 得到一个**帕累托最优解**：

$$\begin{aligned} \min_x \quad & \sum_{j=1}^{q} \lambda_j F_j(x) \qquad \text{原目标函数 } \left(F(x) = (F_1(x), \cdots, F_q(x))^\top\right) \\ \text{s.t.} \quad & f_i(x) \leqslant 0, \quad i = 1, \cdots, m, \\ & h_i(x) = 0, \quad i = 1, \cdots, p. \end{aligned}$$

**例**：考虑最小二乘问题，希望拟合效果最好，同时解最稀疏：

$$\min_x \begin{bmatrix} \|Ax - b\|_2^2 \\ \|x\|_1 \end{bmatrix}.$$

实际中，人们可以通过求解 $\ell_1$ **范数正则化最小二乘问题**达到近似的目的：

$$\min_x \ \frac{1}{2} \|Ax - b\|_2^2 + \lambda_1 \|x\|_1 .$$