模式识别

视觉词元的表征和学习



报告人：李冠彬

中山大学 计算机学院

课程提纲

CONTENTS

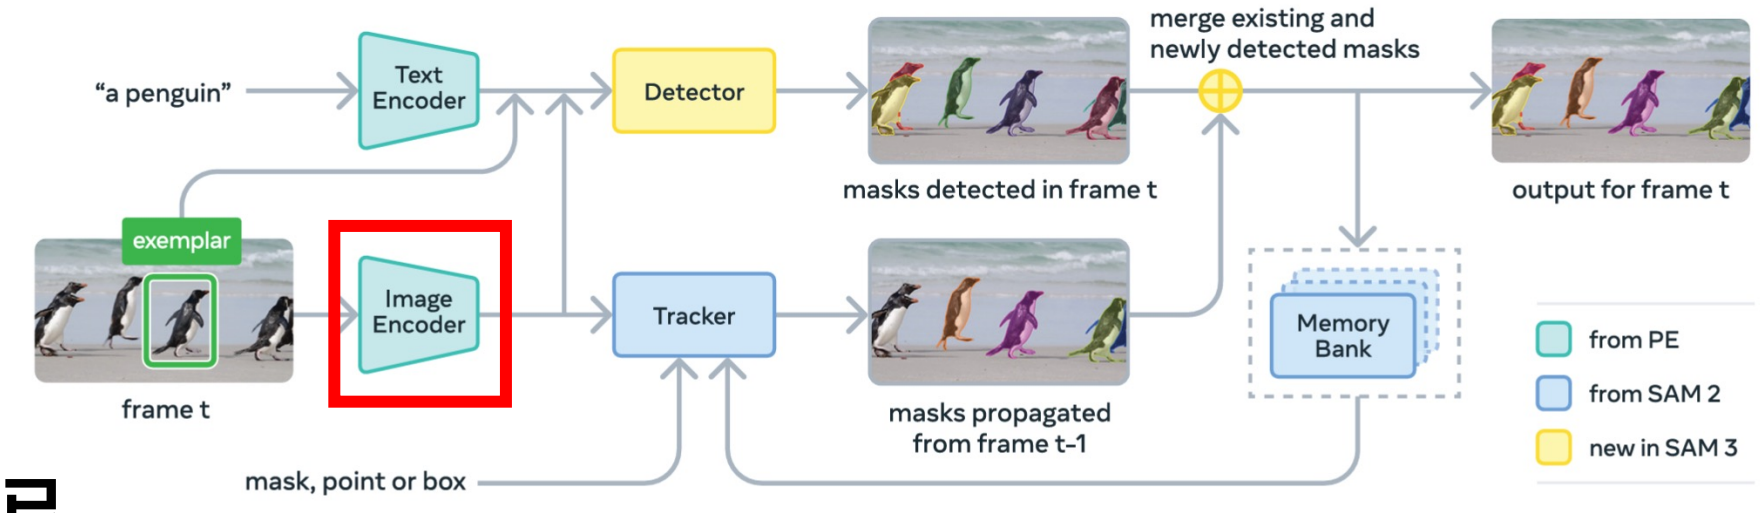
一、从图像到 Token: VIT 的基本思想

二、Visual Token 的改进：
更合理、更高效的视觉表征

三、从视觉到多模态：
Visual Token 如何对接语言模型

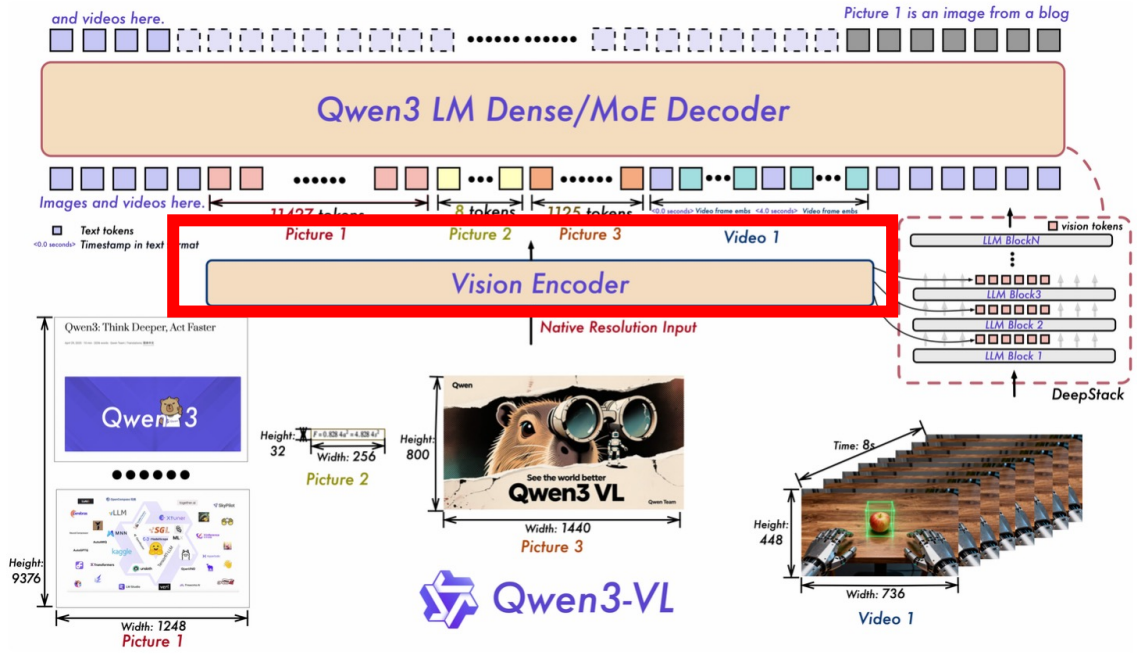
为什么要理解视觉 Token?

SAM3



主流的视觉/多模态模型都已经默认以视觉 Token 对图片进行编码。

Qwen3-VL



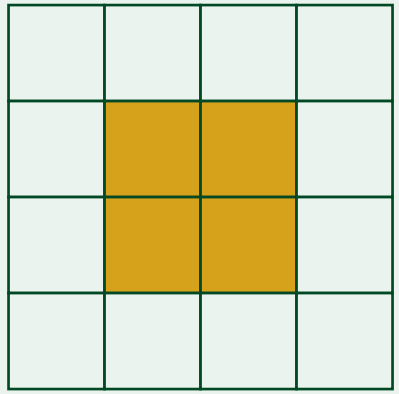
核心问题

图像明明是二维结构，要如何变成 Token 序列?

图像 vs 文本

图像

- 二维网格组织
- 上下左右邻接关系重要
- 局部区域之间有天然空间结构



文本

- 一维序列组织
- 前后顺序关系重要
- 序列位置天然存在



最简单的办法：把图像变成小块



缺点：可能失去二维结构

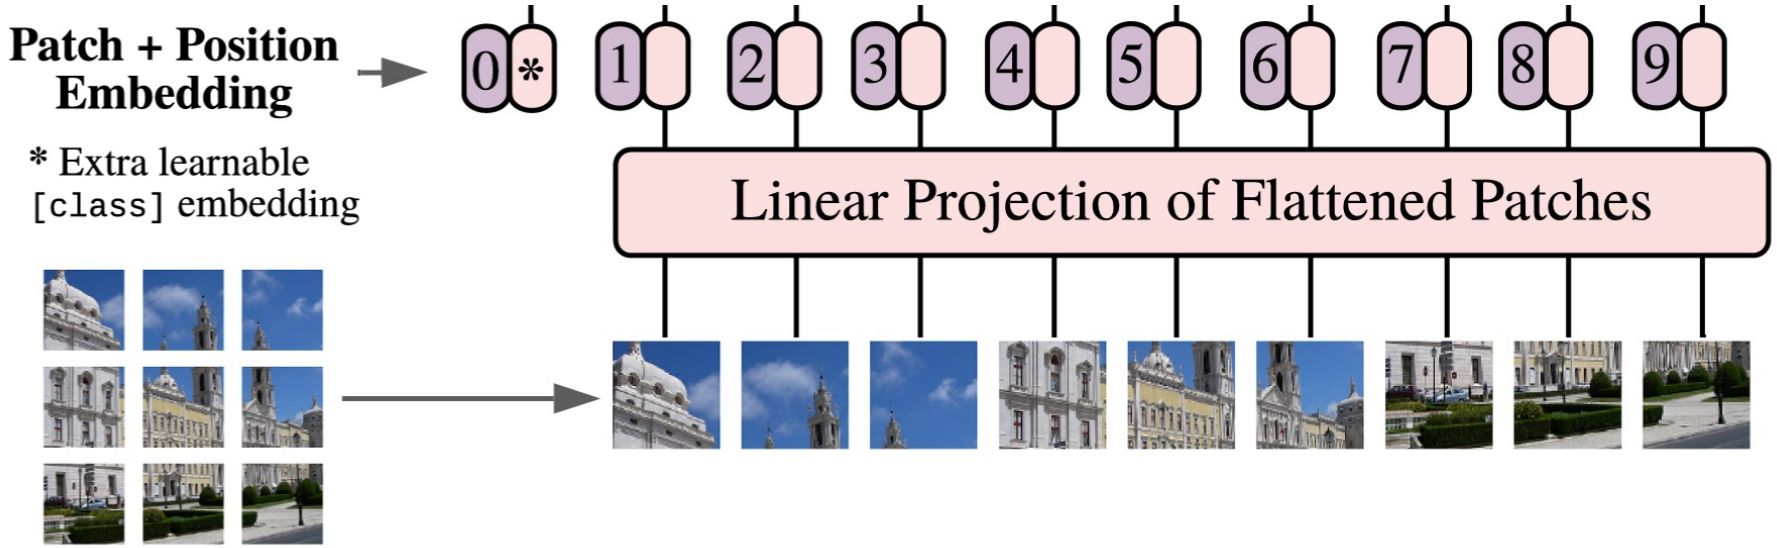
Patch Size 的影响



Patch size 更大：Token 更少，更省计算量

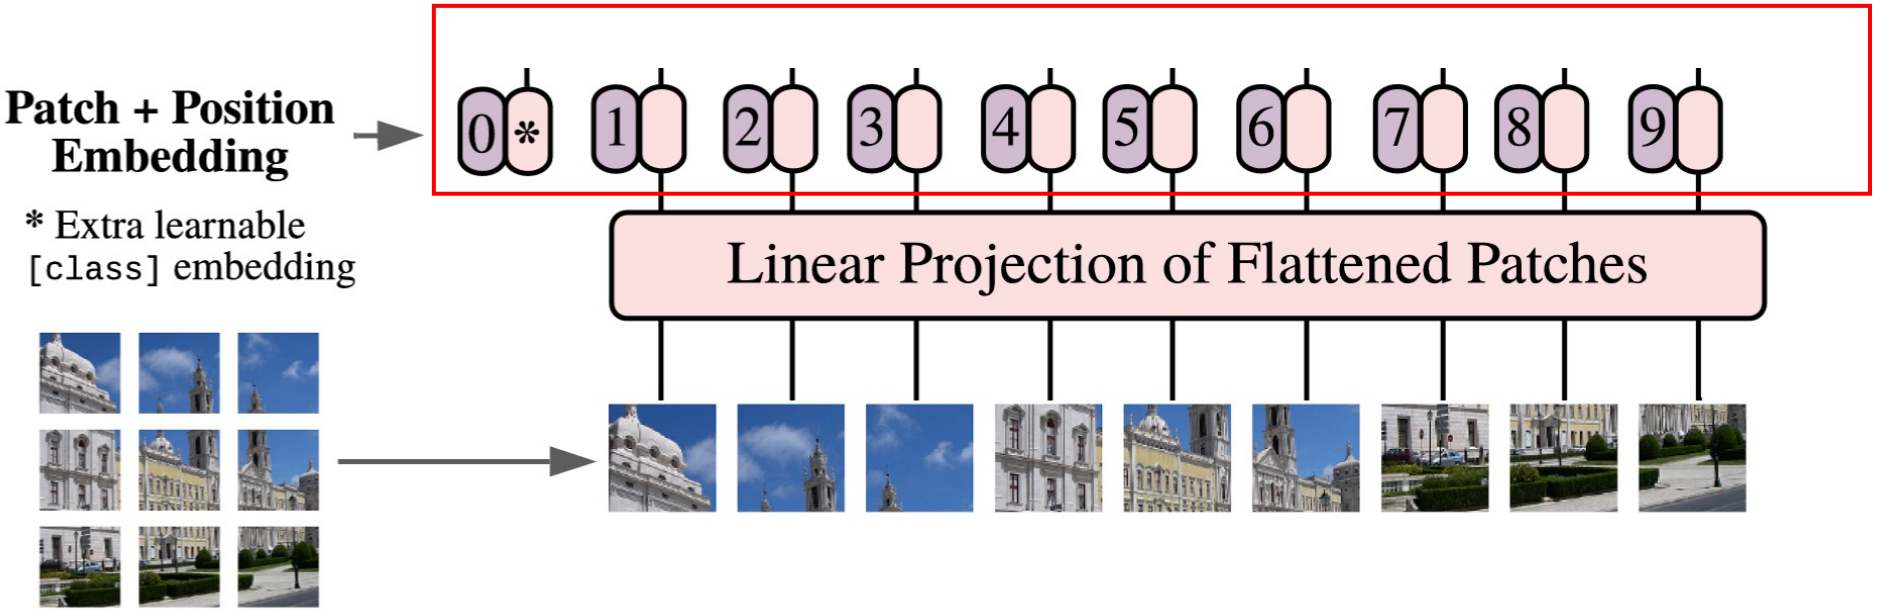
Patch size 更小：细节更多

从 patch 到 Token



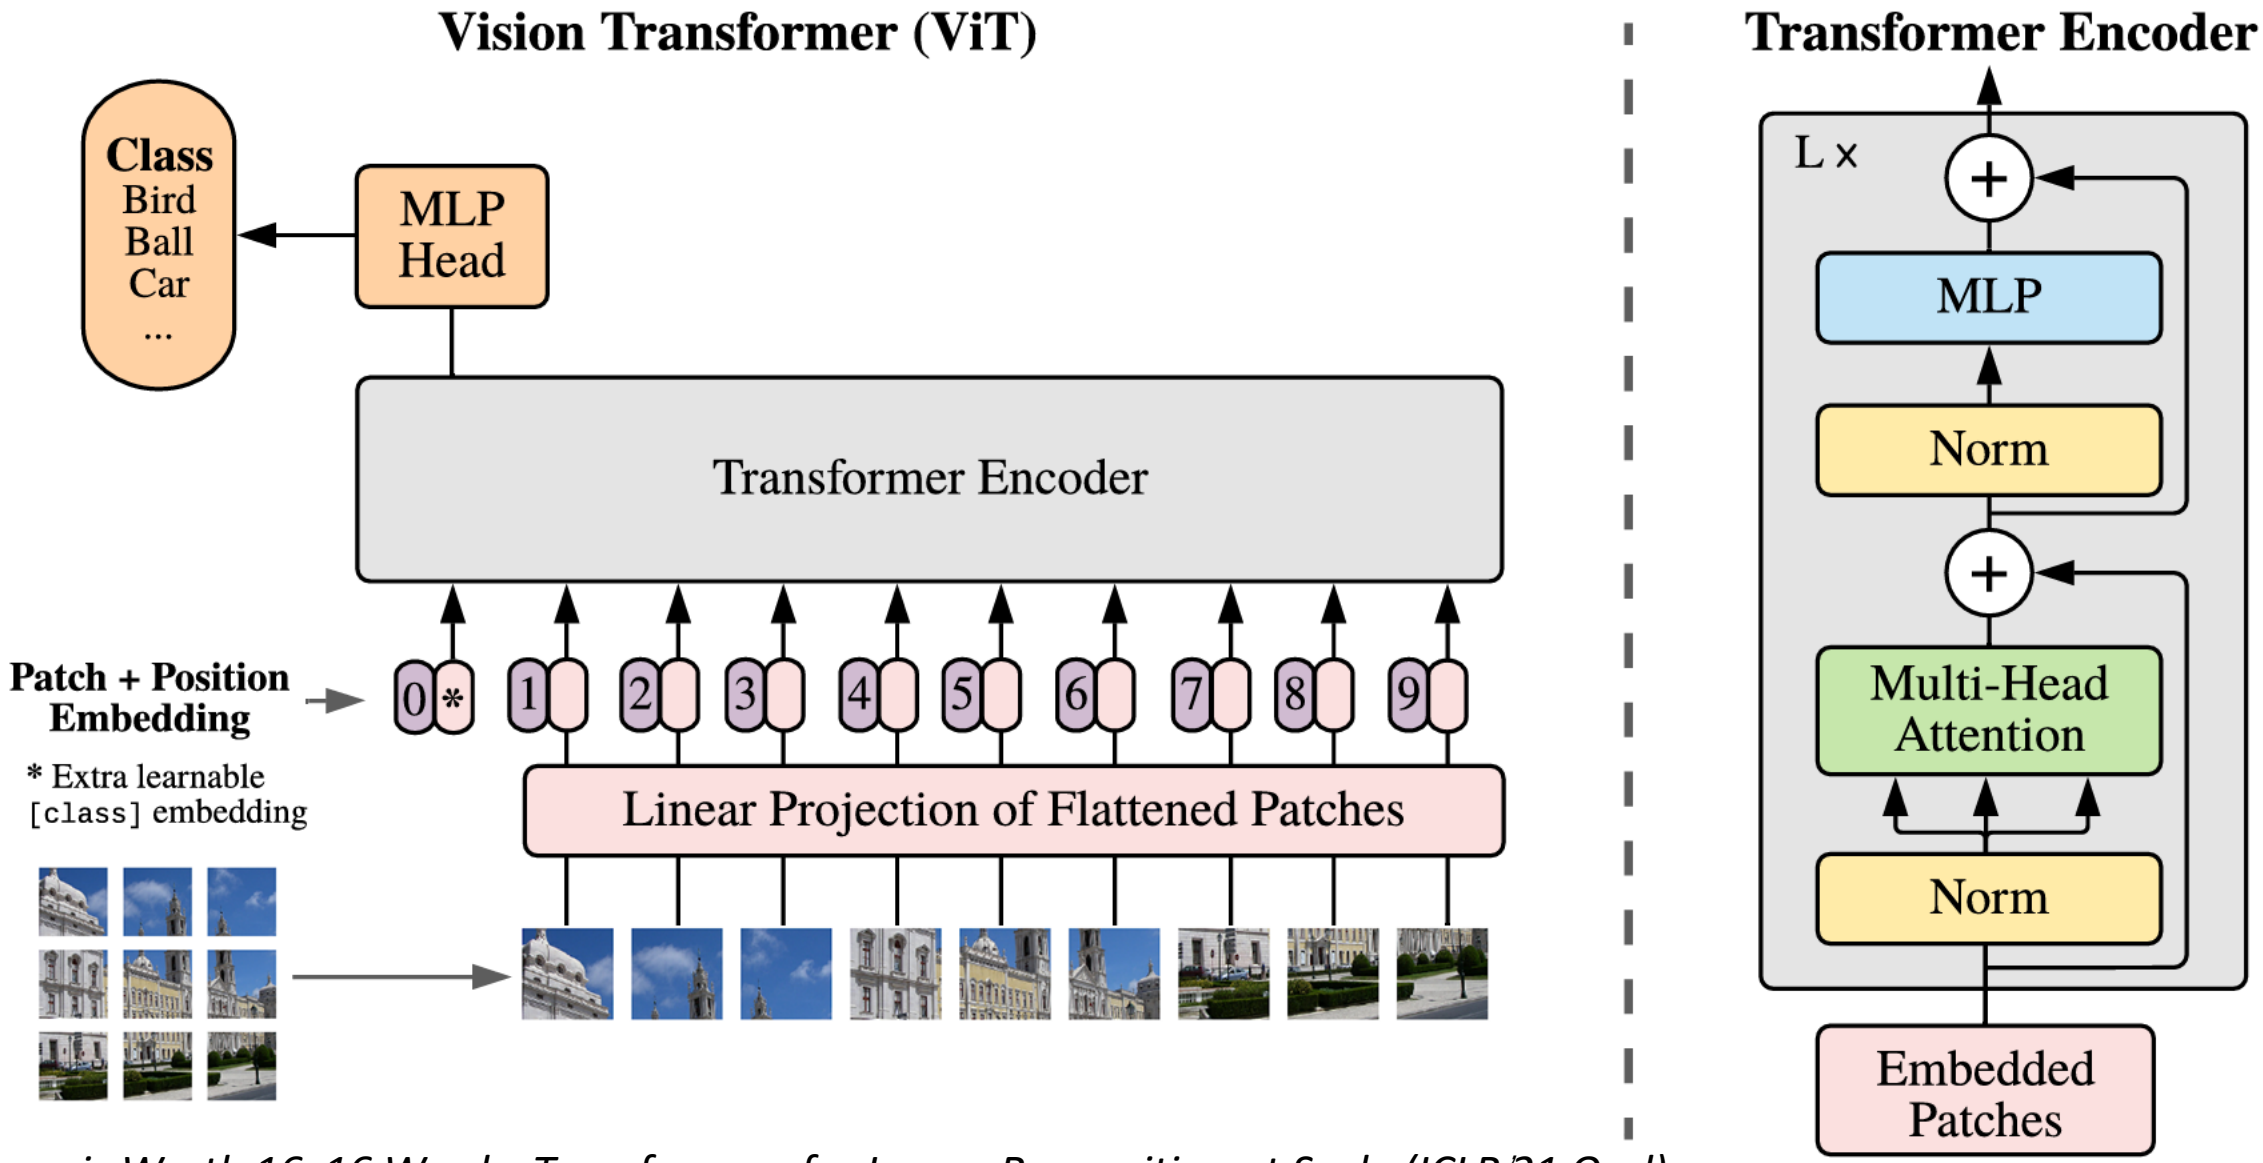
切块 -> 展平 -> 线性映射

为什么还需要位置编码



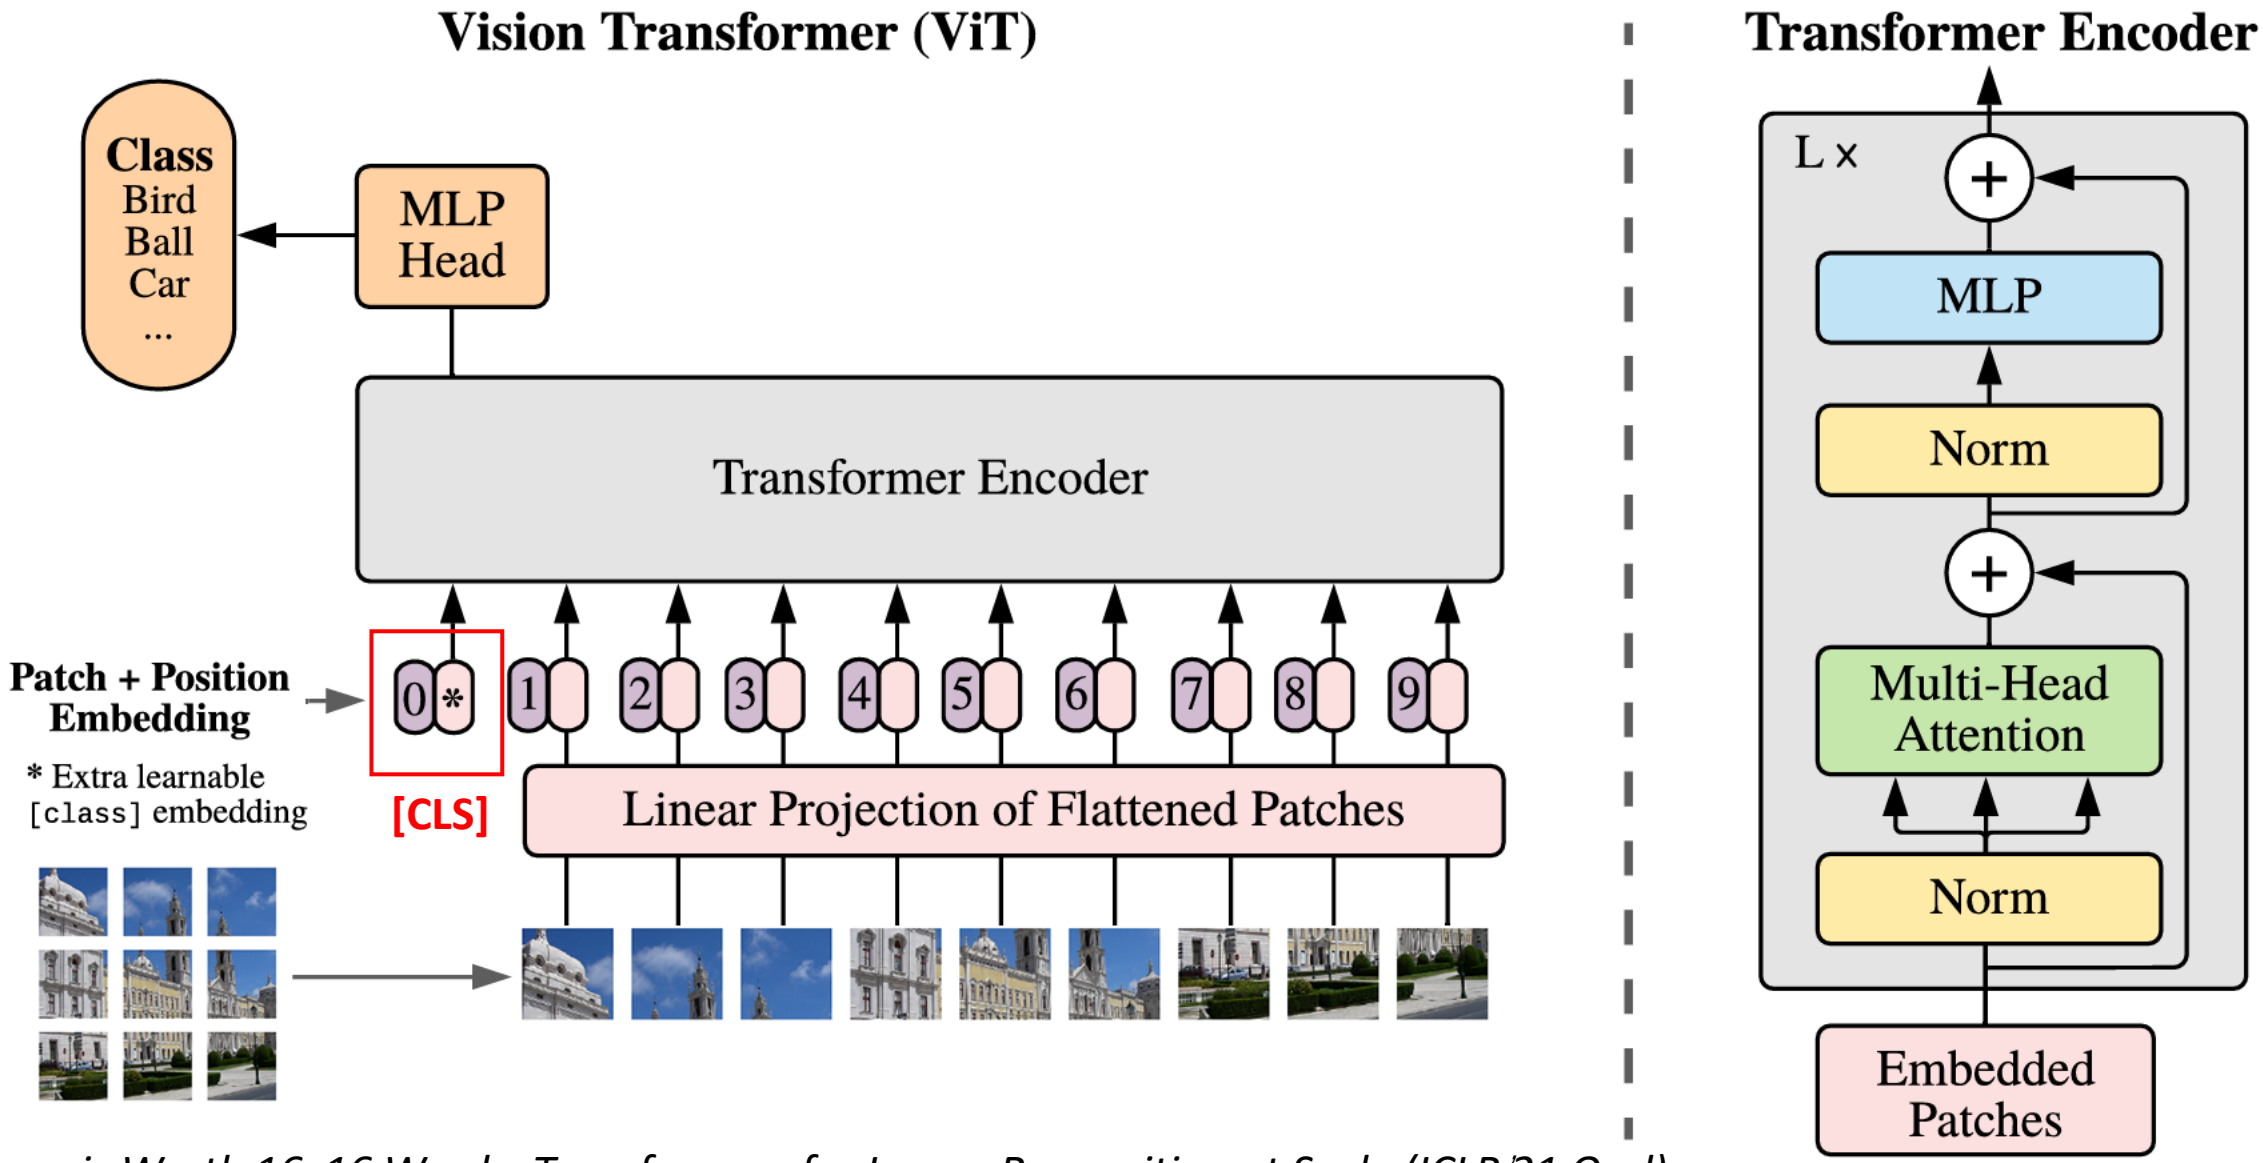
只有 Token 内容，损失了图像的空间结构信息

Vision Transformer (ViT) 整体结构



An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale (ICLR'21 Oral)

[CLS] Token 在做什么?

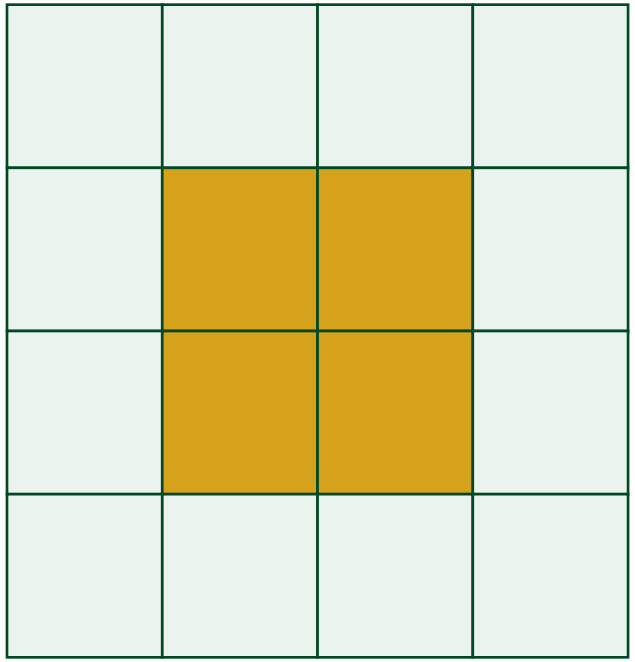


An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale (ICLR'21 Oral)

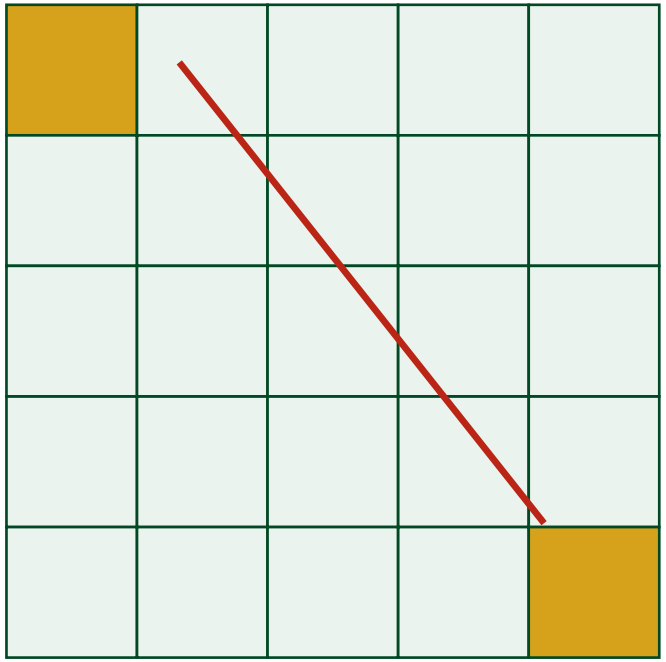
结果

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	**88.55** ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet ReaL	**90.72** ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	**99.50** ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	–
CIFAR-100	**94.55** ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	–
Oxford-IIIT Pets	**97.56** ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	–
Oxford Flowers-102	99.68 ± 0.02	**99.74** ± 0.00	99.61 ± 0.02	99.63 ± 0.03	–
VTAB (19 tasks)	**77.63** ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	–
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

ViT vs. CNN



卷积：局部感受野



注意力机制：远距离 patch 可以直接交互

课程提纲

CONTENTS

一、从图像到 Token: VIT 的基本思想

二、Visual Token 的改进：
更合理、更高效的视觉表征

三、从视觉到多模态：
Visual Token 如何对接语言模型

为什么还要进一步改善 Visual Token?

ViT 解决了“图像如何进入 Transformer”，但固定 Patch Token 仍然存在**表达**与**效率**上的不足。

局限一：单尺度 Visual Token 难以兼顾全局语义与局部细节



Patch size 更大：

- Token 更少，语义更粗
- 容易丢边界和小目标

Patch size 更大：

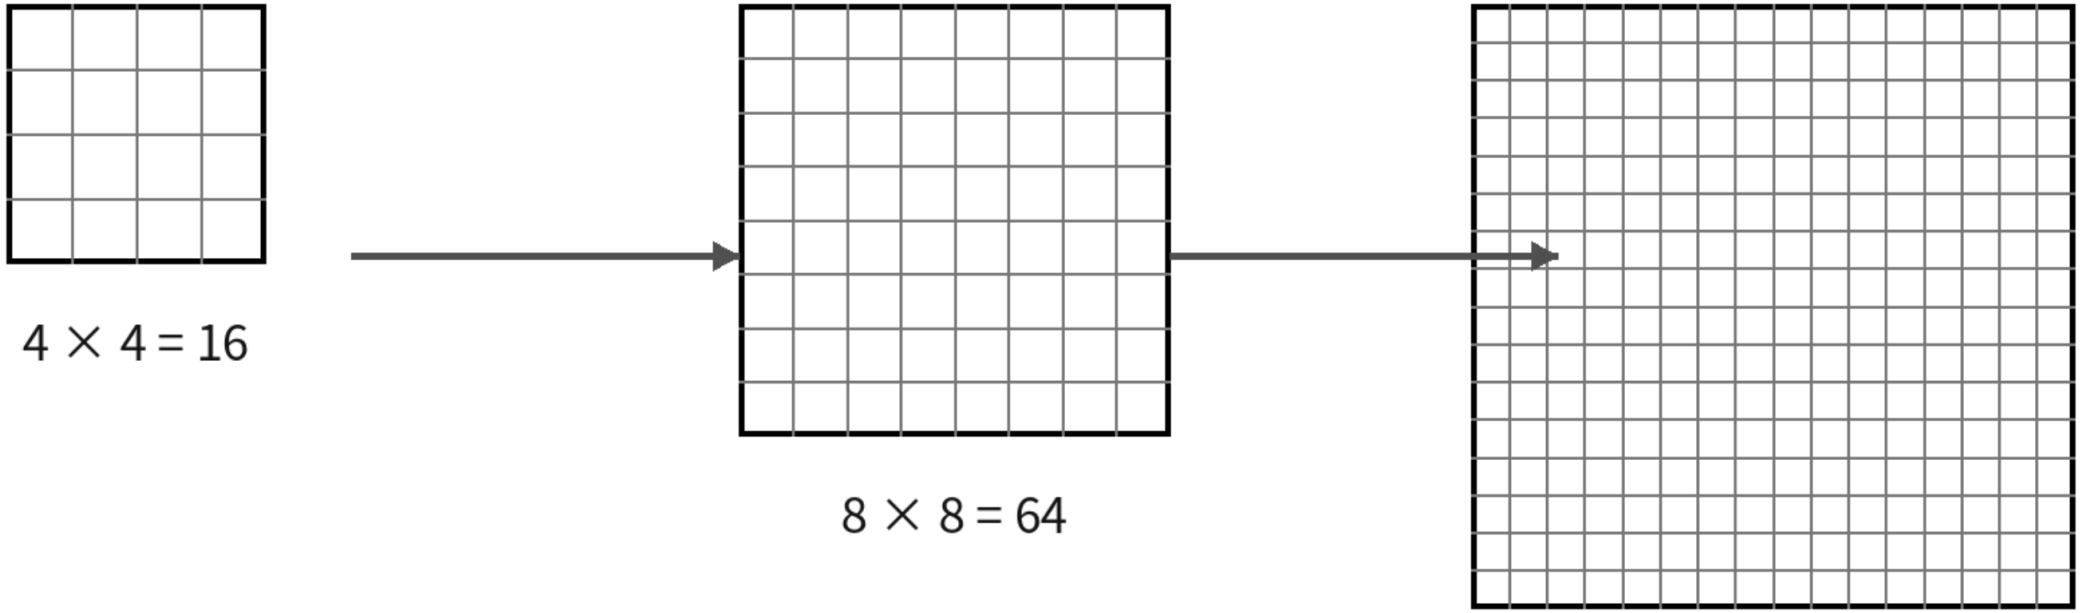
- 更多局部细节
- Token 多，计算效率低

单尺度不够 → 需要多尺度 Visual Token

局限二：全局注意力计算导致效率低下

若输入有 N 个 token，就要计算一个 N×N 的注意力矩阵。
因此 token 数一多，计算量和显存开销都会迅速上升。

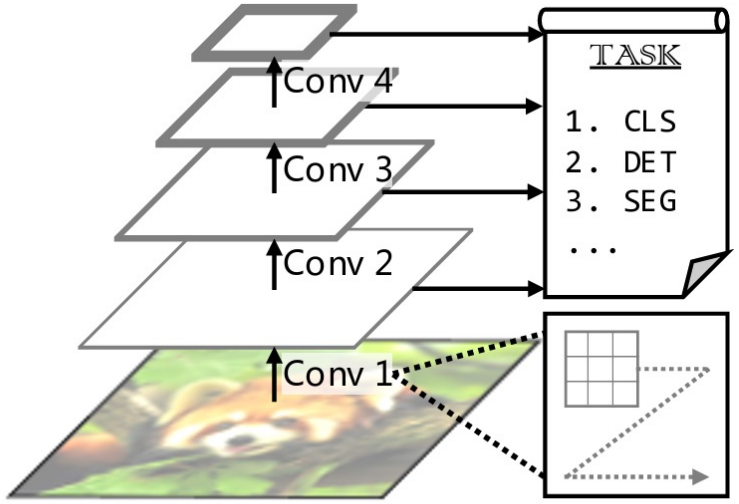
- Token 翻两倍，注意力计算量翻四倍，是 $O(N^2)$ 的。



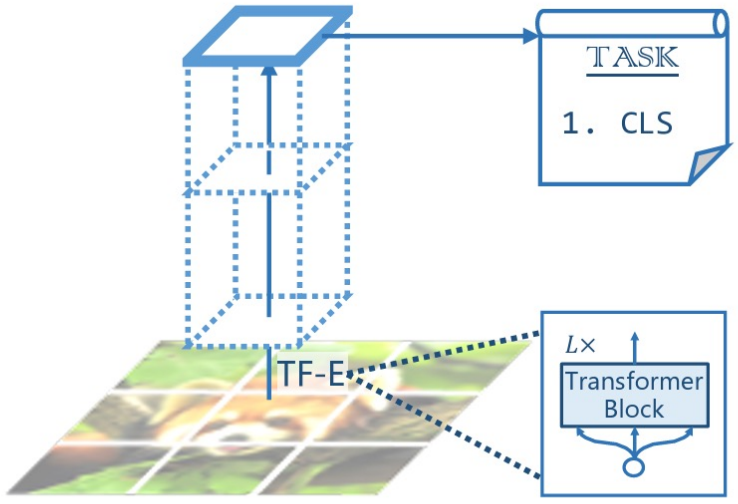
如何让 Visual Token 之间更高效地汇聚信息？

多尺度 Visual Token: PVT

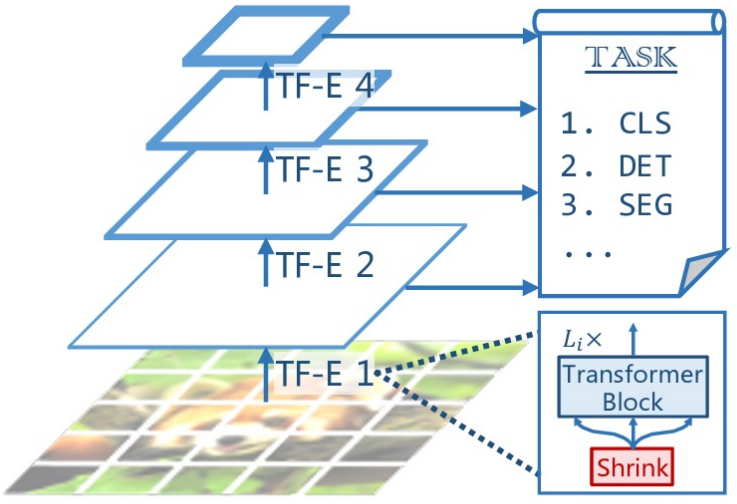
- ViT 能很好地利用 [CLS] Token 汇聚全局信息完成**分类**任务，但固定分辨率的 visual token 丢失了细粒度信息，使其对检测/分割等**密集预测任务**表现不佳。
- PVT 通过引入渐进式缩小的金字塔结构，让 Transformer 也能像传统 CNN 一样输出多尺度特征图。



(a) CNNs: VGG [53], ResNet [21], *etc*.



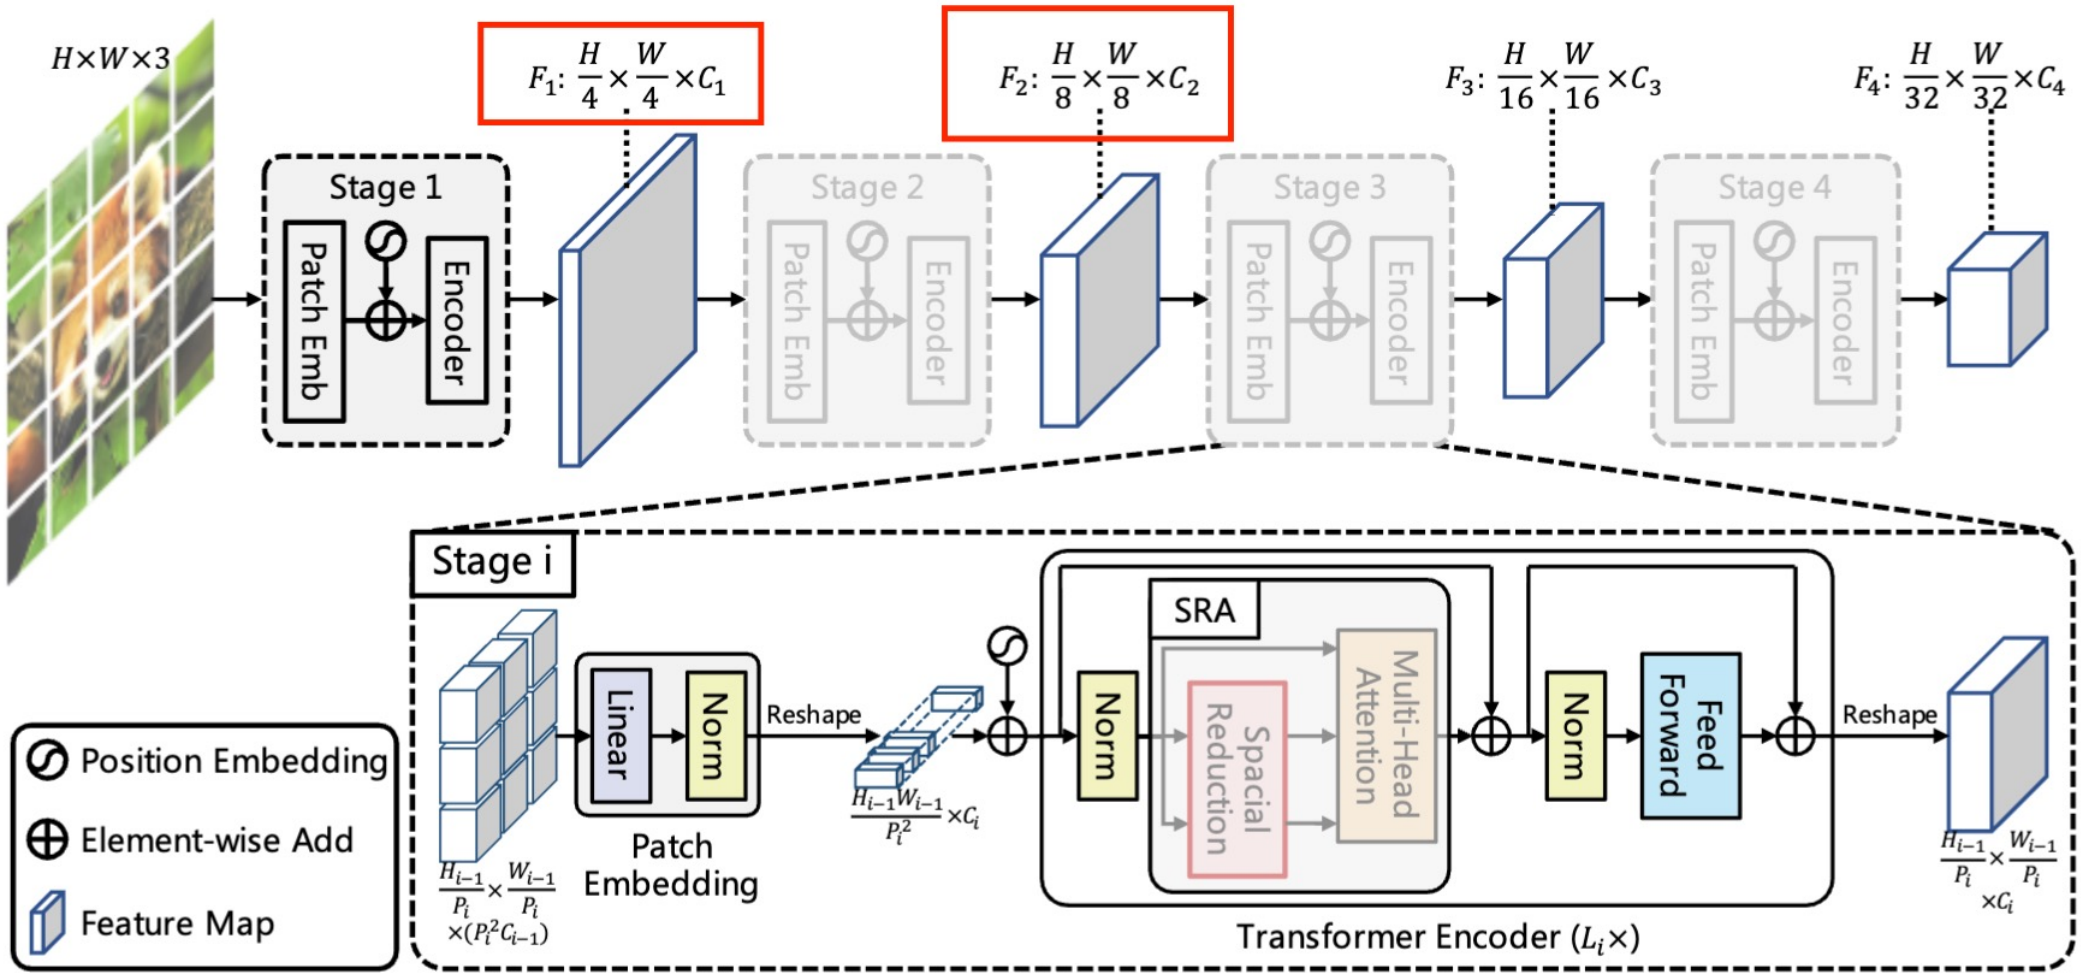
(b) Vision Transformer [12]



(c) Pyramid Vision Transformer (ours)

多尺度 Visual Token: PVT

- 模仿 CNN 的多阶段下采样设计，第一层将图片分成 4x4 的 Patch，第二层再下采样两倍，以此类推。



Pyramid Vision Transformer (ICCV 2021)

多尺度 Visual Token: PVT

实验结果分析

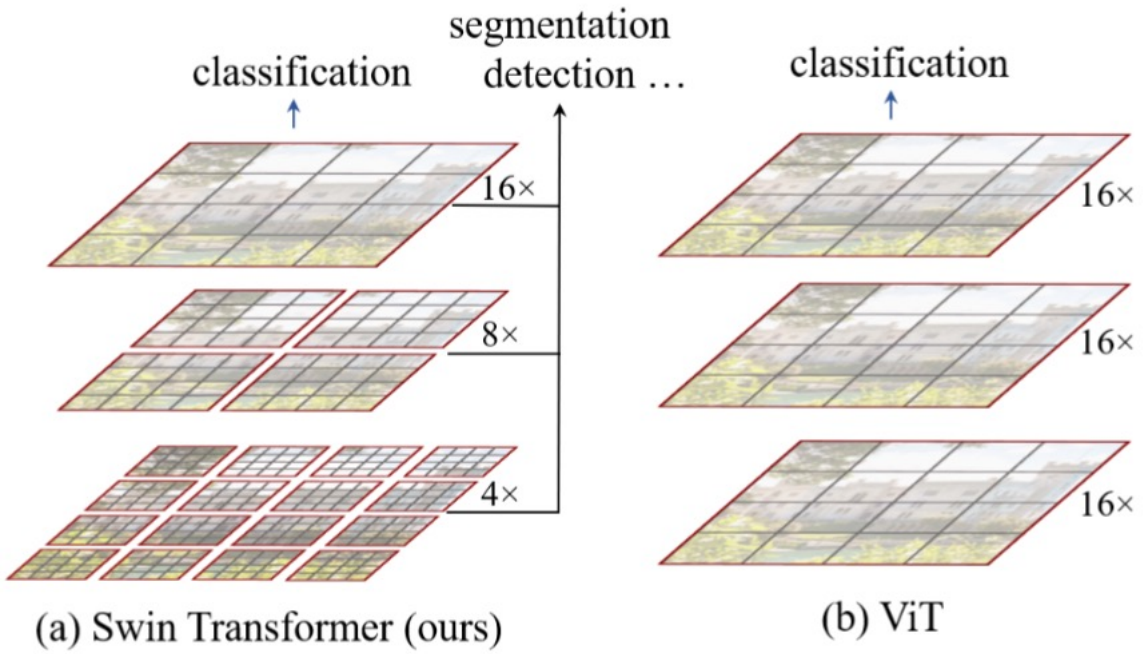
- 在相同参数量下，PVT 的目标检测与实例分割性能超越了 ResNet 与 ResNeXt，预示着多尺度 Visual Token 这一范式的成功。

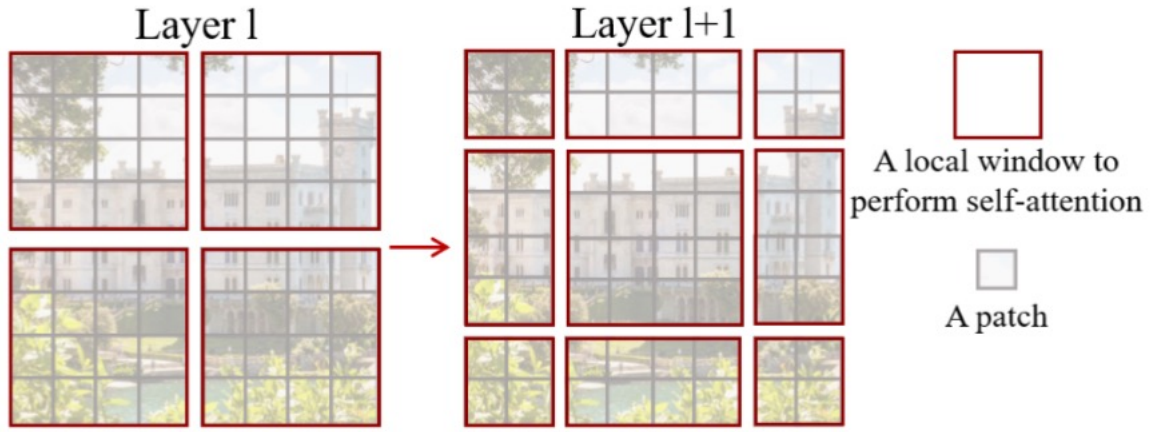
Backbone	#Param (M)	Mask R-CNN 1x						Mask R-CNN 3x + MS					
		AP^b	AP^b_{50}	AP^b_{75}	AP^m	AP^m_{50}	AP^m_{75}	AP^b	AP^b_{50}	AP^b_{75}	AP^m	AP^m_{50}	AP^m_{75}
ResNet18 [22]	31.2	34.0	54.0	36.7	31.2	51.0	32.7	36.9	57.1	40.0	33.6	53.9	35.7
PVT-Tiny (ours)	32.9	36.7(+2.7)	59.2	39.3	35.1(+3.9)	56.7	37.3	39.8(+2.9)	62.2	43.0	37.4(+3.8)	59.3	39.9
ResNet50 [22]	44.2	38.0	58.6	41.4	34.4	55.1	36.7	41.0	61.7	44.9	37.1	58.4	40.1
PVT-Small (ours)	44.1	40.4(+2.4)	62.9	43.8	37.8(+3.4)	60.1	40.3	43.0(+2.0)	65.3	46.9	39.9(+2.8)	62.5	42.8
ResNet101 [22]	63.2	40.4	61.1	44.2	36.4	57.7	38.8	42.8	63.2	47.1	38.5	60.1	41.3
ResNeXt101-32x4d [73]	62.8	41.9(+1.5)	62.5	45.9	37.5(+1.1)	59.4	40.2	44.0(+1.2)	64.4	48.0	39.2(+0.7)	61.4	41.9
PVT-Medium (ours)	63.9	42.0(+1.6)	64.4	45.6	39.0(+2.6)	61.6	42.1	44.2(+1.4)	66.0	48.2	40.5(+2.0)	63.1	43.5
ResNeXt101-64x4d [73]	101.9	42.8	63.8	47.3	38.4	60.6	41.3	44.4	64.9	48.8	39.7	61.9	42.6
PVT-Large (ours)	81.0	42.9(+0.1)	65.0	46.6	39.5(+1.1)	61.9	42.5	44.5(+0.1)	66.0	48.3	40.7(+1.0)	63.4	43.7

Pyramid Vision Transformer (ICCV 2021)

局部窗口 Visual Token：Swin Transformer

- PVT 的缺陷：为了引入多尺度特征，需要对每一个分辨率的 Visual Token 进行注意力计算。
- 而标准 Transformer 使用全局自注意力机制（Global Self-Attention），即每一个 Token 都要和全图所有的 Token 计算相关性。这导致计算复杂度与图像尺寸大小呈**平方级**增长。
- Swin Transformer 通过引入**基于移动窗口的自注意力机制**解决这个问题。





Swin Transformer: Hierarchical Vision Transformer using Shifted Windows , ICCV 2021 Best Paper

局部窗口 Visual Token：Swin Transformer

实验结果分析

- Swin Transformer 在分类和分割任务上，性能达到 SOTA 的同时性能也获得了提高。

ImageNet 图像分割

method	image size	#param.	FLOPs	throughput (image / s)	ImageNet top-1 acc.
R-101x3 [38]	384^2	388M	204.6G	-	84.4
R-152x4 [38]	480^2	937M	840.5G	-	85.4
ViT-B/16 [20]	384^2	86M	55.4G	85.9	84.0
ViT-L/16 [20]	384^2	307M	190.7G	27.3	85.2
Swin-B	224^2	88M	15.4G	278.1	85.2
Swin-B	384^2	88M	47.0G	84.7	86.4
Swin-L	384^2	197M	103.9G	42.1	87.3

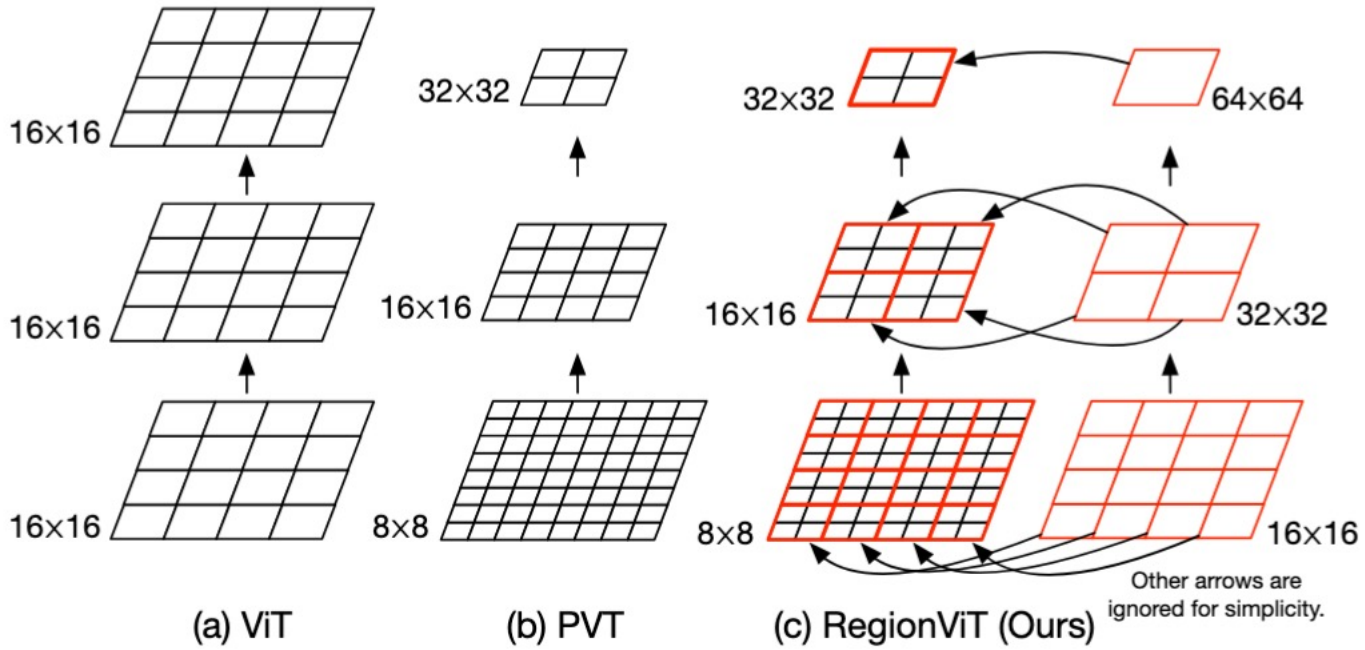
COCO 目标检测 & 实例分割

Method	mini-val AP^{box}	mini-val AP^{mask}	test-dev AP^{box}	test-dev AP^{mask}	#param.	FLOPs
RepPointsV2* [12]	-	-	52.1	-	-	-
GCNet* [7]	51.8	44.7	52.3	45.4	-	1041G
RelationNet++* [13]	-	-	52.7	-	-	-
SpineNet-190 [21]	52.6	-	52.8	-	164M	1885G
ResNeSt-200* [78]	52.5	-	53.3	47.1	-	-
EfficientDet-D7 [59]	54.4	-	55.1	-	77M	410G
DetectoRS* [46]	-	-	55.7	48.5	-	-
YOLOv4 P7* [4]	-	-	55.8	-	-	-
Copy-paste [26]	55.9	47.2	56.0	47.4	185M	1440G
X101-64 (HTC++)	52.3	46.0	-	-	155M	1033G
Swin-B (HTC++)	56.4	49.1	-	-	160M	1043G
Swin-L (HTC++)	57.1	49.5	57.7	50.2	284M	1470G
Swin-L (HTC++)*	**58.0**	**50.4**	**58.7**	**51.1**	284M	-

Swin Transformer: Hierarchical Vision Transformer using Shifted Windows , ICCV 2021 Best Paper

区域 Visual Token：RegionViT

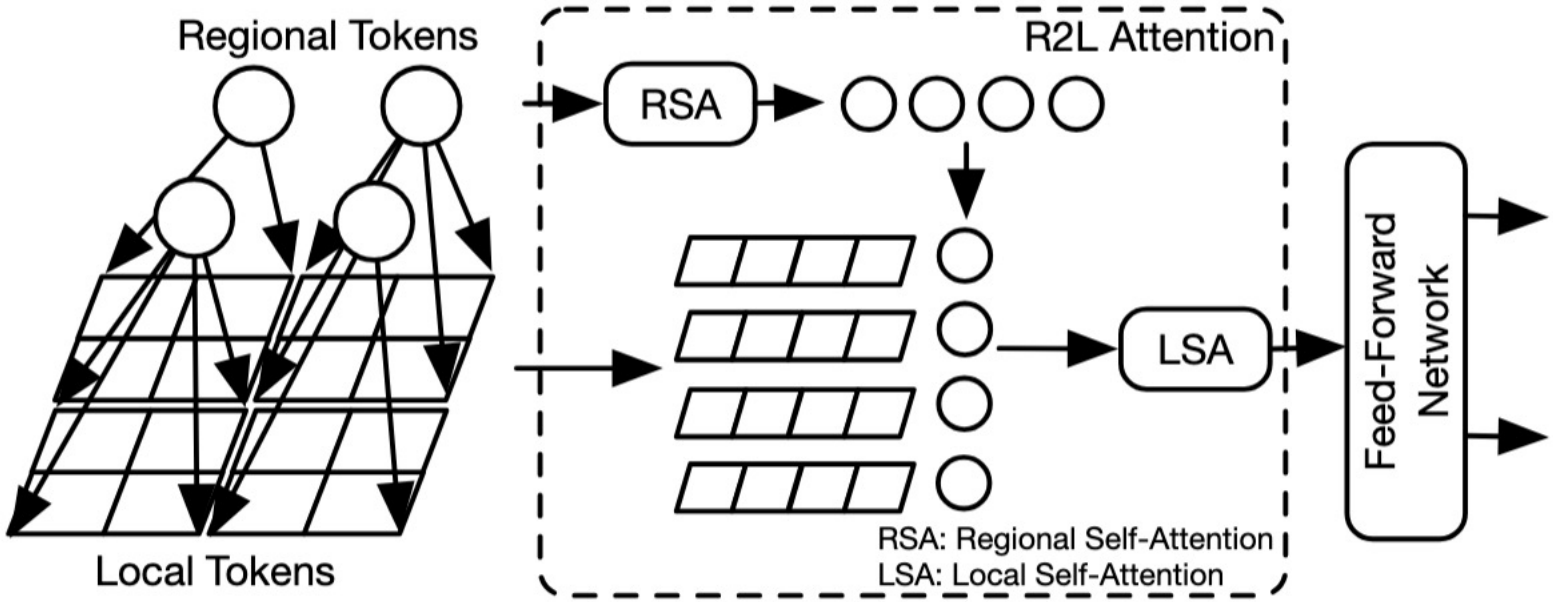
- 同样为了解决 PVT 多尺度特征图带来的计算量问题。
- RegionViT 引入了**区域到局部注意力机制**，将输入图像同时转换为两种尺寸的 Token：大尺寸的区域 Token（红色）和小尺寸的局部 Token（黑色），巧妙地实现了局部与全局的融合。



RegionViT: Regional-to-Local Attention for Vision Transformers, ICLR 2022

区域 Visual Token：RegionViT

- 阶段一：区域自注意力 (RSA)
  - 区域 Token 通过 RSA 模块互相计算注意力。因为区域 Token 数量很少，它们互相计算注意力的计算量非常小。
- 阶段二：局部自注意力 (LSA)
  - 在 LSA 模块中，参与计算的成员是一个区域 Token + 属于该区域的 N 个局部 Token。
  - 目的：局部 Token 交流细节信息，而区域 Token 已经获得了全局信息。



RegionViT: Regional-to-Local Attention for Vision Transformers, ICLR 2022

区域 Visual Token：RegionViT

实验结果

RegionViT 在性能和效率方面都持平或超越了同期金字塔类型的 ViT 变种，强有力地证明了 Region Visual Token 能够大幅缓解了传统 ViT 的计算与内存瓶颈。

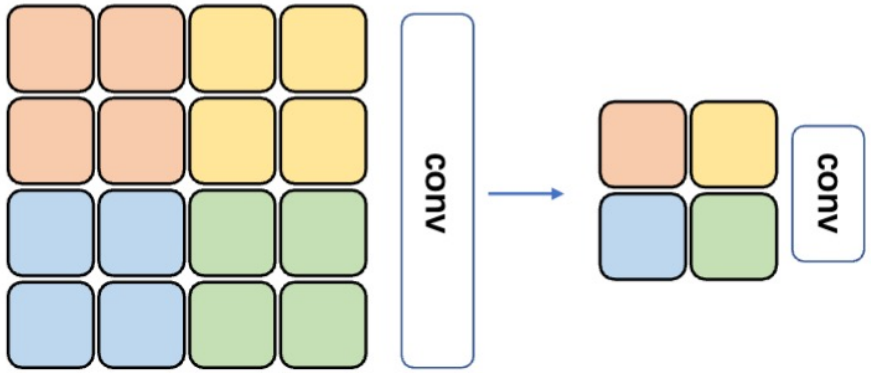
Model	Params (M)	FLOPs (G)	Acc. (%)
ConT-M (Yan et al., 2021)	39.6	6.4	81.8
Twins-PCPVT-B (Chu et al., 2021a)	43.8	6.4	82.7
PVT-M (Wang et al., 2021)	44.2	6.7	81.2
CvT-21 (Wu et al., 2021)	32.0	7.1	82.5
Twins-SVT-B (Chu et al., 2021a)	56	8.3	83.2
ViL-M (Zhang et al., 2021a)	39.7	8.7	83.3
Swin-S (Liu et al., 2021)	50.0	8.7	83.0
PVT-L (Wang et al., 2021)	61.4	9.8	81.7
ConViT-S+ (d'Ascoli et al., 2021)	48.0	10.0	82.2
NesT-S (Zhang et al., 2021b)	38.0	10.4	83.3
RegionViT-M	41.2	7.4	83.1
RegionViT-M+	42.0	7.9	**83.4**

Backbone	Params (M)	FLOPs (G)	RetineNet 1× AP	RetineNet 3× AP	Params (M)	FLOPs (G)	MaskRCNN 1× AP^b	MaskRCNN 1× AP^m	MaskRCNN 3× AP^b	MaskRCNN 3× AP^m
ResNet50	37.7	234	36.3	39.0	44.2	260.0	38.0	34.4	41.0	37.1
ConT-M (Yan et al., 2021)	27.0	217.2	39.3	–	–	–	40.5	38.1	–	–
PVT-S (Wang et al., 2021)	34.2	–	40.4	42.2	44.1	–	40.4	37.8	43.0	39.6
ViL-S (Zhang et al., 2021a)	35.7	252.2	41.6	42.9	45.0	174.3	41.8	38.5	43.4	39.6
Swin-T (Liu et al., 2021)	38.5	245	41.5	43.9	47.8	264	42.2	39.1	46.0	41.6
Twins-SVT-S (w/ PEG) (Chu et al., 2021a)	34.3	209	43.0	45.6	44.0	228	43.5	40.3	46.8	42.6
RegionViT-S	40.8	192.6	42.2	45.8	50.1	171.3	42.5	39.5	46.3	42.3
RegionViT-S+	41.5	204.2	43.1	**46.9**	50.9	182.9	43.5	40.4	47.3	**43.4**
RegionViT-S+ w/ PEG	41.6	204.3	**43.9**	46.7	50.9	183.0	**44.2**	**40.8**	**47.6**	**43.4**

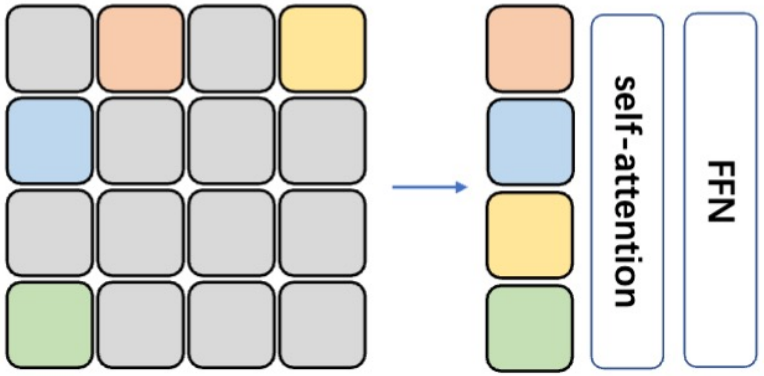
RegionViT: Regional-to-Local Attention for Vision Transformers, ICLR 2022

Visual Token 剪枝：DynamicViT

- 问题：文章观察到注意力在视觉 ViT 中是稀疏的，最终预测实际上只依赖于一小部分最具信息量的 token，而大多数token对分类结果的贡献很小。传统做法会处理所有输入 token，造成大量冗余计算。
- DynamicViT 提出动态、渐进地剪枝冗余 token。



(a) Structural Downsampling



(b) Dynamic Token Sparsification



(c) Attention Visualization

DynamicViT: Efficient Vision Transformers with Dynamic Token Sparsification

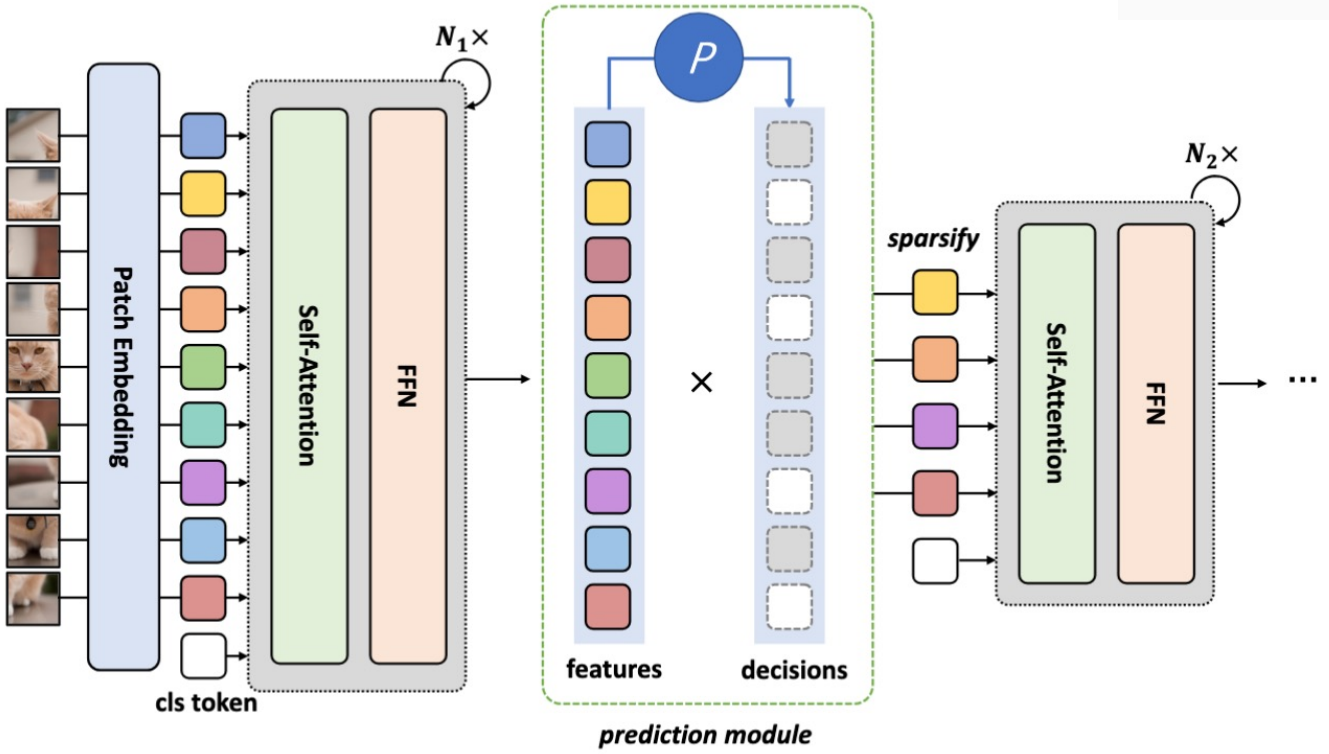
Visual Token 剪枝：DynamicViT

方法：在每层 Transformer Block 中间加入一个 prediction module，来预测哪些 token 该被丢弃。

- 先通过 MLP 对每个 token 独立编码，得到局部特征 z^{local}。
- 再通过自适应平均池化聚合所有现存 token 的信息，得到全局特征 z^{global}。
- 最后将局部特征和全局特征拼接，输入另一个 MLP 来预测保留/丢弃概率。

$$z_i = [z_i^{\text{local}}, z_i^{\text{global}}] \in \mathbb{R}^{2C'}, \quad 1 \le i \le N$$

$$\pi = \text{Softmax}(\text{MLP}(z)) \in \mathbb{R}^{N \times 2}$$



DynamicViT: Efficient Vision Transformers with Dynamic Token Sparsification

Visual Token 剪枝：DynamicViT

实验结果

- 文章在 DeiT 与 LV-ViT 上加入了 prediction module，以微小精度损失的代价显著了降低计算量。

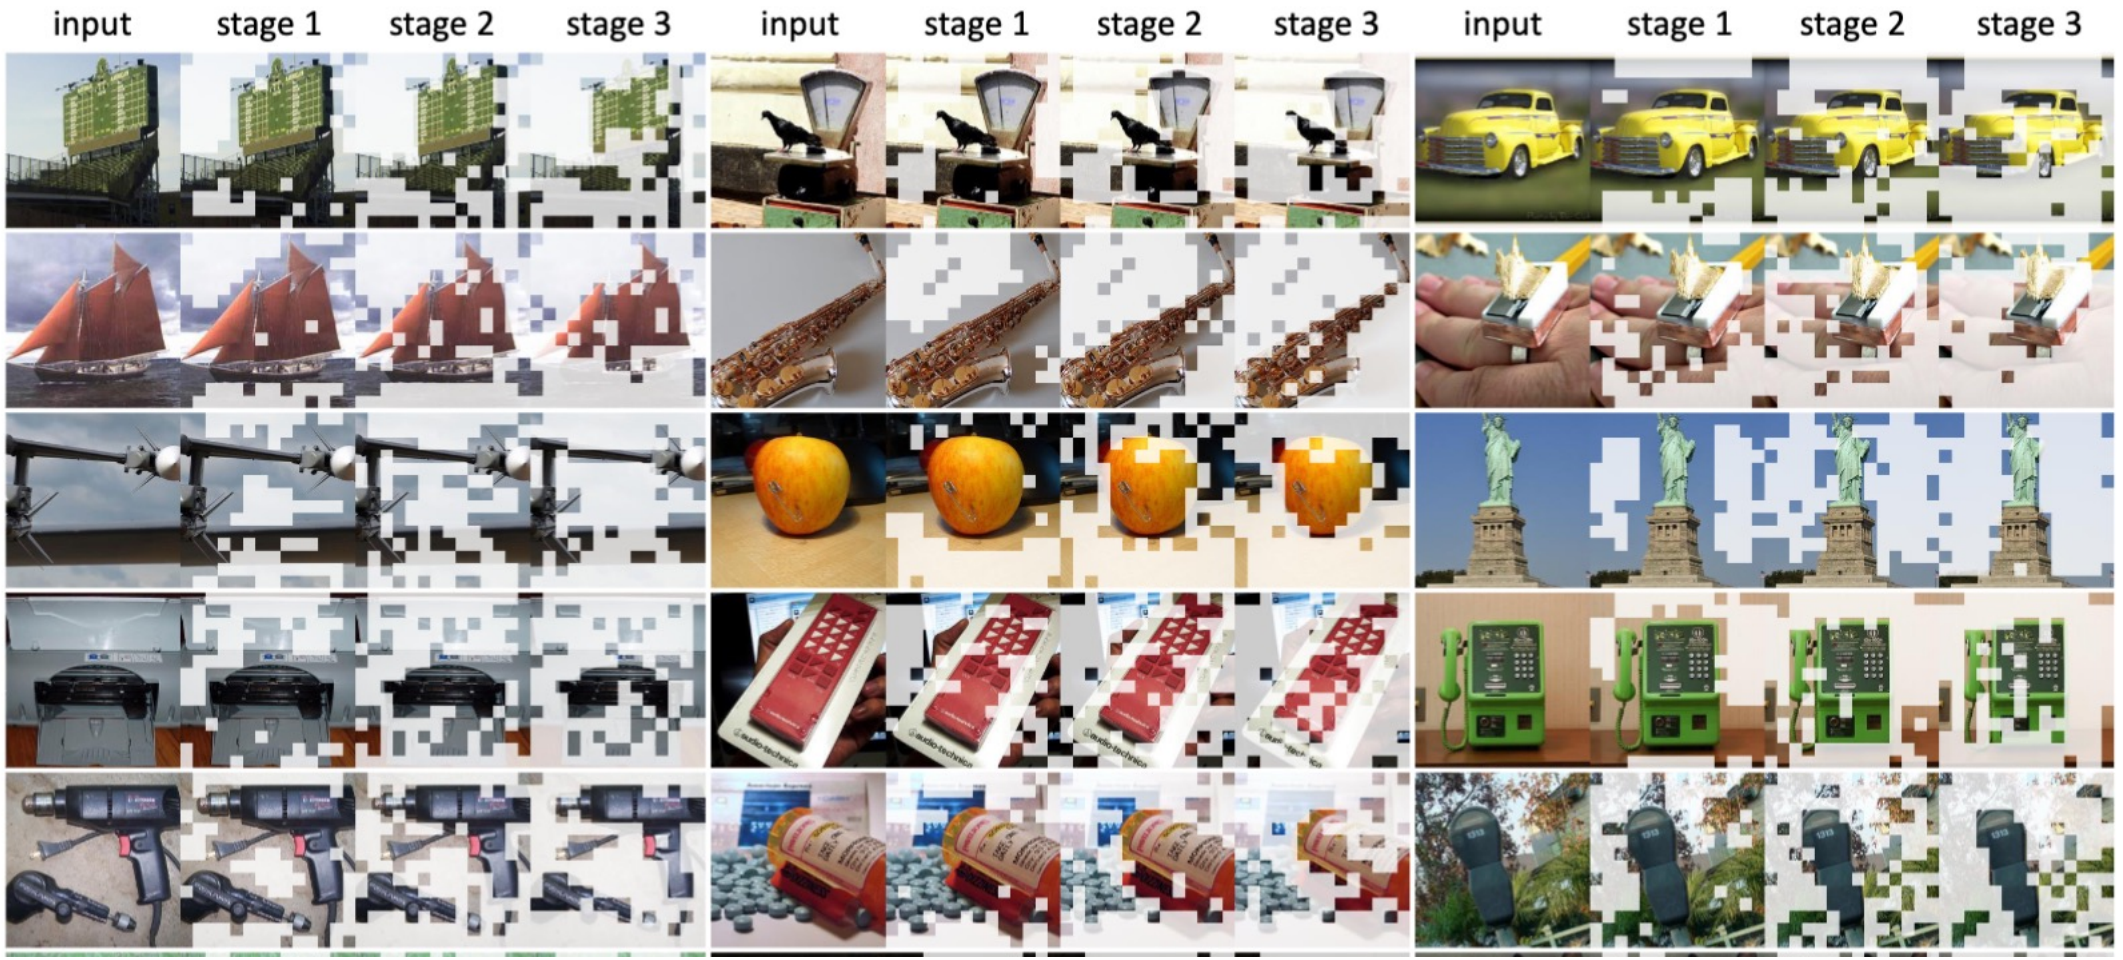
Base Model	Metrics	Keeping Ratio ρ at each stage			
		1.0	0.9	0.8	0.7
DeiT-S [25]	ImageNet Acc. (%)	79.8	79.8 (-0.0)	79.6 (-0.2)	79.3 (-0.5)
	GFLOPs	4.6	4.0 (-14%)	3.4 (-27%)	2.9 (-37%)
	Throughput (im/s)	1337.7	1524.8 (+14%)	1774.6 (+33%)	2062.1 (+54%)
LV-ViT-S [16]	ImageNet Acc. (%)	83.3	83.3 (-0.0)	83.2 (-0.1)	83.0 (-0.3)
	GFLOPs	6.6	5.8 (-12%)	5.1 (-22%)	4.6 (-31%)
	Throughput (im/s)	993.3	1108.3 (+12%)	1255.6 (+26%)	1417.6 (+43%)
LV-ViT-M [16]	ImageNet Acc. (%)	84.0	83.9 (-0.1)	83.9 (-0.1)	83.8 (-0.2)
	GFLOPs	12.7	11.1 (-13%)	9.6 (-24%)	8.5 (-33%)
	Throughput (im/s)	589.5	688.5 (+17%)	791.2 (+34%)	888.2 (+50%)

DynamicViT: Efficient Vision Transformers with Dynamic Token Sparsification

Visual Token 剪枝：DynamicViT

可视化分析

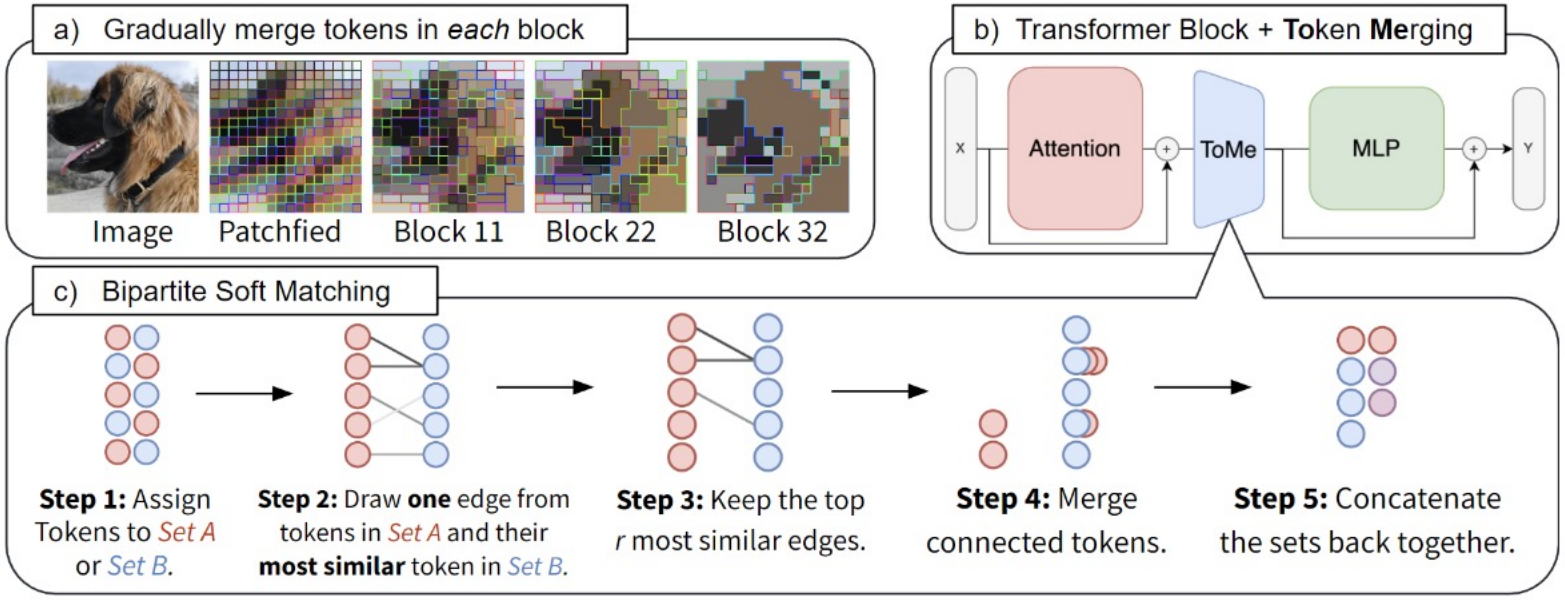
- 随着网络深入，DynamicViT 逐步丢弃背景 token，最终注意力集中在目标物体上。



DynamicViT: Efficient Vision Transformers with Dynamic Token Sparsification

Visual Token 合并：ToMe

- 问题：文章认为现有 Token 剪枝方法存在多重局限性：
  - 直接丢弃 token 的信息损失限制了可压缩的程度且影响准确率
  - 大多数方法需要昂贵地重新训练模型才能有效工作，部分甚至需要引入额外参数
  - 剪枝方法通常在训练时使用掩码 (mask) 而非真正移除 token，抵消了速度优势
- ToMe 通过合并相似 Token 而并非丢弃，无需训练即可应用，并且支持训练和推理的双向加速，且具有跨模态通用性，无需修改即可应用于图像、视频和音频。



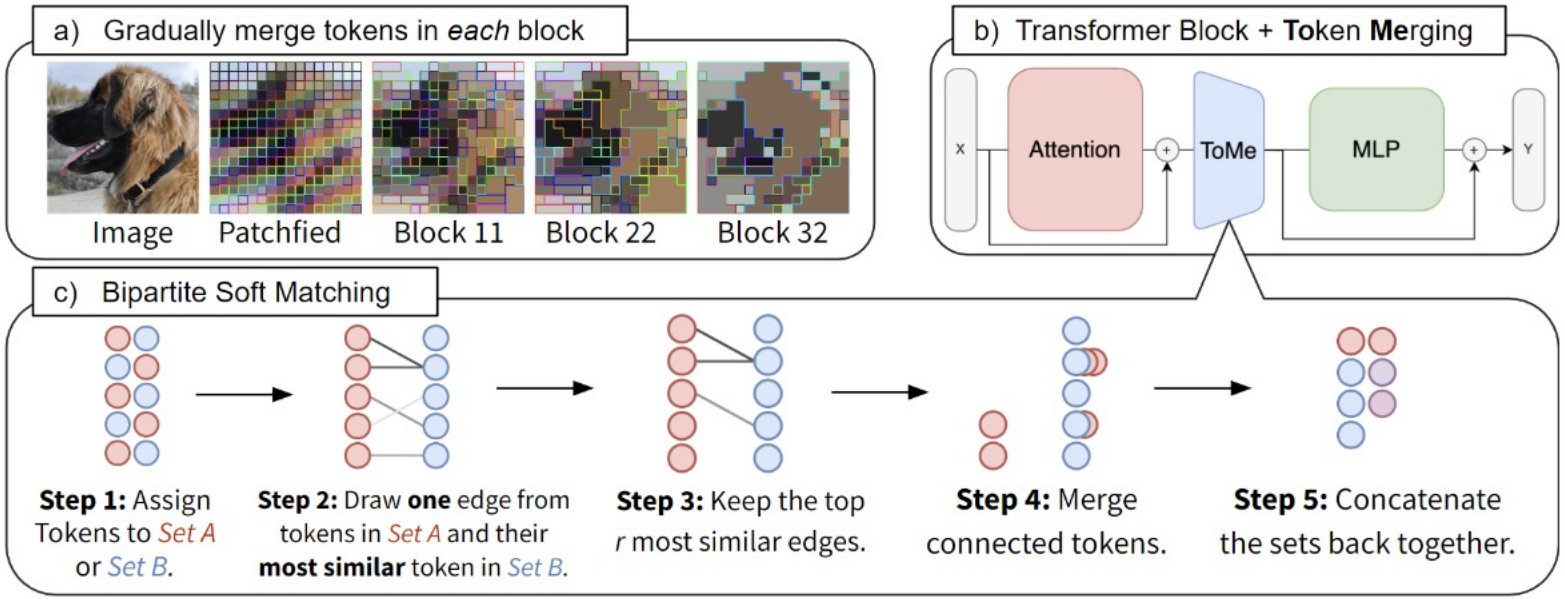
Token Merging: Your ViT But Faster (ICLR 2023 Oral)

Visual Token 合并：ToMe

实现方法

- 将当前层的 Visual Token 分为两组，用二分图匹配的方式对 A 中每个 token 找到 B 中最相似的 Token。
- 然后按照相似度分数对所有匹配对排序，保留前 r 个最高分的匹配对。（r 为每层合并数量）
- 最后对于选定的 r 对 token (s_i，d_i)，目标 token d_i 根据源 Token 加权更新：

$$d_i \leftarrow \frac{s_{src} \cdot src + s_{dst} \cdot dst}{s_{src} + s_{dst}}$$



Token Merging: Your ViT But Faster (ICLR 2023 Oral)

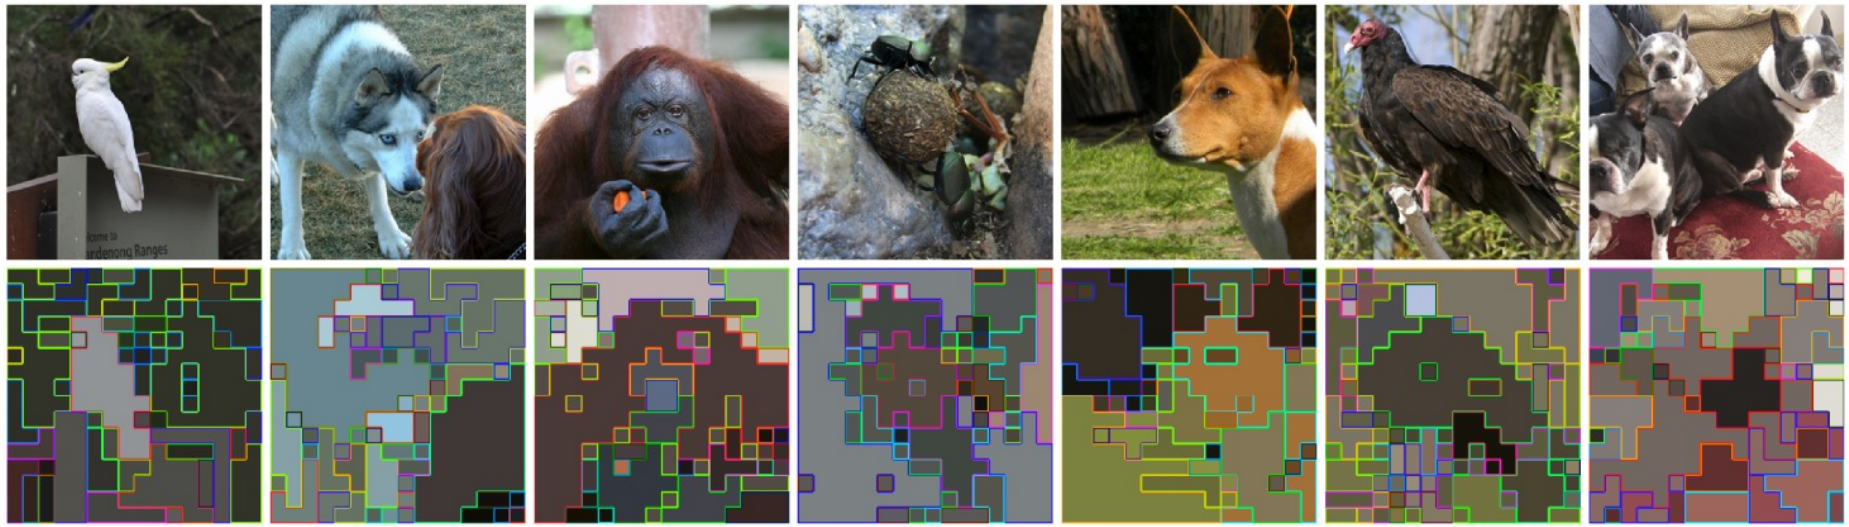
Visual Token 合并：ToMe

中山大學 SUN YAT-SEN UNIVERSITY

实验结果

- ImageNet 上显示能在性能不下降的情况下加速。
- 可视化结果显示，相似的视觉 Token（如动物毛发）成功被合并到一起。

model	input	acc	gflops	im/s
Eff-B5	456	83.6	9.9	169‡
ViT-B MAE	224	83.6	17.6	309
Swin-B*	224	84.0	15.4	278‡
CSWin-B	224	84.2	15.0	250‡
MViTv2-B	224	84.4	10.2	253‡
ToMe				
ViT-L MAE $r_8\searrow$	224	84.2	22.3	241
ViT-L MAE $r_8\rightarrow$	224	**85.1**	31.0	183
ViT-L MAE	224	85.7†	61.6	93
Eff-B6	528	84.0	19.0	96‡
MViTv2-L	224	85.3	42.1	81
ToMe				
ViT-H MAE $r_7\searrow$	224	86.1	72.6	81
ViT-H MAE $r_7\rightarrow$	224	**86.5**	92.9	63
ViT-H MAE	224	86.9†	167.4	35
SwinV2-H*	224	85.7	118.1	49



Token Merging: Your ViT But Faster (ICLR 2023 Oral)

课程提纲

CONTENTS

一、从图像到 Token: VIT 的基本思想

二、Visual Token 的改进：
更合理、更高效的视觉表征

三、从视觉到多模态：
Visual Token 如何对接语言模型

Visual Token 如何接入多模态系统?

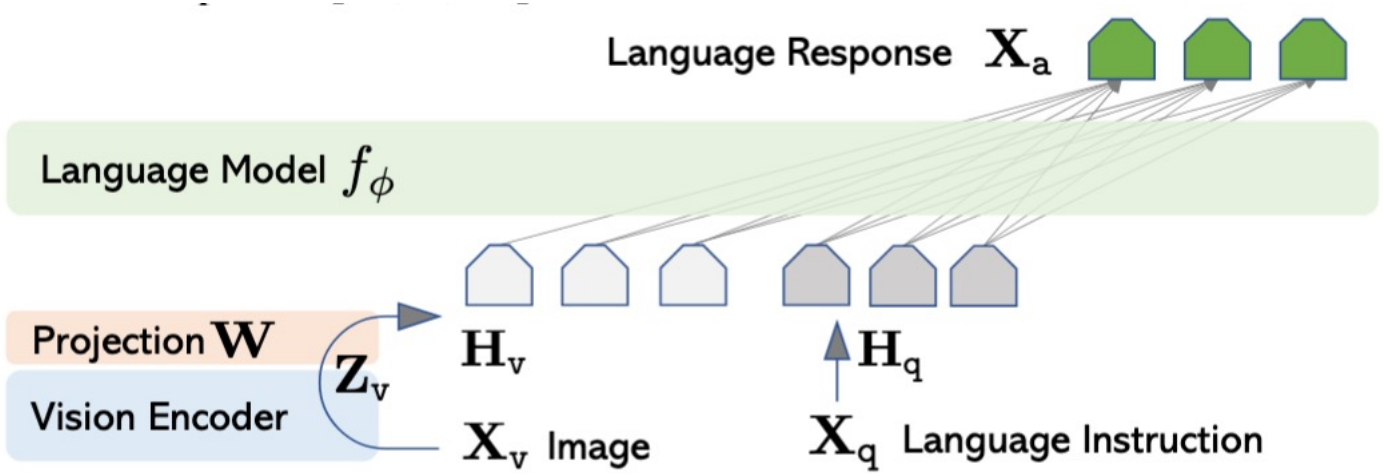
图像 → 视觉编码器 → Visual Token → **对齐/压缩/离散化** → LLM

多模态系统中的三个核心问题:

- 对齐: 如何让语言模型读懂视觉信息?
- 压缩: 如何用更少的 token 表达图像内容?
- 统一: 如何让视觉 token 像文本 token 一样被预测?

VLM 主流范式：以 LLaVA 为代表

- 主流的VLM（LLaVA及后续）沿用了 patchify 的机制，将输入划分为固定的 patch 序列。
- 在经过 ViT 编码之后，VLM 利用一个投影层将视觉表征对齐到语言模型的嵌入空间，后续依靠LLM进行视觉-语言多模态联合学习。



Visual Instruction Tuning, NeurIPS 2023 Oral

LLaVA 的代表性结果

实验结果

- 在 ScienceQA（科学问答 VQA 数据集）显著优于 text-only 的 GPT-4，证明了将 Visual Token 与大语言模型相结合是多模态推理的关键。
- 与 GPT-4 的集成策略取得 SOTA 性能，证明了不同能力模型的协同（ LLaVA 的视觉理解 + GPT-4 的语言推理）能够产生 1+1>2 的效果。

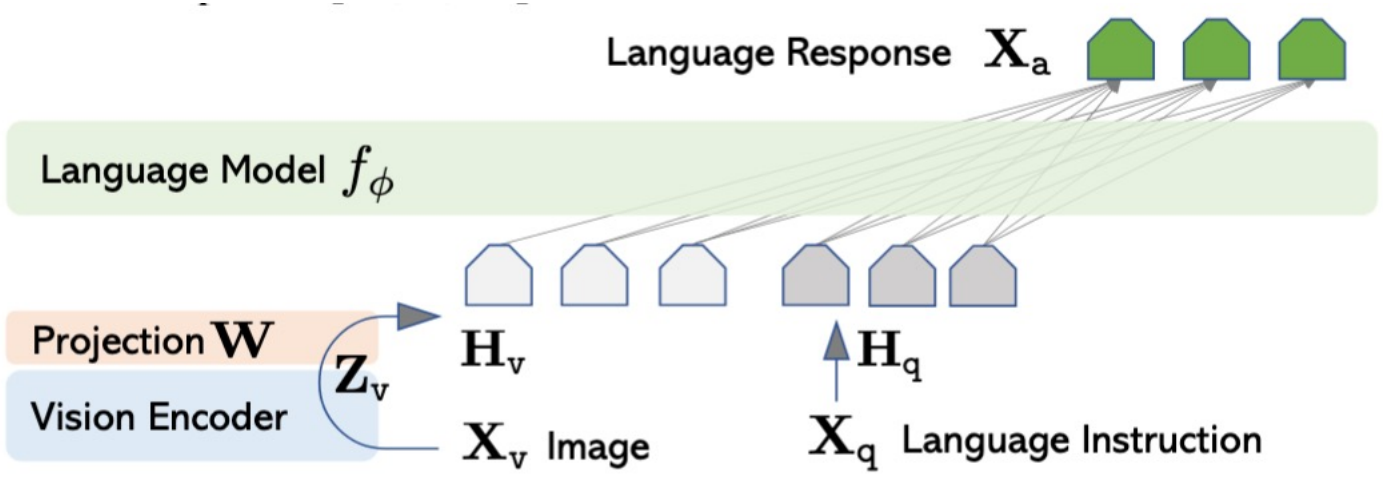
Method	Subject			Context Modality			Grade		Average
	NAT	SOC	LAN	TXT	IMG	NO	G1-6	G7-12	
Representative & SoTA methods with numbers reported in the literature									
Human [34]	90.23	84.97	87.48	89.60	87.50	88.10	91.59	82.42	88.40
GPT-3.5 [34]	74.64	69.74	76.00	74.44	67.28	77.42	76.80	68.89	73.97
GPT-3.5 w/ CoT [34]	75.44	70.87	78.09	74.68	67.43	79.93	78.23	69.68	75.17
LLaMA-Adapter [59]	84.37	88.30	84.36	83.72	80.32	86.90	85.83	84.05	85.19
MM-CoT$_{Base}$ [61]	87.52	77.17	85.82	87.88	82.90	86.83	84.65	85.37	84.91
MM-CoT$_{Large}$ [61]	95.91	82.00	90.82	95.26	88.80	92.89	92.44	90.31	91.68
Results with our own experiment runs									
GPT-4†	84.06	73.45	87.36	81.87	70.75	90.73	84.69	79.10	82.69
LLaVA	90.36	95.95	88.00	89.49	88.00	90.66	90.93	90.90	90.92
LLaVA+GPT-4† (complement)	90.36	95.50	88.55	89.05	87.80	91.08	92.22	88.73	90.97
LLaVA+GPT-4† (judge)	91.56	96.74	91.09	90.62	88.99	93.52	92.73	92.16	**92.53**

Visual Instruction Tuning, NeurIPS 2023 Oral

LLaVA 的局限

缺陷

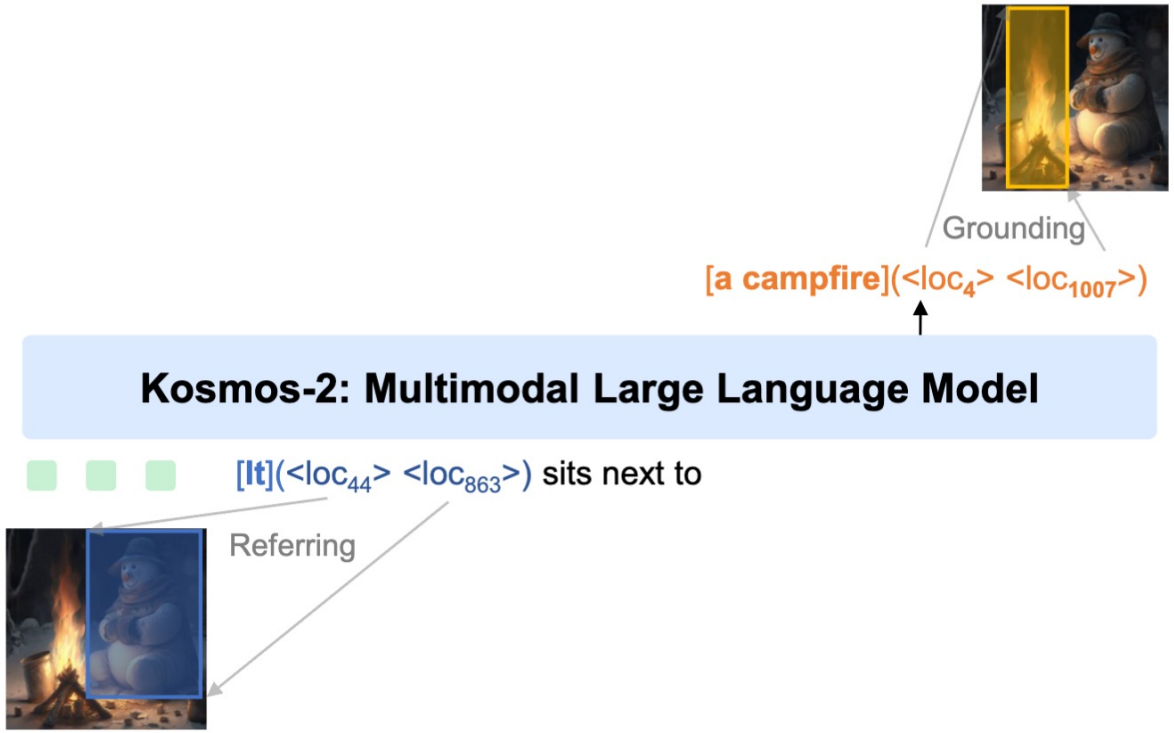
- LLM 原本最擅长的是离散 token 的 next-token prediction。而 LLaVA 这类方法里，图像通常是以外部连续向量的形式注入进去的。它很适合“看图说话”，但不能做到统一到“像语言一样预测图像 token”。



Visual Instruction Tuning, NeurIPS 2023 Oral

细粒度 Visual Token：KOSMOS-2

- KOSMOS-2 解决了多模态大模型在图像定位能力上的缺失。
- 引入了类似于 Markdown 超链接的机制，将图像坐标离散化为“位置标记”（Location Tokens），使模型能够像处理文本一样处理图像区域，从而实现了在生成回复时能同步“指图”的功能。

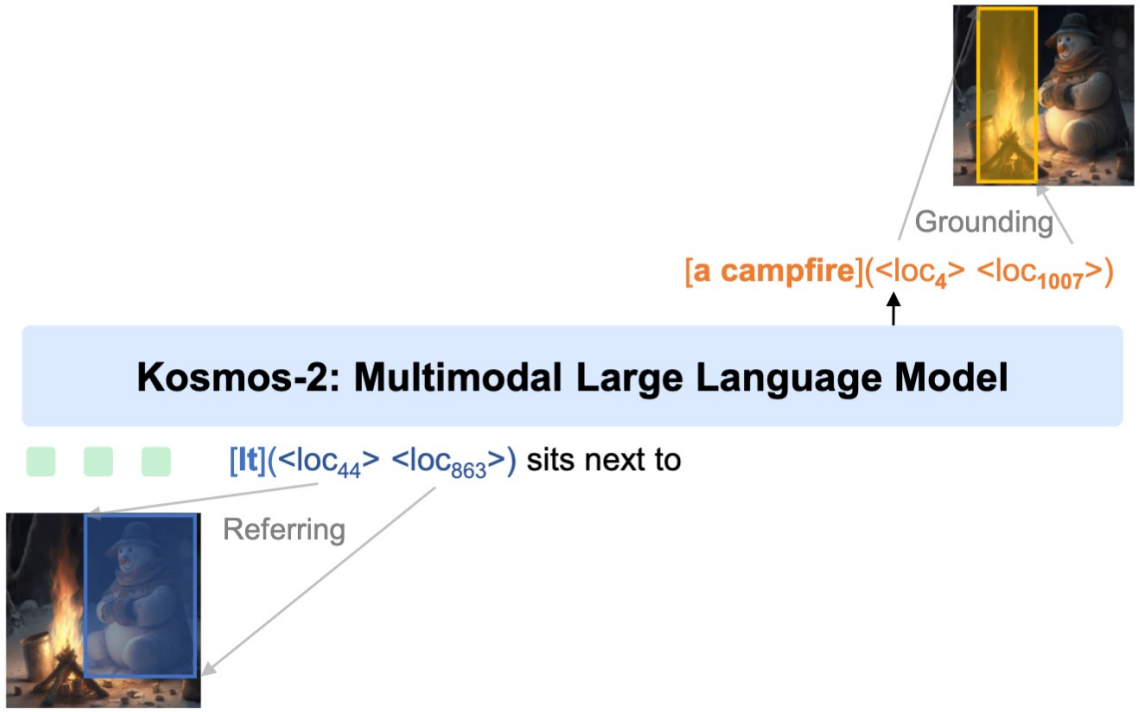


KOSMOS-2: Grounding Multimodal Large Language Models to the World (MicroSoft 2023)

细粒度 Visual Token：KOSMOS-2

具体方法

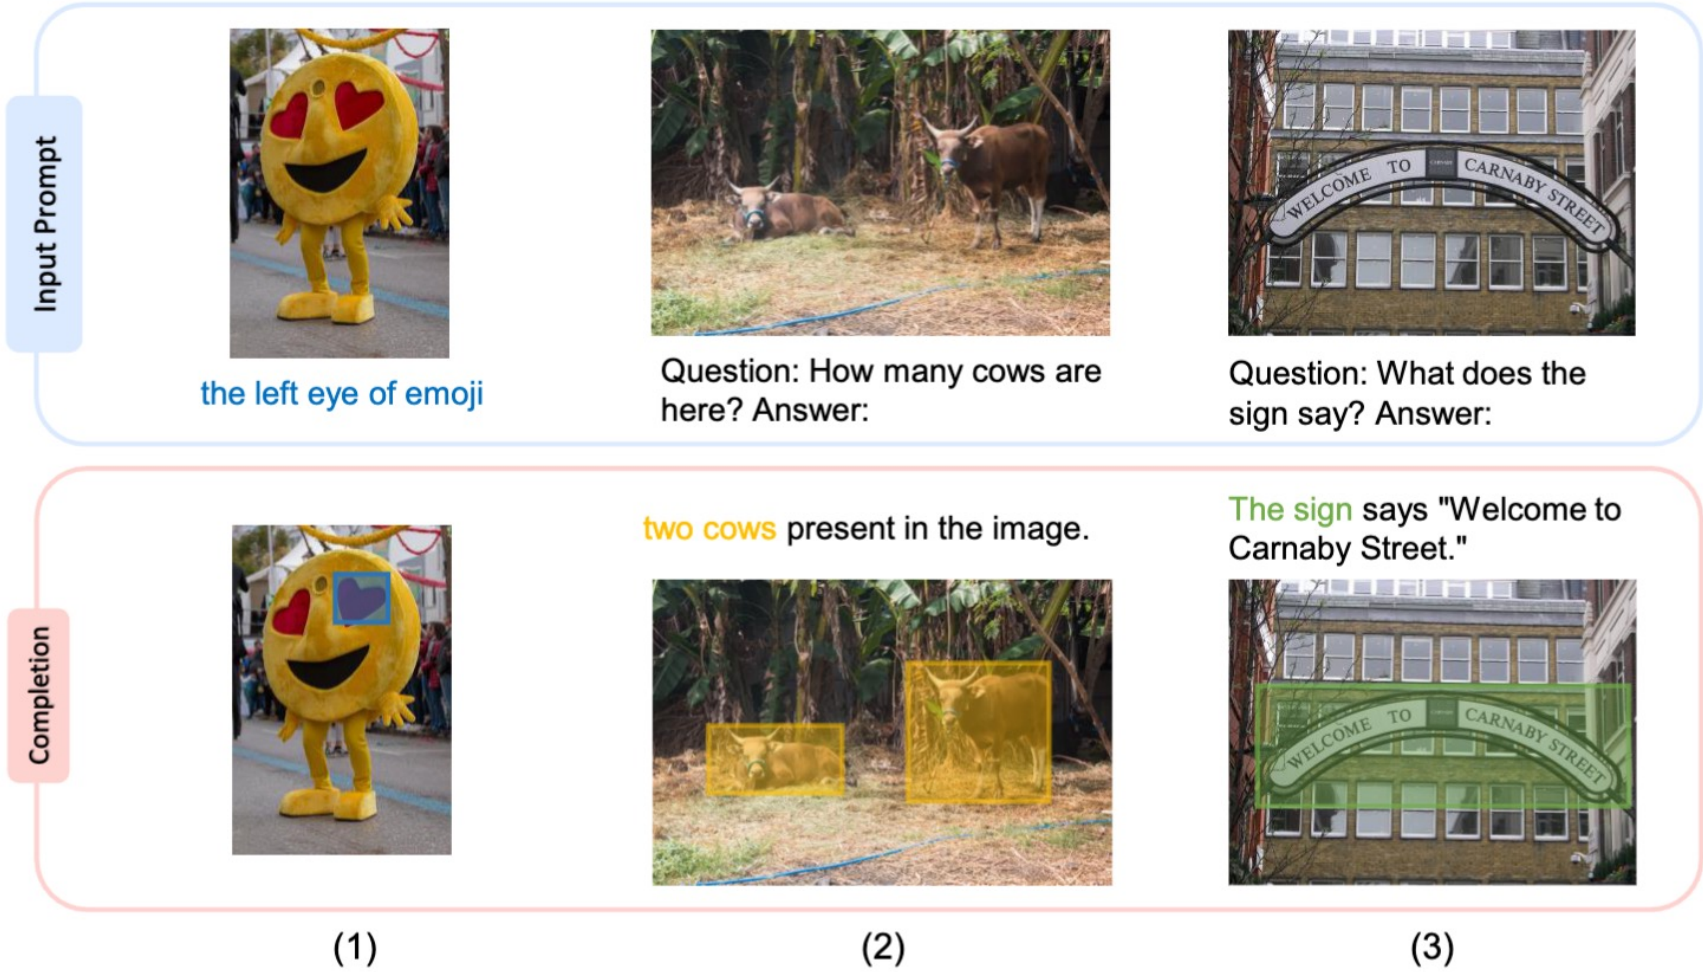
- KOSMOS-2 将图像看作一个由 32x32 个方格组成的网格，总共产生 1024 个特定的位置标记（从 <loc0> 到 <loc1023>）。
- 为了在同一个序列中处理文本和空间信息，KOSMOS-2 使用了类似 Markdown 的格式：[文本片段](<loc_{p1}><loc_{p2}>)。



KOSMOS-2: Grounding Multimodal Large Language Models to the World

细粒度 Visual Token：KOSMOS-2

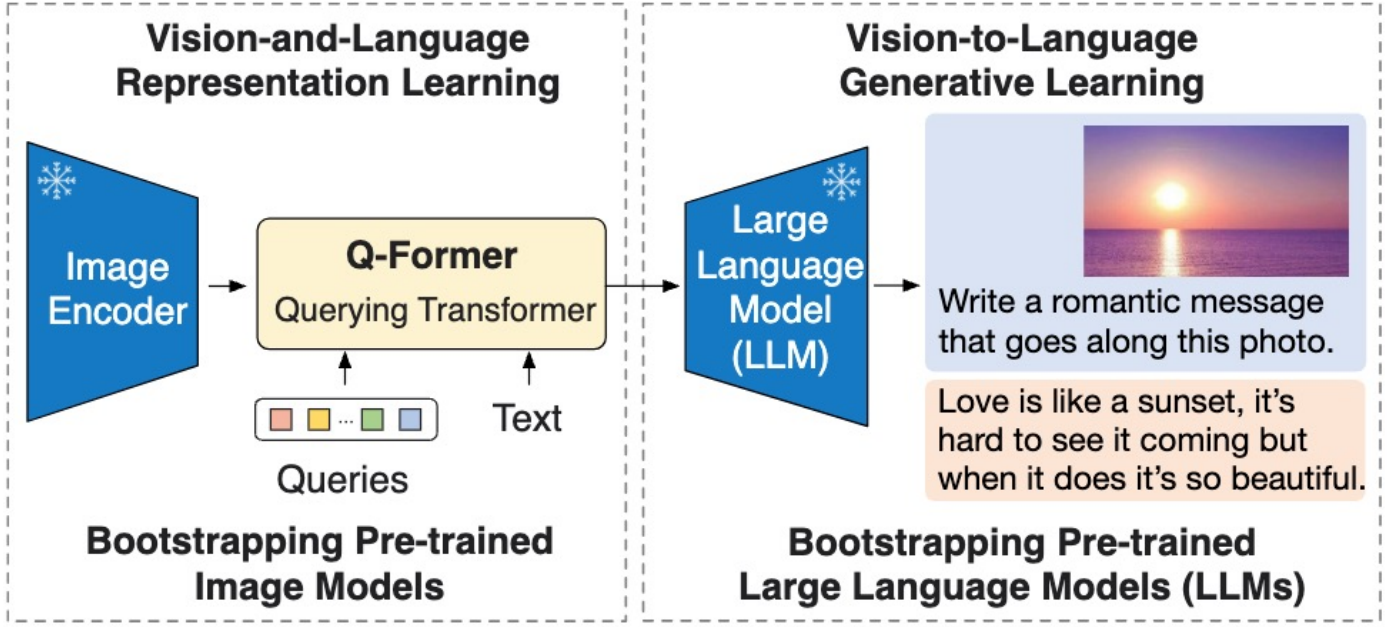
结果展示：(1) Visual Grounding 任务。(2)(3)：Grounded question answering 任务。



KOSMOS-2: Grounding Multimodal Large Language Models to the World (MicroSoft 2023)

从 Patch token 到 Latent token: BLIP-2

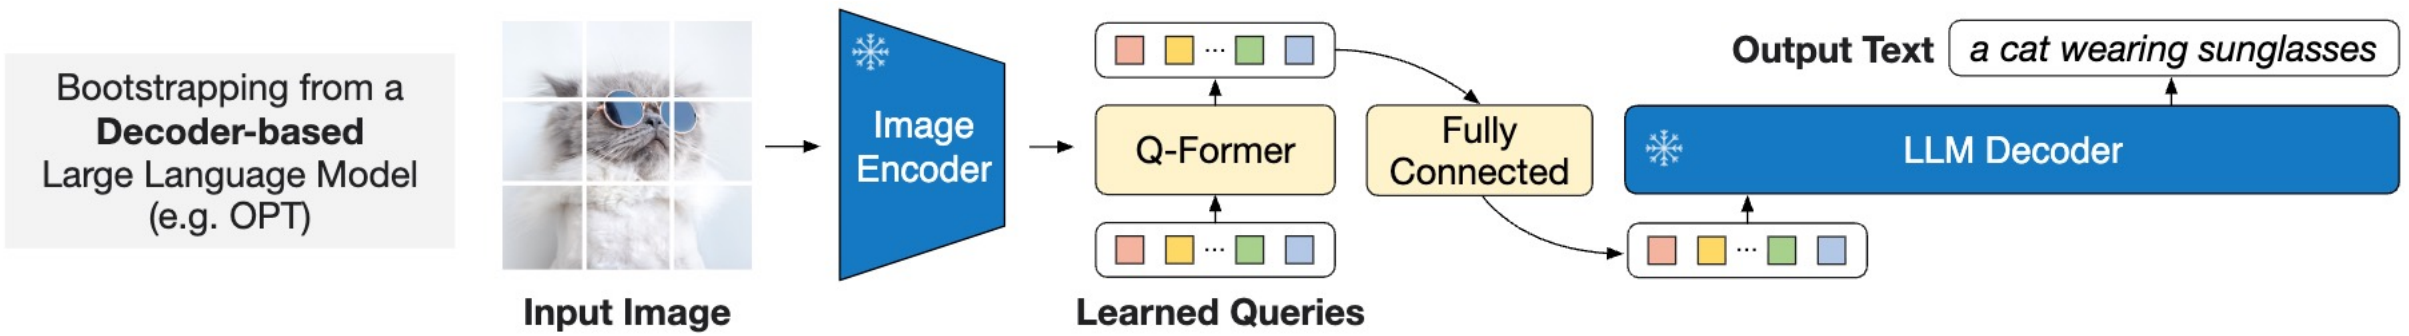
- BLIP-2 认为，不是所有视觉信息都要原封不动送进 LLM。
- 其通过一个 Q-Former，将视觉编码器输出的信息压到少量 query tokens 里，再去连接冻结 LLM。这里输入 LLM 的 token 已经不是原始 patch token 了，而是更抽象、更浓缩的 latent tokens。



BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models (PMLR, 2023)

从 Patch token 到 Latent token: BLIP-2

- 这些经过学习的 latent visual token 经过一个全连接层将其维度投影到文本 embedding 维度，然后与输入文本的 embedding 拼接，共同进入 LLM。



BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models (PMLR, 2023)

从 Patch token 到 Latent token: BLIP-2

实验结果

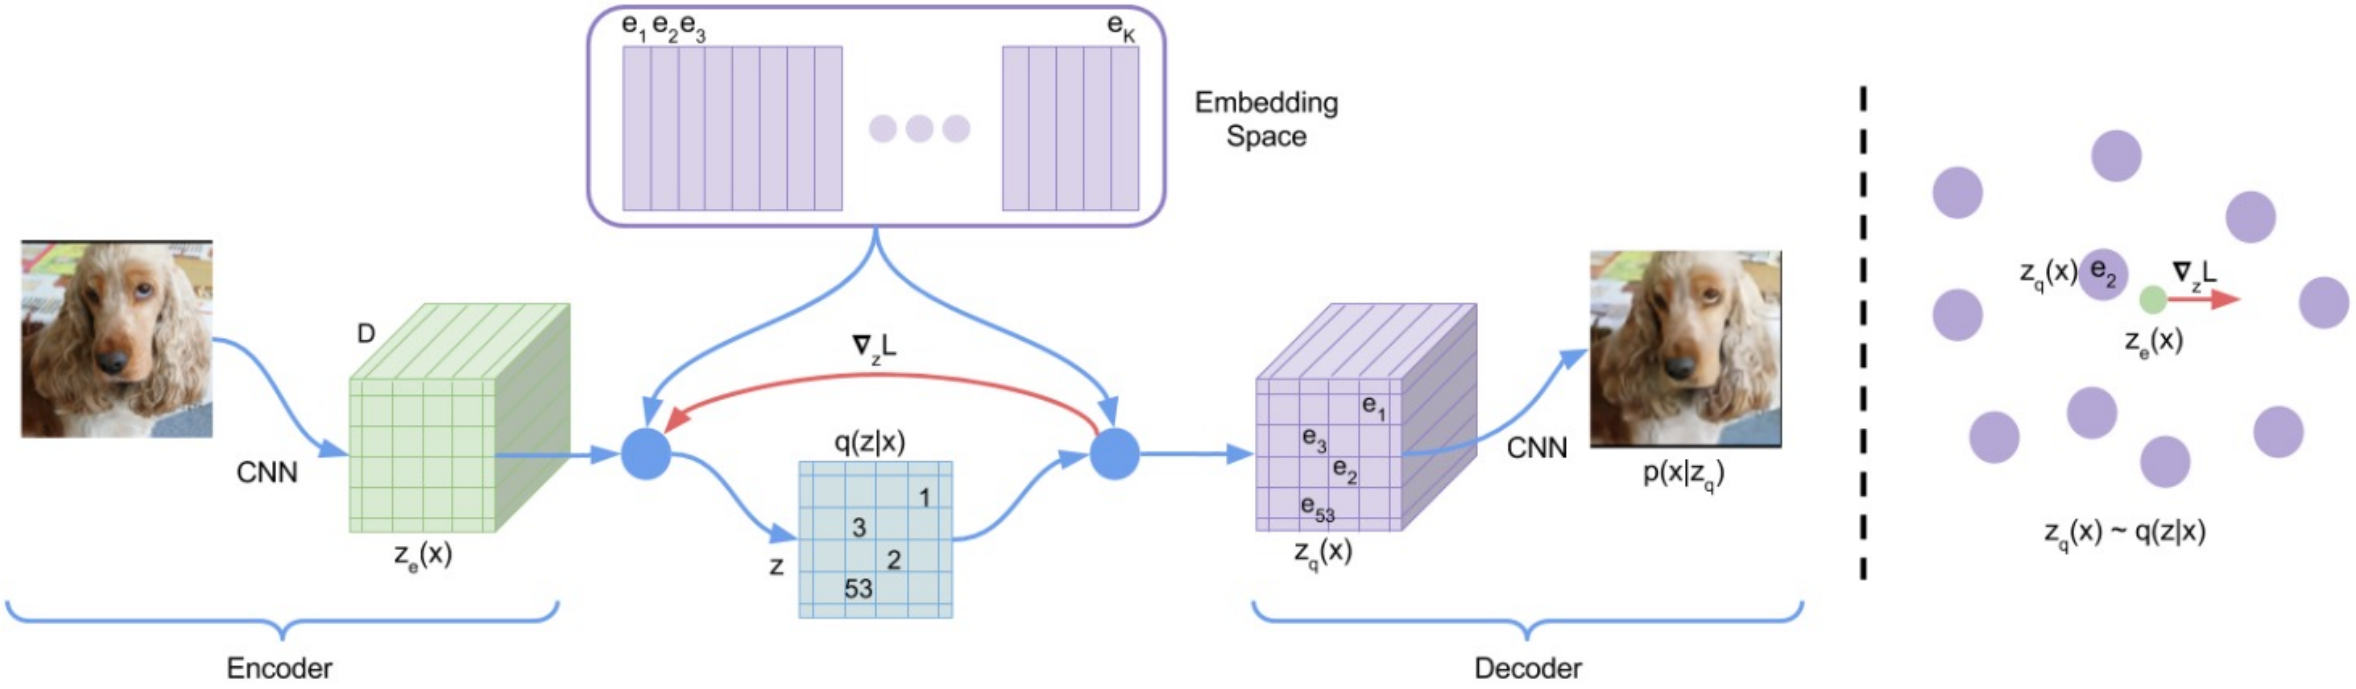
- 在 VQA, Image Captioning 和 Image-Text Retrieval 等多模态任务上都取得了 SOTA 性能
- 证明了视觉信息能过通过浓缩成更紧凑的 latent token 表达。

Models	#Trainable Params	Open-sourced?	**Visual Question Answering** VQAv2 (test-dev) VQA acc.	**Image Captioning** NoCaps (val) CIDEr	SPICE	**Image-Text Retrieval** Flickr (test) TR@1	IR@1
BLIP (Li et al., 2022)	583M	✓	-	113.2	14.8	96.7	86.7
SimVLM (Wang et al., 2021b)	1.4B	✗	-	112.2	-	-	-
BEIT-3 (Wang et al., 2022b)	1.9B	✗	-	-	-	94.9	81.5
Flamingo (Alayrac et al., 2022)	10.2B	✗	56.3	-	-	-	-
BLIP-2	188M	✓	**65.0**	**121.6**	**15.8**	**97.6**	**89.7**

BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models (PMLR, 2023)

Visual Token 离散化：VQ-VAE

- 提出 vector quantization, 将 image embedding 映射到一个有限的 codebook（码本）中，从而将连续的视觉特征离散化。
  - 码本是一个矩阵，里面包含了 K 个向量。

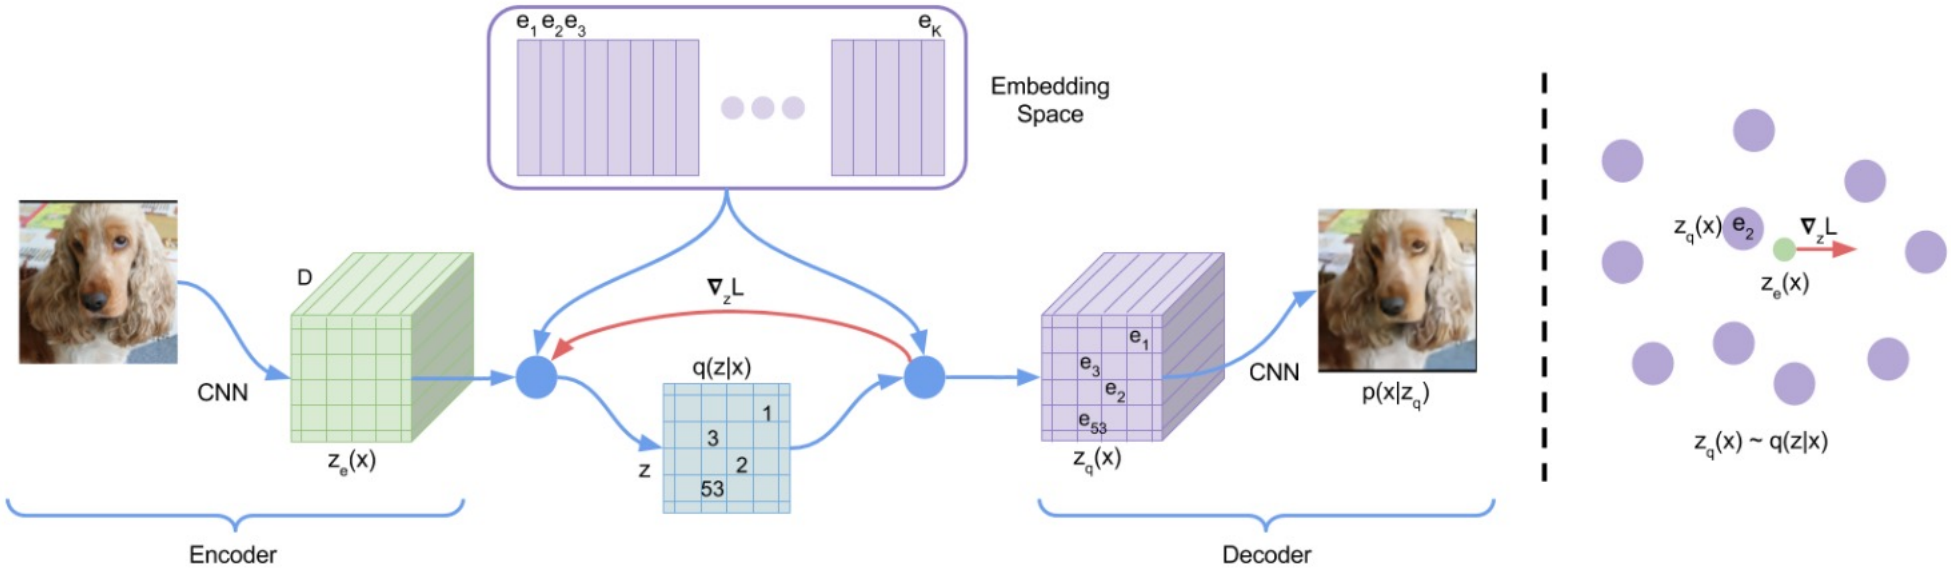


Neural Discrete Representation Learning, 2017

Visual Token 离散化：VQ-VAE

具体方法

- 编码：输入图像 x 经过图像编码器，映射为连续的潜在特征图 $z_e(x) \in 32 \times 32 \times D$.
- 量化：对于 $z_e(x)$ 中的每一个向量，在码本里进行最近邻查找，并使用查找出来的向量替换原向量，得到离散表示 $z_q(x)$。
- 重构：使用解码器将 $z_q(x)$ 重新解码成原图片。

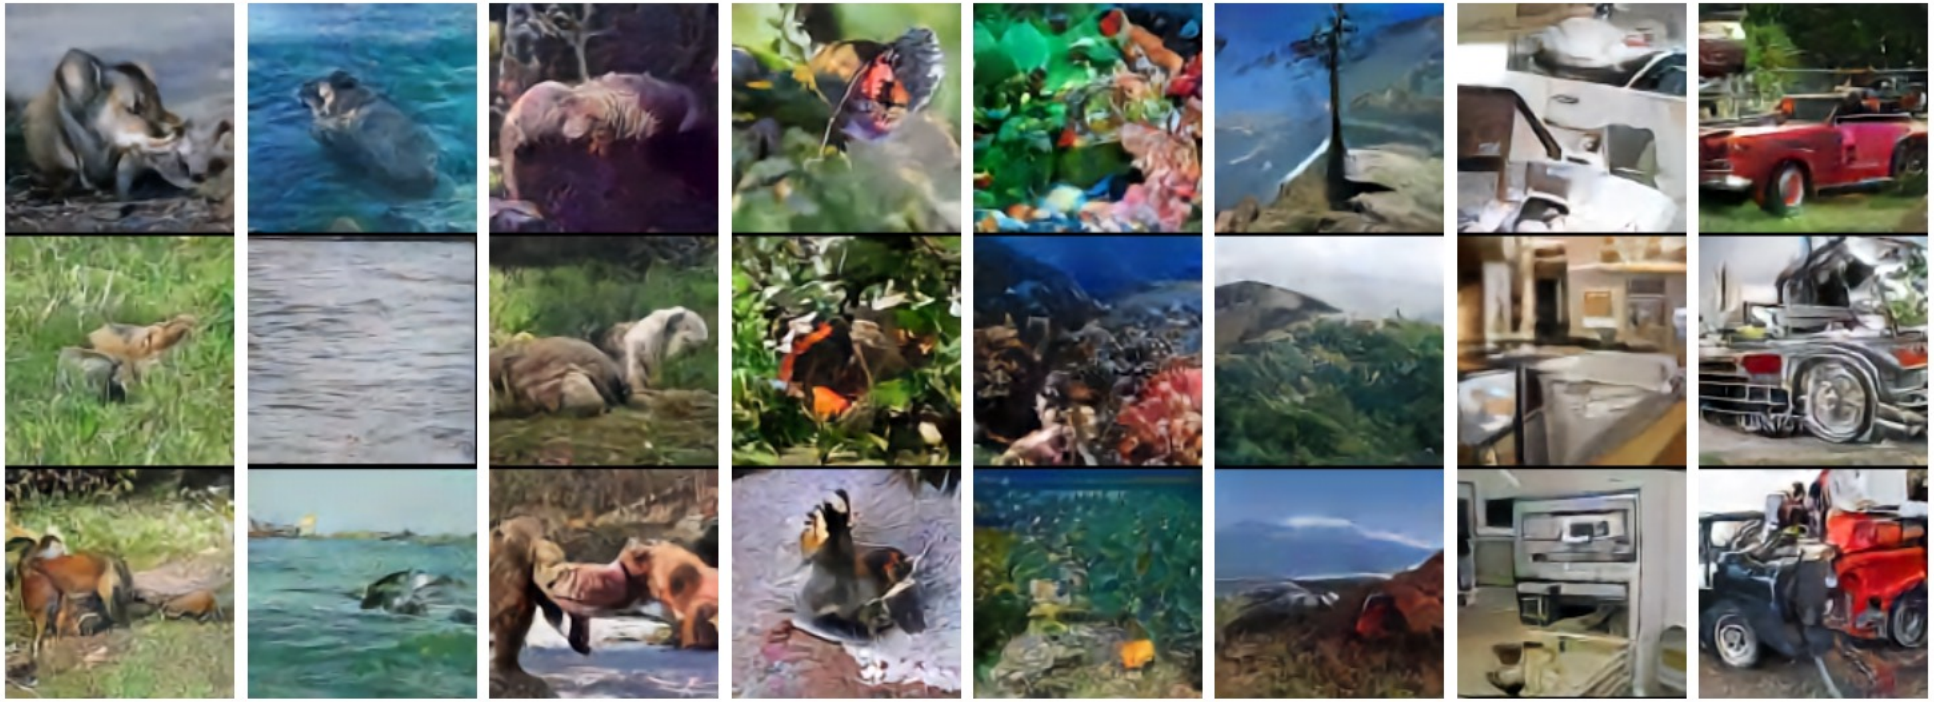


Neural Discrete Representation Learning, 2017

Visual Token 离散化：VQ-VAE

实验结果

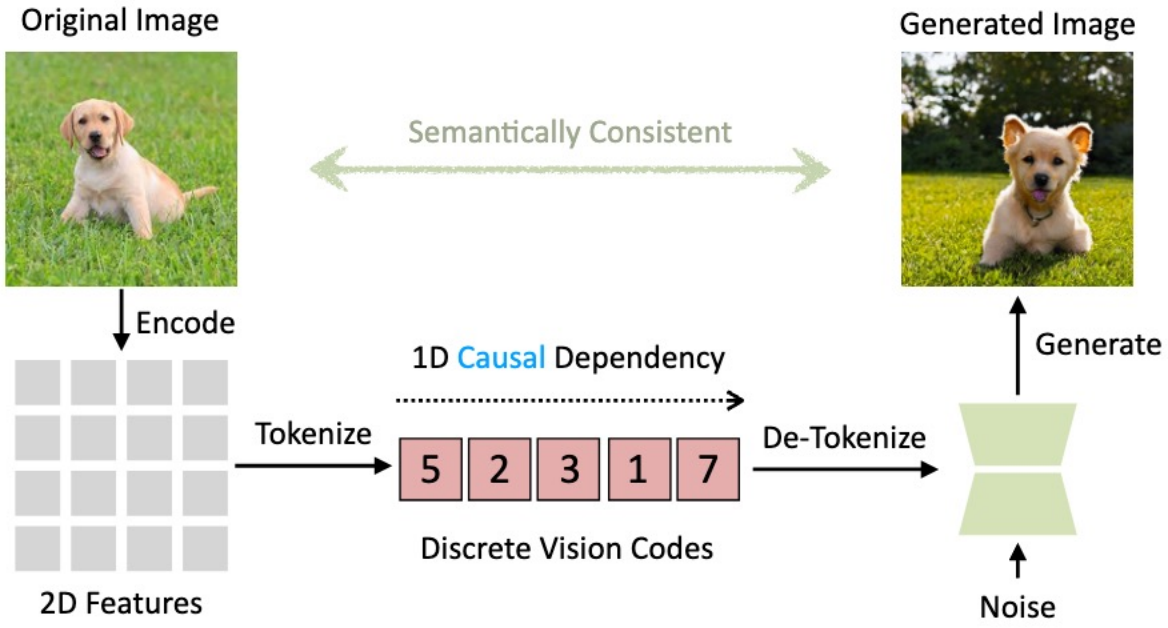
- 推理时，能够直接抽样离散索引，从码本里获取对应的向量，并解码（生成）图片。
- 证明了**图像可以被 token 化为离散的词表。**



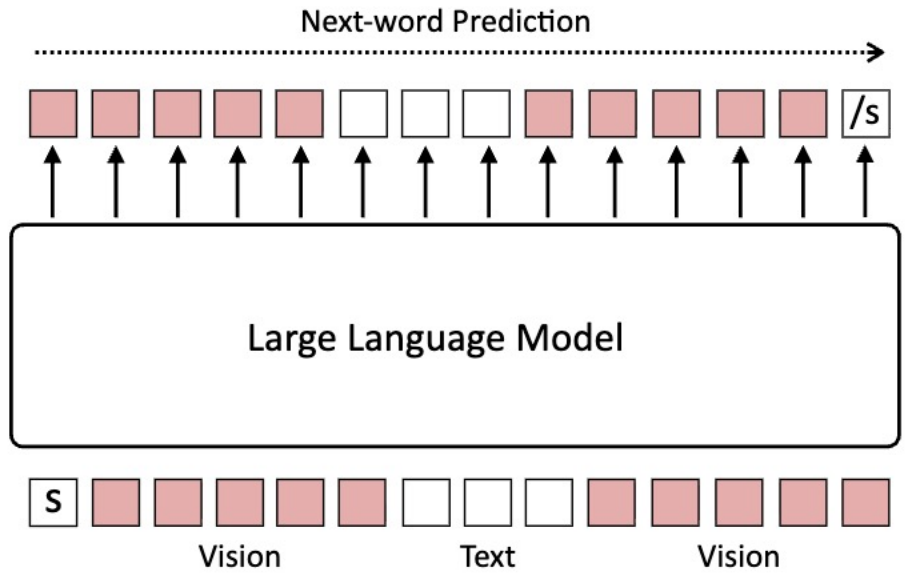
Neural Discrete Representation Learning, 2017

Visual & Text Token 统一建模：SEED

- 目的：用自回归的方式直接输出 visual token，使得 LLM 同时具有视觉理解与生成能力。
- 问题：现有的离散 visual token 基于 2D 物理块位置生成（VQ-VAE），与LLM的单向（左到右）自回归注意力机制不匹配。且现有分词器捕获的低级视觉细节过多，而 LLM 中的文本 token 包含高级语义抽象，导致两者在统一训练时难以对齐。



(a) SEED Visual Tokenizer

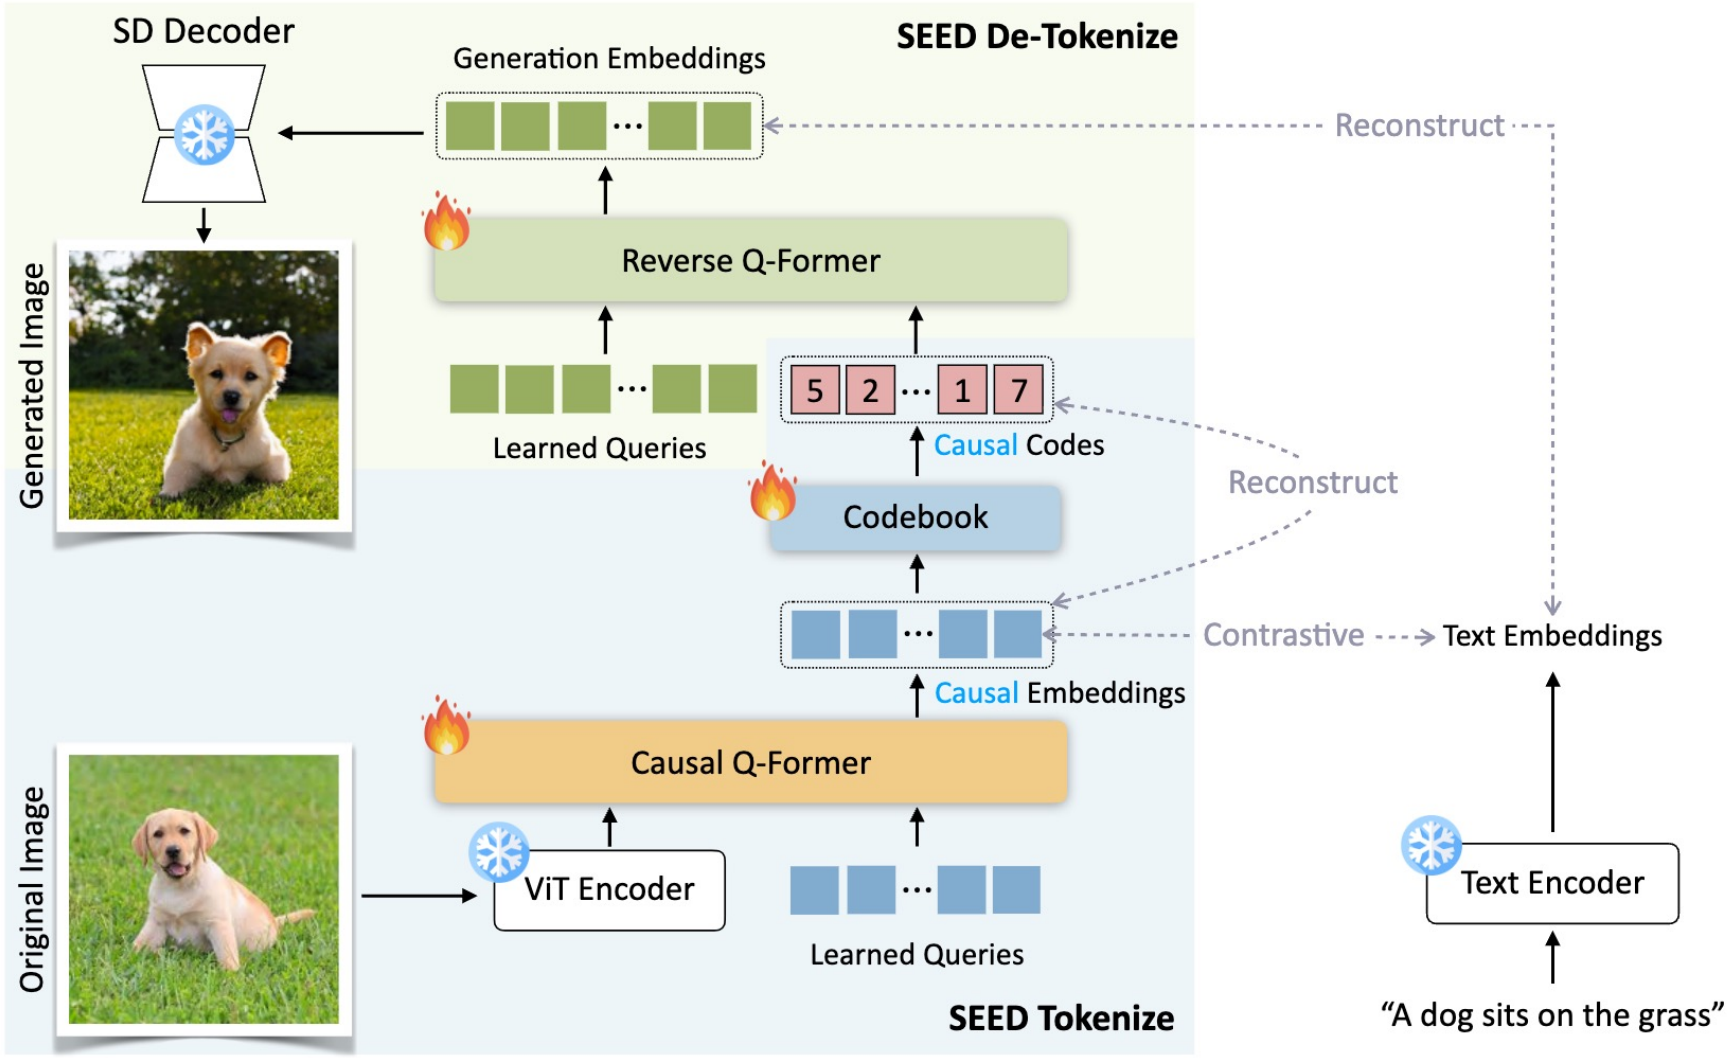


(b) Multimodal Autoregression with SEED tokens

Planting a SEED of Vision in Large Language Model (Tencent 2023)

Visual & Text Token 统一建模：SEED

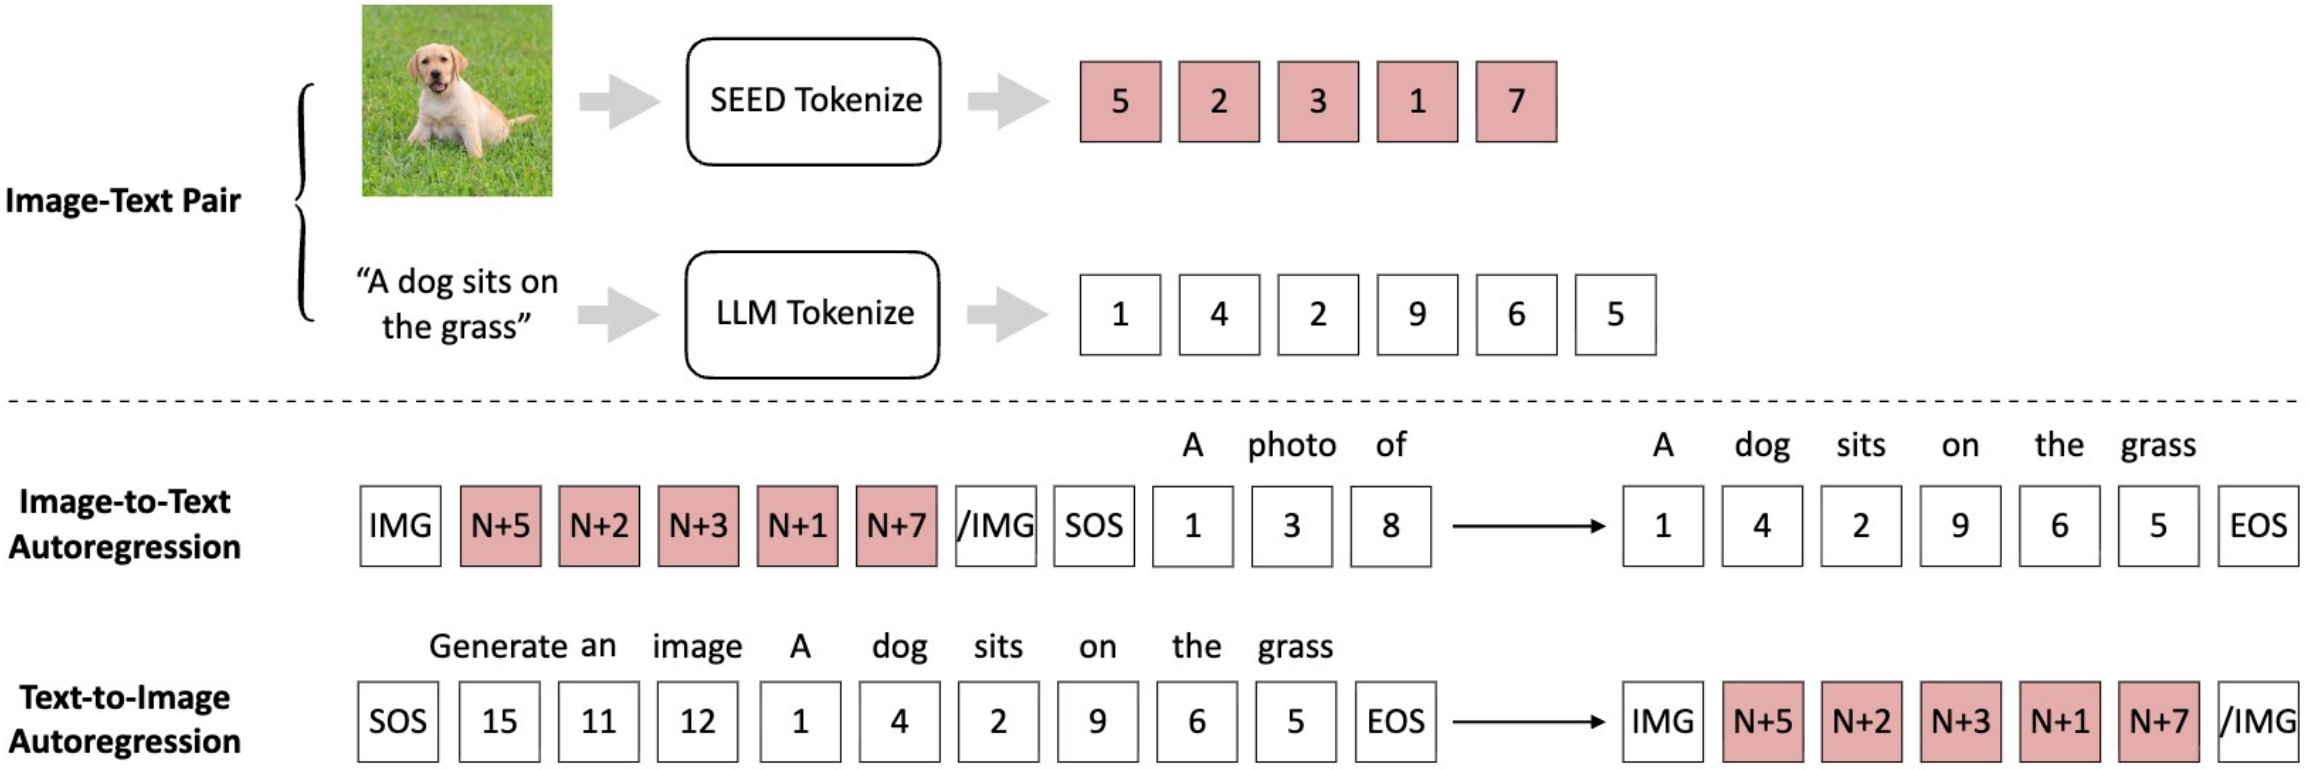
详细架构



Planting a SEED of Vision in Large Language Model (Tencent 2023)

Visual & Text Token 统一建模：SEED

自回归训练过程

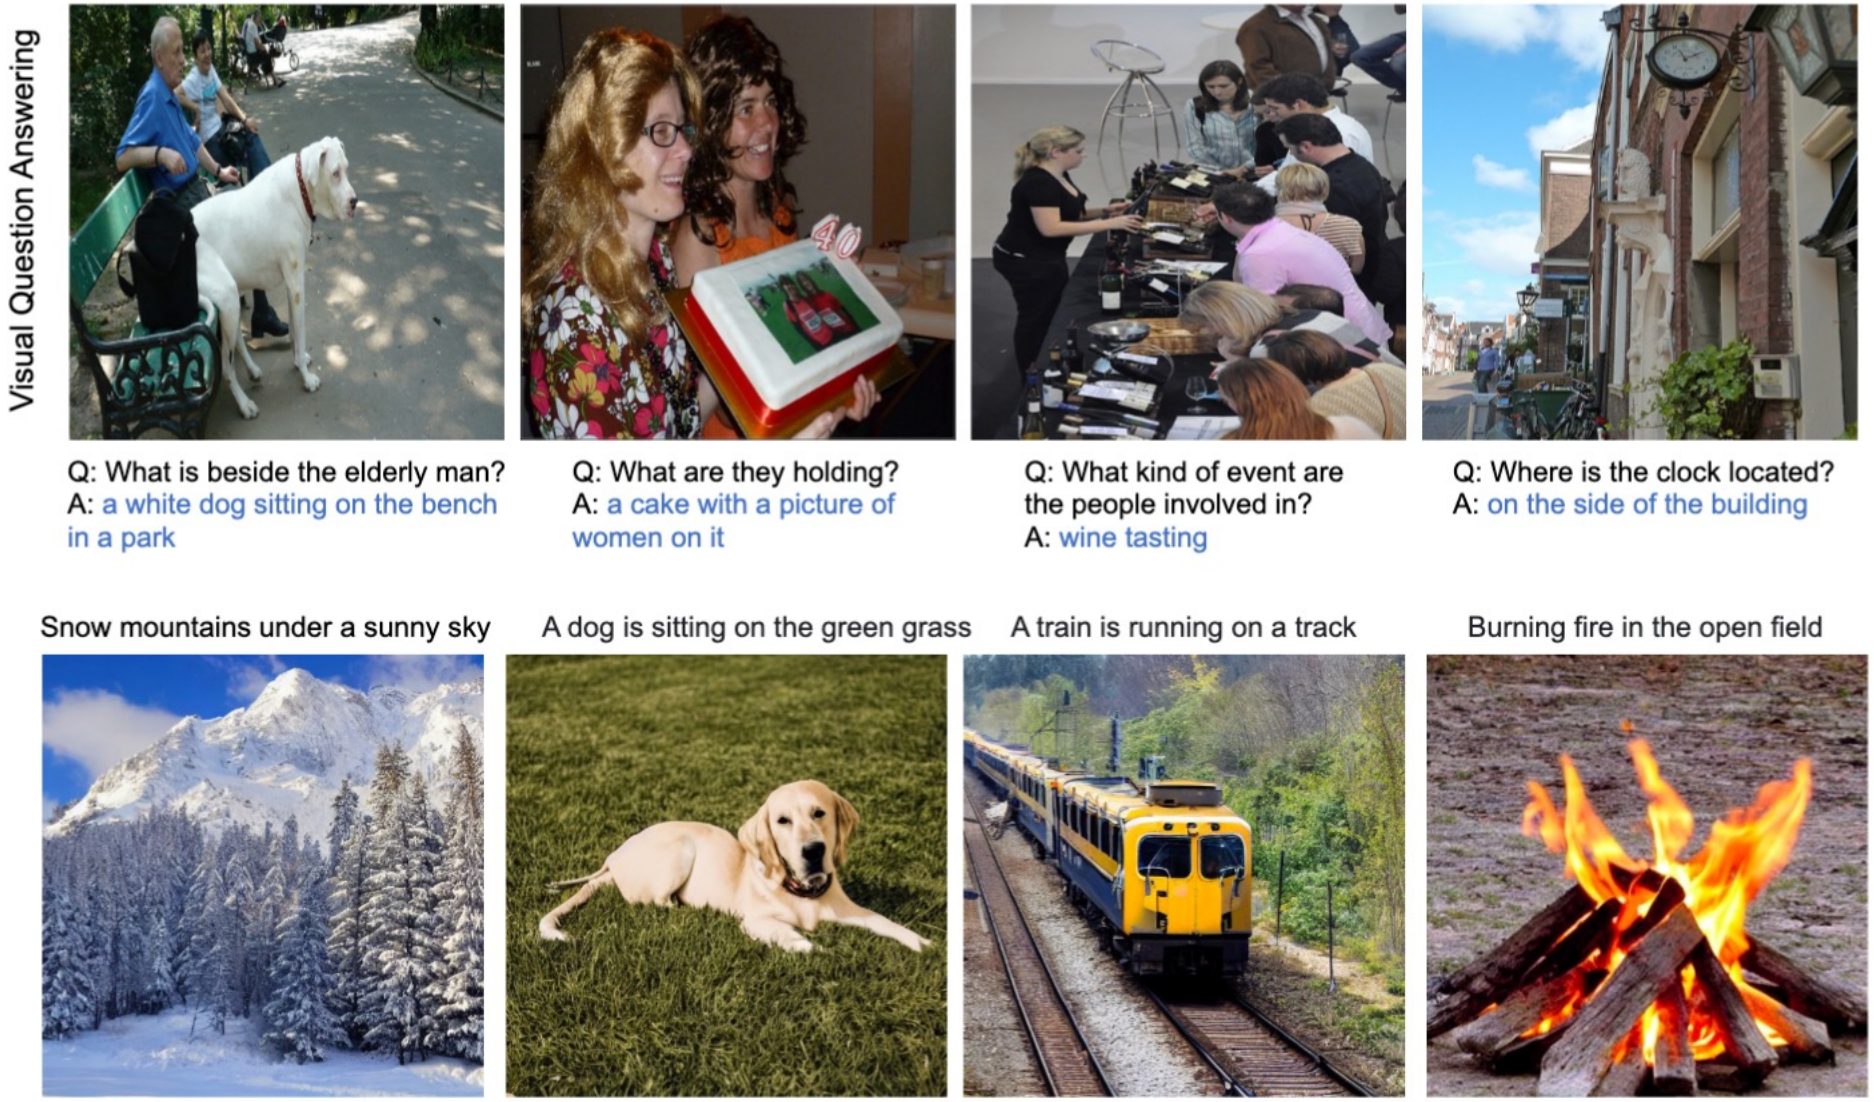


Planting a SEED of Vision in Large Language Model (Tencent 2023)

Visual & Text Token 统一建模：SEED

实验结果

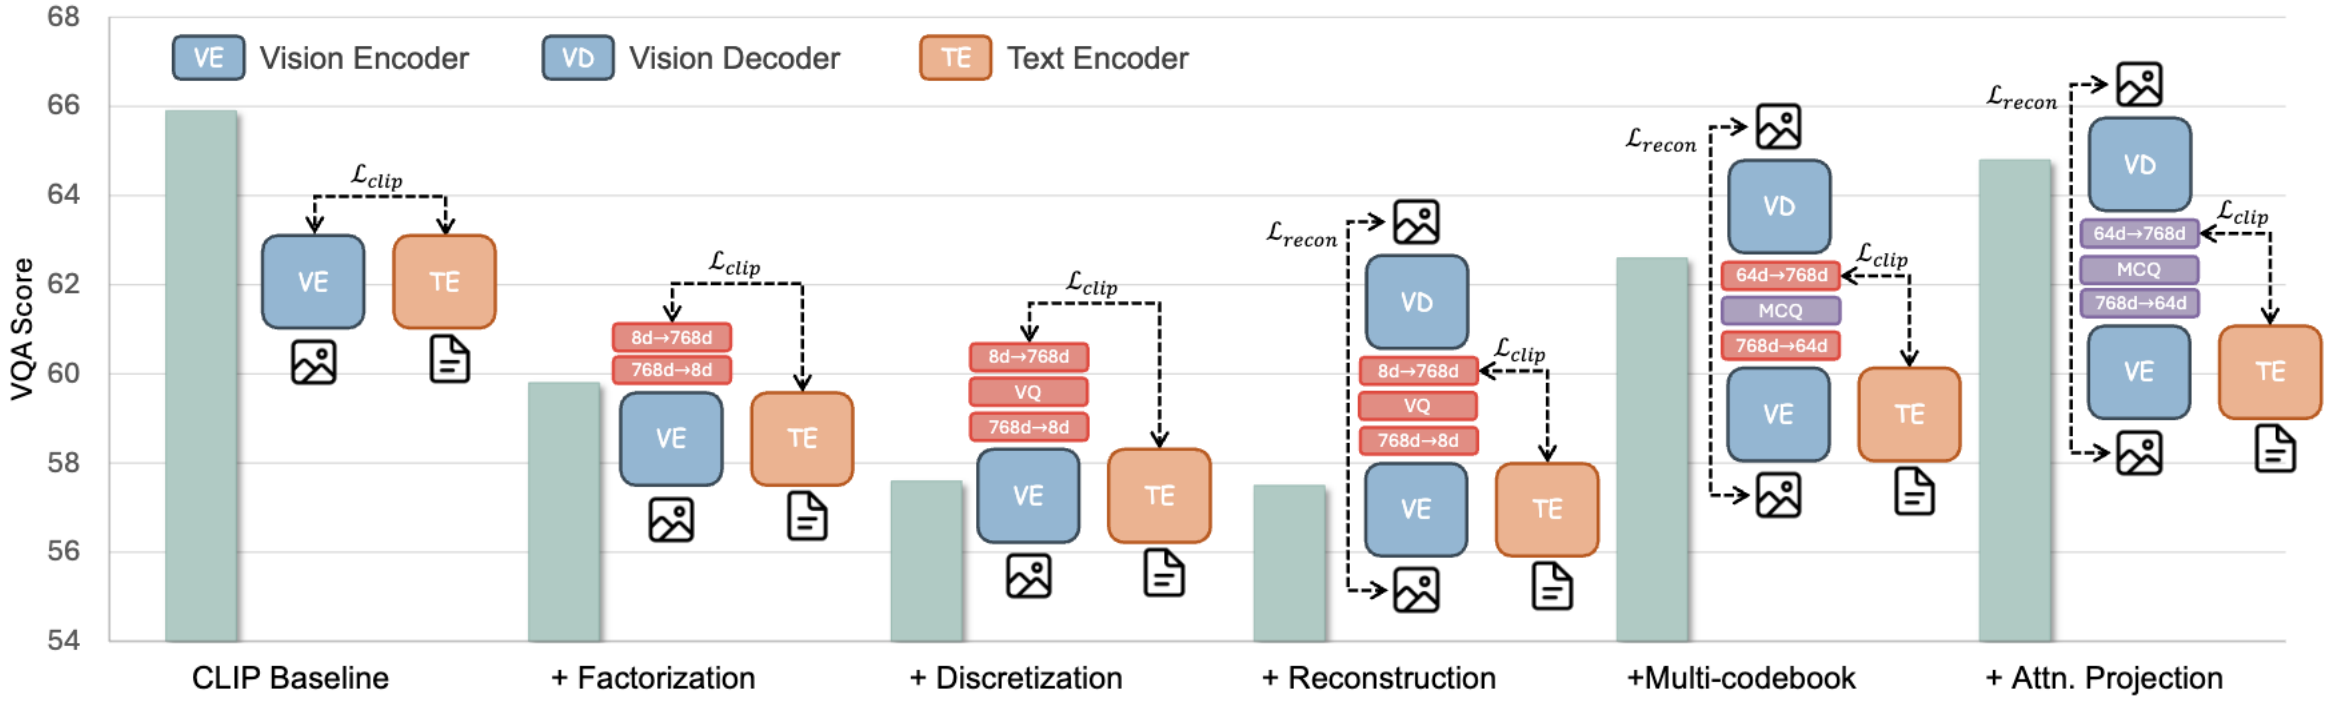
加入 SEED 视觉分词器训练的 LLM 能够同时完成图像理解（VQA）与图像生成两种任务，成功统一了建模范式。



Planting a SEED of Vision in Large Language Model (Tencent 2023)

Visual & Text Token 统一建模: UniTok

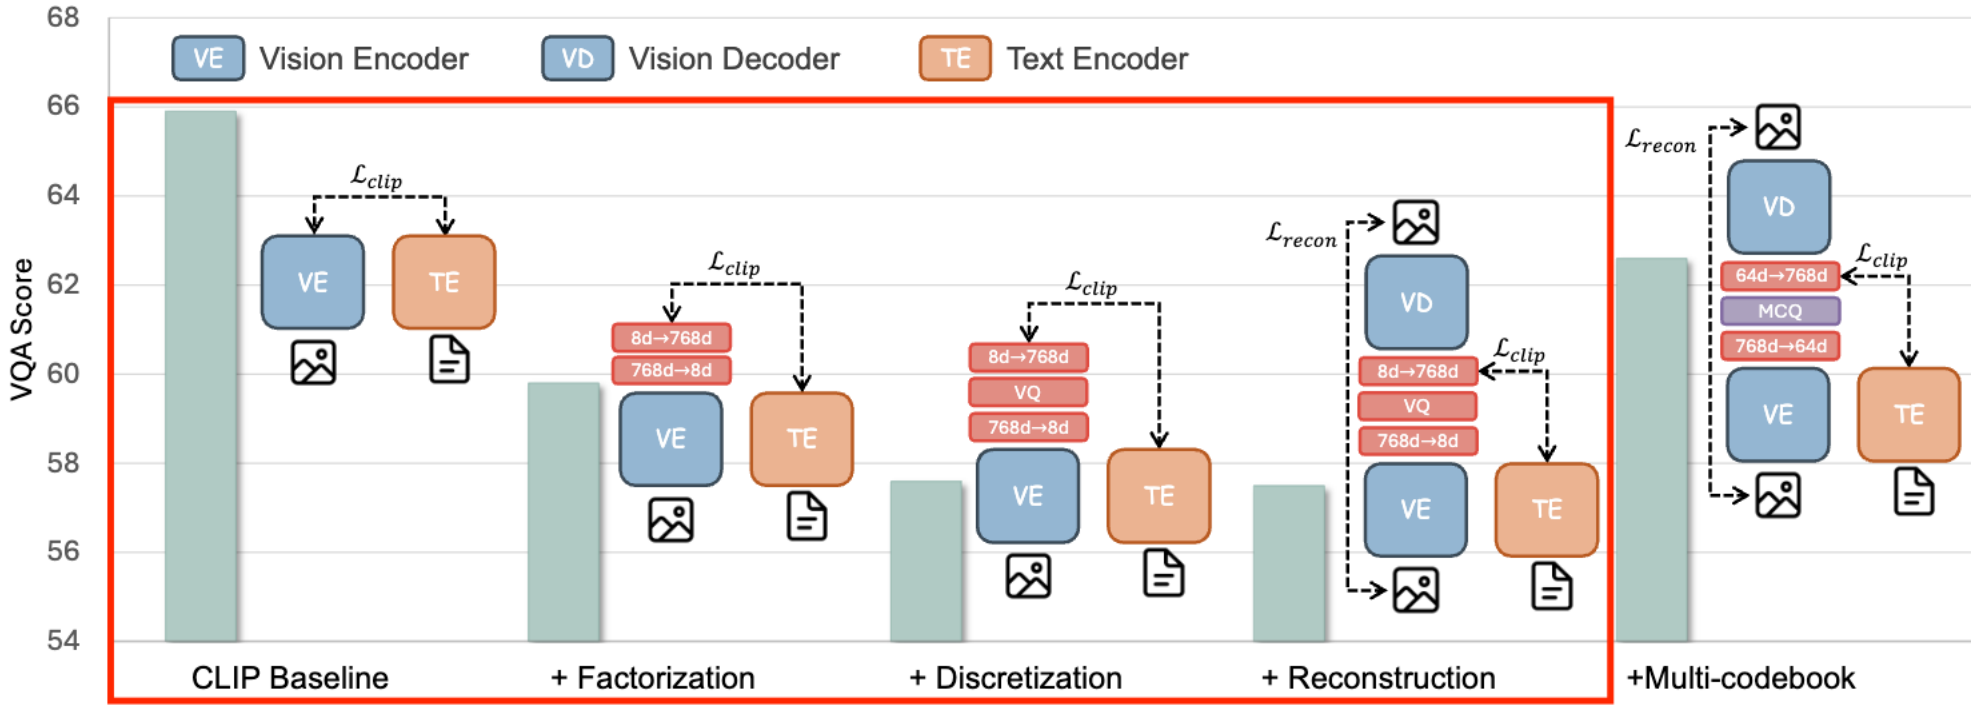
- 指出问题：语言表征天然就是离散的，但视觉特征是连续的，将其强行离散化会不可避免地带来信息损失。
- 从 CLIP 基线开始，依次添加 VQVAE的组件，观察 VQA 任务分数的变化：



UniTok: A Unified Tokenizer for Visual Generation and Understanding (NeruIPS 2025 Spotlight)

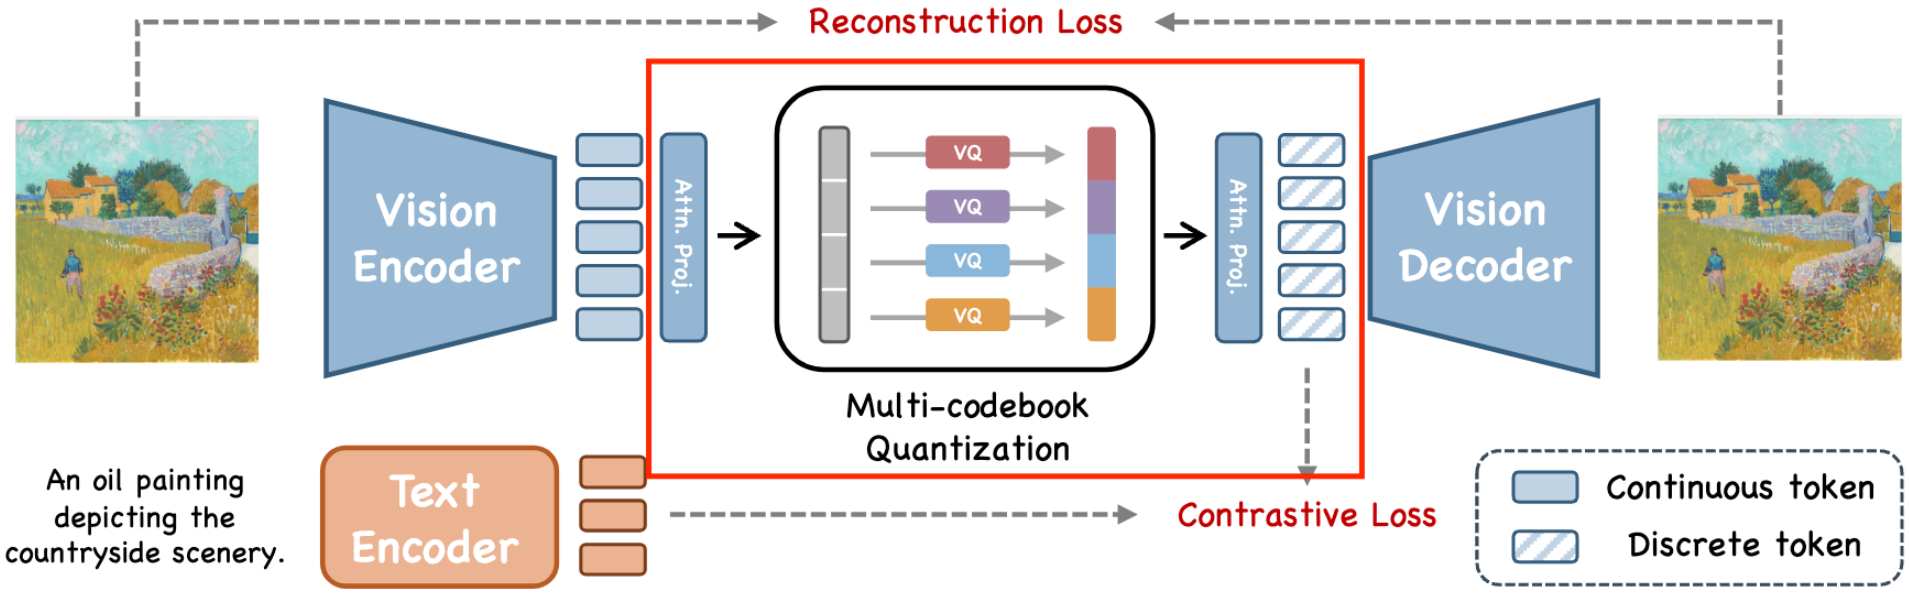
Visual & Text Token 统一建模: UniTok

- 加入 Factorization（通道压缩）：在 CLIP 视觉编码器顶层加入线性投影层，将 768 维降到 16 维再还原。仅这一步压缩操作就导致了 VQA 性能的显著下降。这说明低维空间限制了特征表达。
- 加入 Discretization（离散化）：将上述低维特征映射到 16k 大小的码本（Codebook）中，发现性能进一步下降。将连续向量映射到如此小的离散词表，造成了严重的信息损失。
- 加入 Reconstruction Supervision（重建监督）：发现加入重建损失后，下游理解任务（VQA）的得分几乎没有变化（甚至略有提升）。



Visual & Text Token 统一建模: UniTok

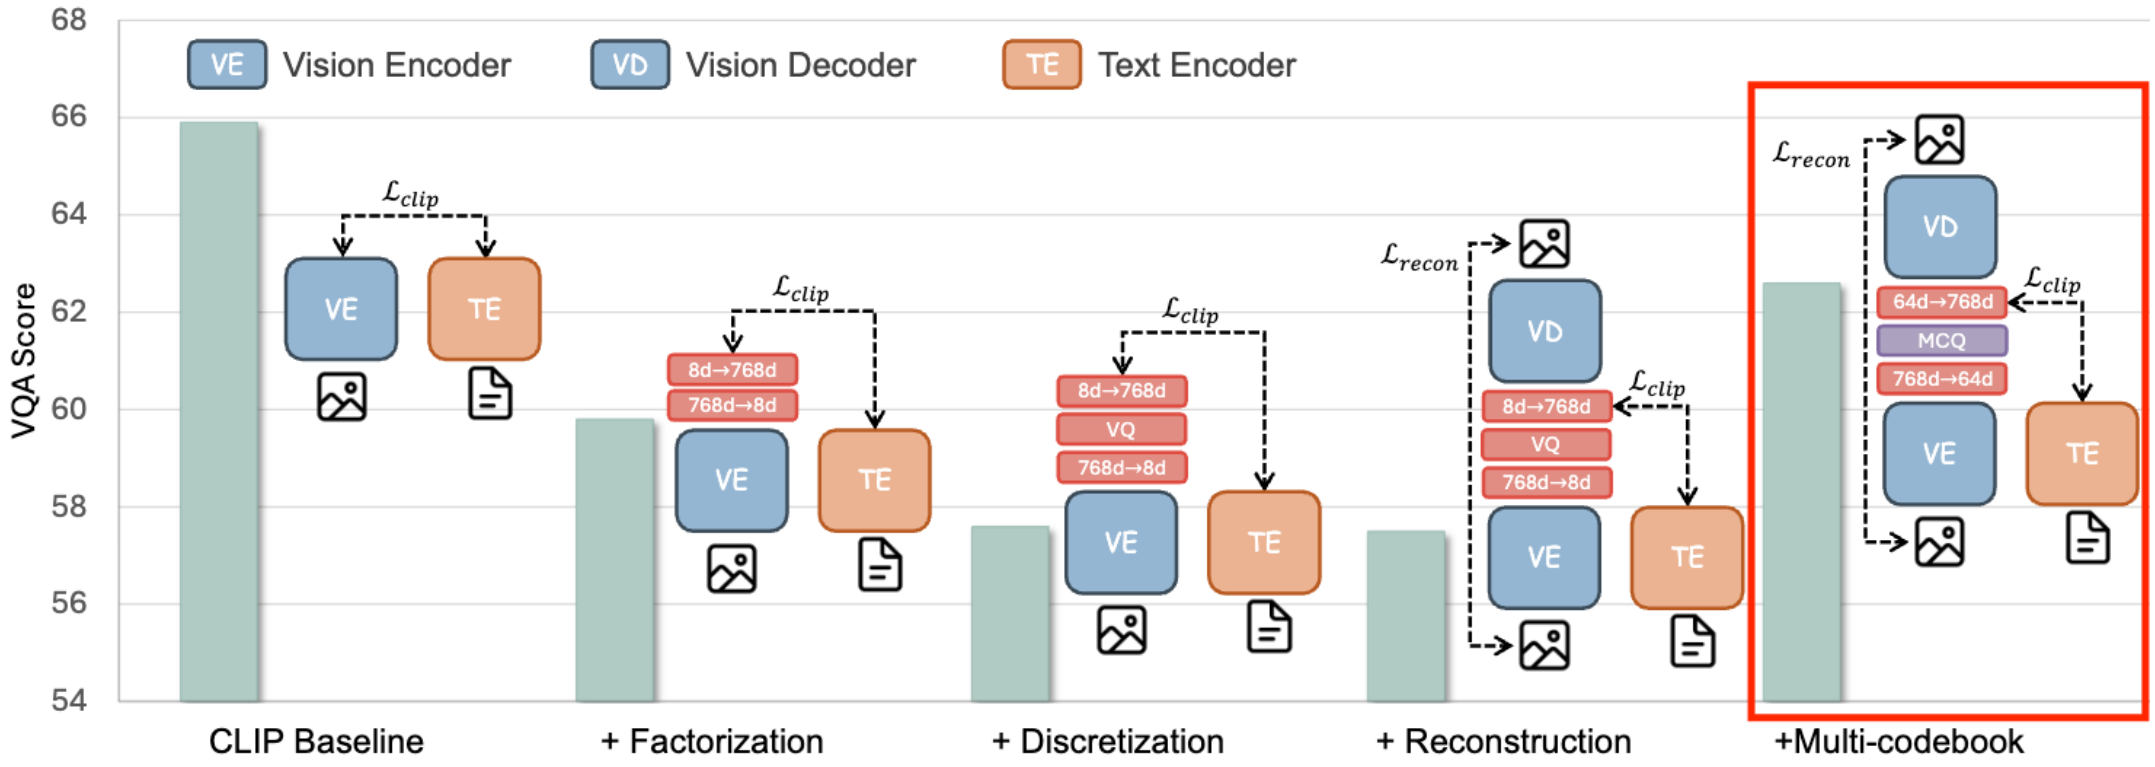
- 认为单码本无法同时兼顾“细节重建”和“高层语义”。
- 为了弥补离散化视觉 token 带来的损失，提出了 MCQ (Multi-Codebook Quantization)，将一个长向量切成多块，每个分块由一个独立的、较小的子码本进行量化。
- 引入注意力投影代替线性投影/卷积层。



UniTok: A Unified Tokenizer for Visual Generation and Understanding (NeruIPS 2025 Spotlight)

UniTok

- 结果显示，加入多级码本量化 MCQ 后显著提升模型性能。



UniTok: A Unified Tokenizer for Visual Generation and Understanding (NeruIPS 2025 Spotlight)

感谢聆听！



李冠彬 http://guanbinli.com